Além do Viés Sistemático: Investigando Diferenças de Gênero em Padrões de Anotação de Classificação de Textos em Português

A. Feitosa, E. Carneiro, G. Guedes

CEFET/RJ - Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, Brazil
alexander.feitosa@aluno.cefet-rj.br,
ericacqueiroz@gmail.com, gustavo.guedes@cefet-rj.br

Abstract. Este estudo explora como os padrões de anotação de gênero influenciam a classificação de sentimentos no português brasileiro e se esses padrões são preservados — ou amplificados — por modelos de aprendizado de máquina. Um corpus de 1.465 frases em estilo de diário foi rotulado independentemente por dois grupos de anotadores com equilíbrio de gênero. Apesar de uma alta concordância final, como indicado pelo coeficiente de Cohen $\kappa = 0{,}8177$, análises estatísticas revelaram comportamentos de anotação divergentes: anotadores do sexo masculino exibiram maior consistência interna e menor entropia, enquanto anotadores do sexo feminino mostraram maior variabilidade e uma maior proporção de rótulos neutros. Classificadores treinados separadamente nos rótulos de cada grupo (SVM, LR, NB, RF, DT) reproduziram essas divergências em graus variados. Notavelmente, o alinhamento entre os modelos de gênero caiu para $\kappa = 0{,}327$ (Árvore de Decisão) e atingiu o pico em $\kappa = 0{,}697$ (Regressão Logística), indicando que os comportamentos de aprendizagem podem diferir substancialmente com base na fonte de anotação. Esses achados reforçam que a anotação é um processo de base social. Divergências interpretativas de gênero podem se propagar por meio de processos de aprendizagem, moldando o comportamento do modelo de maneiras que refletem e potencialmente amplificam o viés de gênero, muitas vezes passando despercebidas sem estratégias de avaliação que levem em conta a anotação. A aprovação ética foi concedida sob o protocolo CAAE 82267824.8.0000.5289.

This study explores how gendered annotation patterns influence sentiment classification in Brazilian Portuguese and whether these patterns are preserved—or amplified—by machine learning models. A corpus of 1,465 diary-style sentences was independently labeled by two gender-balanced annotator groups. Despite a high final agreement, as indicated by Cohen's = 0.8177, statistical analyses revealed divergent annotation behaviors: male annotators exhibited higher internal consistency and lower entropy, while female annotators showed greater variability and a higher proportion of neutral labels. Classifiers trained separately on each group's labels (SVM, LR, NB, RF, DT) reproduced these divergences to varying degrees. Notably, alignment between gendered models dropped to = 0.327 (Decision Tree) and peaked at = 0.697 (Logistic Regression), indicating that learning behaviors may differ substantially based on the annotation source. These findings reinforce that annotation is a socially based process. Gendered interpretive divergences can propagate through learning pipelines, shaping model behavior in ways that reflect and potentially amplify gender bias, often going unnoticed without annotation-aware evaluation strategies. Ethical approval was granted under protocol CAAE 82267824.8.0000.5289

CCS Concepts: • **Computing methodologies** → **Natural language processing**.

Keywords: annotation behavior, gender bias, sentiment classification, supervised learning, fairness in NLP

1. INTRODUÇÃO

A classificação de texto continua sendo um pilar fundamental do aprendizado supervisionado em Processamento de Linguagem Natural (PLN), permitindo a interpretação estruturada de dados de linguagem subjetivos ou ambíguos. A consistência e a precisão tipicamente associadas aos modelos supervisionados os tornam uma boa opção para aplicações de aprendizado de máquina, embora possam ser afetados pelo envolvimento do julgamento humano.[Kowsari et al. 2019]. Uma pesquisa recente analisa mais de 300 artigos sobre preconceito de gênero em PNL, destacando questões persistentes, como suposições binárias de gênero e falta de foco em pesquisas multilíngues. [Stańczak and Augenstein 2021]. [Sun et al. 2019] forneceu uma extensa revisão bibliográfica sobre preconceito

de gênero em PNL, categorizando formas de preconceito de representação e estratégias de mitigação.

No entanto, a investigação sistemática de como esses vieses se manifestam durante o processo de anotação, quando perspectivas sociais são incorporadas aos dados de treinamento, permanece amplamente inexplorada, particularmente em tarefas de classificação de sentimentos. Com a escassez de estudos empíricos nessa área, essa lacuna é especialmente crítica em contextos de língua portuguesa, onde o rico sistema de gênero gramatical da língua aumenta a probabilidade de pistas de gênero influenciarem a anotação.

Neste trabalho, focamos especificamente na anotação de sentimentos, atribuindo rótulos de sentimentos a um corpus compartilhado de frases em português brasileiro com um dos três rótulos de polaridade — negativo (-1), neutro (0) ou positivo (+1). Esse esclarecimento inicial é crucial porque as tarefas de anotação em PLN variam da análise sintática ao reconhecimento de entidades nomeadas, cada uma com considerações distintas de confiabilidade. Além de comparar as distribuições finais de rótulos, examinamos os níveis de concordância, consistência e entropia de rotulagem dentro e entre os grupos para entender como o comportamento de anotação pode refletir diferenças interpretativas que influenciam o aprendizado do modelo. As anotações são tratadas não apenas como entradas, mas como evidências empíricas, sujeitas a análises estatísticas e interpretativas.

A estrutura deste artigo é descrita da seguinte forma. A Seção 2 oferece uma visão geral de pesquisas anteriores sobre viés de gênero no processamento de linguagem natural. A Seção 3 detalha a estrutura metodológica adotada no presente estudo. A Seção 4 apresenta os resultados da avaliação experimental. Por fim, a Seção 5 conclui o artigo resumindo os principais resultados, discutindo as limitações do estudo e propondo direções para pesquisas futuras.

2. TRABALHOS RELACIONADOS

As práticas de anotação de sentimentos têm sido alvo de escrutínio nos últimos anos, particularmente no que diz respeito a como identidades sociais, como gênero, podem influenciar os resultados da rotulagem. As origens do viés em sistemas de PNL foram examinadas criticamente por [Blodgett et al. 2020], que argumentam que anotações tendenciosas podem ser incorporadas em conjuntos de dados desde o seu início. De forma similar, [Lim et al. 2024] mostram que o viés de anotação pode ser medido e mitigado sistematicamente usando análise de mediação causal, sugerindo que a fase de anotação merece tanta atenção quanto a seleção ou avaliação do modelo.

[Shah et al. 2020] enquadra o viés como um resultado sistemático de interações entre arquiteturas de modelos e recursos latentes de conjuntos de dados, o que se alinha com nossas descobertas sobre divergências observadas entre grupos de anotadores. Esse fenômeno de amplificação de viés foi demonstrado empiricamente em tarefas de PNL, como correferência e análise de sentimento [Zhao et al. 2017], onde modelos treinados com dados tendenciosos exageraram associações demográficas além do corpus original. Para mitigar o viés em modelos de sentimento, [Prabhakaran et al. 2021] propôs o uso de explicações post-hoc para expor caminhos de decisão e detectar discrepâncias induzidas por anotação. Nosso estudo complementa essa abordagem examinando o surgimento de vieses durante o treinamento, em vez da pós-previsão.

A dimensão de gênero da anotação é particularmente proeminente em português, onde o gênero gramatical permeia a língua. Padrões linguísticos de gênero influenciam tanto a forma como os anotadores interpretam o texto quanto como os modelos internalizam essas interpretações. [Silva and Moro 2024]. Qualquer mudança no sistema gramatical requer clareza coletiva sobre o âmbito semântico das novas formas e o reconhecimento de que a sua representação formal impõe inevitavelmente limites categóricos. [Schwindt 2020]. [Geva et al. 2019] demonstram ainda que dados demográficos do anotador, como gênero, idade e origem cultural, podem afetar sistematicamente os resultados da rotulagem. Essas observações reforçam a necessidade de estudos em outras línguas além do inglês, onde as estruturas gramaticais podem intensificar tais efeitos.

Além da lente estatística, alguns estudiosos têm defendido uma mudança epistemológica mais ampla na forma como as anotações são entendidas. Em vez de tratar a discordância como ruído a ser minimizado, [Havens and Hedges 2022] defendem o reconhecimento da incerteza como uma característica inerente ao comportamento humano de rotulagem. Essas perspectivas ressoam com críticas mais amplas às práticas de construção de conjuntos de dados, que enfatizam como as escolhas de desenvolvimento, as diretrizes de rotulagem e as identidades dos anotadores contribuem para moldar as dimensões sociais e técnicas dos processos de aprendizagem.[Paullada et al. 2021].

Em consonância com esta perspectiva, trabalhos recentes exploraram a propagação da discriminação em tarefas de classificação, analisando a estratificação de conjuntos de dados e as distribuições de rótulos.[Minatel et al. 2023]. [Raji et al. 2021] argumentam ainda que os próprios benchmarks de avaliação incorporam decisões normativas e que a compreensão do viés requer atenção a todo o ciclo de vida dos dados — da anotação à implantação. Esses esforços se alinham com pesquisas que consolidam fontes conhecidas de viés algorítmico, incluindo dados, premissas de modelagem e ciclos de feedback, conforme descrito de forma abrangente por [Mehrabi et al. 2021].

Nosso estudo contribui para esse discurso em evolução ao comparar comportamentos de anotadores masculinos e femininos na anotação de sentimentos em português e avaliar até que ponto os modelos preditivos treinados nos rótulos de cada grupo replicam as divergências observadas.

3. METODOLOGIA

Esta seção descreve o pipeline adotado para: (i) medir a concordância entre anotadores com equilíbrio de gênero e (ii) avaliar se modelos de classificação de texto treinados em rótulos específicos de gênero reproduzem ou amplificam vieses de anotação. Figura 1 apresenta uma visão geral das etapas propostas pelo nosso estudo.

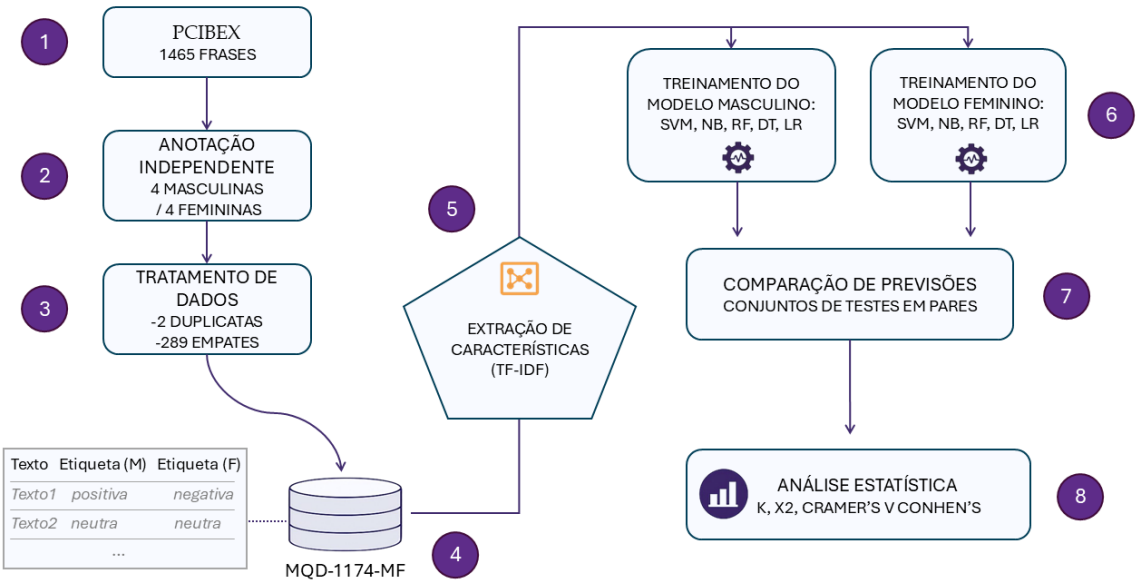

Fig. 1: Classificação de texto por anotadores e modelos treinados com equilíbrio de gênero

3.1 Corpus e Participantes

O corpus é composto por 1.465 frases em português brasileiro coletadas do site "Meu Querido Diário", um diário online que coletou uma grande variedade de depoimentos cotidianos submetidos sob anonimato [Alves et al. 2022]. O conjunto de dados manteve sua forma original — incluindo erros ortográficos e expressões que poderiam ser consideradas desconfortáveis — a fim de preservar a autenticidade e o tom natural do material. Essa decisão foi intencional e alinhada ao caráter exploratório da pesquisa. Além da aprovação ética, concedida sob o protocolo CAAE 82267824.8.0000.5289 da Plataforma Brasil, os participantes forneceram consentimento informado, concordando com os termos descritos no Termo de Consentimento Livre e Esclarecido (TCLE) antes de sua participação.

O experimento envolveu a publicação dessas 1.465 frases na plataforma PCIbex Farm[1](Fig. 1, Step 1). Oito falantes nativos (quatro mulheres e quatro homens) rotularam independentemente cada frase com uma escala de polaridade de três pontos: *negativa* (-1), *neutra* (0) e *positiva* ($+1$) (Fig. 1, Step 2). Todos os participantes eram voluntários adultos, identificados exclusivamente pelo gênero autodeclarado. O recrutamento foi realizado por meio de redes sociais e listas de discussão, resultando em uma amostra predominantemente composta por indivíduos residentes no Rio de Janeiro com ensino superior completo. Apenas frases únicas que receberam a classificação de maioria estrita em ambos os grupos de anotadores foram mantidas (Fig. 1, Step 3), resultando em um subconjunto compartilhado de 1.174 instâncias rotuladas independentemente por anotadores masculinos e femininos (Fig. 1, Step 4). Referimo-nos a este conjunto de dados final como MQD-1174-MF, conforme descrito na Tabela I. A extração de características foi realizada usando representações TF-IDF baseadas em unigramas e bigramas de palavras em língua portuguesa, após a remoção de stopwords (Fig. 1, Step 5).

Table I: Classificação do conjunto de dados MQD-1174-MF

Gênero	**Negativa**	**Neutra**	**Positiva**
Masculino	442	253	479
Feminino	442	307	425

3.2 Treinamento do Modelo

Para investigar padrões de anotação orientados por gênero na aprendizagem supervisionada, treinamos modelos de classificação independentes com base nos rótulos majoritários fornecidos por cada grupo de anotadores. Seguindo as recentes estruturas de PNL com foco na imparcialidade, nosso objetivo foi investigar se tendências subjetivas de anotação são refletidas ou potencialmente amplificadas por sistemas de classificação.

Uma série de classificadores foi empregada — Support Vector Machine (SVM), Naive Bayes (NB), Random Forest (RF), Árvore de Decisão (DT) e Regressão Logística (LR), cada um treinado separadamente nos conjuntos de dados rotulados como masculino e feminino (Fig. 1, Step 6). Para garantir comparações justas e pareadas, aplicamos validação cruzada estratificada de 5 vezes, usando divisões de dados idênticas em modelos específicos de gênero (Fig. 1, Step 7). Os resultados da previsão foram então comparados usando o Kappa de Cohen, os testes qui-quadrado e o V de Cramér para avaliar o nível de concordância e a força da associação entre modelos treinados em diferentes fontes de anotação. (Fig. 1, Step 8).

[1]https://farm.pcibex.net/

3.3 Evolução Comparativa

Para avaliar a consistência entre as anotações humanas baseadas no gênero e as previsões do modelo de aprendizado de máquina na classificação textual, empregamos três métricas complementares: taxa de concordância , Kappa de Cohen e V de Cramér. Além disso, o teste do qui-quadrado(χ^2) foi usado para avaliar se a concordância observada se desvia significativamente do que seria esperado sob independência, indicando que as associações não são devidas ao acaso. A taxa de concordância oferece uma avaliação intuitiva da consistência entre anotadores humanos masculinos e femininos, bem como o alinhamento entre as saídas dos modelos derivadas deles. Além disso, o Kappa de Cohen ajusta essa concordância ao acaso, fornecendo uma estimativa mais robusta da confiabilidade ao contabilizar a concordância aleatória. Finalmente, o V de Cramér complementa essa análise quantificando a força da associação entre saídas categóricas, permitindo comparações entre diferentes padrões de classificação. O uso do Kappa de Cohen e do V de Cramér nos permite avaliar não apenas o nível de concordância além do acaso, mas também a força da associação entre classificações, oferecendo uma perspectiva multidimensional sobre a consistência humano-humano e modelo-modelo.

3.4 Guia para Interpretação

De acordo com [Landis and Koch 1977], $\kappa \geq 0.81$ denota concordância quase perfeita, substancial de 0,61 a 0,80 e moderada de 0,41 a 0,60. Para avaliar a força da associação entre anotações baseadas em gênero, calculamos o V de Cramér e interpretamos sua magnitude de acordo com [Alan and Duncan 1997], que definem associações abaixo de 0,20 como muito baixas, entre 0,20 e 0,39 como baixas, entre 0,40 e 0,69 como modestas, entre 0,70 e 0,89 como altas e de 0,90 a 1,00 como muito altas. O teste qui-quadrado (χ^2) foi usado para avaliar se há uma associação estatisticamente significativa entre as classificações categóricas produzidas por anotadores humanos e modelos de aprendizado de máquina. Um valor alto de χ^2 indica que os padrões de classificação observados se desviam significativamente do que seria esperado sob independência — isto é, se as saídas não estivessem relacionadas.

4. RESULTADOS

Figure 2 apresenta a distribuição dos rótulos de sentimento e as pontuações de entropia correspondentes para cada grupo. Embora ambos os grupos tenham rotulado o mesmo corpus, as anotadoras apresentaram uma distribuição ligeiramente mais equilibrada entre as classes de sentimento, com uma proporção maior de rótulos neutros (26.1% vs. 21.6%) e menor polarização. Isso resultou em uma pontuação de entropia mais alta para o grupo feminino (1,5673 vs. 1,5355), indicando maior dispersão no uso de rótulos. Aplicamos a entropia de Shannon usando a fórmula abaixo:

$$H = -\sum_{i=1}^{n} p_i \log_2 p_i \tag{1}$$

onde p_i denota a frequência relativa de cada classe de sentimento (negativo, neutro, positivo). A entropia oferece uma medida de incerteza ou diversidade em uma distribuição de probabilidade e, nesse contexto, captura o grau de variabilidade interpretativa dentro de cada grupo de anotadores. Em vez de inconsistência, uma entropia mais alta pode refletir uma estratégia de anotação mais cautelosa ou sensível ao contexto — particularmente em frases ambíguas ou emocionalmente complexas.

Table II compila todas as medidas estatísticas entre anotadores e modelos. Os resultados indicam uma associação estatisticamente significativa entre as classificações fornecidas por anotadores homens e mulheres.($\chi^2 = 1548.54$, $p < 0.001$; Cramér's $V = 0.812$; Cohen's $\kappa = 0.8177$). Como descrito na Seção 3.4, esses valores refletem um acordo quase perfeito além do acaso e um grau muito alto

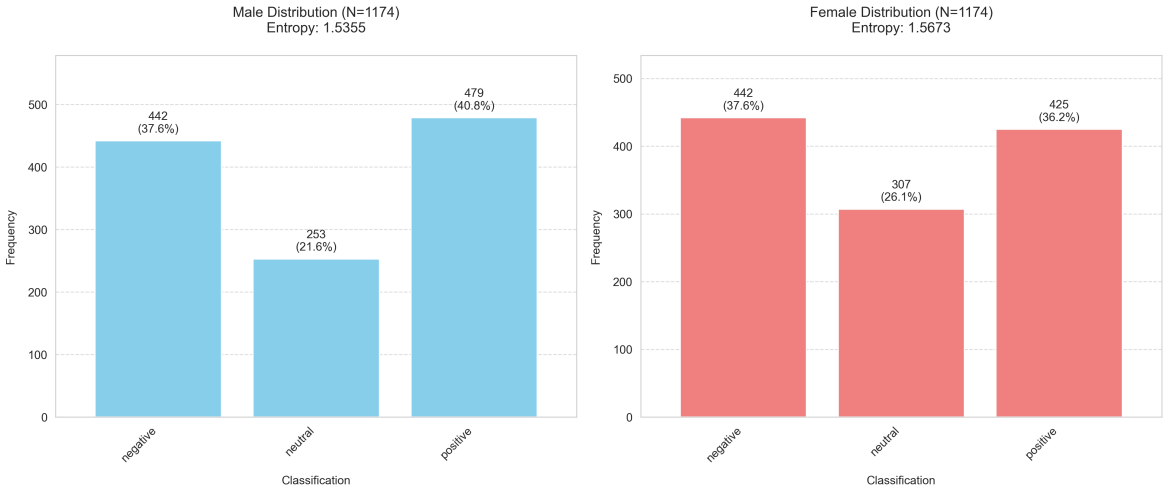

Fig. 2: Distribuição de rótulos de sentimento e entropia por gênero. Embora ambos os grupos tenham rotulado o mesmo corpus, as anotadoras apresentaram rótulos mais neutros, contribuindo para uma entropia mais alta.

Table II: Comparação estatística entre anotadores e modelos.

Métricas	**Anotadores**	**SVM**	**NB**	**RF**	**DT**	**LR**
Cohen's κ	0.8177	0.6466	0.6741	0.5840	0.3838	**0.6952**
Weighted κ	0.8949	0.6710	0.7062	0.6155	0.4810	**0.7369**
χ^2 (stat)	1548.54	750.13	816.11	784.38	353.23	**957.58**
Cramér's V	0.8121	0.5652	0.5896	0.5780	0.3879	**0.6386**

Configuração padrão do Scikit-Learn com stopwords NLTK. O χ^2 produziu valores de p efetivamente iguais a zero ($p < 10^{-70}$) quando aplicado a anotações humanas e previsões de modelos, sugerindo forte dependência estatística entre os resultados da classificação

de associação, indicando que anotadores homens e mulheres exibem comportamentos de rotulagem altamente consistentes, apesar das potenciais diferenças subjacentes na estratégia interpretativa.

Ao analisar modelos de aprendizado de máquina treinados com essas etiquetas específicas de gênero, observamos graus variados de alinhamento entre as saídas do modelo derivadas de anotações masculinas e femininas. A Regressão Logística (LR), por exemplo, produziu um V de Cramér de 0,652 e um Kappa de Cohen de 0,697. Embora esses valores sugiram um alinhamento estatisticamente significativo entre os modelos treinados com anotações masculinas e femininas, eles ficam aquém dos limites associados à forte concordância. Isso indica um nível moderado de consistência entre as condições de treinamento por gênero, inferior ao observado entre anotadores humanos.

Em contraste, o modelo da Árvore de Decisão (DT) mostrou o alinhamento mais fraco entre suas saídas quando treinado em anotações masculinas e femininas ($\chi^2 = 277.39$, $p < 0.001$; V de Cramér $= 0.346$; $\kappa = 0.327$). De acordo com [Alan and Duncan 1997], um V de Cramer de 0.346 cai dentro da faixa de "baixa associação", enquanto o valor de Kappa de Cohen indica apenas uma concordância razoável entre as previsões do modelo em ambas as condições de treinamento. Esses resultados sugerem que a Árvore de Decisão parece ser menos robusta na manutenção de padrões consistentes quando treinada com rótulos de diferentes fontes de anotação, ou menos robusta no aprendizado de regras consistentes de classificação de sentimentos sob diferentes esquemas de rotulagem. Comparado aos altos níveis de associação e concordância observados entre anotadores humanos, o desempenho do modelo de Árvore de Decisão destaca uma queda notável na consistência, reforçando a ideia de que nem todos os modelos de aprendizado de máquina preservam a mesma estrutura interpretativa derivada de estratégias de anotação humanas.

Selecionamos a Regressão Logística para comparação visual devido ao seu alinhamento relativamente forte, porém imperfeito, entre modelos específicos de gênero. As comparações gráficas apresentadas nas Figuras 3 e 4 oferecem insights adicionais sobre os efeitos distributivos do treinamento específico de gênero. Figure 3mostra uma sobreposição quase perfeita entre anotações humanas masculinas e femininas, enquanto a Figura 4 ilustra uma mudança visível nas atribuições de rótulos para modelos treinados sob anotações de gênero opostas — particularmente para classes neutras.

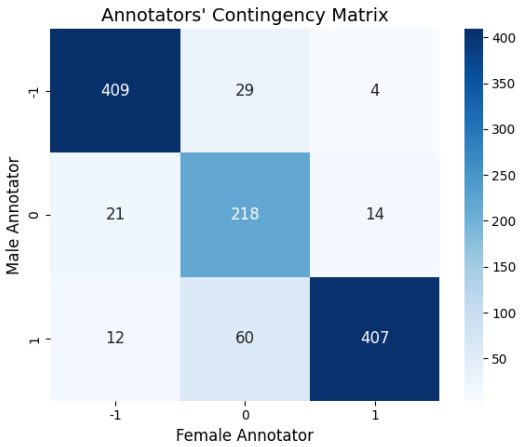

Fig. 3: Alta concordância nos rótulos de sentimento entre anotadores masculinos e femininos, mostrando distribuições quase idênticas.

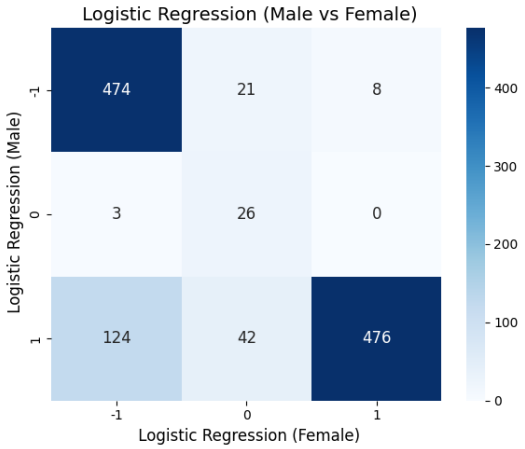

Fig. 4: Divergência de rótulos entre modelos de regressão logística treinados em anotações masculinas e femininas, especialmente em classes neutras e positivas.

Em conjunto, os resultados quantitativos e visuais demonstram que, embora os anotadores humanos estivessem amplamente alinhados em suas interpretações, o comportamento dos classificadores treinados com rótulos de gênero diverge consideravelmente — ocasionalmente reforçando, e em alguns casos exagerando, preferências sutis de anotação que eram menos pronunciadas nos dados humanos originais. Essas descobertas levantam questões importantes sobre a robustez e a imparcialidade do modelo em tarefas que envolvem julgamento subjetivo.

5. CONCLUSÃO E TRABALHOS FUTUROS

Este estudo examinou como os padrões de anotação de gênero influenciam a rotulação de sentimentos em textos em português brasileiro e se tais padrões são preservados — ou mesmo amplificados — quando propagados por meio de modelos de classificação supervisionados. Ao analisar 1.465 frases anotadas independentemente por dois grupos com equilíbrio de gênero, observamos alta concordância geral nas rotulações finais. No entanto, uma análise mais aprofundada revelou diferenças notáveis no comportamento dos anotadores, incluindo padrões específicos de cada grupo em termos de consistência, entropia e tendências de distribuição de classes.

Esses achados corroboram a visão de que a anotação não é meramente uma etapa técnica na preparação de dados, mas um processo social e interpretativo que pode moldar o comportamento de sistemas preditivos. Os anotadores masculinos, por exemplo, exibiram maior concordância interna e menor entropia de rotulagem, sugerindo uma estratégia interpretativa mais homogênea. Em contraste, o grupo feminino apresentou maior diversidade em suas anotações, potencialmente refletindo uma sensibilidade contextual mais ampla. Apesar de convergirem em muitos rótulos finais, os padrões de anotação sugerem que os dois grupos podem ter empregado tendências interpretativas distintas, como evidenciado por diferenças na entropia e na distribuição de rótulos.

Quando modelos de classificação foram treinados com base nos rótulos majoritários de cada grupo, as previsões resultantes não apenas preservaram, mas em alguns casos ampliaram, diferenças sutis observadas nas anotações humanas originais. Essa observação ressalta a necessidade de estratégias de avaliação que levem em conta a anotação, especialmente em contextos onde a imparcialidade e a representatividade são preocupações centrais. Em vez de tratar a discordância entre modelos como uma questão post hoc, nossos resultados sugerem que diferenças no comportamento da anotação podem servir como indicadores precoces de potenciais disparidades no desempenho do modelo. Nesse sentido, este trabalho oferece não apenas um conjunto de resultados, mas também uma estrutura para avaliar como o comportamento da anotação influencia o comportamento do modelo — reforçando a ideia de que as práticas de rotulagem fazem parte do pipeline algorítmico, não apenas sua entrada.

Além de aumentar o tamanho da amostra de anotadores para aprimorar o escopo da generalização, pesquisas futuras poderiam expandir essa base de diversas maneiras. Uma análise qualitativa de anotações de frases altamente divergentes poderia gerar insights sobre estratégias interpretativas e ambiguidades que medidas estatísticas por si só não conseguem capturar. Estudos longitudinais também poderiam revelar como o comportamento de anotação muda ao longo do tempo, especialmente sob fadiga ou exposição repetida a conteúdo emocionalmente carregado. Além disso, estender essa análise a grupos de anotadores não binários (masculinos e femininos) ou mais diversos poderia oferecer uma visão mais ampla de como a identidade molda as práticas de rotulação.

Essas descobertas têm implicações práticas para a implantação de sistemas de PLN em aplicações do mundo real. Modelos treinados em conjuntos de dados com vieses sutis de anotação podem inadvertidamente codificar e reforçar padrões demográficos que não são intrínsecos à tarefa, levando a disparidades não intencionais nas previsões subsequentes. Por exemplo, classificadores de sentimentos incorporados em plataformas de atendimento ao cliente ou ferramentas de monitoramento de mídias sociais podem produzir resultados sistematicamente diferentes dependendo da distribuição de gênero de seus anotadores de treinamento — impactando potencialmente a experiência do usuário, a moderação automatizada ou as métricas de imparcialidade em domínios sensíveis. Reconhecer o comportamento de anotação como um componente crítico do design do modelo pode ajudar a mitigar esses riscos no início do processo de desenvolvimento. Em última análise, este estudo reforça a necessidade de ir além do acordo superficial e em direção a uma compreensão mais profunda de como os dados rotulados são produzidos, bem como de como esse processo de produção influencia os modelos que dependem dele.

ACKNOWLEDGMENT

Este trabalho foi apoiado pelo Programa de Pós-graduação em Ciência da Computação (PPCIC) do CEFET/RJ. Agradecemos aos anotadores anônimos pela contribuição de tempo e esforço.

REFERENCES

Alan, B. and Duncan, C. Quantitative data analysis with spss for windows: A guide for social scientists, 1997.

Alves, A. A. C., de Souza, L. F. M., Varjolo, L. D., Mauro, R. C., Belloze, K., Paschoal, F., and Guedes, G. Vita 2.0 – class evaluation system. In *Proceedings of the 17th Iberian Conference on Information Systems and Technologies (CISTI)*. Iberian Conference on Information Systems and Technologies, Online, 2022. Authors affiliated with Escola Informat & Comp EIC, CEFET RJ, Rio de Janeiro, Brazil.

Blodgett, S. L., Barocas, S., Daumé III, H., and Wallach, H. Language (technology) is power: A critical survey of "bias" in nlp. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. ACL, Association for Computational Linguistics, Online, pp. 5454–5476, 2020.

Geva, M., Goldberg, Y., and Berant, J. Are we modeling the task or the annotator? an investigation of annotator bias in natural language understanding datasets. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Association for Computational Linguistics, Hong Kong, China, pp. 1161–1166, 2019.

Havens, V. and Hedges, M. Uncertainty and inclusivity in gender bias annotation. In *Proceedings of the 1st Workshop*

on Gender Bias in Natural Language Processing. Association for Computational Linguistics, Abu Dhabi, UAE, pp. 25–31, 2022.

Kowsari, K., Meimandi, K. J., Heidarysafa, M., Mendu, S., Barnes, L., and Brown, D. Text classification algorithms: A survey. *Information* 10 (4): 150, 2019.

Landis, J. R. and Koch, G. G. The measurement of observer agreement for categorical data. *Biometrics* 33 (1): 159–174, 1977.

Lim, S. S., Udomcharoenchaikit, C., Limkonchotiwat, P., Chuangsuwanich, E., and Nutanong, S. Identifying and mitigating annotation bias in natural language understanding using causal mediation analysis. In *Findings of the Association for Computational Linguistics: ACL 2024*. Association for Computational Linguistics, Bangkok, Thailand, pp. 11548–11563, 2024.

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., and Galstyan, A. A survey on bias and fairness in machine learning. *ACM Computing Surveys (CSUR)* 54 (6): 1–35, 2021.

Minatel, D., da Silva, A. C. M., dos Santos, N. R., Curi, M., Marcacini, R. M., and de Andrade Lopes, A. Data stratification analysis on the propagation of discriminatory effects in binary classification. In *Anais do 11º Symposium on Knowledge Discovery, Mining and Learning (KDMiLe)*. Sociedade Brasileira de Computação, Belo Horizonte, MG, pp. 73–80, 2023.

Paullada, A., Raji, I. D., Bender, E. M., Denton, E., and Hanna, A. Data and its (dis)contents: A survey of dataset development and use in machine learning research. *Patterns* 2 (11): 100336, 2021.

Prabhakaran, V., Hutchinson, B., and Mitchell, M. Releasing gender bias in sentiment classification with explanations. In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. ACM, Virtual Event, pp. 206–216, 2021.

Raji, I. D., Bender, E. M., Paullada, A., Denton, E., and Hanna, A. Ai and the everything in the whole wide world benchmark. In *Proceedings of the NeurIPS 2021 Datasets and Benchmarks Track*. NeurIPS, Virtual Conference, pp. 1–10, 2021.

Schwindt, L. C. Predizibilidade da marcação de gênero em substantivos no português brasileiro. *Gênero e língua (gem): formas e usos* vol. 1, pp. 279–294, 2020.

Shah, D. S., Schwartz, H. A., and Hovy, D. Predictive biases in natural language processing models: A conceptual framework and overview. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, Online, pp. 5248–5264, 2020.

Silva, M. O. and Moro, M. M. Nlp pipeline for gender bias detection in portuguese literature. In *Anais do Seminário Integrado de Software e Hardware (SEMISH)*. SBC, Sociedade Brasileira de Computação, Brasília, Brazil, pp. 1–10, 2024.

Stańczak, K. and Augenstein, I. A survey on gender bias in natural language processing, 2021.

Sun, T., Gaut, A., Tang, S., Huang, Y., Sap, M., Clark, E., Friedman, D., Choi, Y., Smith, N. A., Zettlemoyer, L., et al. Mitigating gender bias in natural language processing: Literature review. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, Florence, Italy, pp. 1630–1640, 2019.

Zhao, J., Wang, T., Yatskar, M., Ordonez, V., and Chang, K.-W. Men also like shopping: Reducing gender bias amplification using corpus-level constraints. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Copenhagen, Denmark, pp. 2979–2989, 2017.