CEFET/RJ
DIRETORIA DE PESQUISA E PÓS-GRADUAÇÃO

IDENTIFICAÇÃO AUTOMÁTICA DE ATIVIDADE PREDATÓRIA SEXUAL EM CONVERSAS VIRTUAIS NO BRASIL

Leonardo Ferreira dos Santos

Dissertação apresentada ao Programa de Pós-Graduação em Ciência da Computação, do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, CEFET/RJ, como parte dos requisitos necessários à obtenção do título de mestre.

Orientador(a): Professor D.Sc. Gustavo Paiva Guedes e Silva
Coorientador(a):

Rio de Janeiro,

Julho 2019

IDENTIFICAÇÃO AUTOMÁTICA DE ATIVIDADE PREDATÓRIA SEXUAL EM CONVERSAS VIRTUAIS NO BRASIL

Dissertação apresentada ao Programa de Pós-Graduação em Ciência da Computação, do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, CEFET/RJ, como parte dos requisitos necessários à obtenção do título de mestre.

Leonardo Ferreira dos Santos

Banca Examinadora:

Presidente, Professor D.Sc. Gustavo Paiva Guedes e Silva (CEFET/RJ) (Orientador(a))

Professor D.Sc. Eduardo Bezerra da Silva (CEFET/RJ)

Professor D.Sc. Eduardo Soares Ogasawara (CEFET/RJ)

Professor D.Sc. Ronaldo Ribeiro Goldschmidt (IME)

Rio de Janeiro,

Julho 2019

DEDICATÓRIA

AGRADECIMENTOS

Ao Centro Universitário da Fundação Educacional Inaciana (FEI), em particular, o Prof. Dr. Rodrigo Filev Maia e ao Ministério Público Federal de São Paulo (MPF-SP), especialmente à chefe do departamento de Crimes Cibernéticos, Adriana Shimabukuro, pela cooperação na disponibilização dos dados para a pesquisa.

RESUMO

Identificação automática de atividade predatória sexual em conversas virtuais no Brasil

O uso da Internet por crianças e adolescentes possibilita o acesso a um conjunto de oportunidades para o seu autodesenvolvimento. O acesso à informação, material educacional, entretenimento e socialização são algumas das oportunidades que podem ser usufruídas. Um dos principais canais para socialização na Internet consiste no uso de redes sociais. Por meio da criação de um perfil público no momento de ingresso à rede social, crianças e adolescentes podem criar conexões com outros perfis e estabelecer comunicação por meio de conversas virtuais. Predadores sexuais, por sua vez, fazem uso de redes sociais com o propósito de ludibriar essas crianças e adolescentes, estabelecendo uma relação enganosa para posterior execução de diversas atividades criminosas como obtenção de conteúdo pornográfico, extorsão e tentativa de abuso sexual. Nesse cenário, diversos estudos vêm se concentrando na identificação de predadores sexuais na Internet. Embora seja um domínio de pesquisa amplamente explorado, não foram encontrados trabalhos que considerem conversas virtuais realizadas na língua portuguesa. Diante do problema exposto, o presente trabalho tem como principal objetivo propor um algoritmo que permita a construção de um modelo para identificação automática de atividade predatória sexual em conversas virtuais realizadas na língua portuguesa. Os experimentos realizados até o presente momento utilizaram um conjunto de dados com conversas virtuais utilizadas como provas criminais que, após a remoção de informações sensíveis, foram disponibilizadas ao público. Os resultados foram obtidos por meio da reprodução de um dos trabalhos selecionados como referência para a pesquisa, em que foi considerado três classificadores diferentes. O uso de redes neurais convolucionais no domínio da pesquisa alcançou os melhores resultados, com a métrica F_1 de 100% em alguns dos experimentos. Os demais classificadores também apresentaram resultados promissores, abrindo uma lacuna para continuidade das demais tarefas previstas.

Palavras-chave:

ABSTRACT

Automatic identification of sexual predatory activities in virtual conversations in Brazil

The use of the Internet by children and adolescents open access to a set of opportunities for self-development. The access to information, educational material, entertainment and socialization are some of the opportunities that can be enjoyed. One of the main channels for socializing on the Internet is the use of social networks. By creating a public profile at the moment of joining the social network, children and adolescents can create connections with other profiles and establish communication through virtual conversations. Sexual predators, on the other hand, make use of social networks for the purpose of deceiving these children and adolescents, establishing a misleading relationship for subsequent execution of various criminal activities such as obtaining pornographic content, extortion and attemption of sexual abuse. In this scenario, several studies have been focused on the identification of sexual predators on the Internet. Although it is a widely explored domain of research, no studies were found considering virtual conversations performed in the Portuguese language. Given the problem described above, the main objective of this work is to propose an algorithm that allows the construction of a model for automatic identification of predatory sexual activity in virtual conversations performed in the Portuguese language. The experiments described in this work used a set of data with virtual conversations used as criminal evidence that, after the removal of sensitive information, were made available to the public. The current results were obtained through the reproduction of one of the selected papers as reference for the research, in which three different classifiers were considered. The use of convolutional neural networks in the research domain achieved the best results, with the F_1 100 % metric in some of the experiments. The other classifiers also presented promising results, opening a gap for the continuity of other expected tasks.

Keywords:

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de conversa disponibilizada no conjunto de dados PAN-2012. 20

Figura 2 – Resultado da execução do algoritmo SVM em um conjunto de dados com duas classes, representado por pontos pretos e brancos. Vetores classificados erroneamente apresentam uma cruz acima e vetores de suporte são representados por círculos duplos. Autor: Vapnik [2013]. 26

Figura 3 – Exemplo de uma rede neural artificial Perceptron com múltiplas camadas. A rede apresenta 3 neurônios na camada de entrada, 2 camadas ocultas com 3 neurônios cada e uma 1 camada de saída com 2 neurônios. Autor: Próprio. 27

Figura 4 – Anatomia de um neurônio artificial. Autor: Próprio. 28

Figura 5 – Exemplo de conversa predatória disponibilizada pelo MPF-SP e FEI. 41

Figura 6 – Preparação dos dados para posterior uso na biblioteca conText v4: 1) Extração das mensagens das conversas para arquivos de texto, classificando-as em diretórios distintos mediante ocorrência de atividade predatória sexual (”Positive”) ou não (”Negative”). 2) Criação do dicionário de categorias: arquivo de texto contendo para cada linha uma categoria esperada na classificação. 3) Por fim, para cada conjunto criado, são criados dois arquivos: 1 arquivo com extensão *tok* contendo todas as conversas, de forma que cada linha do arquivo contenha todos os *tokens* de uma conversa e 1 arquivo com extensão *tok* em que é informada a categoria correspondente da respectiva linha no arquivo *tok*. 49

Figura 7 – Adaptação para arquitetura de CNN reproduzida nos experimentos presente em Ebrahimi [2016]. Autor: Próprio. 50
Figura 8 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-5000-SGD” 53
Figura 9 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-5000-SGD” 53
Figura 10 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-1000-SGD” 53
Figura 11 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-1000-SGD” 53
Figura 12 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-10000-SGD” 54
Figura 13 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-1000-SGD” 54
Figura 14 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-15000-SGD” 54
Figura 15 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-1000-RMSPROP” 54
Figura 16 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-1000-RMSPROP” 55
Figura 17 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-5000-RMSPROP” 55
Figura 18 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-5000-RMSPROP” 55
Figura 19 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-10000-RMSPROP” 55
Figura 20 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-10000-RMSPROP” 56
Figura 21 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-15000-RMSPROP” 56
Figura 22 – Cronograma com detalhamento das tarefas previstas para a evolução e conclusão do trabalho. Autor: Próprio. 59

LISTA DE TABELAS

Tabela 1 – Características do conjunto de dados disponibilizado para a competição PAN-2012 21

Tabela 2 – Exemplo de uma matriz de confusão para um cenário de classificação binária. Consideradas duas dimensões principais - Predito e Atual, são apresentados os resultados encontrados quanto a ocorrência das classes positiva e negativa 24

Tabela 3 – Critério de inclusão e exclusão considerados para a elaboração do mapa sistemático para pesquisa nos principais canais de publicação 33

Tabela 4 – Resumo dos trabalhos relacionados apresentados no capítulo 39

Tabela 5 – Marcações para preservação de identidade de predadores sexuais e vítimas. 40

Tabela 6 – Volume de conversas disponibilizadas pelo FEI em parceria com o MPF-SP e UFMG. 41

Tabela 7 – Análise estatística descritiva do conjunto de dados “PAN-2012-BR”. 43

Tabela 8 – Resultados obtidos com o primeiro modelo, feito o uso dos algoritmos TF-IDF e SVM e uso do conjunto de dados “PAN-2012-BR” 47

Tabela 9 – Matriz de confusão referente aos resultados obtidos com o Subconjunto 1 47

Tabela 10 – Matriz de confusão referente aos resultados obtidos com o Subconjunto 2 47

Tabela 11 – Resultados do primeiro experimento com o “PAN-2012-BR” considerando os mesmos hiperparâmetros utilizados no trabalho proposto por Ebrahimi [2016]. 52

Tabela 12 – Resultados do segundo experimento considerando variações nas distribuições dos conjunto de treinamento e teste, otimizadores RMSProp e SGD e diferentes tamanhos de vocabulário para treinamento. 52
Tabela 13 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-5000-SGD” 53
Tabela 14 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-5000-SGD” 53
Tabela 15 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-1000-SGD” 53
Tabela 16 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-1000-SGD” 53
Tabela 17 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-10000-SGD” 54
Tabela 18 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-10000-SGD” 54
Tabela 19 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-15000-SGD” 54
Tabela 20 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-1000-RMSPROP” 54
Tabela 21 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-1000-RMSPROP” 55
Tabela 22 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-5000-RMSPROP” 55
Tabela 23 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-5000-RMSPROP” 55
Tabela 24 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-10000-RMSPROP” 55
Tabela 25 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-10000-RMSPROP” 56
Tabela 26 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-15000-RMSPROP” 56

LISTA DE ALGORITMOS

LISTA DE CÓDIGOS

LISTA DE ABREVIATURAS E SIGLAS

SUMÁRIO

Introdução **14**

1 Referencial Teórico **18**

1.1 Características do predador sexual na Internet 18

1.2 PAN-2012 19

1.3 Processamento de linguagem natural 21

1.3.1 Modelagem de Tópicos 21

1.3.2 Bag of Words 22

1.3.3 TF-IDF 22

1.4 Medidas de avaliação e técnicas de validação 23

1.4.1 Validação cruzada 23

1.4.2 Matriz de confusão 24

1.4.3 Acurácia 24

1.4.4 Precisão 25

1.4.5 Abrangência 25

1.4.6 Medida F_β 25

1.5 Máquina de vetores de suporte 26

1.6 Redes neurais artificiais 27

1.6.1 Redes neurais recorrentes 28

1.6.2 Redes neurais convolucionais 29

1.7 Árvores de decisão 29

1.8 Florestas Aleatórias 30

1.9 K vizinhos mais próximos 30

1.10 Máquina de vetores de suporte para uma única classe 31

2 Trabalhos Relacionados **32**

2.1 Mapa Sistemático 32

2.2 Identificação de atividade predatória sexual em conversas virtuais 34

3 Conjunto de dados 40

3.1 Conjunto de dados “PAN-2012-BR” 41

4 Experimentos 46

4.1 Trabalho: “Automatic Identification of Online Predators in Chat Logs by Anomaly Detection and Deep Learning” [Ebrahimi, 2016]. 46

4.1.1 Hipótese 1 47

4.1.2 Hipótese 2 48

5 Trabalhos Futuros 57

Referências 60

Introdução

A possibilidade de contato entre um predador sexual e uma criança ou adolescente é uma preocupação global [Olowu, 2014; Dorasamy et al., 2018; Kloess et al., 2019]. Essa preocupação é crescente na medida em que aplicações sociais *online* se tornam mais acessíveis à massa, permitindo que cada vez mais crianças e adolescentes consigam usá-las sem grandes dificuldades. A presença de crianças e adolescentes em redes sociais a tornam um canal amplamente explorado por predadores sexuais [Hernandez et al., 2018].

Segundo dados da pesquisa *TIC Kids Online Brasil*, que estuda o uso da Internet por crianças e adolescentes [BARBOSA, 2018], 85% das crianças e adolescentes com idades entre 9 e 17 anos possuem acesso à Internet. Nesse cenário, dispositivos móveis são o único meio de acesso para 44% do total de crianças e adolescentes, cuja maioria pertence às classes A e B (76%). Quando questionadas sobre o que consideram um incômodo na Internet, crianças e adolescentes pouco mencionaram o risco de contato ou assédio de pessoas estranhas, indesejadas ou adultos desconhecidos (10% do total), quando comparado à outros riscos como: risco de conduta (32%), risco de exposição à conteúdo inadequado (28%), percepção de sexo (17%) e a percepção de violência (12%). A pouca ocorrência de menção ao risco de contato e a não alteração desse quadro ao longo dos anos conclui a existência de uma ameaça real para crianças e adolescentes [BARBOSA, 2018].

Nesse cenário, uma preocupação legítima dos pais é garantir que os filhos não sejam expostos aos riscos oriundos da Internet, ao mesmo tempo que sejam usufruídos todos os benefícios e oportunidades [Livingstone et al., 2017]. No entanto, intervenções parentais na seleção do conteúdo a ser acessado na Internet apresentam um elevado grau de rejeição devido ao fato de crianças e adolescentes almejarem encontrar na Internet um ambiente para liberdade, além da possibilidade de demonstrar que são capazes de tomar boas decisões e aprender com os erros [Ghosh et al., 2018].

Dentre os riscos a que se expõem as crianças, podemos destacar a possibilidade de conhecer novas pessoas e o desenvolvimento de novas amizades, comportamento considerado básico não somente para crianças e adolescentes mas para todos os seres

humanos [Leary and Baumeister, 2000]. Uma preocupação, vale ressaltar, é que as redes sociais não estão isentas dos mesmos riscos sociais quando ocorre uma interação com uma ou várias pessoas presencialmente. [Clark et al., 2018]. Um fenômeno que atua como agravante nesse contexto é a distância psicológica promovida pela Internet, que atua como um eventual inibidor do senso moral e social, aumentando a ocorrência de comportamentos não éticos [Crowell et al., 2008]. Nesse caso, um fator que contribui como iniciativa é o sentimento de anonimidade que a Internet oferece [Soh et al., 2018]. Essa anonimidade pode se refletir em diversos níveis, desde o uso de um apelido em uma sala de bate-papo assim como construções de perfis falsos em redes sociais [Keipi, 2018]. Nesse cenário, destacam-se o *Cyberbullying*[1], *Sexting*[2] e atividades predatórias.

A atividade predatória sexual apresenta diversas finalidades, conforme identificadas na literatura [NCMEC, 2017]: em 78% das atividades predatórias sexuais, o principal objetivo é a obtenção de conteúdo pornográfico da vítima, enviado por aplicativos de conversas instantâneas. Para 7% atividades predatórias sexuais, a vítima também sofre extorsão (*Sextortion*[3]), esta se caracterizando por pedidos de transferências financeiras, disponibilização de dados de cartão de crédito dos pais e pertences. Em 5% dos casos de atividade predatória sexual busca-se o contato pessoalmente com a vítima com a finalidade de realizar o abuso sexual. Os 10% restantes apresentam outras finalidades que não se enquadram nessas principais razões para a realização do contato.

O impacto da atividade predatória sexual pode ser devastador para um menor de idade. A ocorrência do abuso sexual destrói a espontaneidade e a liberdade da criança ou do adolescente, provocando um terror solitário [Bagley and King, 2003]. As vítimas de abuso sexual originados na Internet tem maior probabilidade de desenvolver distúrbios mentais, tais como a depressão, estresse agudo, estresse pós-traumático, transtornos de conversão podendo levar a tentativas de suicídio [Say et al., 2015].

Diante do cenário apresentado, diversos estudos têm sido conduzidos objetivando a identificação de predadores sexuais na Internet [Pendar, 2007; Morris, 2013; Bogdanova et al., 2014]. A maioria dos trabalhos encontrados na literatura foi viabilizada por conta das

[1] O “Cyberbullying” pode ser definido como uma ação agressiva e intencional realizada por uma pessoa ou grupo de pessoas ao longo do tempo por meio de dispositivos com acesso à Internet contra uma vítima incapaz de se defender totalmente [Slonje and Smith, 2008].

[2] O “Sexting” é uma prática ilegal que consiste na prática em que crianças e adolescentes tiram fotos ou gravam vídeos próprios com teor de nudez e o compartilham com outros que, por sua vez, divulgam em redes sociais na Internet [McLaughlin, 2010].

[3] O “Sextortion” pode ser compreendido como a realização de ameaças após obtenção de conteúdo com teor de nudez da vítima de forma que seja enviado mais conteúdo pornográfico produzido pela vítima [Wolak et al., 2018].

conversas predatórias disponibilizadas pela organização *Perverted-Justice* (PJ)[4]. Essas conversas, em que agentes federais atuam na Internet como crianças e adolescentes de forma a servir de iscas para predadores sexuais convictos, permitiram o estudo de diversas características [Cardei and Rebedea, 2017; Liu et al., 2017] para que pudessem ser criados meios automáticos de identificação.

No entanto, uma limitação frequente nos trabalhos realizados no domínio da pesquisa é a carência de dados reais, isto é, conversas que ocorreram entre predadores sexuais e vítimas, sendo as vítimas crianças ou adolescentes. Nesse cenário, o principal impedimento é o teor sensível dos dados e por serem provas de processos que correm em sigilo na justiça. Por não serem disponibilizados como artefatos resultantes da pesquisa, acabam prejudicando a reprodutibilidade e a sua evolução.

Ao considerar o domínio da pesquisa na língua portuguesa, observa-se uma ausência de trabalhos realizados. Objetivando preencher essa lacuna, o presente trabalho se caracteriza como uma tarefa de classificação para conversas virtuais com o objetivo de identificar a ocorrência de atividade predatória sexual. Um ponto importante é que, para o melhor do nosso conhecimento, este é o primeiro trabalho a fazer uso de um conjunto de dados com conversas predatórias reais na língua portuguesa, antes sob sigilo de justiça brasileira e agora disponibilizadas ao público por meio de uma parceria acadêmica. Dado esse contexto, é considerada a seguinte pergunta de pesquisa: Os modelos de classificação propostos na literatura a respeito de identificação de atividade predatória sexual em conversas virtuais na língua inglesa e candidatos ao estado da arte no domínio da pesquisa apresentam o mesmo desempenho quando considerada a métrica F_1 com conversas virtuais na língua portuguesa? Para responder essa pergunta, parte-se do princípio que o desempenho de um modelo de classificação de textos para um domínio específico pode variar devido às especificidades presentes na escrita de cada idioma, como por exemplo, regionalismos e gírias [Karan and Šnajder, 2018; Chen et al., 2018]. Como contribuição da pesquisa, pretende-se apresentar:

- Com base nos algoritmos identificados como candidatos ao estado da arte na identificação de atividade predatória sexual na Internet considerando conversas na língua inglesa, criar um modelo que apresente resultados significativos considerando a métrica F_1 para identificação de atividade predatória sexual na língua portuguesa.

[4] `https://www.perverted-justice.com`

  - Conjunto de dados usado na pesquisa e seguindo o formato disponibilizado pela competição “PAN-2012”.
  - Disponibilização de *API online* para classificação de conversas quanto ao teor predatório.

Algumas das contribuições acima encontram-se iniciadas nos presentes artigos ao longo do desenvolvimento do presente trabalho:

- Santos, L. and Guedes, G. P. (2018). Detecção de traços de narcisismo em conversas com predadores sexuais. In 7o Brazilian Workshop on Social Network Analysis and Mining (BraSNAM 2018).
- Santos, L. and Guedes, G. P. (2019). Identificação de predadores sexuais brasileiros por meio de análise de conversas realizadas na internet. In 8o Brazilian Workshop on Social Network Analysis and Mining (BraSNAM 2019).

Além desta introdução, segue a organização do restante do trabalho. No capítulo 1, são apresentados conceitos relacionados ao domínio da pesquisa e algoritmos aplicados em trabalhos selecionados; No capítulo 2 são discutidos todos os trabalhos pesquisados e considerados; No capítulo 4 são detalhados todos os experimentos realizados até o presente momento. Por fim, no capítulo 5 são apresentadas as atividades previstas para a conclusão do presente trabalho.

1- Referencial Teórico

1.1- Características do predador sexual na Internet

O perfil do predador sexual que atua na Internet tem sido amplamente estudado em todo o mundo. Normalmente, uma atividade predatória sexual pode ser caracterizada pelos seguintes pontos [Morris, 2013]: 1) Disparidade de idade entre as partes de uma conversa. Uma configuração típica de uma conversa predatória consiste de um adulto, isto é, uma pessoa responsável legalmente por seus atos e um menor de idade; 2) Intimidade inapropriada, ou seja, estímulo ou iniciativa a um teor de conversa que promova uma intimidade artificial e forçada. Uma vez essa intimidade estabelecida, é comum que se estenda a relação recém-criada para um encontro *in loco*. A comunicação realizada normalmente apresenta algum teor sexual. Não é incomum que inicialmente ocorra maior uso de um vocabulário mais moderado e, uma vez que se crie uma relação de confiança, conversas que apresentem teor sexual ocorram com maior frequência [Olson et al., 2007].

Em geral, são homens, solteiros e desempregados e, não apresentam uma idade superior à 26 anos [Fortin et al., 2018; Babchishin et al., 2011] e apresentam traços de transtornos mentais [Santos and Guedes, 2018]. Sobre a escolha das vítimas, idade e gênero costumam ser os fatores decisórios mas também são consideradas as que apresentam um perfil vulnerável e que possam ser consideradas alvos fáceis, como crianças ou adolescentes solitários e carentes de atenção, com sobrepeso e insatisfeitas com a sua própria imagem [Tener et al., 2015]. Adolescentes do gênero feminino com idade entre 13 e 15 anos se apresentam como o grupo de maior risco [Tener et al., 2015]. Predadores sexuais não costumam apresentar comportamento violento [Wolak et al., 2004] ou histórico criminal [Seto et al., 2011]. Sobre a questão comportamental, predadores sexuais apresentam alto grau de empatia com as vítimas [Babchishin et al., 2011] e não são impulsivos [Wolak et al., 2009].

1.2- PAN-2012

A PAN é um evento colocado na conferencia CLEF - acrônimo para *Conference and Labs for Evaluation Forum*, composta por eventos científicos e disponibilização de tarefas no âmbito da análise forense e estilométrica de textos encontrados na Internet no formato de competição. Nos últimos 10 anos, a competição fomentou a pesquisa em uma diversidade de temas como: identificação de autoria, caracterização de perfis, plagiarismo e identificação de atividade enganosa.

No que se refere à identificação de atividade enganosa, a PAN-2012 [Inches and Crestani, 2012] organizou uma competição com o objetivo de identificar predadores sexuais praticando aliciamento em conversas na Internet. Para tal objetivo, foi disponibilizado um grande conjunto de dados com o propósito de não somente atender à finalidade da competição mas servir como referência para o testes de diferentes abordagens oriundas das mais diversas áreas de pesquisa. A tarefa apresentava dois problemas para a solução:

1. Identificar predadores sexuais em conversas na Internet
2. Dado uma conversa predatória, identificar as mensagens enviadas pelo predador sexual

Para o conjunto de dados criado para a competição foram consideradas características realísticas do domínio da pesquisa: pouca ocorrência de conversas predatórias, um grande número de conversas sobre sexo ou tópicos que apresentem alguma similaridade com a comunicação realizada pelo predador sexual e uma quantidade ainda maior de conversas com temas variados. A figura 1 apresenta o formato definido para as conversas presentes no conjunto de dados. Para a obtenção de conversas predatórias, não foram consideradas conversas entre predadores e crianças e adolescentes pois, historicamente, agências policiais apresentam postura relutante e não colaborativa sobre o tópico [Inches and Crestani, 2012]. Diante deste cenário, foram consideradas conversas disponibilizadas no site *Perverted-Justice.com* (PJ). No site, são apresentados os perfis de predadores sexuais identificados por meio de conversas com agentes federais voluntários que agem como crianças e adolescentes em salas de bate-papo. Informações obtidas sobre o criminoso são disponibilizadas para o público assim como as conversas

registradas. Além do PJ, na construção do conjunto de dados foram considerados as seguintes fontes de dados:

1. Omegle[1]: Conversas abusivas e de teor sexual porém não consideradas predatórias.

2. Canais de IRC[2][3]: Conversas não-predatórias sobre diversos tópicos.

```
<conversation id="1d0d6eb4815de5e2b27d0c396abf9dc7">
  <message line="1">
    <author>634f0ee018e70d40d1db4a4bf3a2d35d</author>
    <time>02:55</time>
    <text>hi</text>
  </message>
  <message line="2">
    <author>898d2f30e39b4fc143ebdf8c0b5c6a92</author>
    <time>02:55</time>
    <text>asl</text>
  </message>
  <message line="3">
    <author>634f0ee018e70d40d1db4a4bf3a2d35d</author>
    <time>02:55</time>
    <text>m or f</text>
  </message>
  <message line="4">
    <author>898d2f30e39b4fc143ebdf8c0b5c6a92</author>
    <time>02:55</time>
    <text>m</text>
  </message>
</conversation>
```

Figura 1 – Exemplo de conversa disponibilizada no conjunto de dados PAN-2012.

A seguir, na tabela 1 é possível observar as principais características do conjunto de dados empregado na competição PAN-2012. O subconjunto de treinamento apresentou 30% do total de dados. A proporção definida teve como motivação proporcionar de forma simplificada o domínio da pesquisa para exploração de dados para fins de prática [Inches and Crestani, 2012].

[1] http://web.archive.org/web/20100710040611/http://omegle.inportb.com/
[2] http://web.archive.org/web/20080704032104/http://www.irclog.org/
[3] https://krijnhoetmer.nl/irc-logs/

Tabela 1 – Características do conjunto de dados disponibilizado para a competição PAN-2012

Subconjunto	Classe	Conversas	Usuários únicos
Treinamento	Predatórias	2.016	142
	Não-Predatórias	64.911	97.547
Teste	Predatórias	3.684	254
	Não-Predatórias	151.210	218.488

1.3- Processamento de linguagem natural

Por conta do volume de textos gerado diariamente na Internet, sua compreensão e análise se tornou alvo de diversas áreas de pesquisa dentre estas o processamento de linguagem natural (PLN). O PLN representa um conjunto de técnicas cujo o propósito é permitir que a linguagem humana seja automaticamente analisada e representada [Cambria and White, 2014].

As técnicas contemplam, em sua maioria, a realização de tarefas de classificação e predição [Koppel et al., 2009]: as tarefas de classificação levam em consideração o formato e a fonte do dado disponível durante a definição do modelo de análise [Goldberg, 2017]; nas tarefas de predição, um dos desafios normalmente deparados é a tarefa de atribuição de autoria que remete à identificação do autor ou de características pertencentes ao autor [Koppel et al., 2009] dado um texto. Por fim, o PLN também apresenta um conjunto de técnicas para extração de diferentes tipos de características de um texto.

1.3.1 Modelagem de Tópicos

A modelagem de tópicos caracteriza um conjunto de modelos estatísticos e probabilísticos que atuam de forma a encontrar termos que representem uma determinada coleção de documentos. Diante do crescimento de dados não estruturados textuais disponíveis na Internet, os métodos de modelagem de tópicos tem ganhado crescente atenção e tem sido empregadas para os diversos propósitos: como uma ferramenta de mineração de textos para extração de características [Ma et al., 2013], atuar como

classificadores em modelos [Quercia et al., 2012], identificar a evolução dos tópicos identificados em um conjunto de documentos ao longo do tempo [Gohr et al., 2009], dentre outros.

Os métodos de modelagem de tópicos mais populares atualmente são o *Latent Semantic Analysis* (LSA) [Hofmann, 2001] e o *Latent Dirichlet allocation* (LDA) [Blei et al., 2003].

1.3.2 Bag of Words

O algoritmo *Bag of words* (BoW) é baseado no trabalho de Harris [1954], no qual assume-se a premissa que uma língua representa uma estrutura distribuível, isto é, um conjunto de termos que podem ser organizados de tal forma que permite ser possível compreender o papel do termo em uma afirmação assim como a relação com os demais termos. A característica distribuível da língua vem do fato que termos da língua não são encontrados de forma arbitrária próximos de determinadas classes de termos. Sendo assim, é possível identificar a frequência de ocorrência de um termo e co-ocorrências por meio da posição de demais termos.

Um ponto importante é que o BoW não considera a ordem local dos termos. No entanto, o uso de mais de um termo em conjunto (*Bag of n-grams*) possibilita representar parte da informação presente em um texto, se apresentando como um algoritmo eficiente para extração de características [Wang and Manning, 2012].

1.3.3 TF-IDF

O termo TF-IDF, acrônimo para *Term Frequency - Inverse Document Frequency* representa a combinação de dois métodos estatísticos com o propósito de identificar o grau de significância de uma palavra em um conjunto de textos. Dado um termo t, presente em um documento d, o peso $w_{t,d}$ de um termo t em um documento d pode ser calculado conforme apresentado na equação 1:

$$w_{t,d} = \left[\begin{array}{ll} 1 + \log_{10} \mathrm{tf}_{t,d}, & \text{se } \mathrm{tf}_{t,d} > 0 \\ 0, & \text{caso contrário} \end{array} \right. \tag{1}$$

1.4- Medidas de avaliação e técnicas de validação

A seguir, serão apresentadas as medidas para avaliação de desempenho consideradas nos trabalhos relacionados e nos experimentos. Medidas de avaliação são representadas de forma quantitativa e calculadas mediante fundamentação estatística. Desta forma, diferentes medidas de avaliação permitem a interpretação sob diferentes perspectivas.

1.4.1 Validação cruzada

O método estatístico de validação cruzada foi inicialmente proposto em um estudo da área da psicologia [Larson, 1931] e tem como principal objetivo identificar a capacidade de generalização de um dado modelo. Uma aplicação comum é a divisão do conjunto de dados em duas partes: com a primeira parte do conjunto de dados é realizado o treinamento do modelo enquanto a segunda parte é responsável por validar o qual generalizado se encontra o modelo treinado. A técnica também possibilita identificar dentre um conjunto de algoritmos quais aqueles que melhor apresentam resultados para o conjunto de dados [Refaeilzadeh et al., 2009].

Uma outra forma de se aplicar o método de validação cruzada consiste na idéia de repartir um conjunto de dados em k partes de igual tamanho (*folds*). A partir de então para cada parte k do conjunto de dados considerada para validação, as demais $k-1$ partes são usadas no treinamento do modelo. Após k validações cruzadas, é possível identificar o desempenho geral do algoritmo para o conjunto de dados. Essa forma de aplicação do método de validação cruzada é conhecida como *k-fold*.

1.4.2 Matriz de confusão

Uma ferramenta comum para validação do desempenho de modelos de classificação é a matriz de confusão. No cenário de uma classificação binária, por exemplo, é possível identificar quantos elementos foram corretamente previstos como pertencentes da classe positiva (verdadeiro positivo - tp) ou classe negativa (verdadeiro negativo - tn) assim como também é possível identificar a quantidade de elementos erroneamente classificados como pertencentes à classe positiva (falso positivo - fp) ou classe negativa (falso negativo - fn). A tabela 2 demonstra uma possível representação de uma matriz de confusão.

Tabela 2 – Exemplo de uma matriz de confusão para um cenário de classificação binária. Consideradas duas dimensões principais - Predito e Atual, são apresentados os resultados encontrados quanto a ocorrência das classes positiva e negativa

		Predito	
		Positivo	Negativo
Atual	Positivo	tp	fp
	Negativo	fn	tn

As principais métricas de desempenho consideradas atualmente em tarefas de classificação de textos são inspiradas na extração de informação inicialmente aplicada para a geração de textos sinônimos [Boyer and Lapalme, 1985]. As principais métricas consideradas (Precisão, Abrangência, Medida F_β) valorizam a correta identificação de resultados da classe positiva enquanto a Acurácia busca identificar a capacidade assertiva do modelo treinado. A seguir, é explanado as métricas de desempenho acima citadas.

1.4.3 Acurácia

A acurácia permite identificar a capacidade de acerto de modelo, ou seja, o total de predições corretas realizadas dentre o total de predições realizadas. A equação 2 exemplifica o conceito apresentado.

$$Acurácia = \frac{tp + tn}{tp + tn + fp + fn} \tag{2}$$

1.4.4 Precisão

A medida de precisão representa a capacidade do modelo de classificação de identificar exemplos da classe positiva corretamente dentre todos as ocorrências identificadas como pertencentes à classe positiva presentes em um dado sistema. A precisão é apresentada na equação 3.

$$Precisão = \frac{tp}{tp + fp} \tag{3}$$

1.4.5 Abrangência

A abrangência representa a proporção com que um modelo de classificação é capaz de identificar ocorrências pertencentes à classe positiva em comparação a todas as amostras positivas presentes no modelo. A abrangência pode ser compreendida conforme a equação 4.

$$Abrangência = \frac{tp}{tp + fn} \tag{4}$$

1.4.6 Medida F_β

A medida F_β tem por objetivo medir o grau de eficiência na recuperação de ocorrências da classe positiva considerando o parâmetro de ponderação e os resultados obtidos com métricas Precisão e Abrangência. O parâmetro permite definir uma maior importância para uma métrica. Por exemplo, na competição PAN-2012, para a tarefa de identificação de conversas com teor predatório, foi considerado $= 0,5$, pois foi assumido que seria mais relevante obter resultados mais precisos em detrimento da quantidade de ocorrências obtidas no resultado, comportamento este que agilizaria a atuação de

agentes da lei. Por fim, uma vez definido , é realizada a média harmônica ponderada das métricas Precisão e Abrangência. A equação 5 define a explicação apresentada.

$$F_\beta = \frac{\left(\beta^2 + 1\right) tp}{\left(\beta^2 + 1\right) tp + \beta^2 fn + fp} \tag{5}$$

1.5- Máquina de vetores de suporte

A máquina de vetores de suporte (SVM) representa os dados do modelo como vetores de entrada pertencentes à diferentes classes em um espaço de características com alta dimensionalidade. Uma vez aplicada uma função não-linear nos vetores de entrada, é possível então extrair um hiperplano que maximize a margem entre as classes presentes [Vapnik, 2013]. Os vetores responsáveis por definir a margem máxima do hiperplano resultante são chamados de “vetores de suporte”. Na figura 2 é apresentado o resultado de uma tarefa de classificação considerando duas classes.

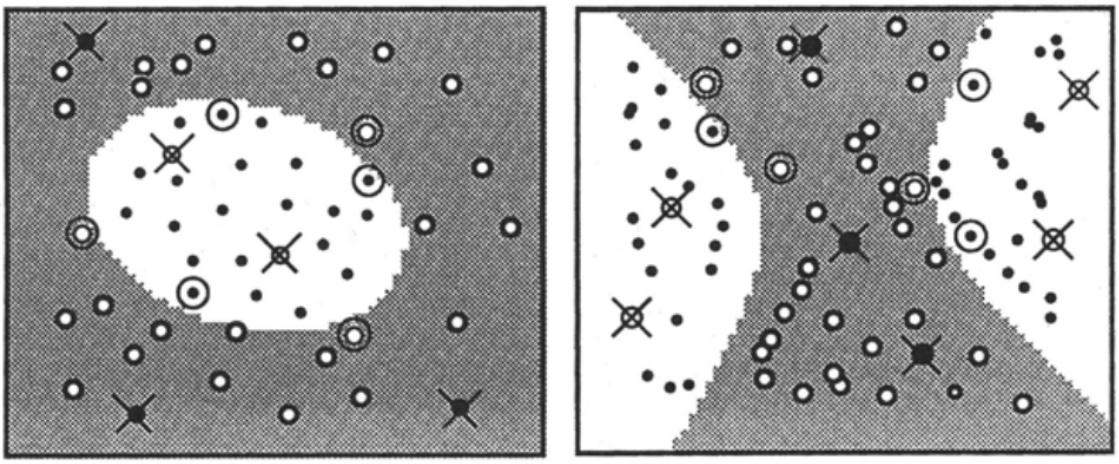

Figura 2 – Resultado da execução do algoritmo SVM em um conjunto de dados com duas classes, representado por pontos pretos e brancos. Vetores classificados erroneamente apresentam uma cruz acima e vetores de suporte são representados por círculos duplos. Autor: Vapnik [2013].

1.6- Redes neurais artificiais

A redes neurais artificiais (RNA) surgiram a partir da concepção que o cérebro humano processa informações de forma totalmente diferente que um computador [Haykin et al., 2009]. Um exemplo clássico de RNAs são as redes *Perceptron* multicamadas (NN-MLP). Essas redes apresentam as seguintes características: seguem uma única direção e são densamente conectadas, ou seja, cada neurônio de uma camada se comunica com todos da camada posterior. NN-MLP apresentam 3 tipos de camadas: uma camada de entrada, que será responsável por processar os elementos do padrão de ativação; camadas ocultas que recebem os padrões processados da camada anterior, reprocessam e transmitem o resultado para a camada seguinte; por fim, uma camada de saída que tem como saída o resultado final de todo o processamento realizado. Um exemplo de NN-MLP pode ser observado na figura 3.

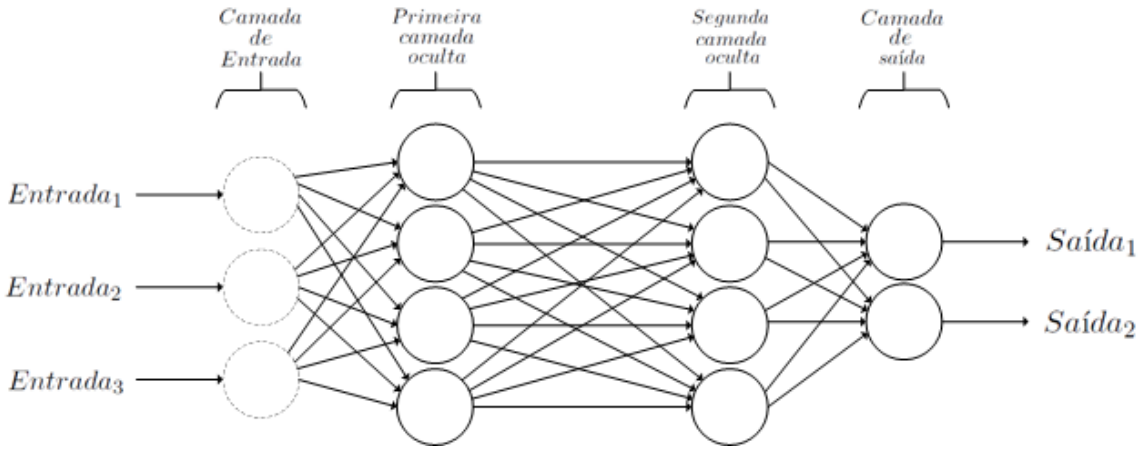

Figura 3 – Exemplo de uma rede neural artificial Perceptron com múltiplas camadas. A rede apresenta 3 neurônios na camada de entrada, 2 camadas ocultas com 3 neurônios cada e uma 1 camada de saída com 2 neurônios. Autor: Próprio.

Um neurônio artificial retrata uma abstração simplificada do neurônio biológico e representa a estrutura básica para criação de RNAs. A estrutura de um neurônio k apresenta n entradas em que cada uma apresenta um peso w. Além das entradas, cada neurônio possui uma entrada adicional com viés b. Considerando $x_{1...n}$ os valores de entrada de neurônio artificial, é realizada a soma ponderada dos valores de entrada com os pesos previamente definidos e posterior adição de viés. Após processamento, o resultado obtido é submetido a uma função de ativação φ obtendo-se a saída $\hat{y}$. A figura 4

apresenta a anatomia de uma neurônio artificial.

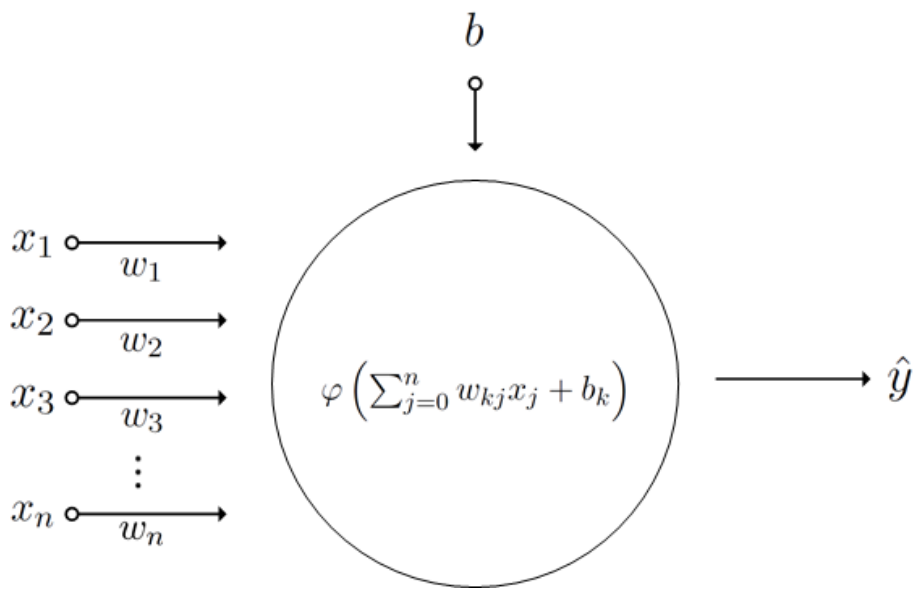

Figura 4 – Anatomia de um neurônio artificial. Autor: Próprio.

1.6.1 Redes neurais recorrentes

As redes neurais recorrentes (RNN) possuem um comportamento diferenciado quando comparadas à NN-MLP: As RNNs apresentam ao menos um ciclo de *feedback* na rede [Haykin et al., 2009]. Um ciclo de *feedback* em RNNs consiste na realimentação dos neurônios da camada de entrada com as saídas obtidas nos neurônios das camadas de saída. A realimentação, esta que pode ocorrer também no neurônio da camada de saída, permite explorar características dinâmicas do modelo e características temporais.

As RNNs possuem a capacidade de aprender a dependência de sinais de forma efetiva para intervalos breves de tempo [Duda et al., 2012]. A deficiência presente nas RNNs para o aprendizado de longas cadeias temporais de sinais se deve a ocorrência do fenômeno denominado *vanishing gradient* [Hochreiter, 1998]. De forma a melhor lidar com *vanishing gradient*, Hochreiter and Schmidhuber [1997] propôs um novo modelo arquitetural para RNNs, denominado “Long Short-Term Memory”(LSTM).

1.6.2 Redes neurais convolucionais

A especialização das NN-MLP denominada redes neurais convolucionais (CNN) foi motivada no trabalho pioneiro realizado no campo de pesquisa neurobiológico por Hubel and Wiesel [1962]. As CNNs combinam três características arquiteturais com o propósito de garantir grau de desvio, escala e invariância de distorção: campos receptores locais, compartilhamento de pesos e subamostragem espacial ou temporal [LeCun et al., 1998].

Os campos receptores locais são inspirados no funcionamento dos sensores visuais de mamíferos. Dessa forma, podemos considerar um campo receptor como um conjunto de neurônios de camada de entrada da rede neural conectados a um neurônio da camada oculta. O neurônio presente na camada oculta atua como o filtro local, também denominado como *kernel*. A possibilidade de compartilhamento de pesos entre os neurônios de uma mesma camada permite que o modelo resultante apresente uma maior capacidade de generalização visto a redução da capacidade de aprendizagem. [Haykin et al., 2009]. A subamostragem ocorre após a realização da convolução de tal forma a reduzir o mapa de características obtidas e também colabora com a melhoria da camada de generalização do modelo.

1.7- Árvores de decisão

O uso de árvores de decisão permitem a criação de modelos de classificação com maior compreensibilidade quando comparado a outros modelos como as RNAs. Essa razão se deve a natureza do algoritmo em si, que se assemelha ao raciocínio humano, sendo composto por uma sucessão de testes simples em que, tipicamente, compara-se um atributo a um intervalo ou conjunto de valores possíveis [Kotsiantis, 2013].

Uma das implementações mais populares atualmente é a $C4.5$ [Quinlan, 1993] por meio da implementação em código aberto na linguagem Java, a $J48$, disponível no software Weka [Witten et al., 2016].

1.8- Florestas Aleatórias

A floresta aleatória é um algoritmo de aprendizado supervisionado em que consiste na combinação de classificadores com a estrutura de árvores de decisão que dependem de entradas aleatórias distribuídas de forma uniforme [Breiman, 2001]. Uma vez que as árvores são criadas, cada árvore contribui com um voto. Ao término da votação é definida a classe mais popular.

Uma das vantagens do uso de florestas aleatórias é a sua capacidade efetiva de generalização. Por consequência, não estão sujeitas ao sobreajuste. Esta propriedade se justifica na Lei dos Grandes Números (LGN). A LGN é um teorema fundamental da lei da probabilidade que busca descrever o resultado de um experimento realizado diversas vezes. Sendo assim, quanto mais experimentos forem realizados, a probabilidade da média aritmética dos resultados será cada vez mais próxima da probabilidade real [Ross, 1997].

1.9- K vizinhos mais próximos

Dado um documento d, o sistema busca identificar os K vizinhos mais próximos entre todos os documentos D conhecidos e classificados. Para atingir tal objetivo, cada documento é representado como um vetor com N características em um espaço multidimensional. A partir de então, é verificada a similaridade entre o vetor que representa o documento d e todos os vetores de documentos D. Para o cálculo da similaridade, uma função comumente aplicada é a distância euclidiana. Considerando x e y a representação vetorial de 2 documentos compostos por N características de tal forma que x = $x_1...x_N$ e y = $y_1...y_N$, a distância euclidiana d_E pode ser calculada conforme a equação 6.

$$d_E(x, y) = \sqrt{\sum_{i=1}^{N} (x_i - y_i)^2}. \tag{6}$$

Para a identificação da classe de um documento d é considerada a maior soma dos documentos de uma mesma classe entre os K mais próximos.

1.10- Máquina de vetores de suporte para uma única classe

Em alguns cenários, categorizar dados para então submeter a um algoritmo de aprendizado supervisionado pode ser uma tarefa cara, complexa e que requira demasiado tempo para sua realização [Haykin et al., 2009]. Nesse cenário, considera-se a possibilidade do uso de algoritmos de aprendizado semi-supervisionado. Dado um conjunto de dados $\{\mathbf{x}_i\}_{i=1}^{N}$ em que x denota o elemento do conjunto e N representa o tamanho de conjunto, pode-se representá-lo em dois subconjuntos distintos: O primeiro subconjunto $\{\mathbf{x}_i\}_{i=1}^{l}$ com o seu conjunto de rótulos $\{d_i\}_{i=1}^{l}$ correspondente enquanto o segundo subconjunto $\{\mathbf{X}_i\}_{i=l+1}^{N}$ não apresenta rótulos associados.

Máquinas de vetores de suporte, como apresentadas anteriormente, são conhecidas pelo bom desempenho em tarefas de classificação binária, por exemplo, uma classe "positiva" e outra "negativa" considerando dados com alta dimensionalidade e, com isso, se apresenta como uma alternativa a ser considerada em tarefas de classificação de textos.

O desenvolvimento de abordagens com o algoritmo SVM para uma única classe surgiu como uma alternativa para identificação de anomalias [Schölkopf et al., 2000]. Conforme detalhado em sua proposta, dado um conjunto de dados $\{\mathbf{x}_i\}_{i=1}^{N}$ com $\mathbf{n}$ características e distribuição de probabilidade P em um espaço $\mathbf{R}^n$, deseja-se encontrar o subconjunto S de tal forma que a probabilidade de um ponto de teste presente em P fique fora do subconjunto S seja igual a priori relativa à $v \in (0, 1)$. Como resultado, busca-se encontrar a seguinte função f de forma que:

$$f(x) = \begin{cases} +1 & \text{se } x \in S \\ -1 & \text{se } x \in \overline{S} \end{cases} \tag{7}$$

Conforme observado na equação 7, deseja-se retornar um resultado positivo para todos os vetores dentro do subconjunto S — região de maior densidade de probabilidade. Para os demais, retorna-se um valor negativo.

2- Trabalhos Relacionados

O presente capítulo tem por finalidade apresentar todo o planejamento de busca e pesquisa realizados até o momento. Primeiramente, foram realizadas pesquisas primeiramente em alguns dos principais canais de publicação (ScienceDirect, IEEE Xplore, ACM Digital Library e SpringerLink) e posteriormente no indexador Google Scholar. A proposta para expandir a busca e considerar o indexador Google Scholar se justifica em dois pontos: 1) busca de trabalhos presentes na literatura nacional; 2) Trabalhos realizados para a competição PAN-2012 para identificação de predadores sexuais em conversas virtuais que não tenham sido publicados nos canais citados previamente. Por conta de não existir um termo único para a tarefa de identificação de atividade predatória sexual na Internet, a ausência de uma terminologia considerada para o predador sexual fica a critério de cada autor. Nesse contexto, foi considerada uma *string* de busca mais abrangente para a composição de um mapa sistemático. Dessa maneira, esse capítulo se encontra estruturado da seguinte forma: na Seção 2.1 é apresentada a pesquisa realizada e criação de um mapa sistemático para a organização dos resultados, na Seção 3 é apresentado o trabalho e iniciativa que tem disponibilizado os dados que servirão de base para as pesquisas e experimentos futuros e por fim, a Seção 2.2 apresenta os trabalhos que obtiveram os melhores resultados e o estado da arte na tarefa de classificação de conversas com conteúdo predatório. Vale ressaltar que, alguns dos trabalhos que aqui serão apresentados também se encontram detalhados em artigos publicados ao longo da realização da presente pesquisa.

2.1- Mapa Sistemático

A criação do mapa sistemático foi composta por três estágios: No primeiro estágio, foram realizadas buscas nos principais canais de publicação citados no parágrafo anterior. As buscas foram realizadas usando os seguintes termos: (“Sexual” AND (“Predator” OR “Offenders”) AND (“Identification” OR “Detection”) AND (“Internet” OR “Online”) AND

(“Conversation” OR “Chat”)) . Para cada um dos trabalhos encontrados foi realizada uma classificação perante critérios de inclusão (CI) e critérios de exclusão (CE) após uma avaliação do título dos trabalhos. A tabela 3 detalha todos os critérios considerados na avaliação preliminar de um trabalho.

Tabela 3 – Critério de inclusão e exclusão considerados para a elaboração do mapa sistemático para pesquisa nos principais canais de publicação

Código	Descrição
CI1	Relacionado ao tema da pesquisa (Técnico)
CI2	Relacionado ao tema da pesquisa (Psicológico)
CE1	Não está escrito em inglês
CE2	Versão anterior de um trabalho já considerado
CE3	Não é um artigo completo, dissertação ou tese
CE4	Trabalho inacessível
CE5	Trabalho fracamente relacionado com a pesquisa
CE6	Trabalho não relacionado com a pesquisa
CE7	Trabalho publicado antes de 2012

Após a realização das buscas esperadas no primeiro estágio foram selecionados um total de 202 trabalhos. Como parte do segundo estágio, os trabalhos foram submetidos a uma segunda revisão em que foi a análise foi expandida para a revisão do resumo. O segundo estágio resultou na seleção de 27 trabalhos. Uma razão para a esse número final ter sido baixo foram o alto número de ocorrências de resultados nos canais ScienceDirect e SpringerLink que não apresentaram relação com o tema da pesquisa (CE6).

Por fim, o último estágio consistiu na leitura completa de todos os trabalhos. Após análise, foram considerados 17 trabalhos relacionados. Um ponto importante é que ao término do terceiro e último estágio não foram encontrados trabalhos na língua portuguesa ou desenvolvidos em centros de pesquisa brasileiros assim como artigos que estejam relacionados diretamente à competição PAN-2012. Para tal, foram realizadas duas buscas no indexador Google Scholar considerando os seguintes termos: (“Sexual” AND (“Predator” OR “Offenders”) AND (“Identification” OR “Detection”) AND (“Internet” OR “Online”) AND (“Conversation” OR “Chat”)) **AND “PAN-2012”** e (“aliciamento” AND “sexual”) AND “pedofilia” AND (“Identificação” OR “Detecção”) AND (“online” OR “internet”) AND “conversas” AND (“Crianças” OR “adolescentes”) . Ao término da busca foram encontrados 162 trabalhos. Assim como para os principais canais de publicação, foram realizados os mesmos procedimentos para análise dos resultados detalhados para cada estágio do mapa sistemático. No total, o presente trabalho considerou 9 trabalhos como base. Toda a pesquisa realizada assim como os resultados se encontram disponíveis na

Internet[1].

2.2- Identificação de atividade predatória sexual em conversas virtuais

Em Villatoro-Tello et al. [2012] o problema de classificação de conversas predatórias é decomposto em duas partes. Na primeira parte o autor busca descartar todas as conversas que não apresentam as características mais frequentes de uma atividade predatória sexual. Sendo assim, foram descartadas todas as conversas com as seguintes características: 1) Conversas com apenas um participante; 2) Conversas com menos de 6 mensagens por participante; 3) Conversas com sequencias longas de caracteres que não compreensíveis como uma frase que faça parte de uma conversa. Esse filtro permitiu não somente otimizar o uso de recursos computacionais como focar nos cenários mais propícios para que ocorra um aliciamento, aproximadamente 10% do conjunto de dados da competição PAN-2012. A segunda parte, responsável pela identificação do predador sexual dentre os participantes de uma conversa, fez uso de uma Rede Neural Perceptron com Múltiplas Camadas e representação binária. O resultado atingido (F_1 = 87,3%, $F_{0.5}$ = 93,4%) conferiu ao autor a primeira colocação na competição PAN-2012.

No trabalho de Bogdanova et al. [2014], buscou-se explorar características psicolinguísticas e comportamentais presente em conversas. Foram consideradas 3 fontes de dados distintas para comparação: O primeiro conjunto de dados foi criado a partir de conversas disponibilizadas no site PJ, o segundo conjunto apresenta apenas conversas variadas, denominado NPSChat [Forsythand and Martell, 2007] e, por último, o terceiro conjunto foi criado com as conversas com teor sexual porém não-predatórias extraídas do site Cybersex[2]. Ao aplicar o classificador SVM com o objetivo de distinguir conversas predatórias e de conversas com teor sexual porém não-predatórias foram obtidos resultados significantes (97% de acurácia). A relevância do conjunto de características fica mais evidente quando a mesma tarefa de classificação é realizada porém considerando apenas características léxicas em que o melhor resultado atingido foi 64% de acurácia.

No trabalho realizado por Cano et al. [2014] a estratégia adotada para identificação da atividade predatória sexual levou em consideração um dos modelos psicológicos que

[1] `https://github.com/leomrl/qualificacao/mapa`
[2] `http://web.archive.org/web/20040728084602/http://www.geocities.com/urgrl21f/`

explicam como o aliciamento é realizado na Internet [O'Connell, 2003]. Para cada estágio do aliciamento previsto no modelo, foram identificados padrões por meio de características léxicas, sintáticas[3], psicolinguísticas, polaridade dos sentimentos[4] contida nas mensagens enviadas, padrões no conteúdo das mensagens e no discurso. Para a extração das características léxicas o algoritmo BoW foi aplicado. A ferramenta LIWC [Pennebaker et al., 2001] permitiu a extração de características psicolinguísticas. Para uma melhor seleção das características psicolinguísticas das sentenças, foi determinado o ganho de informação para cada uma das características possíveis em cada fase do aliciamento, sendo selecionadas as 5 características mais relevantes. Para a criação do conjunto de dados foram consideradas 50 conversas predatórias disponibilizadas no site PJ e cada sentença contida nessas conversas passou por uma classificação perante as etapas de aliciamento do modelo psicológico citado. Os resultados obtidos com o classificador SVM se mostraram satisfatórios para o autor (F_1 = 85%), reconhecendo que características psicolinguísticas e presentes no discurso contribuem para a identificação dos estágios de aliciamento.

A tese apresentada por Ebrahimi [2016] buscou validar duas hipóteses: 1) É possível identificar conversas predatórias usando abordagens empregadas em detecção de anomalias; 2) O uso de arquiteturas de aprendizagem profunda para a classificação podem superar métodos aplicados no estado da arte dentro do domínio da pesquisa. Os experimentos foram realizados em dois conjuntos de dados: o conjunto de dados disponibilizado na competição PAN-2012 e um conjunto de dados privado disponibilizado pelo *Sûreté du Québec* (SQ). Para a validação da primeira hipótese, foi considerado o algoritmo Naïve Bayes como *baseline* e o algoritmo SVM para classificação binária. Para a identificação das conversas predatórias como anomalias foi considerado o algoritmo OC-SVM. Os resultados mais significativos foram encontrados no conjunto de dados SQ (F_1 = 97,4%), no entanto o autor considera o experimento realizado uma prova de conceito e apenas válido para comprovação da hipótese. No segundo experimento o uso de CNN se mostrou promissor (F_1 = 81.64%) quando comparado ao resultado obtido pelos algoritmos de classificação SVM (F_1 = 61.02%) e NN-MLP (F_1 = 79.96%). Um ponto que vale ressaltar neste trabalho é que ele busca validar a aplicação de algoritmos para a classificação no problema de identificação de atividade predatória sexual em conversas na Internet e não definir um novo estado da arte para o problema de identificação de

[3] `https://nlp.stanford.edu/software/tagger.shtml`
[4] `http://sentistrength.wlv.ac.uk/`

conversas predatórias.

Na primeira iniciativa documentada para estudo do comportamento predatório na comunicação em jogos *online* [Cheong and Jensen, 2015], o jogo *MovieStartPlanet*, cujo público-alvo são crianças e adolescentes entre 8 e 15 anos, disponibilizou-se três conjuntos de dados contendo a comunicação escrita de diferentes jogadores: mensagens de *status*, comentários em vídeos e postagens em fóruns, além de conversas públicas e privadas realizadas dentro da plataforma. Em dois dos conjuntos foram considerados apenas conteúdos não predatórios e o terceiro conjunto de dados foi criado a partir de conversas realizadas por 59 predadores sexuais. Alguns dos desafios para a classificação das conversas nesse contexto foram o vocabulário usado pelo público que apresenta um elevado uso de gírias, erros gramaticais e ortográficos além de sequencias digitadas sem sentido e a natureza da conversa realizada na plataforma que pode ser similar a usada pelo predador: conversas sobre namoro, estar solteiro, procurar por um(a) ou estar apaixonado pelo(a) namorado(a) assim como assuntos relacionados à família. De forma a lidar com esse cenário, foi considerada uma combinação de características léxicas, sentimentais e comportamentais. Os resultados obtidos (F_1 = 78%, $F_{0.5}$ = 86%) foram considerados promissores tendo em vista a natureza dos dados.

O uso de quantificadores da teoria da informação também foi considerado em tarefas de classificação de conversas predatórias. Em trabalho recente, Postal et al. [2017] fez uso de dois quantificadores: a entropia de Shannon e a divergência de Jensen-Shannon. A principal motivação é a disposição de recursos computacionais reduzidos em dispositivos móveis que torna proibitivo o uso de algoritmos para geração de características léxicas como o BoW. O conjunto de dados da competição PAN-2012 é considerado, no entanto, como primeira tarefa de pré-processamento, o conjunto é balanceado. Os melhores resultados foram obtidos (F_1 = 90%) combinando o uso de quantificadores com o algoritmo *Naive Bayes* (NB). O ganho de desempenho de 72,9% no tempo de execução quando comparado ao algoritmo BoW se apresentou como uma alternativa para a uso em dispositivos móveis.

O trabalho realizado por Cardei and Rebedea [2017], fez uso da mesma estratégia explanada em Villatoro-Tello et al. [2012], considerando dois estágios para identificação do predador sexual. No primeiro estágio, responsável pela identificação de conversas predatórias, foi considerado o uso de características léxicas, por meio do uso do algoritmo BoW, e características comportamentais que reflitam como o predador atua em uma

conversa. Para a tarefa de classificação dessas características foi aplicado o SVM obtendo resultados que superam o encontrado por Villatoro-Tello et al. [2012] na competição PAN-2012 ($F_{0.5}$ = 93,8%). No segundo estágio, em que se busca identificar o predador sexual em uma conversa, é feito o uso de *Florestas Aleatórias*. Os resultados encontrados (*acurácia* = 100%,*abrangência* = 81.8%, $F_{0.5}$ = 95.7%, F_1 = 89.9%) superam os encontrados na competição PAN-2012.

Recentemente, Monroy et al. [2018] define um modelo de múltiplas perspectivas para representação de documentos. A intuição por trás da proposta se baseia em que, a medida que novas palavras são adicionadas a um texto novas perspectivas serão obtidas e, dada a semântica presente no texto, permitindo que palavras apresentem diferentes níveis de relevância no texto. Para a implementação da proposta é feito o uso de *Bag of Centroids* (BoC) e representação vetorial de palavras. Para efeitos de validação do modelo, são considerados como *baseline* os algoritmos LSA e LDA, usados em tarefas de modelagem de tópicos e também foi feito o uso dos algoritmos BoW e TF-IDF por serem tipicamente empregados em tarefas de classificação de textos. Os conjuntos de dados da competição PAN-2012 e o conjunto de dados da competição *eRisk 2017*[5] com textos que apresentam teor depressivo foram considerados para a validação do modelo. As conversas presentes no conjunto de dados da competição PAN-2012 foram segmentadas em 10 partes e analisadas de forma incremental. Ao final do experimento foi o resultado obtido ($F_{0.5}$ = 97,4%) superou o estado da arte quanto proposta a identificação antecipada de atividade predatória sexual em conversas e os resultados da competição PAN-2012.

Em Liu et al. [2017] é feito o uso de 3 tipos de redes neurais. Uma combinação das arquiteturas de redes neurais LSTM e RNN é aplicada com o propósito de explorar a relação entre os termos de uma sentença. O último estado da camada oculta da rede é usada como entrada de uma outra combinação LSTM-RNN com duas camadas com o objetivo de aprender a relação entre as sentenças de uma dada conversa. O resultado da segunda rede neural é considerado para a identificação de sentimentos com uso da biblioteca de representação vetorial de palavras *Fasttext*[6] com o objetivo de diferenciar em uma dada conversa o perfil do predador de uma vítima. O modelo proposto foi testado em dois conjuntos de dados. Primeiramente, o conjunto de dados da competição PAN-2012 é considerado para as duas tarefas disponibilizadas: a identificação de conversas predatórias e identificação do predador em uma dada conversa. O segundo conjunto

[5] `http://early.irlab.org/2017/index.html`
[6] `https://fasttext.cc/`

de dados, denominado *Large Movie Review Dataset*[7] foi considerado para validação da etapa de identificação de sentimentos do classificador. Os resultados apresentados para a tarefa de identificação de conversas predatórias (*acurácia* = 98,3%, *precisão* = 98,4%, *abrangência* = 98,2%, F_1 = 98,3%, $F_{0.5}$ = 98,4%) são considerados o estado da arte. A última etapa do classificador, responsável por identificar o predador em conversas obteve resultados superiores ao da competição PAN-2012 e muito próximos ao obtido por Cardei and Rebedea [2017] (*acurácia* = 100%,*abrangência* = 81.1%, $F_{0.5}$ = 95.5%, F_1 = 89.5%).

A seguir, na tabela 4 são apresentados os trabalhos com resultados mais significativos e considerados candidatos ao estado da arte na língua portuguesa assim como as principais características. Um ponto importante, vale ressaltar que o trabalho de Bogdanova et al. [2014] não apresentou resultados com a medida F_1 mas sim com a *Acurácia*. Dessa forma, foi adicionada a marcação "$-x-$" no lugar do valor esperado.

[7] `https://ai.stanford.edu/~amaas/data/sentiment/`

Tabela 4 – Resumo dos trabalhos relacionados apresentados no capítulo

Autores	Conjunto de dados	Características	Método	Resultados (F1)
Villatoro-Tello et al. [2012]	PAN-2012	Vetores de características	NN-MLP (Peso Binário)	$87,3\%$
Bogdanova et al. [2014]	*Perverted-Justice* NPSChat Cybersex	Psicolinguísticas Comportamentais	SVM	$-x-$
Cano et al. [2014]	*Perverted-Justice*	BoW+LIWC Comportamentais	SVM	85%
Ebrahimi [2016]	PAN-2012 SQ	Termos mais frequentes	CNN	80%
Cheong and Jensen [2015]	*MovieStarPlanet*	BoW Sentimentais Comportamentais	NN-MLP	78%
Postal et al. [2017]	PAN-2012	H+JSD	Naïve Bayes	90%
Cardei and Rebedea [2017]	PAN-2012	BoW Comportamentais	SVM+RD	$89,9\%$
Monroy et al. [2018]	PAN-2012 eRisk 2017	Unigramas	MulR + TVT	$97,4\%$
Liu et al. [2017]	PAN-2012 Large Movie Review Dataset	TF-IDF	LSTM+RNN+Fasttext	$98,3\%$

3- Conjunto de dados

A disponibilização da versão final do conjunto de conversas na língua portuguesa com predadores sexuais convictos se encontra em andamento e está sendo disponibilizado por meio de uma parceria acadêmica entre o Ministério Público Federal de São Paulo (MPF-SP) e o Centro Universitário da Fundação Educacional Inaciana (FEI). O conjunto de conversas também apresenta conversas não-predatórias. As conversas não-predatórias foram disponibilizadas por meio de uma parceria com a Universidade Federal de Minas Gerais (UFMG). As conversas preliminares disponibilizadas até o presente momento [Andrijauskas et al., 2017] se encontram disponíveis ao público por meio de link provisório[1].

Um impeditivo considerado para a divulgação das conversas predatórias era e presença de informações sensíveis que pudessem permitir a identificação tanto do predador sexual quanto das vítimas ou demais participantes. Sendo assim, foi realizado um pré-processamento das conversas visando omitir qualquer informação que permita identificar tanto o predador sexual quando a vítima. Esse pré-processamento consistiu em inserir marcações específicas no lugar das informações sensíveis de forma a caracterizar o teor da informação trocada.

Tabela 5 – Marcações para preservação de identidade de predadores sexuais e vítimas.

Marcação	Teor da informação
>audio<	Mensagens de áudio enviadas e/ou recebidas
>emoticon<	Caracteres Emoji. (Os emoticons textuais foram preservados)
>foto<	Imagens enviadas e/ou recebidas
>local<	Nomes de ruas, bairro, cidade, estado, país ou nacionalidade
>nome<	Nomes ou apelidos
>telefone<	Números de telefones

Conforme observado na figura 5, os dados estão apresentados de forma similar ao formato usado na competição PAN-2012. No entanto, algumas informações não foram disponibilizadas como, por exemplo, o horário de envio das mensagens e o arquivo com a lista de participantes das conversas considerados predadores sexuais presentes nas

[1] https://github.com/Andrijauskas/Datasets-Conversas

conversas.

```
<conversa id="1">
  <linha num="1">
    <autor>709916bfe16ef8cdd6102dc5453f302f</autor>
    <mensagem>Voce deita com migo na cama pelada</mensagem>
  </linha>
  <linha num="2">
    <autor>13f27f55ef3622f4e987aac6a57b1ce8</autor>
    <mensagem>Nao posso durmi ai</mensagem>
  </linha>
  <linha num="3">
    <autor>709916bfe16ef8cdd6102dc5453f302f</autor>
    <mensagem>Nao e pra dumir e so fica com migo ate as 3 horas da tardi</mensagem>
  </linha>
  <linha num="4">
    <autor>709916bfe16ef8cdd6102dc5453f302f</autor>
    <mensagem>Ai eu levo voce em bora</mensagem>
  </linha>
  <linha num="5">
    <autor>13f27f55ef3622f4e987aac6a57b1ce8</autor>
    <mensagem>Tah</mensagem>
  </linha>
</conversa>
```

Figura 5 – Exemplo de conversa predatória disponibilizada pelo MPF-SP e FEI.

Desta forma, a Tabela 5 apresenta todas as marcações presentes no conjunto de dados.

A Tabela 6 apresenta as informações básicas sobre as conversas disponibilizadas para experimentação.

Tabela 6 – Volume de conversas disponibilizadas pelo FEI em parceria com o MPF-SP e UFMG.

Classe	Conversas	Usuários únicos
Predatória	*39*	*78*
Não-Predatória	*137*	*274*

3.1- Conjunto de dados “PAN-2012-BR”

Entende-se que o formato proposto, estudado e difundido na competição PAN-2012 facilitará estudos comparativos assim como a validação de modelos previamente propostos. Portanto, decidiu-se criar um conjunto de dados com formato análogo ao da

competição PAN-2012. Esse conjunto de dados recebeu o nome de “PAN-2012-BR”[2].

Como primeira tarefa para criação do conjunto de dados, foi realizada uma análise exploratória das conversas disponibilizadas por Andrijauskas et al. [2017]. Após análise individual das conversas predatórias foi possível identificar um erro de imputação dos dados em uma das conversas (*id* = 2). A conversa erroneamente apresenta dois predadores sexuais e uma vítima, porém o segundo predador sexual não apresenta relação com o contexto da discussão. Este erro foi ignorado, visto que ele não interfere até o presente momento nos objetivos definidos para o trabalho. Outro ponto identificado em conversas predatórias é o fato de que em nem todas existe a presença de uma criança ou adolescente. Em algumas conversas foi possível observar a presença de pais se passando pela criança ou adolescente. Em outras conversas predatórias é possível identificar a presença de um segundo criminoso ou amigo do predador sexual. Um ponto observado foi a presença de mais de uma codificação (ISO-8859-1 e UTF-8) nas conversas o que poderia implicar em resultados imprecisos na reprodução de trabalhos em ambiente UNIX. Sendo assim, para a construção do conjunto de dados “PAN-2012-BR”, foi necessária a execução de algumas tarefas de pré-processamento:

- Conversão de todos as conversas para codificação UTF-8.
- Substituição do uso de caracteres “>” e “<”, considerados ilegais[3], como delimitadores dos marcadores para preservação de identidade. Para o lugar foram considerados os caracteres “[” e “]”.
- De forma a permitir a construção de conjuntos de treinamento e teste e permitir a viabilidade de tarefas de classificação, fez-se necessário identificar entre os participantes das conversas predatórias quem é o predador sexual. Para atingir esse objetivo, cada conversa foi analisada individualmente e o *hash* de cada participante considerado predador sexual foi preenchido em um arquivo de texto à parte. O arquivo resultante dessa análise, denominado “*pan12-br-sexual-predator-identification-training-corpus-predators.txt*” apresentou um total de 39 predadores e segue estritamente o formato proposto na competição PAN-2012.
- Adequação das conversas ao mesmo formato de arquivo XML proposto pela competição PAN-2012.

[2] `https://github.com/leomrl/qualificacao/dados`
[3] `https://www.w3schools.com/xml/xml_syntax.asp`

Para uma melhor compreensão do conjunto recém criado e as conversas que o compõe, foi realizada a uma análise estatística descritiva baseada na proposta por Sokolova and Bobicev [2018]. Os resultados preliminares podem ser observados na tabela 7.

Tabela 7 – Análise estatística descritiva do conjunto de dados "PAN-2012-BR".

Característica	Classe predatória	Classe não-predatória	Total
Termos	2.370	195.403	197.773
Vocabulário	1.001	12.941	13.477
Número de mensagens	436	21.909	22.345
Termos por conversa (μ)	60,77	1.426,30	1.123,71
Termos por conversa (σ)	39,64	496,63	716,92
Termos por mensagem (μ)	5,44	8,93	8,86
Termos por mensagem (σ)	6,27	23,42	23,22
Hapax Legomena	690	6.199	6.597
Dis Legomena	137	2.102	2.160

Após análise dos resultados preliminares, observa-se uma diferença de volume de dados significante entre as classes disponíveis no conjunto de dados. A classe predatória apresenta conversas mais curtas, compostas por mensagens mais objetivas e uma maior riqueza do vocabulário empregado. Esta riqueza de vocabulário, representada pela razão entre os termos não repetidos e o total de termos, quando analisada, apresenta algumas características. Importante ressaltar que parte destas características estão identificadas na literatura [Olson et al., 2007] que estuda o comportamento do predador sexual na Internet:

- **Emprego de termos com erros de ortografia**: A presença acentuada dessa característica é justificada pela ocorrência de dois fenômenos: o primeiro, por conta da presença de crianças e/ou adolescentes na maioria das conversas, estas fazem uso de termos comumente encontrados na Internet (*"vx"*, *"tah"*, *"q"*, *"c"*, *"add"*, etc) e, não somente atrelado a esse ponto, também se remete a não aplicação da escrita correta dos termos (*"istudo"*, *"perginta"*, *"iscola"*, etc). Por outro lado, predadores sexuais também exploram esse vocabulário informal de forma a conversarem de forma similar com as vítimas (*"tete"*, *"tyambem"*, *"dexa"*, *"BRAXAR"*, *"MOTRE"*, etc). Essa estratégia é identificada na literatura [Olson et al., 2007] como uma forma de aproximação da vítima.

- **Exploração de caracteres repetidos**: Uma outra característica usada como forma de dissuasão por predadores sexuais é a repetição de caracteres, sejam estes em palavras ou explorados na pontuação (*"sim..."*, *"Blz..."*, *"Hum???"*, *",,,,,????"*, etc). No ciclo de aliciamento proposto por Olson et al. [2007] esse tipo de comunicação busca agir de forma coercitiva e/ou intimidatória de forma a se atingir o objetivo da atividade predatória sexual.

- **Uso de vocabulário com apelo sexual**: Nos estágios mais avançados de aliciamento entre predadores sexuais e vítimas é comum observar a presença de apelo sexual no teor das mensagens trocadas.

Tendo em vista quantificar a riqueza do vocabulário da classe predatória foi considerado o cálculo do percentual de termos raros (PTR). Entende-se por termos raros, aqueles que apresentam a frequência de uso abaixo de um limiar definido. Nesse contexto, o limiar pode ser definido de diferentes formas dependendo do domínio. Por exemplo, um valor fixo de ocorrências em um vocabulário [Ponomareva and Thelwall, 2012] ou a frequência inversa média das palavras [Sutskever et al., 2014]. O PTR pode ser definido conforme a Equação 8.

$$PTR = \frac{|\{t \in V | c(t) < 3\}|}{|V|} \tag{8}$$

Onde, V representa o vocabulário, $|V|$ é o tamanho do vocabulário, t significa o termo presente no vocabulário V e $c(t)$ é o número de ocorrências do termo t em um vocabulário V. No nosso cenário, são considerados termos raros os *Hapax Legomena* e *Dis Legomena* [Sokolova and Bobicev, 2018]. No total, 82,6% dos termos sem repetição são considerados raros.

Por outro lado, as conversas não-predatórias assim como as mensagens trocadas nestas conversas tendem a ser mais extensas e representam parte significativa do vocabulário total do conjunto de dados (96,4%). Uma hipótese para a presença das mensagens longas é a transcrição de mensagens de áudio realizadas na preparação dos dados [Andrijauskas et al., 2017]. Como implicação das características das conversas e mensagens não-predatórias trocadas, o total de termos presentes é 82 vezes maior quando comparado aos da classe predatória e uma baixa riqueza de vocabulário, ou seja, os termos do vocabulário repetem com uma maior frequência. A ocorrência deste fenômeno gera um impacto imediato em tarefas de classificação em que se considera a

eleição de termos mais frequentes como estratégia de seleção de características para geração de um modelo. Um possível impacto é o desbalanceamento do vocabulário considerado para a tarefa de classificação.

4- Experimentos

O presente capítulo tem por objetivo apresentar os experimentos realizados de tal forma a validar a hipótese proposta e definida na motivação do presente trabalho. Para a reprodução dos experimentos foi utilizado um computador com o processador Intel Core i9-9900k com 8 núcleos, 32GB de memória RAM 3200MHz e placa gráfica GeForce RTX 2080 Ti com 11Gb de memória. A distribuição Linux usada no ambiente foi o Ubuntu 18.04 AMD64.

Os experimentos descritos são oriundos de trabalhos realizados na literatura que apresentaram significativos no domínio de pesquisa da atividade predatória sexual na Internet. Para cada trabalho, serão apresentadas as hipóteses consideradas e os respectivos resultados encontrados quando considerado o conjunto de dados "PAN-2012-BR". O código necessário para a reprodução dos experimentos encontra-se disponível na Internet[1].

4.1- Trabalho: "Automatic Identification of Online Predators in Chat Logs by Anomaly Detection and Deep Learning" [Ebrahimi, 2016].

No primeiro trabalho considerado para reprodução, Ebrahimi [2016] considerou duas hipóteses como base para a pesquisa:

Hipótese 1 (H1): Considerando o desbalanceamento entre conversas predatórias e não-predatórias no mundo real, é possível considerar a identificação de conversas predatórias como um problema de uma única classe e obter resultados comparáveis à algoritmos de classificação binária.

Hipótese 2 (H2): O uso de algoritmos de aprendizagem profunda é capaz de atingir desempenho superior à algoritmos de classificação considerados estado da arte no domínio de identificação de atividade predatória sexual na Internet quando considerada a medida F_1.

[1] `https://github.com/leomrl/qualificacao/experimentos`

4.1.1 Hipótese 1

Para validação da H1, Ebrahimi [2016] implementou dois modelos distintos com o auxílio da ferramenta *RapidMiner*[2]. Uma facilidade obtida com o uso da ferramenta é a possibilidade de configurar e executar modelos preditivos com o auxílio de uma interface gráfica. O primeiro modelo, um classificador binário, fez uso do algoritmo TF-IDF para extração das características mais relevantes em conjunto com o algoritmo SVM.

Seguindo a proposta do autor, que fez uso dos conjuntos de treinamento e teste disponibilizados pela competição PAN-2012 em experimentos separados, decidiu-se por seguir abordagem similar, criando dois subconjuntos do conjunto de dados "PAN-2012-BR" com proporção aproximada aos usados no experimento original. O primeiro com 70% do total de conversas de forma, denominado "Subconjunto 1" e o restante dos dados em um subconjunto identificado como "Subconjunto 2". Para a avaliação do modelo foi considerada a estratégia de validação cruzada considerando 10 grupos. A tabela 8 apresenta os resultados obtidos após o treinamento do modelo com o conjunto de dados "PAN-2012-BR" enquanto as tabelas 9 e 10 apresentam as matrizes de confusão obtidas a partir da execução do algoritmo SVM.

Conjunto de dados	**Acurácia**	**Precisão**	**Abrangência**	F_1
Subconjunto 1	97,54%	96,94%	100%	98,45%
Subconjunto 2	87,04%	85,71%	100%	92,31%

Tabela 8 – Resultados obtidos com o primeiro modelo, feito o uso dos algoritmos TF-IDF e SVM e uso do conjunto de dados "PAN-2012-BR"

Tabela 9 – Matriz de confusão referente aos resultados obtidos com o Subconjunto 1

		Predito	
		Positivo	Negativo
Atual	Positivo	24	3
	Negativo	0	95

Tabela 10 – Matriz de confusão referente aos resultados obtidos com o Subconjunto 2

		Predito	
		Positivo	Negativo
Atual	Positivo	7	5
	Negativo	0	42

Considerando os resultados do experimentos com os algoritmos TF-IDF e SVM, foi realizado um terceiro experimento com o algoritmo OC-SVM. No experimento original, o qual se obteve os resultados significativos, é realizado pré-processamento, consistindo

[2]https://rapidminer.com/

nas seguintes tarefas: diminuição do texto das conversas para minúsculo e remoção de ruídos, como por exemplo, marcações de horário. Após pré-processamento, as características são geradas por meio de uma combinação dos algoritmos TF-IDF e BoW, mais especificamente bigramas. Seguindo o experimento original e realizando o treinamento do modelo considerando o conjunto de dados "PAN-2012-BR", não foi possível identificar nenhuma conversa predatória sexual (0% de acurácia).

Diante do cenário encontrado, foi realizada uma alteração na estratégia inicialmente proposta, considerando uni-gramas para geração das características. A fim de melhor explorar o hiperparâmetro ν, responsável pela definição das fronteiras que definem o número de vetores de suporte, foram testados todos os valores no intervalo entre 0.001 e 0.999. O melhor resultado alcançado com essa estratégia foi o valor de 85,36% de acurácia para o conjunto denominado "Subconjunto 1" e 73,95% de acurácia em "Subconjunto 2" quando o parâmetro ν apresentou o valor de 0,19.

4.1.2 Hipótese 2

A validação da segunda hipótese consiste na reprodução da arquitetura da CNN especificada por Ebrahimi [2016] no conjunto de dados recém criado "PAN-2012-BR". Para a reprodução do experimento foi considerada a biblioteca conText v4[3], que implementa uma especialização do algoritmo CNN que considera a ordem das palavras [Johnson and Zhang, 2015]. Os *scripts* contendo os parâmetros para montagem e configuração da CNN foram disponibilizados pelo autor. Para a execução apropriada do experimento foram necessárias tarefas de pré-processamento específicas, conforme pode ser observado na figura 6.

Para o treinamento e teste da CNN foram utilizados os mesmos hiperparâmetros e o pré-processamento considerado no trabalho considerado como referência [Ebrahimi, 2016]: 2000 neurônios para a camada de entrada, 3 regiões, regularização L2 = 10^{-4}, taxa de *Dropout* = 50% , função de perda quadrática, função de ativação *ReLU* e Kernel Linear. Conforme detalhado previamente no pré-processamento dos dados para posterior uso na biblioteca conText v4, cada conversa foi considerada uma característica e todas

[3] `http://riejohnson.com/cnn_download.html`

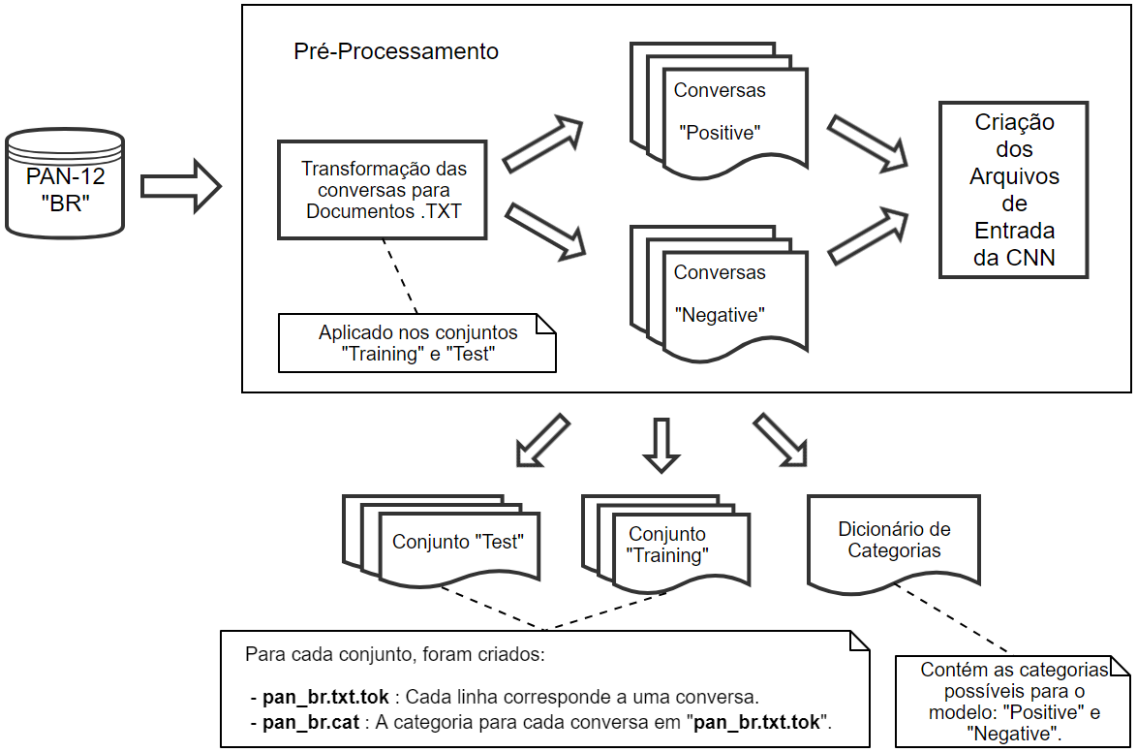

Figura 6 – Preparação dos dados para posterior uso na biblioteca conText v4: 1) Extração das mensagens das conversas para arquivos de texto, classificando-as em diretórios distintos mediante ocorrência de atividade predatória sexual (”Positive”) ou não (”Negative”). 2) Criação do dicionário de categorias: arquivo de texto contendo para cada linha uma categoria esperada na classificação. 3) Por fim, para cada conjunto criado, são criados dois arquivos: 1 arquivo com extensão *tok* contendo todas as conversas, de forma que cada linha do arquivo contenha todos os *tokens* de uma conversa e 1 arquivo com extensão *tok* em que é informada a categoria correspondente da respectiva linha no arquivo *tok*.

foram convertidas para minúsculo e para codificação UTF-8. Na fase de treinamento, foram consideradas as 5.000 palavras com maior ocorrência nas conversas, 100 épocas e decaimento de peso. Nos demais hiperparâmetros, foram considerados os valores padrão da biblioteca. A arquitetura proposta pelo autor pode ser observada na figura 7.

Os experimentos realizados consideraram duas distribuições dos dados: 70% dos dados para realizar o treinamento e 30% para testes, abordagem esta orientada a como modelos de aprendizado de máquina são desenvolvidos e, seguindo a metodologia disposta na competição PAN-2012 em que 30% do total de dados foi disponibilizado como treinamento de tal forma que fosse possível conhecer os dados e realizar experimentos e então submetê-los ao conjunto de testes, este composto pelos 70% dos dados restantes.

Como primeiro experimento, foi considerada a arquitetura de CNN proposta de

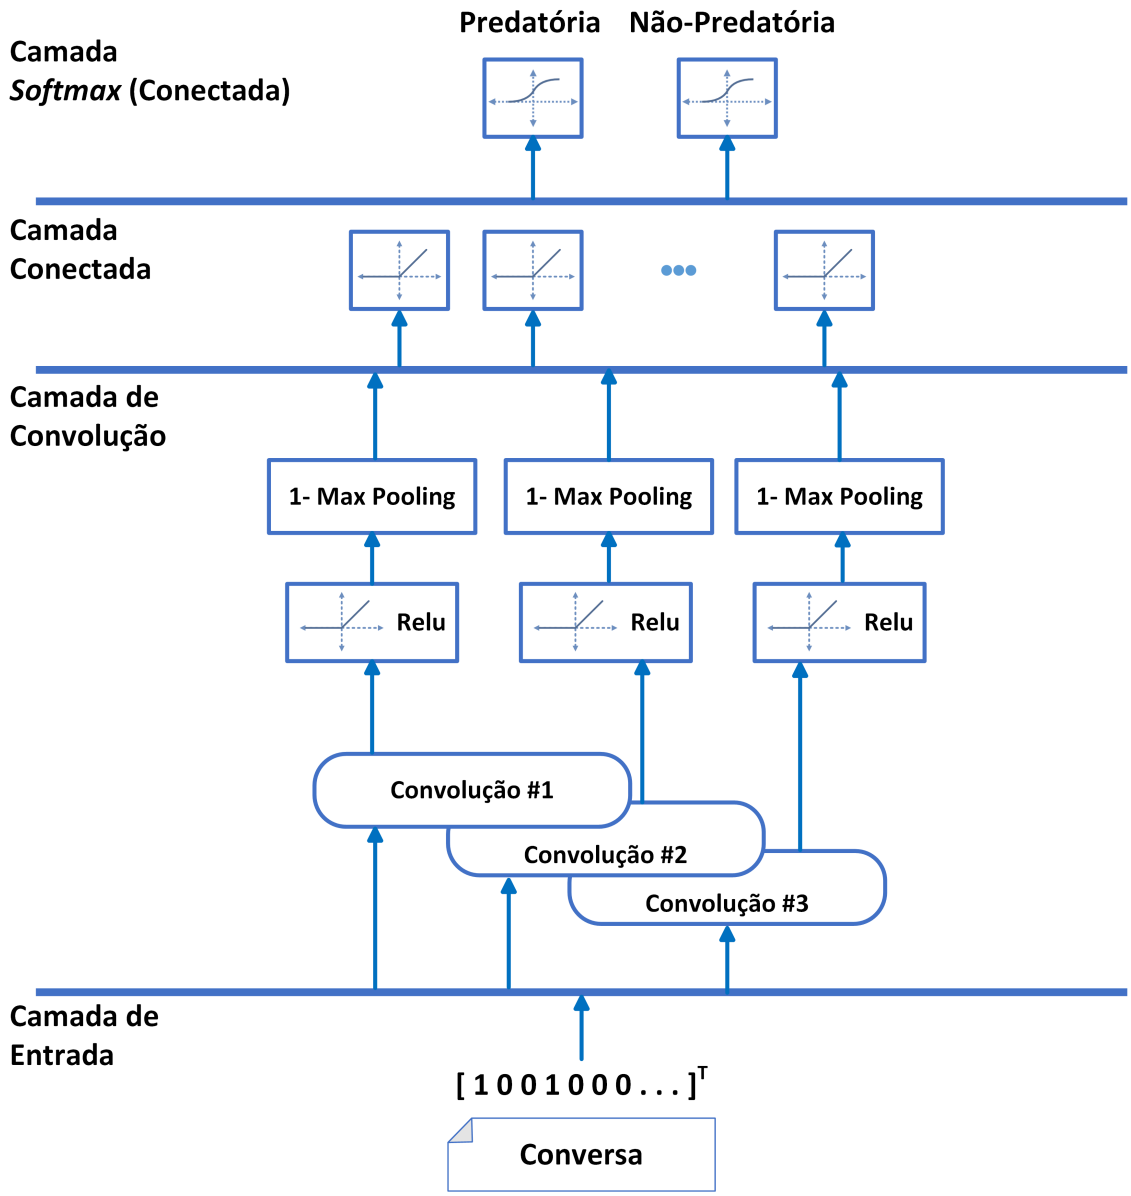

Figura 7 – Adaptação para arquitetura de CNN reproduzida nos experimentos presente em Ebrahimi [2016]. Autor: Próprio.

Ebrahimi [2016] e os mesmos hiperparâmetros. A seleção de características também seguiu as mesmas especificadas pelo autor, sendo assim, foram considerados 5.000 termos mais frequentes no conjunto de treinamento. Após o treinamento do modelo, considerando ambas as distribuições de dados previamente explanadas, foram obtidos resultados significativos conforme pode ser observado na tabela 11. O modelo "CNN-70-30-5000-SGD" apresentou o melhor desempenho quando comparado aos demais obtendo 100% na medida F_1. De forma a explorar os resultados inicialmente obtidos, foi aplicado o algoritmo K-Fold estratificado (K = 5), no entanto, os resultados não apresentaram

mudança significativa. A partir de então, foi realizado um segundo experimento com o propósito de explorar o comportamento dos modelos obtidos quando alterados a dimensão do conjunto de características selecionadas, o algoritmo de otimização para convergência do modelo e ainda considerando as duas distribuições para conjuntos de treinamento e testes aplicada.

Os resultados encontrados e detalhados na tabela 12 apresentaram similares e próximos ao primeiro experimento, sendo assim, foi feita uma análise em maior profundidade em cima dos dados disponibilizados pela biblioteca conText v4. A biblioteca conText v4 disponibiliza a taxa de erro a cada época treinada. Sendo assim, é possível medir a acurácia do modelo ao longo das épocas. Para cada modelo testado foi representado o histórico de acurácia, compreendidos entre as imagens 8 e 21 e as respectivas matrizes de confusão, compreendidas entre as tabelas 13 e 26.

Ao analisar os modelos que consideraram o o algoritmo de otimização SGD, é possível observar que em todos os modelos foi atingida acurácia acima dos 90% antes da 40ª época. Todos os modelos obtiveram resultados altos considerando a métrica de acurácia, em algumas simulações atingiu-se 100% de acurácia. Os modelos em que a distribuição aplicada nos dados considerou 30% de dados para treinamento e 70% para testes não foram capaz de reconhecer uma das conversas considerada predatória, atingindo 99% de acurácia conforme pode ser observado na tabela 15. Também entende-se que, nesse cenário, ocorreu sobreajuste, dado a queda de desempenho, descrita na figura 10.

Por outro lado, os modelos que fizeram uso do algoritmo de otimização RMSProp, embora também tivessem apresentado resultados significantes, apresentaram um comportamento diferente durante o treinamento. Ao segmentar a análise e considerar apenas os modelos em que se foi empregado 30% dos dados para treinamento e o restante para testes, foi observado um fenômeno ao longo das épocas interpretado como uma dificuldade de convergência do modelo por conta de uma taxa de aprendizado alta. Além dos intervalos com alta variabilidade da acurácia do modelo, essa conclusão obtida por conta do modelo após a épocas 80 e 90. A estratégia de decaimento de peso, ou seja, redução da taxa de aprendizado de forma que seja atingida uma convergência do modelo está configurada para correr nestas épocas. Analisando os modelos restantes que fizeram uso do algoritmo de otimização RMSProp, foi possível identificar uma dificuldade no reconhecimento de conversas predatórias, conforme detalhado nas tabelas 21, 23 e 26.

Outro ponto importante, vale citar que também foi observado uma oscilação significativa da acurácia do modelo ao longo das épocas o que fez levantar-se a possibilidade de ajuste da taxa de aprendizado do modelo.

O histórico de acurácia ao longo das épocas em todos os modelos remete a questões sobre a complexidade do conjunto de dados. Conforme foi observado na seção 3.1, o atual conjunto de dados apresenta um desbalanceamento, não somente pelo número de conversas não-predatórias assim como a quantidade de termos presentes nestas conversas. Esse desbalanceamento impacta a seleção de termos frequentes e por consequência permite o modelo atingir uma maior capacidade de classificação de conversas não-predatórias.

Tabela 11 – Resultados do primeiro experimento com o "PAN-2012-BR" considerando os mesmos hiperparâmetros utilizados no trabalho proposto por Ebrahimi [2016].

Modelo	**Acurácia**	**Precisão**	**Abrangência**	F_1	$F_{0.5}$
CNN-30-70-5000-SGD	99%	100%	99%	99%	99%
CNN-70-30-5000-SGD	100%	100%	100%	100%	100%
CNN-5-Fold-5000-SGD	99%	100%	99%	99%	99%

Tabela 12 – Resultados do segundo experimento considerando variações nas distribuições dos conjunto de treinamento e teste, otimizadores RMSProp e SGD e diferentes tamanhos de vocabulário para treinamento.

Modelo	**Acurácia**	**Precisão**	**Abrangência**	F_1	$F_{0.5}$
CNN-30-70-1000-SGD	99%	100%	99%	99%	99%
CNN-70-30-1000-SGD	100%	100%	100%	100%	100%
CNN-30-70-10000-SGD	99%	100%	99%	99%	99%
CNN-70-30-10000-SGD	100%	100%	100%	100%	100%
CNN-70-30-15000-SGD	100%	100%	100%	100%	100%
CNN-30-70-1000-RMSProp	99%	98%	100%	99%	99%
CNN-70-30-1000-RMSProp	92%	91%	100%	95%	92%
CNN-30-70-5000-RMSProp	100%	100%	100%	100%	100%
CNN-70-30-5000-RMSProp	94%	93%	100%	96%	94%
CNN-30-70-10000-RMSProp	99%	98%	100%	99%	99%
CNN-70-30-10000-RMSProp	92%	91%	100%	95%	92%
CNN-70-30-15000-RMSProp	92%	91%	100%	95%	92%

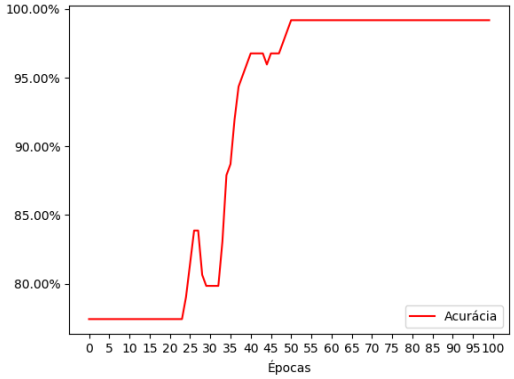

Figura 8 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-5000-SGD”

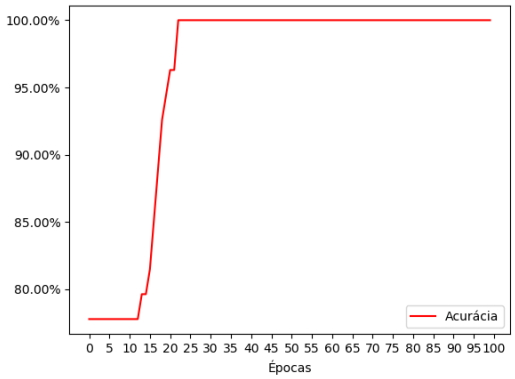

Figura 9 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-5000-SGD”

Tabela 13 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-5000-SGD”

		Predito	
		Positivo	Negativo
Atual	Positivo	28	1
	Negativo	0	95

Tabela 14 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-5000-SGD”

		Predito	
		Positivo	Negativo
Atual	Positivo	12	0
	Negativo	0	42

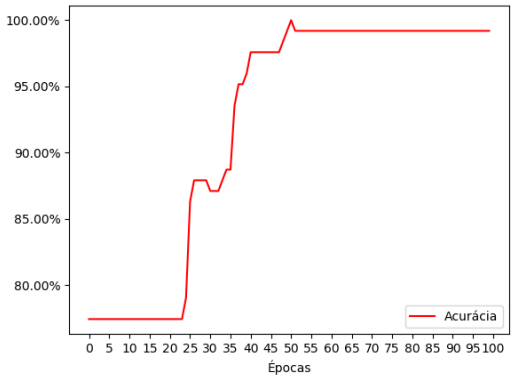

Figura 10 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-30-70-1000-SGD”

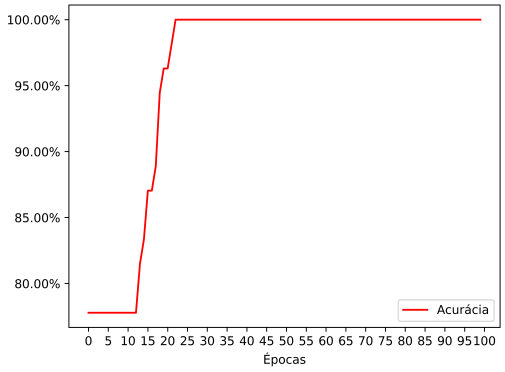

Figura 11 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-1000-SGD”

Tabela 15 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-30-70-1000-SGD”

		Predito	
		Positivo	Negativo
Atual	Positivo	28	1
	Negativo	0	95

Tabela 16 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-1000-SGD”

		Predito	
		Positivo	Negativo
Atual	Positivo	12	0
	Negativo	0	42

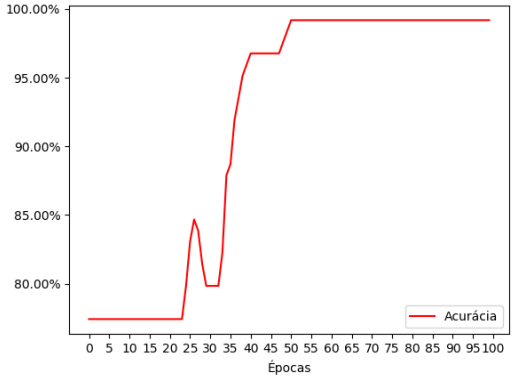

Figura 12 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-30-70-10000-SGD"

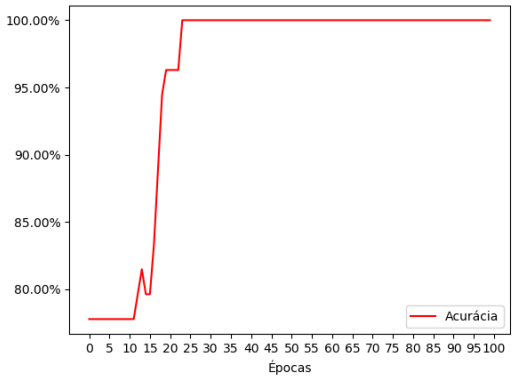

Figura 13 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-70-30-1000-SGD"

Tabela 17 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-30-70-10000-SGD"

		Predito	
		Positivo	Negativo
Atual	Positivo	28	1
	Negativo	0	95

Tabela 18 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-70-30-10000-SGD"

		Predito	
		Positivo	Negativo
Atual	Positivo	12	0
	Negativo	0	42

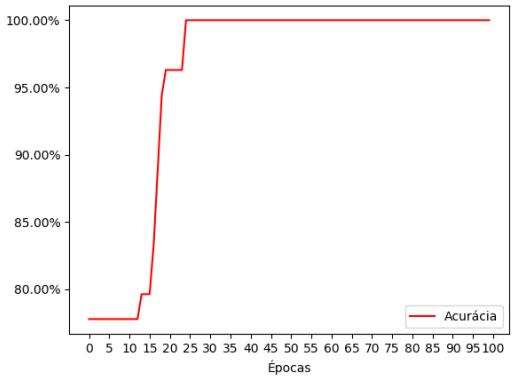

Figura 14 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-70-30-15000-SGD"

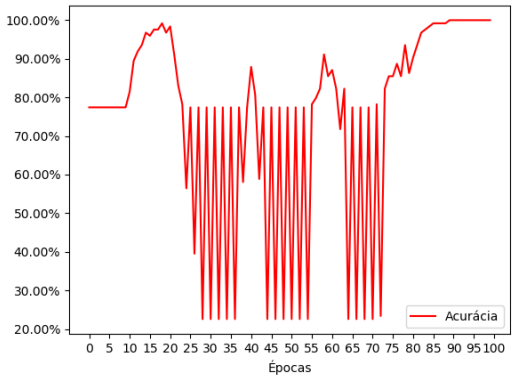

Figura 15 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-30-70-1000-RMSPROP"

Tabela 19 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-70-30-15000-SGD"

		Predito	
		Positivo	Negativo
Atual	Positivo	12	0
	Negativo	0	42

Tabela 20 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-30-70-1000-RMSPROP"

		Predito	
		Positivo	Negativo
Atual	Positivo	28	0
	Negativo	0	96

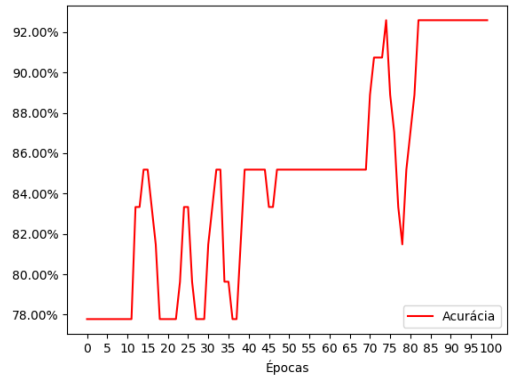

Figura 16 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-70-30-1000-RMSPROP"

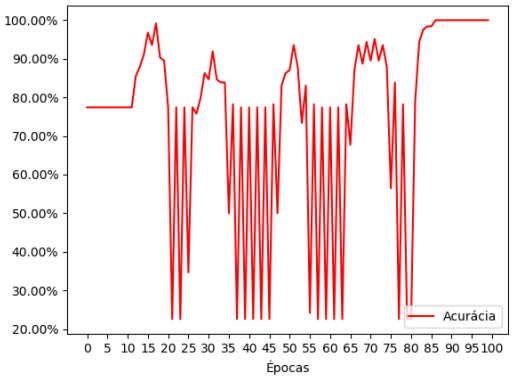

Figura 17 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-30-70-5000-RMSPROP"

Tabela 21 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-70-30-1000-RMSPROP"

		Predito	
		Positivo	Negativo
Atual	Positivo	8	4
	Negativo	0	42

Tabela 22 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-30-70-5000-RMSPROP"

		Predito	
		Positivo	Negativo
Atual	Positivo	28	0
	Negativo	0	96

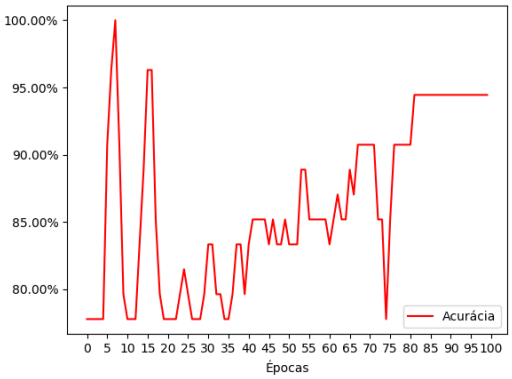

Figura 18 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-70-30-5000-RMSPROP"

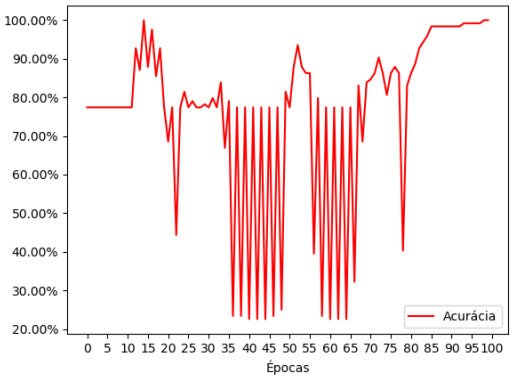

Figura 19 – Histórico de acurácia ao longo das épocas de treinamento do modelo "CNN-30-70-10000-RMSPROP"

Tabela 23 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-70-30-5000-RMSPROP"

		Predito	
		Positivo	Negativo
Atual	Positivo	9	3
	Negativo	0	42

Tabela 24 – Matriz de confusão referente aos resultados obtidos com o modelo "CNN-30-70-10000-RMSPROP"

		Predito	
		Positivo	Negativo
Atual	Positivo	28	0
	Negativo	0	96

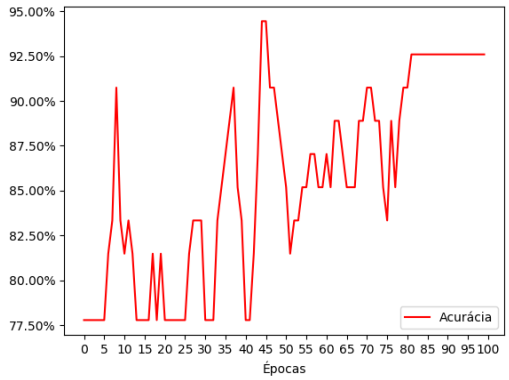

Figura 20 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-10000-RMSPROP”

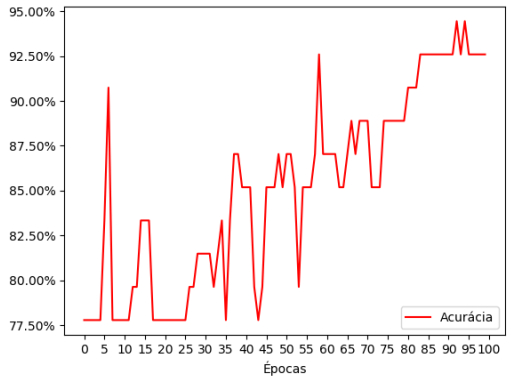

Figura 21 – Histórico de acurácia ao longo das épocas de treinamento do modelo “CNN-70-30-15000-RMSPROP”

Tabela 25 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-10000-RMSPROP”

		Predito	
		Positivo	Negativo
Atual	Positivo	8	4
	Negativo	0	42

Tabela 26 – Matriz de confusão referente aos resultados obtidos com o modelo “CNN-70-30-15000-RMSPROP”

		Predito	
		Positivo	Negativo
Atual	Positivo	8	4
	Negativo	0	42

5- Trabalhos Futuros

O capítulo tem como propósito apresentar os próximos passos do presente trabalho. Considerando os experimentos realizados até a data atual identificou-se a possibilidade de evolução em alguns pontos para que sejam atingidos os objetivos propostos no início do trabalho. A seguir, seguem os pontos de forma detalhada:

- **Expansão do conjunto de dados:** Uma variedade maior de conversas no conjunto de dados, abrangendo uma quantidade de maior de assuntos assim como conversas que apresentem vocabulário similar ao usado pelo predador sexual porém rotuladas como não-predatórias, são um fator relevante para a aproximação do conjunto de dados ao mundo real. O aumento de conversas predatórias no atual conjunto de dados "PAN-2012-BR" também é considerado. O MPF-SP e o Centro Educacional FEI seguem trabalhando para disponibilizar um novo conjunto de conversas predatórias como continuação do trabalho iniciado em Andrijauskas et al. [2017]. Como resultado dessa nova iniciativa entre o MPF-SP e o FEI, são aguardadas a adição de 43 novas conversas predatórias ao conjunto de dados "PAN-2012-BR".

- **Reprodução do estado da arte considerando a medida F_1:** Por se tratar do primeiro trabalho de classificação de conversas considerando o domínio de atividade predatória sexual na Internet e fazendo uso de dados obtidos na língua portuguesa que se tem conhecimento, entende-se a necessidade de uma maior experimentação dos algoritmos propostos e modelos identificados na literatura para quem então seja possível atingir a principal contribuição do presente trabalho com a proposta de algoritmo para identificação automática de atividade predatória sexual em conversas virtuais para a língua portuguesa. Neste cenário, além do trabalho reproduzido e apresentado na seção anterior e, independente dos resultados obtidos, enxerga-se a necessidade da reprodução do estado da arte na língua inglesa [Liu et al., 2017].

- **Desenvolvimento de API *online* para classificação de conversas quanto ao teor predatório:** A última contribuição do trabalho será disponibilizada mediante prévia autorização para consumo de tal forma que plataformas que ofereçam o

serviço de conversas entre os usuários por exemplo, redes sociais e salas de bate-papo, tenham a possibilidade de adicionar uma camada adicional de segurança na comunicação virtual ocorrida. Nesse contexto, enxerga-se também como oportunidade a aquisição de mais conversas virtuais de forma que seja possível continuar trabalhando na evolução do conjunto de dados “PAN-2012-BR”.

Uma vez atendido os objetivos do presente trabalho, enxerga-se como oportunidade, uma revisão ampla e em profundidade da escrita aplicada, melhor elaboração e organização de tabelas e figuras, maior aprofundamento das discussões realizadas e referências empregadas. Um maior detalhamento das tarefas levantadas nesta seção assim como outras não relacionadas porém que contribuem diretamente para a evolução e conclusão do trabalho são detalhadas no cronograma presente na figura 22.

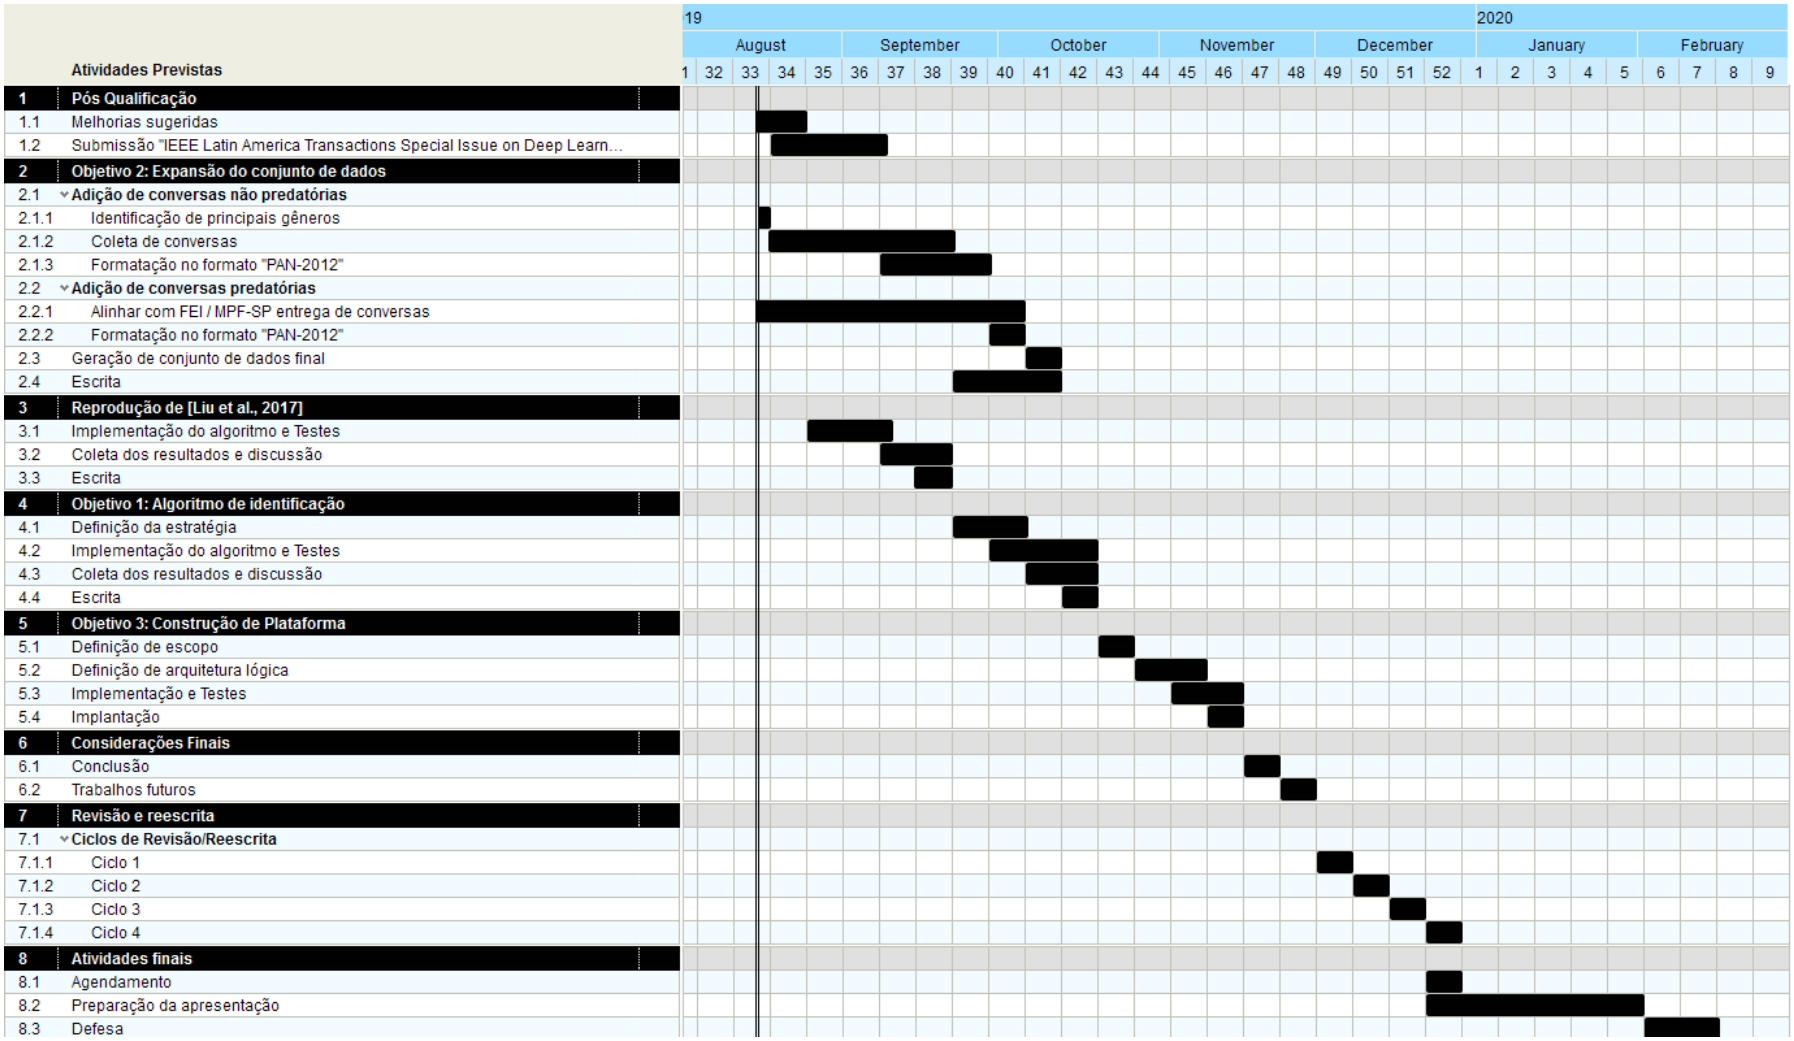

Figura 22 – Cronograma com detalhamento das tarefas previstas para a evolução e conclusão do trabalho. Autor: Próprio.

Referências Bibliográficas

Andrijauskas, A., Shimabukuro, A., and Maia, R. F. (2017). Desenvolvimento de base de dados em língua portuguesa sobre crimes sexuais. *VII Simpósio de Iniciação Científica, Didática e de Ações Sociais da FEI*.

Babchishin, K. M., Karl Hanson, R., and Hermann, C. A. (2011). The characteristics of online sex offenders: A meta-analysis. *Sexual Abuse*, 23(1):92–123.

Bagley, C. and King, K. (2003). *Child sexual abuse: The search for healing*. Routledge.

BARBOSA, A. F. (2018). Pesquisa sobre o uso da internet por crianças e adolescentes no brasil: Tic kids online brasil 2017. *São Paulo: Comitê Gestor da Internet no Brasil*.

Blei, D. M., Ng, A. Y., and Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of machine Learning research*, 3(Jan):993–1022.

Bogdanova, D., Rosso, P., and Solorio, T. (2014). Exploring high-level features for detecting cyberpedophilia. *Computer speech & language*, 28(1):108–120.

Boyer, M. and Lapalme, G. (1985). Generating paraphrases from meaning-text semantic networks. *Computational Intelligence*, 1(1):103–117.

Breiman, L. (2001). Random forests. *Machine learning*, 45(1):5–32.

Cambria, E. and White, B. (2014). Jumping nlp curves: A review of natural language processing research. *IEEE Computational intelligence magazine*, 9(2):48–57.

Cano, A. E., Fernandez, M., and Alani, H. (2014). Detecting child grooming behaviour patterns on social media. In *International conference on social informatics*, pages 412–427. Springer.

Cardei, C. and Rebedea, T. (2017). Detecting sexual predators in chats using behavioral features and imbalanced learning. *Natural Language Engineering*, 23(4):589–616.

Chen, X., Sun, Y., Athiwaratkun, B., Cardie, C., and Weinberger, K. (2018). Adversarial deep averaging networks for cross-lingual sentiment classification. *Transactions of the Association for Computational Linguistics*, 6:557–570.

Cheong, Y.-G. and Jensen, A. K. (2015). Detecting predatory behavior in game chats. *IEEE Transactions on Computational Intelligence and AI in Games*, 7(3):220–232.

Clark, J. L., Algoe, S. B., and Green, M. C. (2018). Social network sites and well-being: the role of social connection. *Current Directions in Psychological Science*, 27(1):32–37.

Crowell, C. R., Narvaez, D., and Gomberg, A. (2008). Moral psychology and information ethics: Psychological distance and the components of moral behavior in a digital world. In *Information Security and Ethics: Concepts, Methodologies, Tools, and Applications*, pages 3269–3281. IGI Global.

Dorasamy, M., Jambulingam, M., and Vigian, T. (2018). Building a bright society with au courant parents: Combating online grooming.

Duda, R. O., Hart, P. E., and Stork, D. G. (2012). *Pattern classification*. John Wiley & Sons.

Ebrahimi, M. (2016). *Automatic Identification of Online Predators in Chat Logs by Anomaly Detection and Deep Learning*. PhD thesis, Concordia University.

Forsythand, E. N. and Martell, C. H. (2007). Lexical and discourse analysis of online chat dialog. In *International Conference on Semantic Computing (ICSC 2007)*, pages 19–26. IEEE.

Fortin, F., Paquette, S., and Dupont, B. (2018). From online to offline sexual offending: Episodes and obstacles. *Aggression and Violent Behavior*.

Ghosh, A. K., Badillo-Urquiola, K., Guha, S., LaViola Jr, J. J., and Wisniewski, P. J. (2018). Safety vs. surveillance: what children have to say about mobile apps for parental control. In *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems*, page 124. ACM.

Gohr, A., Hinneburg, A., Schult, R., and Spiliopoulou, M. (2009). Topic evolution in a stream of documents. In *Proceedings of the 2009 SIAM International Conference on Data Mining*, pages 859–870. SIAM.

Goldberg, Y. (2017). Neural network methods for natural language processing. *Synthesis Lectures on Human Language Technologies*, 10(1):1–309.

Harris, Z. S. (1954). Distributional structure. *Word*, 10(2-3):146–162.

Haykin, S. S., Haykin, S. S., Haykin, S. S., Elektroingenieur, K., and Haykin, S. S. (2009). *Neural networks and learning machines*, volume 3. Pearson education Upper Saddle River.

Hernandez, S. C. L. S., Lacsina, A. C., Ylade, M. C., Aldaba, J., Lam, H. Y., Estacio Jr, L. R., and Lopez, A. L. (2018). sexual exploitation and abuse of children online in the philippines: A review of online news and articles. *Acta Medica Philippina*, 52(4):306.

Hochreiter, S. (1998). The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(02):107–116.

Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8):1735–1780.

Hofmann, T. (2001). Unsupervised learning by probabilistic latent semantic analysis. *Machine learning*, 42(1-2):177–196.

Hubel, D. H. and Wiesel, T. N. (1962). Receptive fields, binocular interaction and functional architecture in the cat's visual cortex. *The Journal of physiology*, 160(1):106–154.

Inches, G. and Crestani, F. (2012). Overview of the international sexual predator identification competition at pan-2012. In *CLEF (Online working notes/labs/workshop)*, volume 30.

Johnson, R. and Zhang, T. (2015). Effective use of word order for text categorization with convolutional neural networks. In *Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 103–112.

Karan, M. and Šnajder, J. (2018). Cross-domain detection of abusive language online. In *Proceedings of the 2nd Workshop on Abusive Language Online (ALW2)*, pages 132–137.

Keipi, T. (2018). Relatedness online: an analysis of youth narratives concerning the effects of internet anonymity. *Young*, 26(2):91–107.

Kloess, J. A., Hamilton-Giachritsis, C. E., and Beech, A. R. (2019). Offense processes of online sexual grooming and abuse of children via internet communication platforms. *Sexual Abuse*, 31(1):73–96.

Koppel, M., Schler, J., and Argamon, S. (2009). Computational methods in authorship attribution. *Journal of the Association for Information Science and Technology*, 60(1):9–26.

Kotsiantis, S. B. (2013). Decision trees: a recent overview. *Artificial Intelligence Review*, 39(4):261–283.

Larson, S. C. (1931). The shrinkage of the coefficient of multiple correlation. *Journal of Educational Psychology*, 22(1):45.

Leary, M. R. and Baumeister, R. F. (2000). The nature and function of self-esteem: Sociometer theory. In *Advances in experimental social psychology*, volume 32, pages 1–62. Elsevier.

LeCun, Y., Bottou, L., Bengio, Y., Haffner, P., et al. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324.

Liu, D., Suen, C. Y., and Ormandjieva, O. (2017). A novel way of identifying cyber predators. *arXiv preprint arXiv:1712.03903*.

Livingstone, S., Ólafsson, K., Helsper, E. J., Lupiáñez-Villanueva, F., Veltri, G. A., and Folkvord, F. (2017). Maximizing opportunities and minimizing risks for children online: The role of digital skills in emerging strategies of parental mediation. *Journal of Communication*, 67(1):82–105.

Ma, B., Zhang, D., Yan, Z., and Kim, T. (2013). An lda and synonym lexicon based approach to product feature extraction from online consumer product reviews. *Journal of Electronic Commerce Research*, 14(4):304.

McLaughlin, J. H. (2010). Crime and punishment: Teen sexting in context. *Penn St. L. Rev.*, 115:135.

Monroy, A. P. L., González, F. A., Montes, M., Escalante, H. J., and Solorio, T. (2018). Early text classification using multi-resolution concept representations. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 1216–1225.

Morris, C. (2013). *Identifying online sexual predators by svm classification with lexical and behavioral features*. PhD thesis.

NCMEC (2017). The online enticement of children: An in-depth analysis of cybertipline reports. *National Center for Missing & Exploited Children Web site., https://missingkids-stage.adobecqms.net/ourwork/publications/exploitation/onlineenticement. Acessado em 16 de março de 2019*.

Olowu, D. (2014). Cyber-based obscenity and the sexual exploitation of children via the internet: Implications for africa. In *AFRICAN CYBER CITIZENSHIP CONFERENCE 2014 (ACCC2014)*, page 115.

Olson, L. N., Daggs, J. L., Ellevold, B. L., and Rogers, T. K. (2007). Entrapping the innocent: Toward a theory of child sexual predators' luring communication. *Communication Theory*, 17(3):231–251.

O'Connell, R. (2003). A typology of child cybersexploitation and online grooming practices. *Preston, UK: University of Central Lancashire*.

Pendar, N. (2007). Toward spotting the pedophile telling victim from predator in text chats. In *International Conference on Semantic Computing (ICSC 2007)*, pages 235–241. IEEE.

Pennebaker, J. W., Francis, M. E., and Booth, R. J. (2001). Linguistic inquiry and word count: Liwc 2001. *Mahway: Lawrence Erlbaum Associates*, 71(2001):2001.

Ponomareva, N. and Thelwall, M. (2012). Biographies or blenders: Which resource is best for cross-domain sentiment analysis? In *International Conference on Intelligent Text Processing and Computational Linguistics*, pages 488–499. Springer.

Postal, J. G. et al. (2017). Avaliação do uso de quantificadores de teoria da informação para identificação de conversas online de pedofilia.

Quercia, D., Askham, H., and Crowcroft, J. (2012). Tweetlda: supervised topic classification and link prediction in twitter. In *Proceedings of the 4th Annual ACM Web Science Conference*, pages 247–250. ACM.

Quinlan, J. R. (1993). *C4.5: Programs for Machine Learning*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA.

Refaeilzadeh, P., Tang, L., and Liu, H. (2009). Cross-validation. *Encyclopedia of database systems*, pages 532–538.

Ross, S. M. (1997). *Introduction to Probability Models*. Academic Press, San Diego, CA, USA, sixth edition.

Santos, L. and Guedes, G. P. (2018). Detecção de traços de narcisismo em conversas com predadores sexuais. In *7º Brazilian Workshop on Social Network Analysis and Mining (BraSNAM 2018)*, volume 7. SBC.

Say, G. N., Babadağı, Z., Karabekiroğlu, K., Yüce, M., and Akbaş, S. (2015). Abuse characteristics and psychiatric consequences associated with online sexual abuse. *Cyberpsychology, Behavior, and Social Networking*, 18(6):333–336.

Schölkopf, B., Williamson, R. C., Smola, A. J., Shawe-Taylor, J., and Platt, J. C. (2000). Support vector method for novelty detection. In *Advances in neural information processing systems*, pages 582–588.

Seto, M. C., Karl Hanson, R., and Babchishin, K. M. (2011). Contact sexual offending by men with online sexual offenses. *Sexual Abuse*, 23(1):124–145.

Slonje, R. and Smith, P. K. (2008). Cyberbullying: Another main type of bullying? *Scandinavian journal of psychology*, 49(2):147–154.

Soh, P. C.-H., Chew, K. W., Koay, K. Y., and Ang, P. H. (2018). Parents vs peers' influence on teenagers' internet addiction and risky online activities. *Telematics and Informatics*, 35(1):225–236.

Sokolova, M. and Bobicev, V. (2018). Corpus statistics in text classification of online data. *arXiv preprint arXiv:1803.06390*.

Sutskever, I., Vinyals, O., and Le, Q. V. (2014). Sequence to sequence learning with neural networks. In *Advances in neural information processing systems*, pages 3104–3112.

Tener, D., Wolak, J., and Finkelhor, D. (2015). A typology of offenders who use online communications to commit sex crimes against minors. *Journal of Aggression, Maltreatment & Trauma*, 24(3):319–337.

Vapnik, V. (2013). *The nature of statistical learning theory*. Springer science & business media.

Villatoro-Tello, E., Juárez-González, A., Escalante, H. J., Montes-y Gómez, M., and Pineda, L. V. (2012). A two-step approach for effective detection of misbehaving users in chats. In *CLEF (Online Working Notes/Labs/Workshop)*, volume 1178.

Wang, S. and Manning, C. D. (2012). Baselines and bigrams: Simple, good sentiment and topic classification. In *Proceedings of the 50th annual meeting of the association for computational linguistics: Short papers-volume 2*, pages 90–94. Association for Computational Linguistics.

Witten, I. H., Frank, E., Hall, M. A., and Pal, C. J. (2016). *Data Mining: Practical machine learning tools and techniques*. Morgan Kaufmann.

Wolak, J., Finkelhor, D., and Mitchell, K. (2004). Internet-initiated sex crimes against minors: Implications for prevention based on findings from a national study. *Journal of adolescent health*, 35(5):424–e11.

Wolak, J., Finkelhor, D., and Mitchell, K. J. (2009). Trends in arrests of"online predators".

Wolak, J., Finkelhor, D., Walsh, W., and Treitman, L. (2018). Sextortion of minors: Characteristics and dynamics. *Journal of Adolescent Health*, 62(1):72–79.