CEFET/RJ
DIRETORIA DE PESQUISA E PÓS-GRADUAÇÃO

O DISCURSO DE ÓDIO HOMOFÓBICO NO TWITTER, UMA PROPOSTA DE MÉTODO DE CLASSIFICAÇÃO DE TEXTOS

Vinícius Soares dos Santos

Qualificação de Mestrado apresentada ao Programa de Pós-graduação em Ciência da Computação, Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ, como parte dos requisitos necessários à obtenção do grau de mestre.

Orientadores:
Professor D.Sc. Gustavo Paiva Guedes e Silva

Rio de Janeiro,

Agosto de 2024

O discurso de ódio homofóbico no Twitter, uma proposta de método de classificação de textos

Qualificação de Mestrado em Ciência da Computação, Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, CEFET/RJ.

Vinícius Soares dos Santos

Aprovada por:

Presidente, Professor D.Sc. Gustavo Paiva Guedes e Silva (orientador)

Professor D.Sc. Eduardo Ogasawara

Professor D.Sc. Ronaldo Ribeiro Goldschmidt

Rio de Janeiro,

Agosto de 2024

DEDICATÓRIA

Dedico esta dissertação de mestrado aos meus queridos e estimados pais, Egnaldo José dos Santos e Kátia Lima Soares. A eles, pelo encaminhamento a uma Educação de qualidade e libertadora, por todo suporte emocional, amor incondicional e carinho excepcional.

"Sei que dois e dois são quatro,
sei que a vida vale a pena,
mesmo que o pão seja caro
e a liberdade pequena."
Ferreira Gullar

AGRADECIMENTOS

Agradeço ao meu orientador, Prof. D.Sc. Gustavo Paiva Guedes e Silva, por todo apoio durante minha trajetória no Mestrado Acadêmico e orientação na produção desta dissertação.

A todo quadro docente do Programa de Pós-graduação em Ciência da Computação (PPCIC) do CEFET/RJ, em especial ao Professor D.Sc. Eduardo Ogasawara que por meio da sua apresentação na NVIDIA Rio Info AI Conferência no ano 2019, pude conhecer o programa de pós graduação e aplicar no ano seguinte.

A todos os discentes do PPCIC, pelo grupo formado durante a pandemia de Covid 19, à rede de apoio e colaboração no ensino-aprendizagem.

Ao meu parceiro de vida, Rodrigo Pinheiro Dantas, por todo estímulo ininterrupto, por fomentar um ambiente de paz para que eu seguisse em frente no alcance dos meus objetivos acadêmicos e profissionais.

RESUMO

O discurso de ódio homofóbico no Twitter, uma proposta de método de classificação de textos

Vinícius Soares dos Santos

Orientadores:
Professor D.Sc. Gustavo Paiva Guedes e Silva

Resumo da Dissertação submetida ao Programa de Pós-graduação em Ciência da Computação do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ como parte dos requisitos necessários à obtenção do grau de mestre.

O discurso de ódio homofóbico trata-se da ação ou incitamento ao ódio, à discriminação ou à hostilização de um indivíduo, motivado por um preconceito contra pessoas de orientação sexual lésbicas, gays, bissexuais, transexuais e travestis (LGBT). A homofobia foi criminalizada por meio de ação no Supremo Tribunal Federal do Brasil, em 13 de junho de 2019, que a enquadrou como racismo. O objetivo principal deste trabalho é propor um método de identificação automática para o discurso de ódio homofóbico. Para o alcance do objetivo, apresenta-se como objetivos específicos a criação de um léxico homofóbico, a criação de uma base de dados de textos extraídos de tweets rotulados por humanos, cujas as classes são "é conteúdo homofóbico", "não é conteúdo homofóbico" e "não tem certeza". Para o uso de humanos nesta pesquisa, submeteu-se ao Comitê de Ética em Pesquisa (CEP), subordinado ao Ministério da Saúde do Brasil, recebendo a aprovação para sua realização sob o número de protocolo 59293922.0.0000.5289. Por fim, aplicou-se modelos de aprendizagem de máquina tradicionais KNN e Árvore de Decisão e classificador ensemble Random Forest à base de dados rotuladas, comparando os modelos a partir das métricas de precisão, revocação e F1-measure.

Palavras-chave: discurso de ódio; homofobia; aprendizado de máquina; aprendizado profundo; léxico; mineração de texto; classificação de texto

Rio de Janeiro,

Agosto de 2024

ABSTRACT

O discurso de ódio homofóbico no Twitter, uma proposta de método de classificação de textos

Vinícius Soares dos Santos

Advisors:
Professor D.Sc. Gustavo Paiva Guedes e Silva

Abstract of dissertation submitted to Programa de Pós-graduação em Ciência da Computação - Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ as partial fulfillment of the requirements for the degree of master.

The Homophobic hate speech is the action or incitement to hate, discrimination or harassment of an individual, motivated by prejudice against people with sexual orientation such as lesbian, gay, bisexual, transsexual and transvestite (LGBT). The homophobia was criminalized through action in the Supreme Court of Brazil, on June 13th in 2019, which framed it as racism.This study aims to propose an automatic identification method for homophobic hate speech. To reach the main objective, it is proposed as a specific goals the creation of a homophobic lexicon, as well as the creation of a database of texts extracted from tweets labeled by humans, whose classes are "content is homophobic", "content not homophobic" and "not sure". Regarding the use of humans in this research, it was submitted to the Research Ethics Committee (in portuguese, Comitê de Ética em Pesquisa - CEP), subordinated to the Ministry of Health of Brazil, receiving approval for its realization under the protocol number 59293922.0.0000.5289. Finally, traditional KNN machine learning models and Decision Tree and Random Forest ensemble classifier were applied to the labeled database, comparing the models from the metrics of precision, recall and F1-measure.

Key-words: hate speech; homophobia; machine learning; deep learning; lexicon; text mining; text classification

Rio de Janeiro,

Agosto de 2024

Sumário

I Introdução **1**

I.1 Exemplo motivador 1

I.2 Definição do Problema 3

I.3 Objetivo 4

I.4 Considerações 4

I.5 Organização da dissertação 5

II Fundamentação Teórica **6**

II.1 Léxico 6

II.2 Processamento de Linguagem Natural 6

II.2.1 Termo Frequência-Frequência Inversa Documento (TF-IDF) 6

II.3 Mineração de Texto 7

II.4 Aprendizado de máquina 7

II.4.1 Aprendizado supervisionado 7

II.4.2 Modelos de Classificação 8

II.4.3 Validação cruzada: processo de avaliação do modelo 10

II.5 Medidas de avaliação de modelos de aprendizado de máquina 11

II.5.1 Matriz de confusão 11

II.5.2 Acurácia 12

II.5.3 Precisão e revocação 12

II.5.4 F-measure 13

III Trabalhos relacionados **14**

III.1 Dataset para o discurso de ódio homofóbico 15

III.2 Abordagem lexical e Modelos de aprendizagem de máquina 16

III.2.1 Considerações finais 17

IV Metodologia **19**

IV.1 Método de criação do Léxico homofóbico (MCLH) 20

IV.2 Método de criação dataset *tweets* (MCDT) 22

IV.2.1 Coleta dos dados 22
IV.2.2 Pré-processamento 23
IV.2.3 Amostragem 23
IV.3 Método de rotulagem textos homofóbicos (MRTH) 23
IV.4 Método de classificação de aprendizado de máquina (MCAM) 25

V Avaliação Experimental 26
V.1 MCLH 26
V.2 Simulação: MCDT 27
V.3 Simulação: MRTH 29
V.4 Simulação: MCAM 31
V.4.1 K-vizinhos mais próximos ou KNN 32
V.4.2 Árvore de decisão ou Decision Tree 33
V.4.3 Florestas aleatórias ou Random Forest 33
V.4.4 Resumo dos classificadores 34

VI Conclusões 35

Referências Bibliográficas 36

Apêndice A - API Twitter V2 41

Apêndice B - Termo de consentimento livre e esclarecido 43

Apêndice C - Léxico homofóbico 45

Apêndice D - Revisão Sistemática 46

Lista de Figuras

I.1 Homofobia no Twitter - fonte: S.PAULO [2017] 2

II.1 Exemplo modelo KNN para diferentes pesos - fonte Scikit-learn 8

II.2 Exemplo de uma árvore de decisão - fonte Scikit-learn 9

II.3 Exemplo de uma florestas aleatórias - fonte Scikit-learn 10

II.4 Processo de validação cruzada. Fonte Scikit-learn 10

II.5 Processo de validação cruzada. Fonte Scikit-learn 11

II.6 Matriz de confusão 12

IV.1 Metodologia de Classificação Automática para Conteúdo Homofóbico (MCACH) 19

IV.2 Contribuição humana ao léxico homofóbico 21

IV.3 Método de rotulagem de mensagens textuais homofóbicas - MRMTH 24

V.1 MCLH - Pergunta 1 - Exemplo de termos homofóbicos Hatebase (demais omitidos) 26

V.2 MCLH - Léxico homofóbico - Pergunta 2 27

V.3 Termos mais frequentes 28

V.4 Termos mais frequentes 28

V.5 Histograma do número de palavras dos tweets 29

V.6 Distribuição número de palavras dos tweets - Corte até 21 palavras 29

V.7 Rotulagem mensagens potencialmente homofóbicas 30

V.8 Frequência dos rótulos - Simulação 30

V.9 Boxplot rótulos por tamanho das frases 31

V.10 Matriz de confusão dados de teste - Classificador KNN 32

V.11 Matriz de confusão Teste - Classificador Decision Tree 33

V.12 Matriz de confusão Treinamento - Classificador Random Forest 34

VI.1 Planejamento etapas desenvolvimento dissertação 36

VI.2 E-mail de confirmação da submissão API Twitter v2 - Pesquisador 41

VI.3 E-mail de aprovação da submissão API Twitter v2 - Pesquisador 42

VI.4 Área do desenvolvedor API Twitter v2 - Pesquisador 42

VI.5 Termo de consentimento livre e esclarecido 44

Lista de Tabelas

III.1 Critério de inclusão e exclusão - revisão sistemática 14

III.2 Resumo do levantamento bibliográfico 18

IV.1 Termos homofóbicos em português - fonte: Hatebase [2020] 20

V.1 Simulação: Tabela resumo modelos de classificação - validação cruzada 34

Lista de Abreviações

API	*Application Programming Interface*	3
CEP	Comitê De Ética Em Pesquisa	4
CMC	Comunicação Mediada Pelo Computador	1
CNS	Conselho Nacional De Saúde	5
CONEP	Comissão Nacional De Ética Em Pesquisa	4
DT	*Decision Tree*	4, 8, 16, 35
FN	Falsos Negativos	11
FP	Falsos Positivos	11
KNN	*K-Nearest Neighbors*	4, 8, 35
LGBT	Lésbicas, Gays, Bissexuais E Transexuais	2, 17
MCACH	Metodologia De Classificação Automática Para Conteúdo Homofóbico	19, 35
MCAM	Método De Classificação De Aprendizado De Máquina	19, 25, 26, 35
MCDT	Método De Criação Do Dataset Tweets	19, 22, 26, 27, 35
MCLH	Método De Criação Do Léxico Homofóbico	19, 20, 26, 35
MLP	*Multilayer Perceptron*	17
MRTH	Método De Rotulagem De Textos Homofóbicos	19, 23, 26, 29, 35
PLN	Processamento De Linguagem Natural	6
STF	Supremo Tribunal Federal	2
SVM	*Suport Vector Machine*	4, 15, 16, 17, 35, 36
TCLE	Termo De Consentimento Livre E Esclarecido	20, 23
TF-IDF	Termo Frequência-Frequência Inversa Do Documento	7, 16, 17
VN	Verdadeiros Negativos	11
VP	Verdadeiros Positivos	11

Capítulo I Introdução

O advento da *Internet* proporcionou diversas mudanças ao mundo contemporâneo, dentre elas a maneira como a sociedade se relaciona. Para Recuero [2012], ferramentas de Comunicação Mediada pelo Computador (CMC) permitiram que pessoas, instituições ou grupos de pessoas se expressassem e socializassem, por meio da interação e a comunicação entre si. Segundo a autora, as relações em uma rede social são formadas pela interação social, no qual percebe-se as mais variadas trocas de informação, relacionadas ao campo afetivo, pessoal ou profissional, por exemplo.

A revista Exame [2022] divulgou uma estimativa apontando que as redes sociais no mundo já chegam 4,62 bilhões de usuários. Segundo a matéria, esse número tende a chegar rapidamente a 60% da população global, uma vez que as plataformas recebem cerca de um milhão de novos usuários por dia. Dados do jornal de economia Valor Investe [2022], apontavam que, em janeiro do ano de 2022, o *Twitter* possuía mais de 217 milhões de usuários em sua plataforma. Ainda segundo o jornal, a quarta maior base de usuários do Twitter no mundo é de brasileiros, com um total estimado de aproximadamente 19 milhões de usuários ativos no período em questão.

O *Twitter* é definido como um serviço de microblogue, por meio do qual pessoas e empresas podem se comunicar por mensagens [Honey and Herring, 2009]. O significado do termo microblogue é definido pelo tipo de serviço que é oferecido, e que segundo a própria empresa consiste em: "*as pessoas publicam mensagens, que podem conter fotos, vídeos, links e texto. Essas mensagens são publicadas em seu perfil e enviadas a seus seguidores, podendo ser encontradas por meio de busca na rede*" [Twitter, 2020]. A característica que destaca o *Twitter* das outras redes sociais é que as mensagens trocadas limitam-se a 280 caracteres, chamadas pelo microblogue de *tweets*, que permitem que os usuários compartilhem suas "*últimas histórias, ideias, opiniões e notícias em tempo real, escolhendo entre mensagens públicas ou um grupo selecionado*" [Twitter, 2020].

I.1 Exemplo motivador

Segundo Meyer-Pflug [2008], entende-se como discurso de ódio a manifestação de incitação a discriminação racial, sexual, social ou religiosa. Ainda segundo a autora, o discurso do ódio é mais do que uma manifestação de antipatia, ele é indicado como hostilidade, ameaças e agressões verbais.

Para Costa and Nardi [2015], o termo Homofobia é utilizado para conceituar o preconceito e dis-

criminação contra pessoas cuja orientação sexual seja diferente da heterossexual. Os autores citam, no contexto histórico do século XX, a interpretação dominante da psicologia e da psiquiatria, a respeito da homossexualidade, corroborou para o preconceito contra homossexuais. Ainda segundo eles, o termo "homossexualismo" foi considerado por muito tempo no manual de diagnóstico de doenças psiquiátricas. Por fim, os autores abordam a homofobia como um preconceito contra à diversidade sexual.

Ao passo que as redes se popularizam, o reflexo da sociedade em torno do discurso de ódio também é percebido. Segundo o portal *UOL Notícias*, um perfil homofóbico chamado "*HomofobiaSIM*" teve rápida ascensão na rede social *Twitter*, contando com mais de 15 mil seguidores e forte incitação . O perfil, como seu próprio nome sugere, incitava violência contra homossexuais. A reportagem ainda destaca que o perfil chegava ao ponto de compartilhar que homossexuais mereciam morrer (*e.g.*, "*Um viadinho [sic] brasileiro foi espancado, aí que está o erro, ele deveria ter sido é morto, acabe com Aids, mate um gay*") [UOL, 2010].

Outra notícia que traz à tona casos de homofobia foi relatada pelo jornal *O Estado de São Paulo*. Um usuário do *Twitter* com mais de 7 milhões de inscritos em suas redes sociais, contratado pelo Governo Federal para divulgação do programa de Reforma do Ensino Médio no ano de 2017, teve mensagens antigas denunciadas por diversos usuários da rede por conter discurso de ódio. Dentre essas mensagens, destaca-se uma de cunho homofóbico, divulgada na mesma matéria jornalística, conforme exibido na Figura I.1.

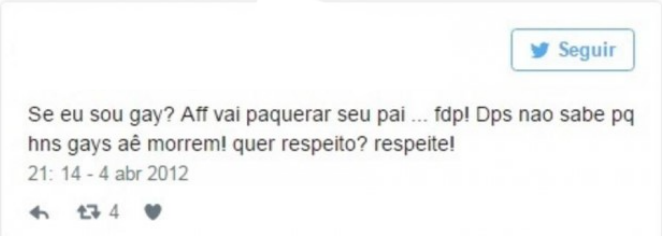

Figura I.1: Homofobia no Twitter - fonte: S.PAULO [2017]

O Supremo Tribunal Federal (STF) do Brasil, em 13 de junho de 2019, julgou como crime de racismo casos de agressões contra pessoas de orientação sexual Lésbicas, Gays, Bissexuais e Transexuais (LGBT) [UOL, 2020]. Na ação denominada "*Homofobia e omissão legislativa*", lista-se o julgamento e as alegações da suprema corte. Dentre os trechos da determinação, destaca-se o enquadramento de atos homofóbicos e transfóbicos como formas contemporâneas do racismo [Brasil, 2019].

I.2 Definição do Problema

Em 2017, o Twitter definiu novas regras para combater o abuso, violência e discurso de ódio. Em constante atualização, a conduta de propagação de ódio define que não é permitido "*promover violência, atacar diretamente ou ameaçar outras pessoas com base em raça, etnia, nacionalidade, orientação sexual, sexo, identidade de gênero, religião, idade, deficiência ou doença grave*" [Twitter, 2020].

A aplicação dessas regras, entretanto, pode requerer um grande esforço manual para revisar cada mensagem compartilhada na rede. MacAvaney et al. [2019] destacam que as ferramentas de identificação e classificação automáticas podem acelerar o processo de curadoria dos textos, e ainda que, os recursos humanos poderiam ser utilizados em análises mais aprofundadas de temas específicos ainda não automatizados. Desse modo, o *Twitter* poderia impedir que as mensagens de cunho homofóbico fossem compartilhadas ainda no momento da sua postagem, impedindo sua disseminação na rede.

Uma limitação à classificação automática de textos para este contexto de pesquisa é a incipiência de alguns léxicos para discurso de ódio homofóbico no idioma português. Cita-se como exemplo a ferramenta *Hatebase*, um vocabulário multilíngue, mantido por funcionários e voluntários em mais de 90 idiomas e mais de 200 países. Para construção do Hatebase [2020], foi desenvolvido o *Hatebrain*, uma engenharia de processamento de linguagem natural que realiza análises linguísticas em conversas públicas para estimar uma probabilidade de conteúdo com discurso de ódio. Todos os dados estão disponíveis para consulta por meio do seu sítio eletrônico ou sua interface de programação de aplicativos, em inglês, *Application Programming Interface* (API). Atualmente, nessa ferramenta, existem 28 termos relacionados à homofobia no idioma português.

Uma outra limitação ao uso de aprendizado de máquina supervisionado para classificação é a necessidade de um conjunto de dados rotulados. No trabalho de Fortuna et al. [2019b], um banco de dados para o discurso de ódio foi construído a partir da coleta no Twitter para 19 termos de ódio e 10 *hashtags*. Duas pessoas julgaram as mensagens extraídas para os rótulos de "sim" e "não" quanto ao discurso de ódio. Os respondentes quando julgavam que o conteúdo era discurso de ódio, informavam, na sequência, que tipo de discurso de ódio era, para uma lista contendo "homofobia", "racismo", "religião" e outros. No total, 5.668 *tweets* foram rotulados, porém apenas 365 destes, ou aproximadamente 6,4% da base de dados, foi para o discurso homofóbico. A amostra de 365 *tweets* ainda é limitada e uma expansão desse conjunto de dados é necessária.

Com o intuito de superar as limitações levantadas nessa seção, uma revisão sistemática na plataforma *Scopus* foi realizada a partir do termo chave *ALL(hate AND speech AND (classification OR detection) AND (homophobia OR homophobic))*, resultando em 167 documentos encontrados.

Em seguida, técnicas de *snowbowlling* foram consideradas para análise das referências e citações dos documentos selecionados.

I.3 Objetivo

Dada a problemática relatada na seção anterior, o objetivo geral da pesquisa é desenvolver um método de identificação do discurso homofóbico em mensagens do *Twitter*. O interesse do estudo está em conteúdos textuais, apresentando conceitos e trabalhos relacionados a métodos de classificação automática do discurso de ódio, essencialmente o discurso homofóbico. Para alcançar o objetivo principal, tem-se como objetivos específicos:

- Criação de um léxico de termos homofóbicos
- Criação de uma base de dados de textos, produzidos por meio da extração da informação dos *tweets* da rede social em questão
- Rotulagem dos textos a partir do julgamento humano para as classes "é conteúdo homofóbico", "não é conteúdo homofóbico" e "não tem certeza".
- Aplicação de modelos de classificação ao conjunto de tweets rotulados, para: (i) classificadores tradicionais, como *Suport Vector Machine* (SVM), *K-Nearest Neighbors* (KNN), *Decision Tree* (DT) e Naive Bayes; (ii) classificadores ensemble como, Random Forest, Adaptive Boosting e Gradient Boosting; (iii) redes neurais artificiais (deep learning).

I.4 Considerações

A presente pesquisa foi submetida à apreciação do *Twitter*, a fim de adquirir os direitos de uso de sua *API Developer V2*, lançada em janeiro de 2021, permitindo a coleta de até 10 milhões de *tweets* mensalmente. Segundo o Twitter [2020], além do acesso gratuito a pesquisadores, sua *API* permite a busca por dados históricos, antes restritos a usuários pagantes. A empresa disponibiliza guias técnicos e metodológicos, para facilitar a construção das consultas e análises dos conteúdos extraídos.

No dia 22 de setembro de 2021, a empresa aprovou a submissão e concedeu as credenciais de uso. Destaca-se ainda que a justificativa para a escolha dos dados provenientes do *Twitter* foi devido aos exemplos de homofobia relatados na seção I.1, o acesso gratuito à plataforma e os recursos disponibilizados pela rede social aos pesquisadores para elaboração da pesquisa.

Ressalta-se que a pesquisa envolve seres humanos na criação do léxico homofóbico e na rotulagem dos textos potencialmente homofóbicos, devido a isso, foi submetido o pedido ao Comitê de Ética em Pesquisa (CEP), coordenado pela Comissão Nacional de Ética em Pesquisa (CONEP), subordinada

ao Conselho Nacional de Saúde (CNS) do Ministério da Saúde do Brasil, recebendo a aprovação sob o número de protocolo 59293922.0.0000.5289.

I.5 Organização da dissertação

As próximas seções estão estruturadas da seguinte forma: no capítulo 2, são apresentadas as fundamentações teóricas; no capítulo 3, estão elencados os trabalhos relacionados; no capítulo 4, apresenta-se a metodologia; no capítulo 5, a avaliação experimental e os resultados parciais; no capítulo 6, as conclusões iniciais.

Capítulo II Fundamentação Teórica

Com o intuito de promover o entendimento dos principais conceitos abordados nesta proposta de pesquisa, começando pelo Léxico. Em seguida, apresenta-se a teoria acerca do Processamento de Linguagem Natural (PLN). Posteriormente, aborda-se a referência teórica para aprendizado de máquina supervisionado e modelos de classificação e por fim, discorre-se sobre medidas de avaliação de modelos de classificação em aprendizagem de máquina.

II.1 Léxico

De acordo com Vilela [1997] , Léxico é um conjunto de palavras utilizadas por determinados grupos linguísticos para se comunicarem entre si, como uma codificação de conhecimento compartilhado. O autor diferencia o vocabulário de léxico, no qual segundo ele, o vocabulário é parte do léxico, como por exemplo, o léxico de um texto ou autor.

II.2 Processamento de Linguagem Natural

O PLN é parte da inteligência artificial e linguística, cujo objetivo é fazer os computadores entenderem as declarações ou palavras escritas quaisquer que sejam as línguas humanas, conforme relatado em Khurana et al. [2017].

II.2.1 Termo Frequência-Frequência Inversa Documento (TF-IDF)

Segundo Kusner and Kolkin [2015], a frequência do termo no documento d é a frequência que representa o número de instâncias de um determinado termo t. Enquanto que, para ele, a frequência do documento *df* avalia o significado do texto para toda coleção do corpus. No documento d, TF é o contador de frequência para um termo t, enquanto *df* é o número de ocorrências no conjunto de documentos N do termo t.

$$TF(t) = \frac{\text{Número de vezes que t aparece no documento}}{\text{Número total de termos no documento}} \tag{II.1}$$

Para o autor, a frequência inversa do documento *idf* avalia o quão relevante é o termo, de modo que o mais comum é considerado menos significativo.

$$IDF(t) = ln\left(\frac{\text{Número total de termos do documento}}{\text{Número de documentos que possuem o termo t}}\right) \tag{II.2}$$

Com isso, Termo Frequência-Frequência Inversa do Documento (TF-IDF) será definido por TF-IDF $= tf(t) \times idf(t)$.

II.3 Mineração de Texto

Segundo Guimarães et al. [2019], mineração de texto, também conhecida como mineração de dados de texto, refere-se ao processo de extração de padrões ou de informações relevantes sobre documentos textuais não estruturados. Ainda segundo os autores, vários campos da ciência em pesquisas se complementam em torno dessa temática, como estatística, linguística computacional e mineração de dados.

II.4 Aprendizado de máquina

O Aprendizado de máquina é uma área da Inteligência Artificial, cujo objetivo é desenvolver técnicas computacionais e a construção de sistemas capazes de adquirir conhecimento de forma automática Monard and Baranauskas [2003]. Os diversos sistemas de aprendizado de máquina possuem características particulares e comuns que possibilitam a classificação quanto à linguagem, modo ou paradigma de aprendizado adotado.

II.4.1 Aprendizado supervisionado

Segundo Ricci et al. [2010], modelos de aprendizagem de máquina supervisionada são construídos a partir de uma entrada de dados rotulados, assim sendo possível avaliar a saída predita com os dados reais. Ainda segundo o autor, os modelos supervisionados são divididos em regressão e classificação, no qual a regressão busca encontrar como uma variável evolui em relação a outras e a classificação busca explicar uma variável categórica.

As variáveis categóricas dos modelos de aprendizado de máquina de classificação são, segundo o autor:

- binárias: apenas duas categorias, representadas por "ocorrência de um evento = 1" ou "não ocorrência de um evento = 0";
- faixas: como níveis de renda, faixas de idade, escalas e outros;
- variáveis puramente categóricas não ordenadas:o gênero, raça, sexo, cor, religião e outros.

II.4.2 Modelos de Classificação

K-Nearest Neighbor (KNN)

Segundo Pedregosa et al. [2011], a classificação baseada em KNN, ou seja, k-vizinhos mais próximos, é um aprendizado baseado em instâncias. A classificação é calculada a partir de uma votação majoritária simples, a um determinado ponto é atribuído a classe de dados que tem mais representantes dentro dos k-vizinhos mais próximos do ponto.

A figura II.1 ilustra o modelo de classificação k-vizinhos mais próximos para $k = 15$ considerando pesos uniformes e de distância para 3 classes.

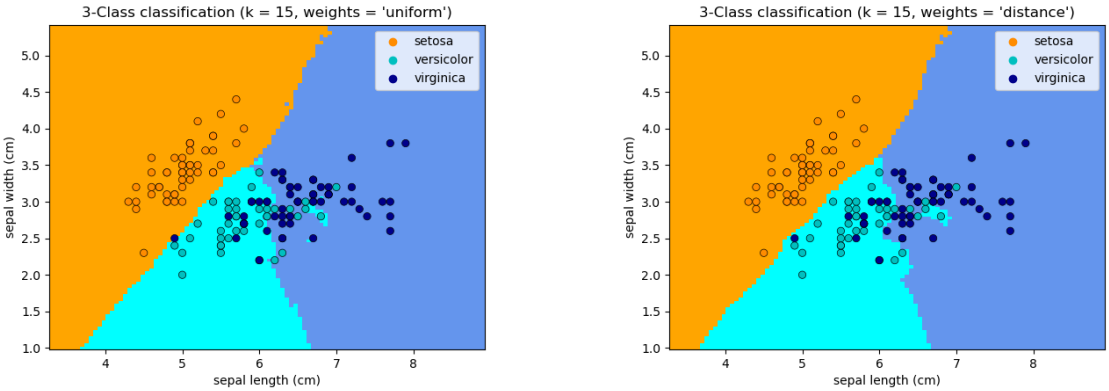

(a) KNN - Uniforme

(b) KNN - Distância

Figura II.1: Exemplo modelo KNN para diferentes pesos - fonte Scikit-learn

Decision Tree

As DT, ou árvores de decisão, são um método de aprendizado supervisionado não paramétrico usado para classificação e regressão [Pedregosa et al., 2011]. Para os autores, o objetivo é criar um modelo que preveja o valor de uma variável de destino aprendendo regras de decisão simples inferidas a partir dos recursos de dados.

Segundo Pedregosa et al. [2011], uma árvore pode ser vista como uma aproximação constante por partes, segundo a figura II.3, por exemplo, as árvores de decisão aprendem com os dados para um conjunto de regras de decisão, chamada *if-then-else*. Quanto mais profunda a árvore, mais complexas as regras de decisão e mais adequado é o modelo.

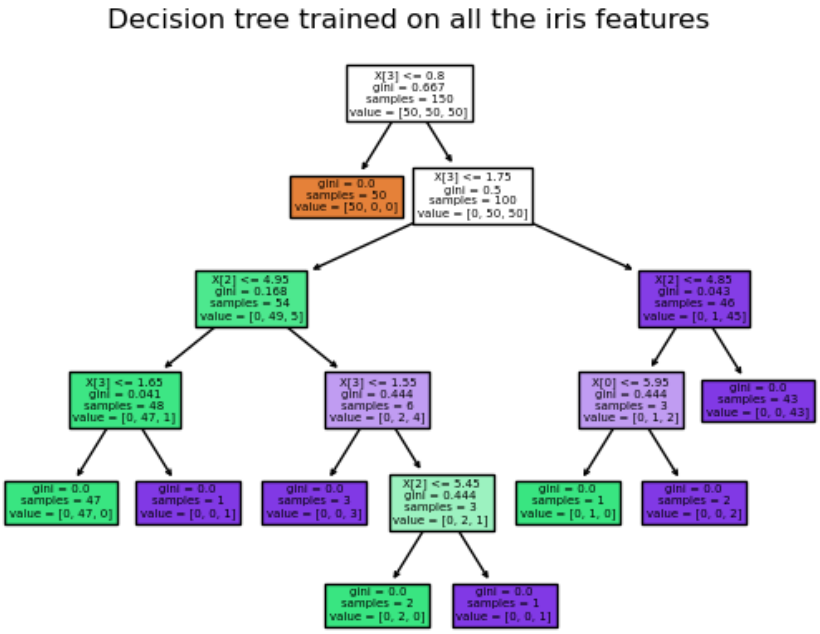

Figura II.2: Exemplo de uma árvore de decisão - fonte Scikit-learn

Random Forest

Os métodos ensemble de Random Forest, ou florestas aleatórias, são técnicas de perturbação e combinação especificamente projetadas para árvores de decisão. Segundo Pedregosa et al. [2011], um conjunto diversificado de classificadores é criado pela introdução de aleatoriedade na construção do classificador.

Ainda segundo os autores, em florestas aleatórias, cada árvore no ensemble é construída a partir de uma amostra com substituição para o conjunto de treinamento. Ao dividir cada nó durante a construção de uma árvore, a melhor divisão é encontrada em todos os recursos de um subconjunto aleatório, conforme ilustrado na figura II.3. As árvores de decisão individuais normalmente exibem alta variância e tendem a se ajustar demais, enquanto a aleatoriedade injetada nas florestas produz árvores de decisão com redução da variância, resultando em um modelo que melhor se adapta aos dados.

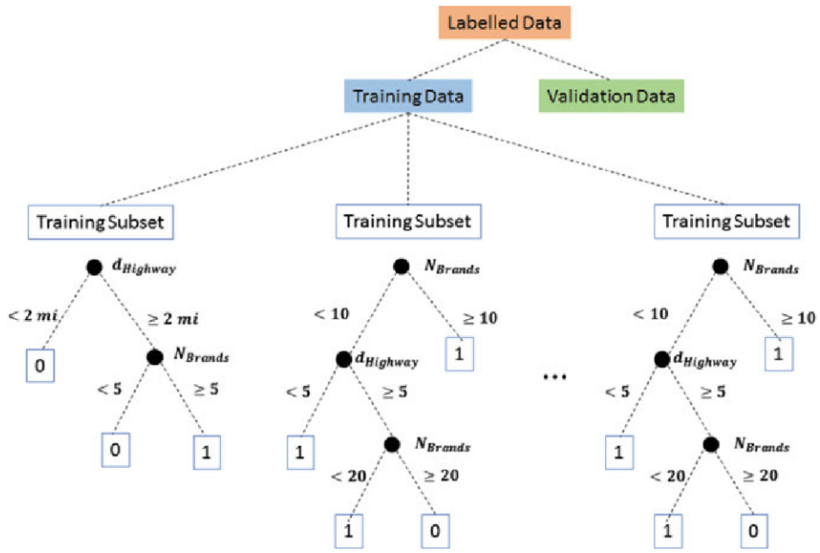

Figura II.3: Exemplo de uma florestas aleatórias - fonte Scikit-learn

II.4.3 Validação cruzada: processo de avaliação do modelo

Segundo Pedregosa et al. [2011], treinar os parâmetros de uma função de previsão e testá-la nos mesmos dados é um erro metodológico, pois assim o modelo apenas repetiria os rótulos aprendidos nas amostras, mas não conseguiria prever com a mesma avaliação sobre os dados não vistos. Os autores chamam essa situação como *overfitting*, ou sobreajuste, e segundo eles, para evitar isso, uma prática comum ao realizar um experimento de aprendizado de máquina supervisionado é separar parte dos dados disponíveis como um conjunto de testes e treinamento. Um fluxograma de validação cruzada no treinamento do modelo pode ser ilustrado pela figura II.4, indicando melhores parâmetros podem ser determinados por técnicas de busca em grade (*GridSearchCV*).

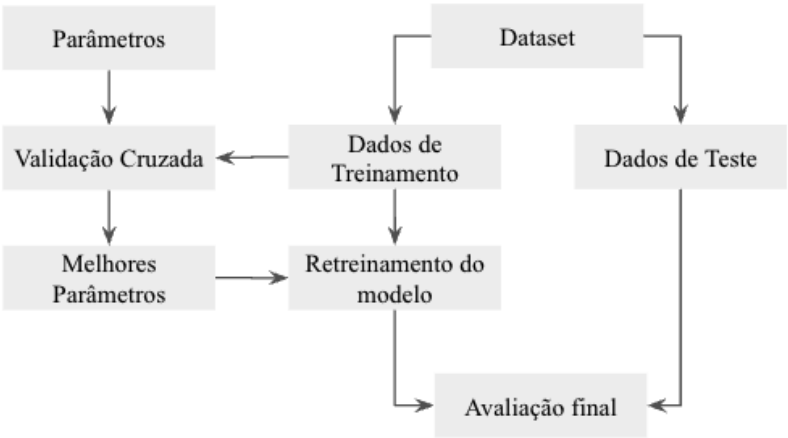

Figura II.4: Processo de validação cruzada. Fonte Scikit-learn

Ainda de acordo com os autores, o processo de validação cruzada utiliza várias partições ou divisões (em inglês, *k-folds*) do conjunto de treinamento com o objetivo de identificar os melhores

parâmetros. Como exemplo do processo, pode-se ilustrar o procedimento de validação cruzada por meio da figura II.5.

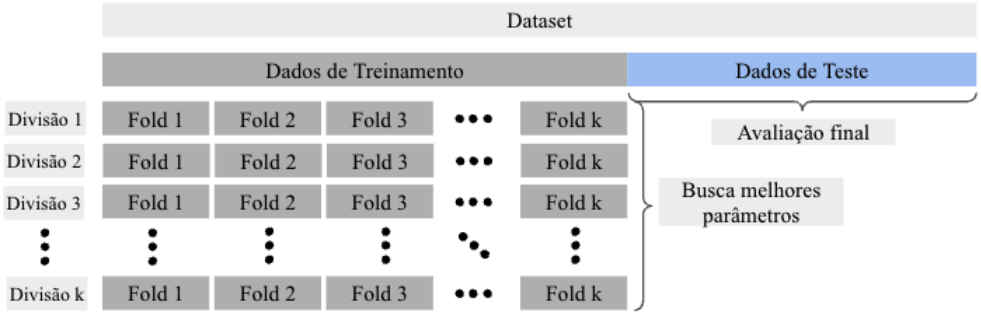

Figura II.5: Processo de validação cruzada. Fonte Scikit-learn

II.5 Medidas de avaliação de modelos de aprendizado de máquina

Segundo Hossin and M.N [2015], as métricas de avaliação têm por objetivo alcançar o modelo ideal durante treinamento de classificação de dados. Com o intuito de abordar os principais conceitos envolvendo as medidas de avaliação, os autores destacam a matriz de confusão, as medidas de precisão, revocação e f1-measure.

II.5.1 Matriz de confusão

A matriz de confusão é uma representação dos valores reais e dos valores preditos pelo modelo [Hossin and M.N, 2015]. Segundo os autores, os conceitos da matriz são tais que:

- Verdadeiros Positivos (VP): são os valores reais verdadeiros e o modelo os classificou como sendo verdadeiros;
- Verdadeiros Negativos (VN): são os valores reais falsos e o modelo os classificou como sendo falsos;
- Falsos Positivos (FP): são os valores reais falsos e o modelo os classificou como sendo verdadeiros;
- Falsos Negativos (FN): são os valores reais verdadeiros e o modelo os classificou como sendo falsos;

Com o objetivo de ilustrar uma matriz de confusão, adota-se os conceitos relacionados por Hossin and M.N [2015] por meio da figura II.6:

		Valor previsto	
		Verdadeiro	Falso
Valor real	Verdadeiro	VP	FN
	Falso	FP	VN

Figura II.6: Matriz de confusão

II.5.2 Acurácia

A acurácia mede a proporção de predições corretas sobre o número total de instâncias avaliadas [Ricci et al., 2010]. A equação II.3 representa o racional para a acurácia.

$$\text{Acurácia} = \frac{\text{VP} + \text{VN}}{\text{Total}} \tag{II.3}$$

II.5.3 Precisão e revocação

Precisão é usada para avaliar o falso-positivo do modelo [Ricci et al., 2010] . A equação II.4 ilustra o racional do cálculo da precisão.

$$\text{Precisão} = \frac{\text{VP}}{\text{VP} + \text{FP}} \tag{II.4}$$

A revocação é uma métrica que avalia a classificação correta do modelo. A equação II.5 aborda o racional do cálculo da revocação.

$$\text{Revocação} = \frac{\text{VP}}{\text{VP} + \text{FN}} \tag{II.5}$$

II.5.4 F-measure

F-measure é a média harmônica entre precisão e revocação.

$$F_1 = \frac{2 \times \text{ Precisão } \times \text{ Revocação}}{\text{Precisão} + \text{Revocação}} \tag{II.6}$$

Capítulo III Trabalhos relacionados

Neste capítulo, aborda-se alguns trabalhos relacionados à problemática do presente estudo. Inicialmente, descreve-se a abordagem Lexical nos modelos de aprendizado de máquina para métodos de classificação de textos. Em seguida, são apresentados alguns estudos orientados a modelos de aprendizado de máquina supervisionados, como modelos tradicionais, modelos ensemble e modelos de apredizagem profunda. Ao término, um resumo das métricas de avaliação e abordagem são apresentados.

A revisão sistemática é utilizada nesse capítulo, com o objetivo de identificar os principais trabalhos relacionados. A chave de busca pesquisada foi a *ALL(hate AND speech AND (classification OR detection) AND (homophobia OR homophobic))*, considerando trabalhos escritos nas línguas inglesa e portuguesa. Ao todo, 167 documentos foram encontrados para a chave em questão, e após isso, cada documento foi classificado seguindo um critério de inclusão e exclusão para textos relacionados ao objetivo do presente estudo, conforme III.1.

Critérios	**Descrição**
CI-MCDO	Critério de inclusão - O texto refere-se a métodos ou modelos de classificação ou detecção textual do discurso de ódio
CI-MCDOH	Critério de inclusão - O texto refere-se a métodos ou modelos de classificação ou detecção textual do discurso de ódio homofóbico
CE-NMCDO	Critério de exclusão - O texto não refere-se a métodos ou modelos de classificação ou detecção textual do discurso de ódio

Tabela III.1: Critério de inclusão e exclusão - revisão sistemática

Dos resultados da busca, 35 documentos foram considerados como inclusão, sendo 21 documentos como CI-MCDO e 14 documentos como CI-MCDOH. O próximo passo utilizado na seleção dos documentos foi avaliar a significância dos trabalhos, para dois critérios: (a) resultados dos modelos avaliados pela métrica F1-measure; (b) método de classificação e características textuais semelhantes ao presente estudo. Assim, considerando 5 trabalhos relacionados com a presente pesquisa. A avaliação da significância dos trabalhos pode ser consultada no Apêndice D.

Após a seleção final, foi aplicada a técnica de snowbowlling para análise das referências e citações dos documentos selecionados, onde foi possível identificar 2 trabalhos relacionados ao dataset para o discurso homofóbico em português e 2 trabalhos relacionadas a aplicação da classificação de textos em português no Twitter. Ao final, 9 trabalhos são considerados para a concepção deste capítulo.

III.1 Dataset para o discurso de ódio homofóbico

Segundo de Pelle e Viviane P. Moreira [2017], o aprendizado supervisionado para classificação de conteúdo de discurso de ódio depende da existência de conjuntos de dados rotulados. Devido a ausência de um conjunto de dados disponíveis para o contexto abordado em português, os autores propuseram a criação de um, a partir da coleta dos comentários do portal de notícias G1[1]. Eles coletaram as informações de diversas notícias do portal e identificaram que 90% delas continham ao menos um comentário com discurso de ódio. Dois datasets foram gerados a partir dos julgamentos de 3 pessoas, o primeiro contendo 1.250 registros, no qual o rótulo foi definido quando ao menos 2 pessoas concordavam, chamado OFFCOMBR-2. O segundo contendo 1.033 comentários para julgamentos unânimes, chamado OFFCOMBR-3. Os julgadores respondiam se o conteúdo era de discurso de ódio e qual tipo de discurso identicaram (e.g. racismo, religião, blasfêmia, homofobia e outros). Os autores analisaram os rótulos aplicados a cada conjunto de dados, evidenciando que apenas 14 comentários foram julgados como homofóbicos. Ao final, os autores aplicaram dois modelos de classificação a ambos os datasets. Eles observaram que os modelos SVM e Naive Bayes, performaram respectivamente em 82% e 79% para a métrica F1-measure aplicado ao dataset OFFCOMBR-3. Ambos os datasets podem ser consultados pelo repositório do autor, OFFCOMBR[2].

Utilizando como referência o trabalho feito por de Pelle e Viviane P. Moreira [2017], Fortuna et al. [2019a] expandiram o trabalho de construção de um dataset em português para o discurso de ódio. Eles arbitraram 29 perfis do Twitter e a partir deles fizeram uma busca por 19 termos e 10 *hashtags* para o discurso de ódio. Os autores filtraram por *tweets* em português, entre 8 e 9 de março de 2017 e contendo ao menos 3 palavras. Além disso, eliminaram repetições e retweets para evitar duplicações, removeram html, tags e outros conteúdos não textuais. Após a coleta, eles submeteram as mensagens extraídas ao julgamento de 2 pessoas e utilizaram a métrica Cohens Kappa para avaliar a concordância entre eles para as classes de discurso de ódio (e.g., homofobia, racismo, religião, imigrantes e outros). No total, o dataset contém 5.668 *tweets*, sendo apenas 365 para o discurso de ódio homofóbico. A base de dados se encontra disponível para livre consulta.

A incipiência de datasets é uma limitação que busca-se resolver com o presente estudo. Mesmo com as contribuições feitas por de Pelle e Viviane P. Moreira [2017] e Fortuna et al. [2019a], poucos são os textos coletados com o rótulo para homofobia, fazendo-se necessário a expansão do conjunto de dados, abordando diferentes tipos de termos homofóbicos.

[1] `g1.globo.com`
[2] `https://github.com/rogersdepelle/OffComBR`

III.2 Abordagem lexical e Modelos de aprendizagem de máquina

Uma maneira clássica de se identificar o discurso de ódio é usar uma abordagem baseada em palavras-chave, conforme descrito em MacAvaney et al. [2019]. Para os autores, com base em uma ontologia ou dicionário, textos que contenham potencial discurso de ódio podem ser identificados. Um exemplo considerado pelos autores é o vocabulário *Hatebase*. Eles ponderam que apenas o uso do termo presente no texto não é suficiente para definir a presença do discurso de ódio. Além disso, destacam que, a utilização dessa abordagem exclusivamente não permite identificar discurso de ódio em textos que não contenham quaisquer palavras-chave de incitação ao ódio, como é o caso do uso de linguagem figurada. Vale destacar que podem ser encontrados 28 termos homofóbicos, em português, no *Hatebase*.

Coutinho and Malheiros [2020] abordaram o tema da detecção de mensagens homofóbicas em português, no *Twitter*, usando análise de sentimentos. Os autores construíram a base de dados consultando a interface do *Twitter* com quatro termos de cunho homofóbico (e.g., *"sapatão", "viado", "traveco" e "gay"*). Após isso, vetorizaram as mensagens utilizando TF-IDF e treinaram um modelo de Regressão Logística aplicados ao TASH-PT, um banco de dados para análise de sentimentos na língua portuguesa com dados coletados do *Twitter*. Os autores relatam que para construção do TASH-PT foram avaliados 2.787 *tweets*, sendo 888 positivos, 881 negativos e 1.018 neutros. Para validação do modelo, os autores fizeram uso de cinquenta e sete julgadores humanos. Para avaliar a qualidade do modelo de classificação adotado, tais julgadores responderam se cerca de 160 mensagens classificadas pela Regressão Logística eram ou não mensagens homofóbicas. Os resultados observados foram: acurácia de 61,48%, precisão de 66,67%, revocação de 62,16% e *F-Measure* de 64,33%.

Davidson et al. [2017] coletaram dados do Twitter em inglês, a partir do léxico extraído do *Hatebase* para o discurso de ódio em geral. No total, uma amostra de 25 mil tweets foi rotulada por funcionários da empresa *CrowdFlower* (CF), empresa especializada em rotulagem. Apenas 5% dos tweets foram considerados discurso de ódio, eles utilizaram uma métrica de concordância chamada *intercoder-agreement*. Os autores avaliaram diversas abordagens de de classificação, como Regressão logística, Naive Bayes, DT, Florestas aleatórias e SVM linear. Cada modelo foi testado utilizando validação cruzada com 5 e utilizaram como *features* bigramas, unigramas e trigramas, com pesos calculados por TF-IDF. Ao final, os autores concluíram que o melhor modelo foi a Regressão logística com regularização L2, tendo precisão de 91%, revocação de 90% e F1-measure de 90%.

Quatro modelos de aprendizado de máquina para classificação foram estudados em Silva and Roman [2020]. Os autores utilizaram a base de dados criada por Fortuna et al. [2019b] de tweets

extraído para o discurso de ódio. Os algoritmos analisados foram *Naive Bayes*, SVM , *Bayesian Logistic Regression* e *Multilayer Perceptron* (MLP). Os autores utilizaram como recursos *BOW*, TF-IDF e n-grams. Para avaliação dos modelos, eles fizeram validação cruzada para 10 partições, obtendo como melhor modelo o SVM , com *F-measure* de 71,3%.

Em Burnap and Williams [2015], utilizou-se a abordagem híbrida para um classificador de aprendizado de máquina supervisionado e modelagem estatística aplicados a um conjunto de dados de mensagens do *Twitter*. Eles propuseram uma combinação de classificadores probabilísticos, *rule-based* e *spatial-based*, com um meta-classificador conjunto, *voted ensemble* com máxima probabilidade. Segundo os autores, o meta-classificador utilizou como base os modelos *Bayesian Logistic Regression* (BLR), *Random Forest Decision Tree* (RFDT) e *Support Vector Machine* (SVM). Os resultados obtidos foram: precisão de 95%, revocação de 95% e *F-measure* de 95%.

No estudo de Vandersmissen [2012], foi projetado dois métodos de aprendizado de máquina supervisionado para o conjunto de dados "Dutch Netlog Corpus" uma rede social holandesa. O autor utilizou como rótulos, conteúdos do discurso de ódio racista ou sexual, incluindo homofobia. Ao todo, 535 mensagens foram classificadas manualmente pelo autor para o discurso de ódio, sendo 173 racista e 362 sexual. O primeiro classificador aplicado ao conjunto de dados foi Naive Bayes, tendo um desempenho ruim e atingindo uma precisão de 9% e revocação de 86%. O segundo classificador avaliado foi SVM, obtendo 69% de precisão e 62% de revocação. Com o objetivo de otimizar os resultados aferidos, o autor adotou uma abordagem híbrida combinando um classificador semântico com SVM, atingindo precisão de 100%, revocação de 79% e F-measure de 88,3%.

Saha et al. [2019] utilizaram como proposta de estudo casos de estresse da comunidade LGBT por meio dos dados extraídos da plataforma *REDDIT*. Os autores coletaram 12.645 mensagens da rede entre janeiro de 2016 e maio de 2018, após isso aleatorizaram 347 conteúdo a serem rotulados pelos próprios. Os autores avaliaram alguns modelos de classificação adotando validação cruzada para 5 partições. Os modelos foram Naive Bayes, Regressão Logística, Florestas aleatórias, SVM e MLP. Ao final, o modelo de melhor performance foi o Multilayer Perceptron (MLP), com precisão de 75%, revocação de 74% e F1-measure de 75%.

III.2.1 Considerações finais

A revisão sistemática evidenciou a incipiência de estudos para o discurso de ódio homofóbico para a língua portuguesa. As buscas feitas por Coutinho and Malheiros [2020] e Fortuna et al. [2019a] por termos de discurso de ódio na etapa de coleta dos dados, se basearam em um número limitado para o léxico, 4 e 19 termos respectivamente. Ainda nesse contexto, o *Hatebase* é o único que dispões de termos e expressões homofóbicos em português, com 28 termos. A presente pesquisa tem por objetivo específico expandir o Léxico homofóbico e com isso abordar uma maior variedade

de termos ou expressões.

Os trabalhos relacionados ao Processamento de Linguagem Natural (PLN) permitem ilustrar as técnicas utilizadas nos mais diversos contextos de discurso de ódio. Utilize-se a Tabela III.2 com o objetivo de resumir as informações sobre as abordagens utilizadas pelos autores dos trabalhos relacionados.

Autor e obra	**Base de dados**	**Modelo**	**Precisão**	**Revocação**	**F-measure**
Burnap, P. and Williams, M. L. (2015). Cyber hate speech on twitter: An application of machine classification and statistical modeling for policy and decision making.	Twitter	Classificadores probabilíticos, rule-based e spatial-based, com meta-classificador conjunto, voted ensemble e máxima probabilidade.	95,0%	95,0%	95,0%
Coutinho, V. M. and Malheiros, Y. (2020). Detecção de mensagens homofóbicas em português no twitter usando análise de sentimentos.	Twitter	Regressão Logística aplicados ao TASH-PT	66,7%	62,2%	64,3%
Davidson et al. (2017). Automated hate speech detection and the problem of offensive language	Twitter	Regressão Logística com regularização L2	91,0%	90,0%	90,0%
de Pelle e Moreira (2017). Offensive comments in the brazilian web: a dataset and baseline results	Twitter	Linear SVM	-	-	82,0%
Saha et al. (2019). The language of LGBTQ+ minority stress experiences on social media	Reddit	Multilayer Perceptron (MLP)	75,0%	74,0%	75,0%
Silva e Roman (2020). Hate Speech detection in portuguese with naive bays, svm, MLP e Logistic Regression.	Twitter	Abordagem SVM combinada com BOW	-	-	71,3%
Vandersmissen, B. (2012) em Automated detection of offensive language behavior on social networking sites.	Dutch Netlog Corpus	Abordagem híbrida combinando um classificador semântico com SVM	100,0%	79,0%	88,3%

Tabela III.2: Resumo do levantamento bibliográfico

Capítulo IV Metodologia

Esta seção detalha a Metodologia de Classificação Automática para Conteúdo Homofóbico (MCACH) para o alcance do objetivo principal e dos objetivos específicos. Primeiro, definindo a criação do léxico homofóbico, após isso, a criação do dataset de mensagens do *Twitter*. Na sequência, a rotulagem dos textos quanto ao conteúdo homofóbico e por fim, o método de classificação de aprendizado de máquina.

Com intuito de trazer clareza sobre a abordagem da metodologia, ilustra-se por meio da figura IV.1 a sequência das etapas. Cada método produz um dataset como saída, com exceção do último, e cada dataset serve de entrada ao fluxo de outro método.

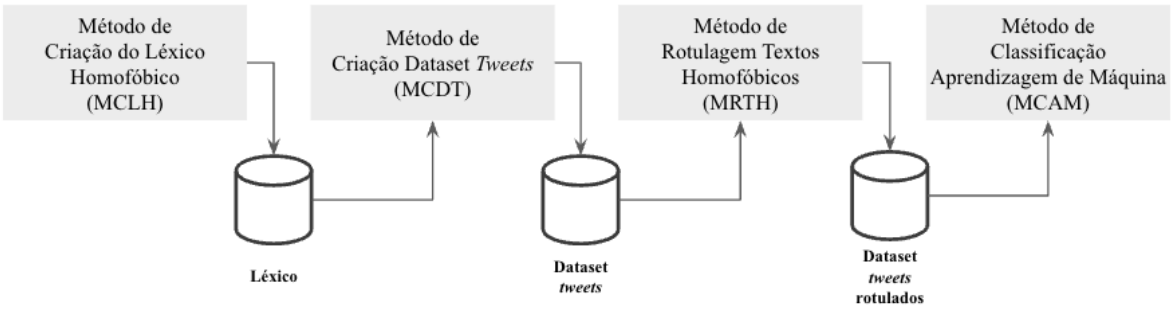

Figura IV.1: Metodologia de Classificação Automática para Conteúdo Homofóbico (MCACH)

O Método de criação do léxico homofóbico (MCLH) é o passo no processo de geração do Léxico, o Método de criação do dataset tweets (MCDT) é a etapa de geração do dataset de *tweets*. O Método de Rotulagem de Textos Homofóbicos (MRTH) é o estágio de geração do dataset de *tweets* rotulados. Por fim, o Método de Classificação de Aprendizado de Máquina (MCAM) é o passo da classificação dos tweets quanto a homofobia.

IV.1 Método de criação do Léxico homofóbico (MCLH)

Uma limitação à classificação automática de textos homofóbicos é a incipiência de um léxico. Como descrito no capítulo I, a plataforma *Hatebase* dispõe de apenas 28 termos ou expressões relacionados à homofobia, no idioma português.

O MCLH visa romper com tal limitação, por meio da opinião de seres humanos, incrementando termos ou expressões homofóbicas ao léxico. Inicialmente, cada participante é apresentado ao Termo de Consentimento Livre e Esclarecido (TCLE). Após isso, pergunta-se para cada uma das pessoas, se estas conhecem os termos ou expressões homofóbicas presentes no *Hatebase*, conforme tabela IV.1,

Termos Homofóbicos
Baitola (Variante De Boiola)
Bambi
Bambis (Plural De Bambi)
Biba
Bicha
Bichinha (Variante De Bicha)
Bichona (Variante De Bicha)
Boiola
Boiolas
Desviada (Variante De Desviado)
Desviadas (Plural De Desviada)
Desviado
Desviados (Variante De Desviado)
Escorregar No Quiabo
Fufa
Fufas (Plural De Fufa)
Maricas
Mulherzinha
Mulherzinhas (Plural De Mulherzinha)
Paneleira
Paneleiras (Plural De Paneleira)
Paneleiro
Paneleiros (Plural De Paneleiro)
Rabeta
Rabetas (Plural De Rabeta)
Sapatão
Sapatões (Plural De Sapatão)
Viado

Tabela IV.1: Termos homofóbicos em português - fonte: Hatebase [2020]

O intuito de exibir a lista em questão, é fazer com que as pessoas reflitam sobre o que já se tem conhecimento *a priori*. Na sequência, ocorre a colaboração dos respondentes à criação do léxico homofóbico. Os participantes são perguntados se eles têm conhecimento de outros termos ou expressões não listados. Todo processo é ilustrado, detalhadamente, por meio da figura IV.2.

O formulário de pesquisa utilizado para coleta das informações foi o *Google Forms*, devido a ser uma plataforma gratuita, sem limitação de respondentes, simples e objetiva. Além disso, a plataforma permite baixar os dados coletados e encerrar a pesquisa quando do fim do período.

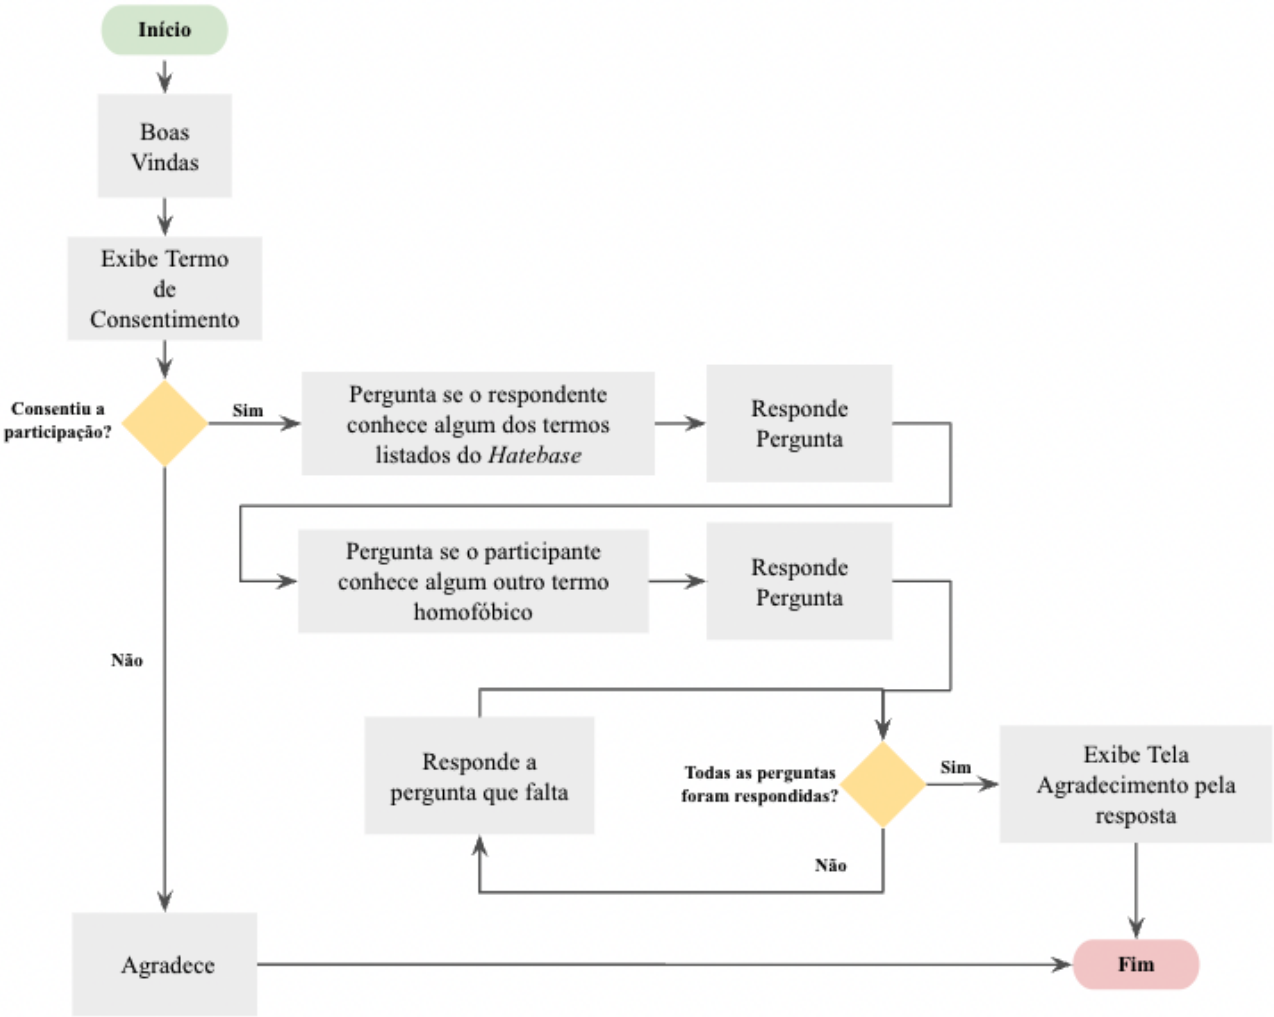

Figura IV.2: Contribuição humana ao léxico homofóbico

IV.2 Método de criação dataset *tweets* (MCDT)

O MCDT utiliza-se da consulta ao *Twitter API V2*, recurso que permite acesso aos dados históricos públicos. Conforme relatado por Twitter [2020], por meio de acesso a API, os pesquisadores dispõem de um conjuntos de dados mais precisos, completos e imparciais.

IV.2.1 Coleta dos dados

A pesquisa inicia-se com a construção da Base de Dados, representada por uma coleção de *tweets*. Esta etapa do processo prevê o acesso aos dados e, para isso, foi utilizada a *API* do *Twitter*, em `https://developer.twitter.com/en/support/twitter-api/v2`.

A consulta feita a *API* do *Twitter* utilizou como recurso computacional a linguagem de programação Python[1]. Além disso, duas bibliotecas foram tomadas como construção do algoritmo de busca, são elas: *tweepy*[2] e *pandas*[3].

A biblioteca *tweepy* permite configurar a conexão com a *API*, por meio das chaves de acesso. Enquanto que a biblioteca *pandas* possibilita a criação do banco de dados, apendando os textos extraídos na consulta. O algoritmo de busca foi construído na plataforma *Google Colab*[4] de modo que todo processamento dos dados ocorressem em ambiente colaborativo.

Os seguintes critérios foram estabelecidos na construção do algoritmo de busca:

- Consultas por mensagens no período de 01/01/2019 a 30/06/2022, *API* semestralmente a fim de evitar bloqueio do *Twitter* por excesso de requisição;
- Buscas por textos em português e escritos no Brasil;
- Não consideração de retweets ou textos compartilhados, evitando duplicidade do mesmo conteúdo;
- Para evitar que os termos estivessem contidos no nome de algum perfil (i.e. viadoescroto), considerou-se buscas que não contivessem menções;
- Todos os termos ou expressões homofóbicas construídos na seção IV.1 foram buscados para o mesmo período, para os mesmo critérios de busca.

[1] `https://www.python.org/`
[2] `https://www.tweepy.org/`
[3] `https://pandas.pydata.org/`
[4] `https://research.google.com/colaboratory/intl/pt-BR/faq.html`

IV.2.2 Pré-processamento

A etapa de pré-processamento do texto consiste em tratar os documentos coletados para a etapa de rotulagem. Para isso, inicialmente foram removidos conteúdos não textuais: urls, emojis, imagens, hashtags e múltiplos espaços. Após a remoção, os textos foram agrupados de modo a evitar textos duplicados. Por fim, foram desconsiderados registros de consultas vazias ou ausência de dados.

IV.2.3 Amostragem

A etapa de coleta dos dados não limitou a quantidade de resultados desejados para cada item do dataset de léxico homofóbico. Nesta etapa, deseja-se que a quantidade de textos seja suficientemente adequada para cada um dos termos homofóbicos na seção IV.1. Para isso, é sorteado aleatoriamente 60 *tweets* do universo de textos coletados, em consonância ao Teorema Central do Limite (TCL).

IV.3 Método de rotulagem textos homofóbicos (MRTH)

Uma limitação descrita no capítulo II, refere-se a uma ausência de um *dataset* rotulado para textos de conteúdo homofóbico, para língua portuguesa. O MRTH visa submeter ao julgamento humano os textos coletados de mensagens extraídas do *Twitter*. Para tal, os seguintes rótulos são avaliados no método: "é conteúdo homofóbico", "não é conteúdo homofóbico" e "não tem certeza".

Para o desenho do formulário de pesquisa, utilizou-se a plataforma *PCIBEX* em `https://farm.pcibex.net/`. Seu uso justifica-se pois a plataforma é totalmente gratuita, de código aberto, colaborativa e desenvolvida para a realização de experimentos *online*.

Inicialmente, exibe-se o TCLE ao participante. Em seguida, sorteia-se um grupo de textos, no qual cada grupo é dividido com o objetivo de que cada pessoa receba 30 textos para o julgamento. O número é estimado, considerando que cada indivíduo conclua a pesquisa em até 8 minutos, ou seja, cada pergunta respondida leva, em média, 15 segundos. Na sequência, dentro do grupo selecionado, sorteia-se aleatoriamente a ordem das perguntas. Os respondentes avaliam cada um dos 30 textos, ou *tweets*, presentes no banco de dados da seção IV.2. O processo de pesquisa é ilustrado na figura IV.3.

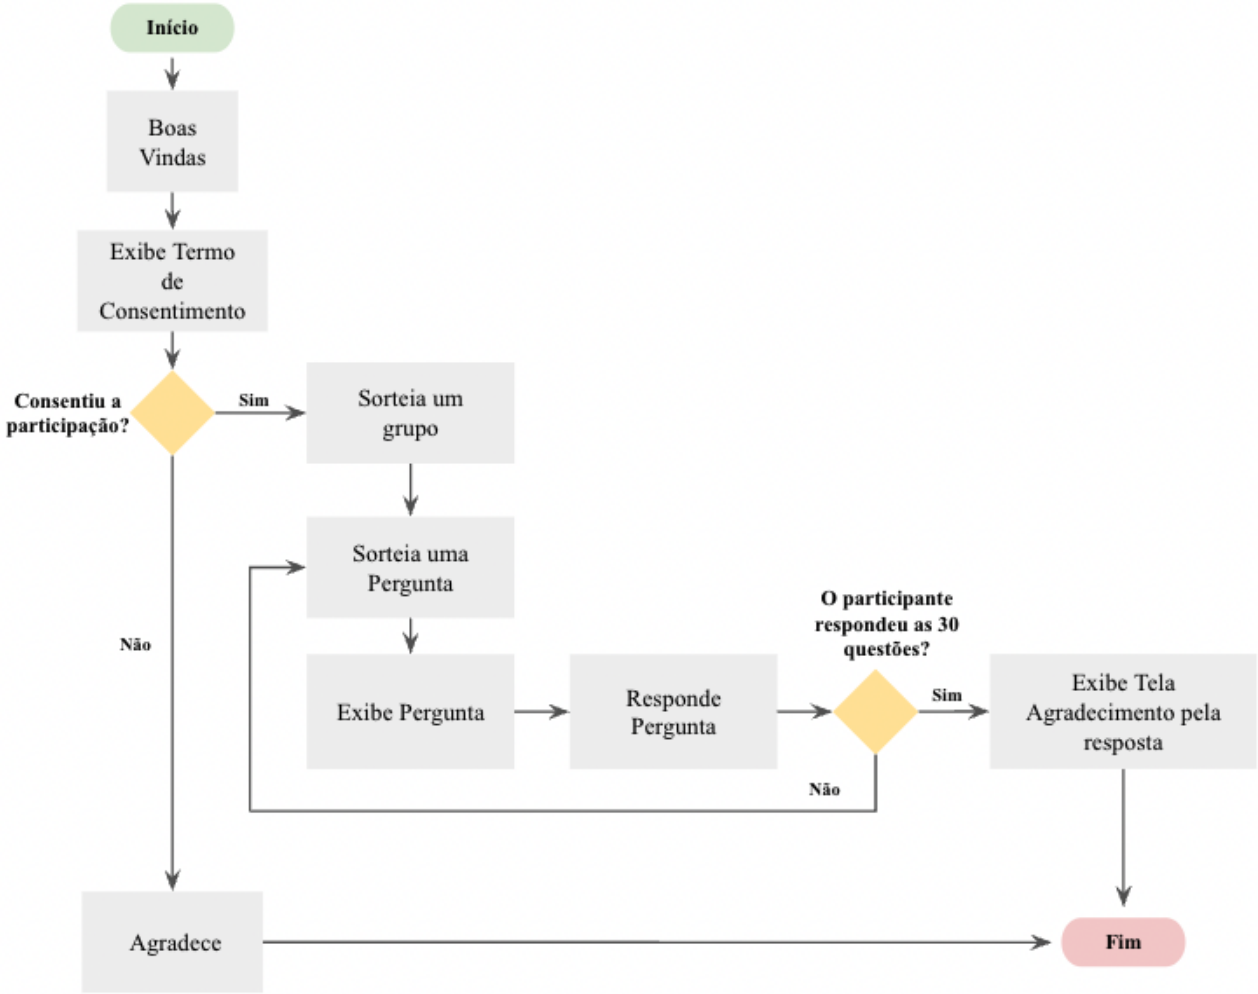

Figura IV.3: Método de rotulagem de mensagens textuais homofóbicas - MRMTH

IV.4 Método de classificação de aprendizado de máquina (MCAM)

O MCAM utiliza o dataset de tweets rotulados quanto ao conteúdo homofóbico descrito na seção IV.3. Os classificadores aplicados ao conjunto de dados são avaliados quanto as métricas descritas no capítulo II (e.g., precisão, revocação e F1-measure).

Nesta etapa , utiliza-se a biblioteca *sklearn*[5] do *python*, considerando duas abordagens iniciais. A primeira faz uso de modelos tradicionais, com o classificador K-vizinhos mais próximos ou *KNN*[6] e o classificador árvore de decisão ou *Decision Tree*[7]. A segunda faz uso de modelos ensemble, com o classificador Floresta Aleatória ou *Random Forest*[8]. Além disso, com o objetivo de ajustar os melhores parâmetros para os modelos em questão, adota-se o *GridSearchCV*[9] que avalia exaustivamente possíveis candidatos a parâmetros. Por fim, para avaliar a qualidade dos classificadores, analisa-se matriz de confusão, o método de validação cruzada e as métricas de precisão, revocação e F1-measure.

[5] `https://scikit-learn.org/stable/index.html`
[6] `https://scikit-learn.org/stable/modules/neighbors.html`
[7] `https://scikit-learn.org/stable/modules/tree.html`
[8] `https://scikit-learn.org/stable/modules/ensemble.html#forests-of-randomized-trees`
[9] `https://scikit-learn.org/stable/modules/grid_search.html`

Capítulo V Avaliação Experimental

O capítulo de Avaliação Experimental tem como objetivo descrever acerca dos experimentos realizados. Os experimentos seguem a metodologia proposta no capítulo IV, para cada um dos métodos elencados. Inicialmente, apresenta-se a aplicação do MCLH e suas especificidades. Em seguida, relata-se o MCDT e seus detalhes. Na sequência, discorre-se sobre uma simulação ao MRTH e o cenário incipiente. Por fim, expõe-se o MCAM e uma abordagem inicial.

V.1 MCLH

A incipiência de um léxico homofóbico faz com que seja necessário abranger termos e expressões que não foram contemplados na plataforma *Hatebase*. Conforme descrito no capítulo IV, uma pesquisa de opinião com seres humanos foi proposta para resolver tal limitação.

O questionário foi construído na plataforma *Google Forms* a partir de duas perguntas. A primeira referia-se aos termos e expressões conhecidos *a priori*, a resposta era obrigatória para "*Conheço*" e "*Não conheço*". A pergunta consistia no seguinte texto: "*Dos termos homofóbicos listados abaixo, marque os que você conhece e os que não conhece*", conforme figura V.1.

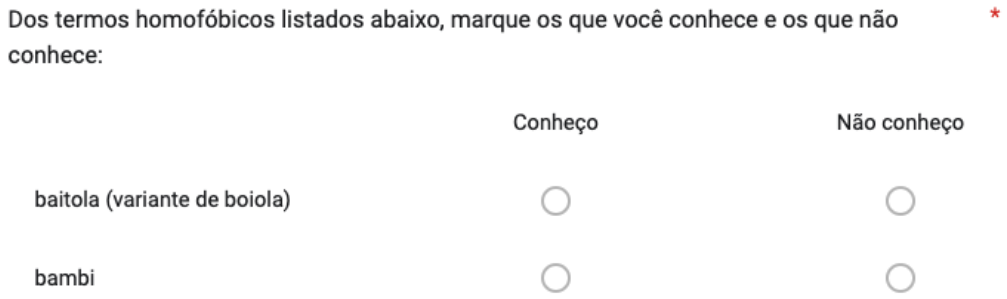

Figura V.1: MCLH - Pergunta 1 - Exemplo de termos homofóbicos Hatebase (demais omitidos)

A segunda pergunta referia-se a contribuição incremental ao léxico homofóbico, a resposta era obrigatória e e perguntava-se: "*Você conhece algum outro termo, expressão homofóbica? Escreva aqui, separado por vírgula*", conforme ilustrado na figura V.2.

Você conhece algum outro termo, expressão homofóbica? Escreva aqui, separado por vírgula: *

Texto de resposta longa

Figura V.2: MCLH - Léxico homofóbico - Pergunta 2

A pesquisa foi disponibilizada por meio da url `https://forms.gle/R2pcz7x1RdpH8kii8`, no período entre os dias 01 de julho de 2022 e 10 de julho de 2022. O recrutamento dos participantes ocorreu utilizando as mídias sociais, como *Facebook*, *Whatsapp* e *Linkedin*, além de *e-mail* aos grupos de coordenadores do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca - Cefet/RJ. Ao término do período de pesquisa, obteve-se o total de 487 pessoas respondentes.

A partir da análise dos dados coletados, pode-se construir a base de dados desejada. Para isso, os seguintes passos foram considerados:

- Separação dos termos ou expressões por vírgula na pergunta 2;
- Contagem das ocorrências de cada termo;
- Filtragem dos termos com mais de uma ocorrência.

Ao término dos passos da análise, 54 termos ou expressões homofóbicas foram considerados na criação do Léxico, incluindo os termos provenientes do *Hatebase*, disponível para consulta no Apêndice C. Os passos seguintes da metodologia são simulados com um léxico homofóbico menor (i.e., "bicha", "viado", "sapatão", "boiola" e "traveco"), para que seja possível ilustrar à banca de qualificação os efeitos práticos a serem abordado na entrega final da dissertação.

V.2 Simulação: MCDT

O MCDT utiliza a base de léxico homofóbico criada na seção V.1. Conforme a metodologia descrita no capítulo IV, a coleta dos dados ocorreu pelo acesso a *API* do *Twitter* com o uso da biblioteca *tweepy*.

O primeiro passo foi conectar com as credenciais da *API*, via linguagem de programação *Python*. Após isso, cada um dos 5 termos homofóbicos foram buscados, "bicha", "viado", "sapatão", "boiola" e "traveco", respeitando os critérios estabelecidos na metodologia. Por fim, uma amostra de 60 textos para cada termo foi considerada, totalizando 300 *tweets* extraídos.

Após a etapa de tratamento dos textos, uma ilustração das 20 palavras mais frequentes pode ser analisada, conforme figura V.3. Os termos homofóbicos são os mais frequentes, já que a coleta os utilizou para extração dos *tweets*. Uma outra verificação a partir da figura V.3, é que dentre os

termos mais frequentes estão as palavras de uso na comunicação na internet, como a palavra “ta” para “está”. Essa limitação será abordada no capítulo de conclusão inicial da qualificação, como próximos passos da dissertação.

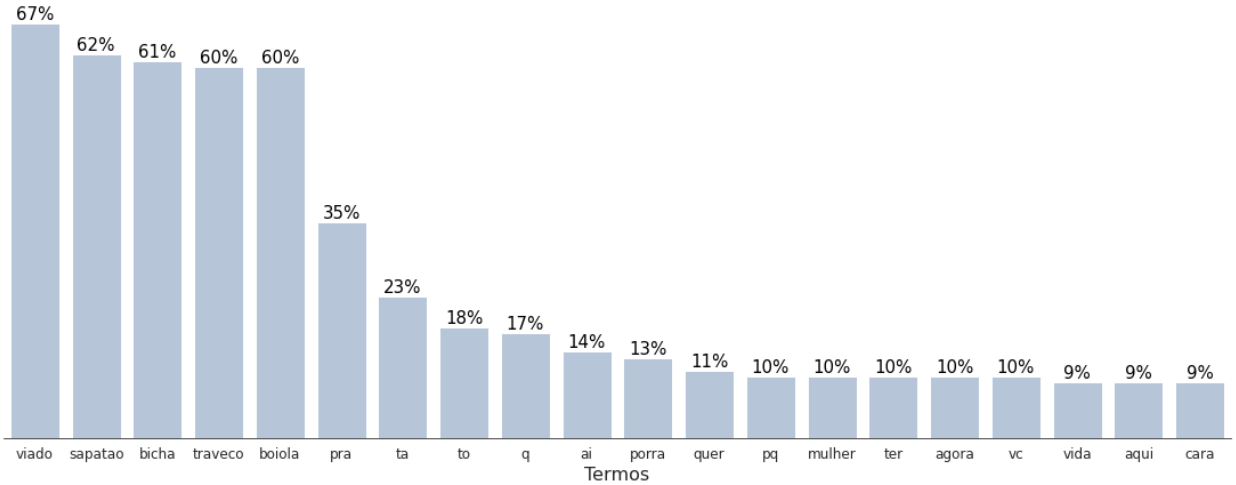

Figura V.3: Termos mais frequentes

Generalizando os termos mais frequentes, a nuvem de palavras permite, visualmente, avaliar todo conjuntos de termos que foram extraídos dos *tweets*, conforme figura V.4. O tamanho das palavras dentro da nuvem indica a frequência de cada uma em relação às demais. Além dos termos mais frequentes ilustrados na figura V.3, também é possível observar o uso de expressão de risada, como o caso de “kkkkkkk”. Esse é mais um exemplo de limitação da remoção das *stopwords* que será mencionado na conclusão inicial da qualificação.

Figura V.4: Termos mais frequentes

Uma outra característica de interesse para a proposta de classificação automática de textos é o número de palavras de cada um dos textos. A figura V.5 ilustra a distribuição do número de palavras, no qual a maior parte dos *tweets* extraídos contém 5 palavras, ou aproximadamente 8% deles.

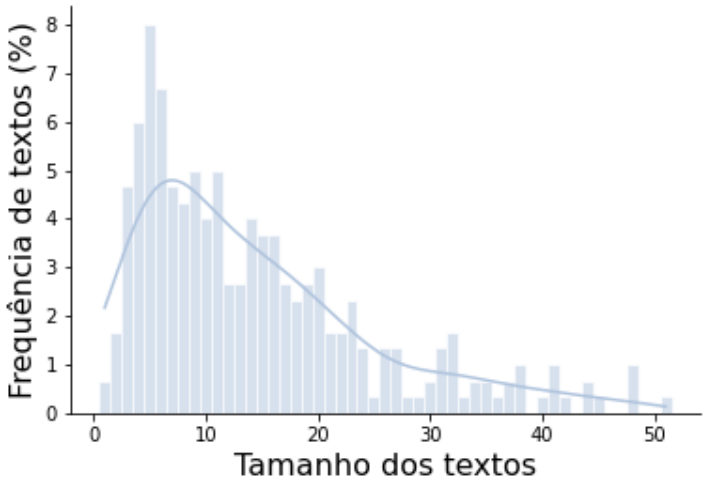

Figura V.5: Histograma do número de palavras dos tweets

Os *tweets* com mais de 21 palavras são aqueles presentes na cauda longa, conforme figura V.5. Um recorte do tamanho das palavras dos *tweets* até 21 é proposto para ilustrar melhor os percentuais de textos, conforme figura V.6.

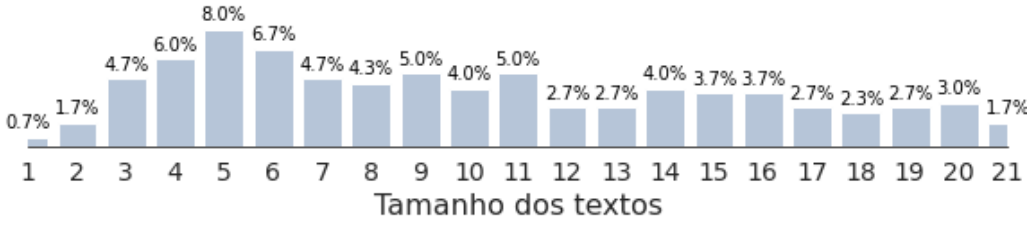

Figura V.6: Distribuição número de palavras dos tweets - Corte até 21 palavras

O recorte proposto na figura V.6 evidencia que aproximadamente 2,4% da base de dados possui menos de 3 palavras, ou 7 dos 300 textos extraídos do Twitter. Essa informação constará como limitação do texto da qualificação a ser abordado na dissertação, para a definição de um número mínimo de palavras por texto.

V.3 Simulação: MRTH

A não existência de uma base de dados rotuladas para o discurso de ódio homofóbico é uma limitação a ser superada por meio do MRTH. Para a simulação proposta para a qualificação, um total de 300 textos foram coletados do *Twitter* para os 5 termos homofóbicos iniciais, “bicha”, “viado”, “sapatão”, “boiola” e “traveco”.

O questionário de coleta dos rótulos foi construído na plataforma *PCIBEX*, de acordo com a metodologia proposta, e ficou disponível na url `https://farm.pcibex.net/p/ugwObt/` no dia 31 de julho de 2022. Três respondentes foram convidados a participar, por meio de envio da url na mídia social *Whatsapp*, levando em média 40 minutos para concluir a pesquisa. Os participantes julgaram cada *tweet* extraído, respondendo como "sim", "não"e "não tenho certeza"a pergunta se o conteúdo era homofóbico, conforme exemplo da figura V.7.

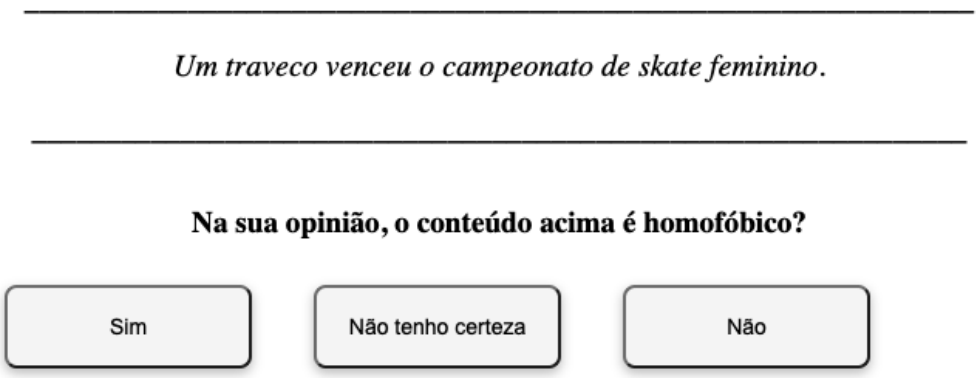

Figura V.7: Rotulagem mensagens potencialmente homofóbicas

Ao término da simulação do MRTH, pode-se analisar os resultados das respostas dos participantes. O rótulo de cada *tweet* foi considerado seguindo a opinião da maioria dos julgadores, ou seja, 2 julgamentos ou mais e em caso de empate, a classificação do texto ficou como "empate". O resultado dos trezentos textos rotulados pelos três respondentes pode ser analisado pela figura V.8.

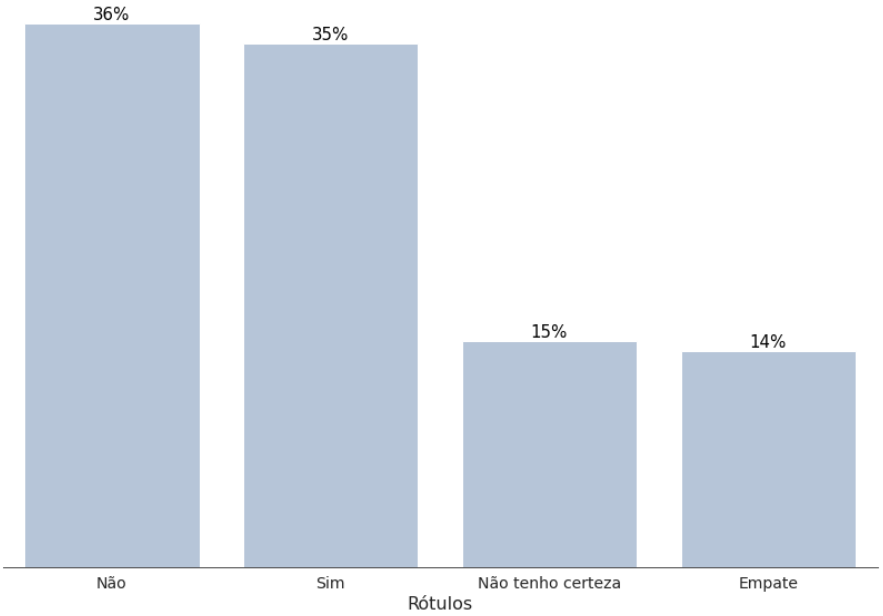

Figura V.8: Frequência dos rótulos - Simulação

Observa-se pela figura V.8 que, aproximadamente 71% dos *tweets* rotulados puderam ser considerados no julgamento, sendo o rótulo "sim" para 34,7% (ou 104 tweets) e o rótulo "não" para 36,0% (ou 108 tweets). Os outros 30% foram considerados como dúvida no julgamento, por não ter certeza sobre o julgamento ou pelo empate entre os três respondentes.

Como interesse dessa etapa, pode-se avaliar a quantidade de palavras dos *tweets* por rótulo, com a finalidade de identificar se as pessoas têm certeza sobre o conteúdo quando o texto é maior ou menor, por exemplo. A figura V.9 ilustra a distribuição do número de palavras dos tweets extraídos para cada rótulo.

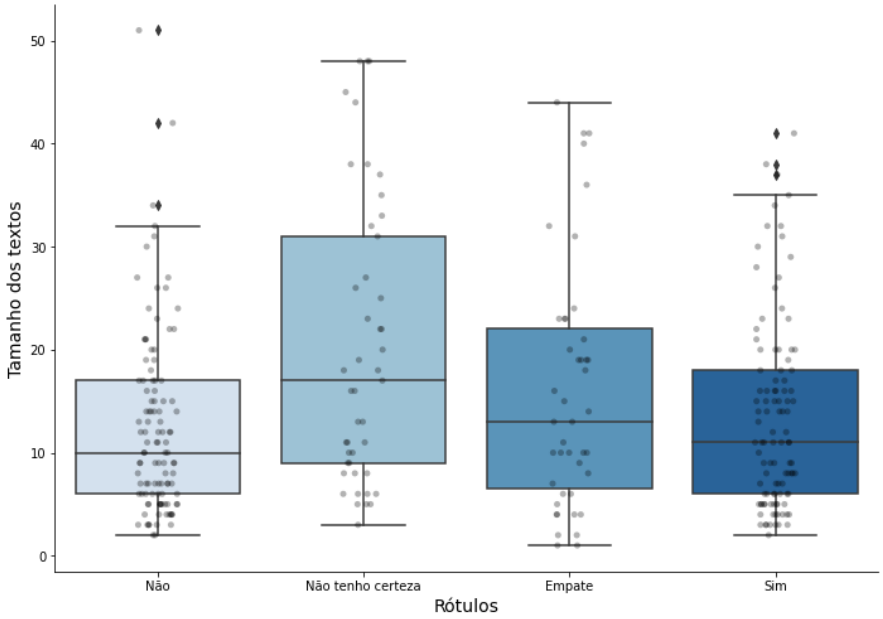

Figura V.9: Boxplot rótulos por tamanho das frases

O *boxplot* permite verificar que o rótulo "Não tenho certeza" apresenta a maior mediana, enquanto os rótulos "Sim" e "Não" apresentam as menores, porém com presença de outliers. O rótulo "Empate" é o que possui o menor limite inferior, cujo tamanho de palavras no texto é 1. Esse é um indicativo de que a avaliação quando só 1 palavra está presente gera dificuldade de julgamento para os respondentes, ficando somente o termo homofóbico. Observa-se ainda que tweets entorno de 10 palavras foram aqueles onde foi possível o julgamento para "sim" ou "não".

V.4 Simulação: MCAM

A simulação do MCAM tem por objetivo utilizar as abordagens dos modelos de aprendizado de máquina, conforme descrito no capítulo IV. Para isso, três classificadores foram analisados com o ajuste dos hiper-parâmetros por meio da função *GridSearchCV* utilizando uma estratégia de

validação cruzada com o número de partições igual a cinco.

Os modelos de classificação abordados são: modelos tradicionais (k-vizinhos mais próximos e árvore de decisão) e modelo ensemble (florestas aleatórias). Inicialmente, são exibidos os hiper parâmetros ajustados. Na sequência, são ilustradas as matrizes de confusão para os dados de treinamento para cada um dos modelos. A matriz de confusão exibe as classes reais e as classes previstas, de modo que 0 é a classe "não" e 1 é a classe "sim" para conteúdo homofóbico. Em seguida, os modelos são avaliados considerando as métricas de F1-Score, precisão e revocação. Por fim, utiliza-se a validação cruzada como técnica para avaliar a capacidade de generalização do modelo, para todo conjunto de dados.

V.4.1 K-vizinhos mais próximos ou KNN

O ajuste dos parâmetros do modelo de classificação K-vizinhos próximos, utilizou-se como parâmetros iniciais o tamanho dos vizinhos: [1,31]. O resultado do ajuste do parâmetro foi número de vizinhos igual a 27 e a figura V.10 ilustra a matriz de confusão para o classificador aplicado aos dados de treinamento, com o parâmetro ajustado.

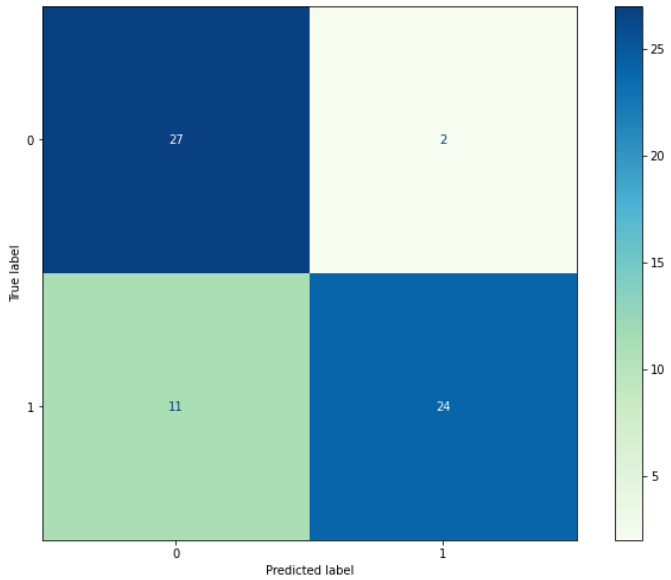

Figura V.10: Matriz de confusão dados de teste - Classificador KNN

A partir da matriz de confusão, podemos avaliar o modelo aplicado aos dados de teste com as métricas de interesse: precisão de 83,09%, revocação de 77,14% e F1-measure de 83,08%. Por fim, a partir da validação cruzada do modelo aplicado a todo conjunto de dados, tem-se as seguintes métricas: precisão de 78% com desvio padrão de 7%, revocação de 77% com desvio padrão de 6% e F1-measure de 77% com desvio padrão de 6.

V.4.2 Árvore de decisão ou Decision Tree

O ajuste dos parâmetros do modelo de classificação Árvore de Decisão, utilizou-se como parâmetros iniciais o tamanho máximo de folhas [2,100] e o número mínimo de amostras da divisão [2, 3, 4]. O resultado do ajuste dos parâmetros foi tamanho máximo de folhas igual a 2 e número mínimo de amostras da divisão igual a 2. A figura V.11 ilustra a matriz de confusão para os dados de teste, com os parâmetros ajustados.

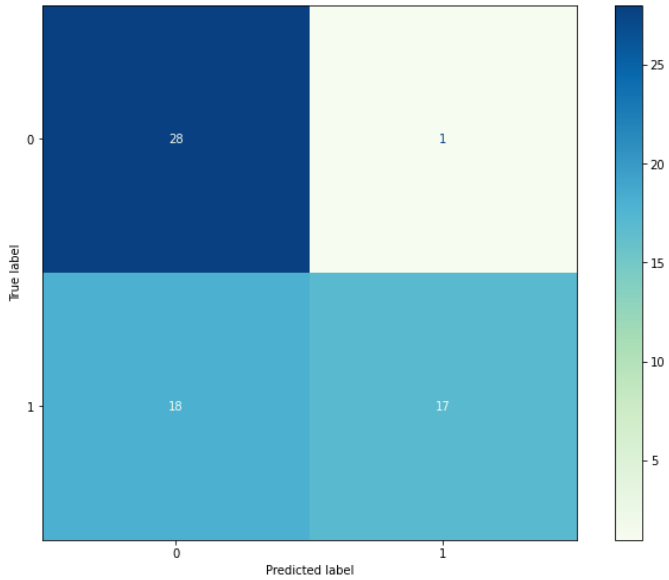

Figura V.11: Matriz de confusão Teste - Classificador Decision Tree

As métricas de interesse avaliadas a partir da matriz de confusão são: precisão de 94,44%, revocação de 48,57% e F1-measure: 64,15%. A partir da validação cruzada do modelo, por fim, tem-se as métricas a todo conjunto de dados: precisão de 81% com desvio padrão de 8%, revocação de 73% com desvio padrão de 7% e F1-measure de 71% com desvio padrão de 9%.

V.4.3 Florestas aleatórias ou Random Forest

Utilizou-se para o ajuste dos parâmetros do modelo de classificação Florestas aleatórias os seguintes atributos iniciais:

- número de estimadores: entre 200 e 500
- máximo de recursos: “auto”, “sqrt”e “log2”
- profundidade máxima da árvore: [4,5,6,7,8]
- critério para medir a qualidade de uma divisão: [“gini”, “entropy”]

Como resultado desse processo de ajuste dos parâmetros, tem-se número de estimadores 200, máximo de recursos igual a "auto", profundidade máxima da árvore igual a 6 e critério para medir a qualidade de uma divisão igual a "entropy". Na sequência, a matriz de confusão foi utilizada aos dados de teste, conforme figura V.12.

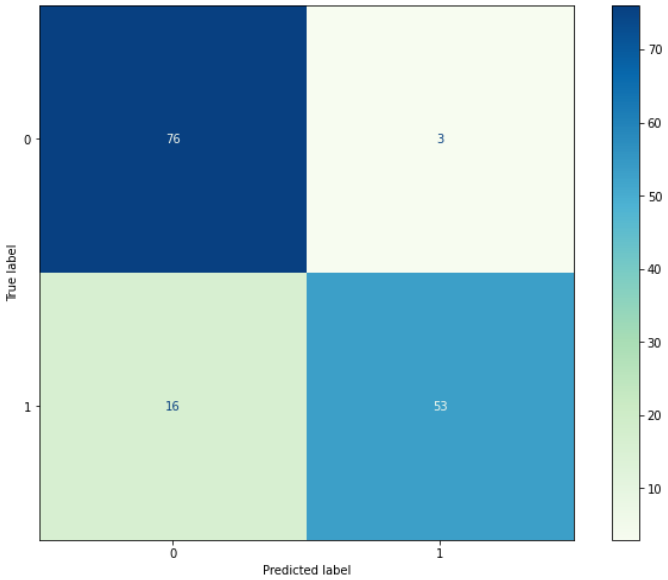

Figura V.12: Matriz de confusão Treinamento - Classificador Random Forest

A partir da matriz pode-se calcular as métricas de avaliação de interesse, sendo elas: precisão de 96,77%, revocação de 85,71% e F1-measure: 90,91%. A partir da validação cruzada do modelo, por fim, tem-se as métricas aplicadas a todo conjunto de dados: precisão de 81% (desvio padrão de 6%), revocação de 80% (desvio padrão de 6%) e F1-measure de 80% (desvio padrão de 6%).

V.4.4 Resumo dos classificadores

Ao término da aplicação dos modelos de classificação aos dados extraídos do *Twitter*, pode-se resumir as métricas de avaliação dos mesmo por meio da tabela V.1. O modelo de classificação supervisionado que melhor se adapta aos dados, conforme as métricas de interesse avaliadas, é a Floresta Aleatória com precisão de 81%, revocação de 80% e F1-measure de 80%.

Classificador	Precisão	Revocação	F1-measure
K-vizinhos mais próximos	78,00%	77,00%	77,00%
Árvore de decisão	81,00%	73,00%	71,00%
Florestas aleatórias	81,00%	80,00%	80,00%

Tabela V.1: Simulação: Tabela resumo modelos de classificação - validação cruzada

Capítulo VI Conclusões

O objetivo geral da pesquisa foi desenvolver um método de identificação do discurso homofóbico em mensagens do *Twitter*, para conteúdos textuais na língua portuguesa. Como objetivos específicos, definiu-se: a criação de um léxico de termos homofóbicos, a criação de uma base de dados do *Twitter* a partir do uso do léxico de termos homofóbicas, a rotulagem dos textos extraídos quanto ao julgamento "é conteúdo homofóbico", "não é conteúdo homofóbico" e "não tem certeza". Por fim, a aplicação de modelos de classificação de aprendizado ao dataset de tweets rotulados, para: (i) máquina tradicionais, como SVM, KNN, DT e Naive Bayes; (ii) classificadores ensemble como, Random Forest, Adaptive Boosting e Gradient Boosting; (iii) redes neurais artificiais (deep learning).

A MCACH foi dividida em etapas do processo. O MCLH é o passo no processo de geração do Léxico, o MCDT é a etapa de geração do dataset de *tweets*. O MRTH é o estágio de geração do dataset de *tweets* rotulados. Por fim, o MCAM é o passo da classificação dos tweets quanto a homofobia.

Como proposta de abordagem inicial para o texto de qualificação, as etapas a partir do MCDT foram simuladas para um universo de 5 termos ou expressões homofóbicas, "bicha", "viado", "sapatão", "boiola" e "traveco". A coleta de dados considerou 60 *tweets* para cada um dos 5 termos, totalizando 300 textos extraídos. A etapa do MRTH foi simulada por meio de 3 julgadores e o MCAM utilizou, inicialmente, como modelos de classificação tradicionais KNN e DT e modelo ensemble para Florestas Aleatórias. Considerando a simulação, o classificador que melhor se adapta aos dados, seguindo métricas de avaliação e validação cruzada, é o modelo ensemble para Florestas Aleatórias com precisão de 81,00%, revocação de 80,00% e F1-measure de 80,00% .

Algumas limitações foram mapeadas durante a avaliação experimental, sendo necessário considerá-las no trabalho de dissertação. São elas:

- extensão para os 54 temos ou expressões homofóbicas para a coleta dos dados para etapa do MCDT;
- extensão de 300 textos para 3.240 textos, com isso o maior número de julgadores para o MRTH;
- considerar como stopwords termos oriundos da fala na internet;

- considerar o número mínimo de palavras para cada *tweet* coletado;
- expandir os classificadores para os outros modelos de interesse não abordados no texto da qualificação, como os modelos tradicionais SVM e Naive Bayes, modelos ensemble como *Adaptive Boosting* e *Gradient Boosting*, e redes neurais artificiais profundas (*deep learning*);
- revisão da fundamentação teórica considerando trabalhos relevantes para métricas e classificadores, como Jiawei Han e Micheline Kamber para a obra *Data Mining: Concepts and Techniques*.

O planejamento dos próximos passos orienta o desenvolvimento da dissertação e a superação das limitações elencadas na qualificação. Por meio da figura VI.6, ilustra-se o cronograma das atividades necessárias para conclusão do trabalho.

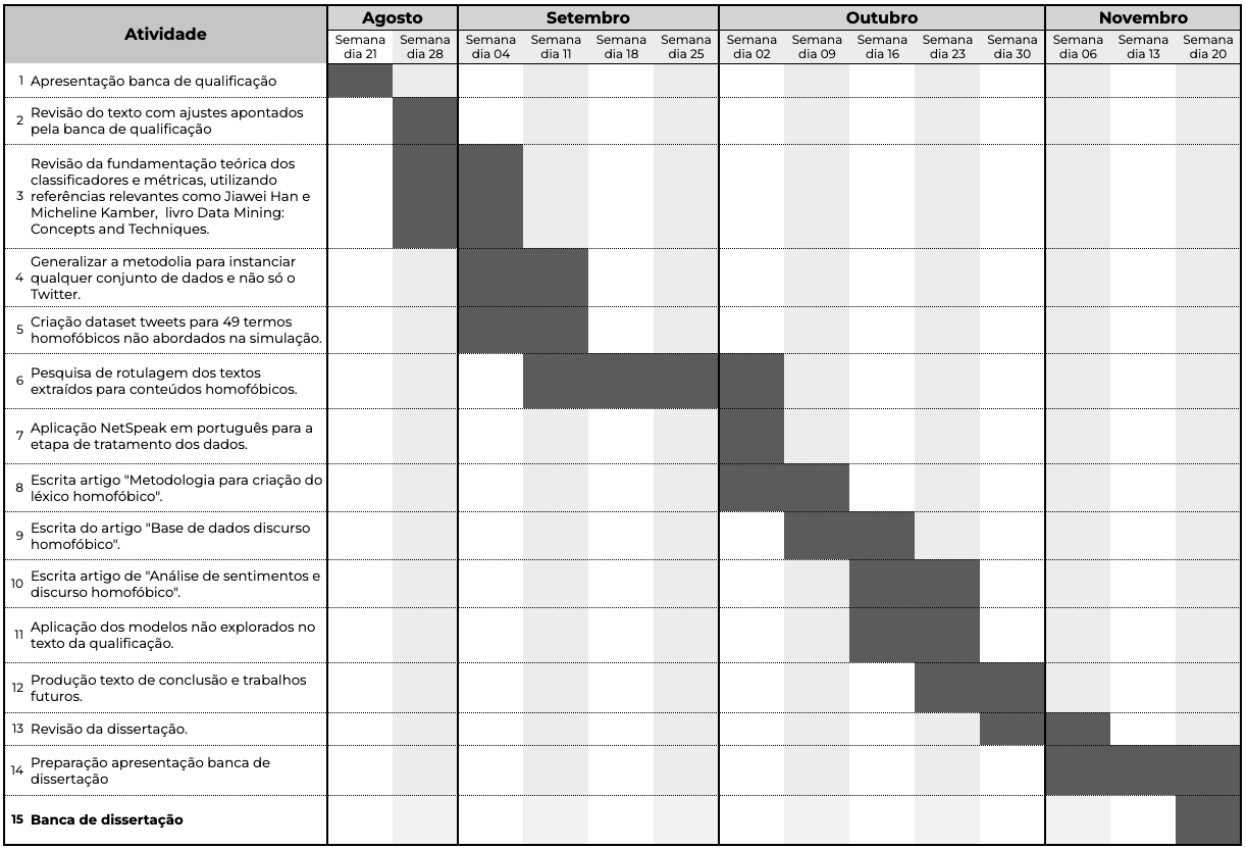

Figura VI.1: Planejamento etapas desenvolvimento dissertação

Referências Bibliográficas

Brasil (2019). *Direito Constitucional - Ação Direta de Inconstitucionalidade por omissão*. Supremo Tribunal Federal. `http://www.stf.jus.br/arquivo/informativo/documento/informativo931.htm`. Acessado em 14 de setembro de 2020. 2

Burnap, P. and Williams, M. L. (2015). Cyber hate speech on twitter: An application of machine classification and statistical modeling for policy and decision making. *Policy & Internet*, 7(2):223–242. Acessado em 21 de setembro de 2020. 17

Costa, A. B. and Nardi, H. C. (2015). Homofobia e preconceito contra diversidade sexual: debate conceitual. *Temas em Psicologia*, 23:715 – 726. 1

Coutinho, V. M. and Malheiros, Y. (2020). Detecção de mensagens homofóbicas em português no twitter usando análise de sentimentos. pages 1–12, Porto Alegre, RS, Brasil. SBC. `https://sol.sbc.org.br/index.php/brasnam/article/view/11158`. Acessado em 21 de setembro de 2020. 16, 17

Davidson, T., Warmsley, D., Macy, M., and Weber, I. (2017). Automated hate speech detection and the problem of offensive language. 16

de Pelle e Viviane P. Moreira, R. P. (2017). Offensive comments in the brazilian web: a dataset and baseline results. 15

Exame (2022). *Redes sociais registram 4,62 bi de usuários - e vão continuar crescendo*. `https://exame.com/colunistas/empreender-liberta/redes-sociais-registram-462-bi-de-usuarios-e-vao-continuar-crescendo/`. Acessado em 23 de julho de 2022. 1

Fortuna, P., Rocha, J., Soler Company, J., Wanner, L., and Nunes, S. (2019a). A hierarchically-labeled portuguese hate speech dataset. pages 94–104. 15, 17

Fortuna, P., Rocha da Silva, J., Soler-Company, J., Wanner, L., and Nunes, S. (2019b). A hierarchically-labeled Portuguese hate speech dataset. In *Proceedings of the Third Workshop on Abusive Language Online*, Florence, Italy. Association for Computational Linguistics. `https://www.aclweb.org/anthology/W19-3510`. Acessado em 21 de setembro de 2020. 3, 16

Guimarães, L. M. S., Meireles, M. R. G., and Almeida, P. E. M. d. (2019). Avaliação das etapas de pré-processamento e de treinamento em algoritmos de classificação de textos no contexto da recuperação da informação. *Perspectivas em Ciência da Informação*, 24:169 – 190. http://www.scielo.br/scielo.php?script=sci_arttext&pid=S1413-99362019000100169&nrm=iso. Acessado em 21 de setembro de 2020. 7

Hatebase, I. (2020). How it works? https://hatebase.org/how_it_works. Acessado em 13 de setembro 2020. , 3, 20

Honey, C. and Herring, S. (2009). Beyond microblogging: Conversation and collaboration via twitter. pages 1 – 10. Acessado em 21 de setembro de 2020. 1

Hossin, M. and M.N, S. (2015). A review on evaluation metrics for data classification evaluations. *International Journal of Data Mining & Knowledge Management Process*, 5:01–11. https://www.researchgate.net/publication/275224157_A_Review_on_Evaluation_Metrics_for_Data_Classification_Evaluations .Acessado em 22 de setembro de 2021. 11

Investe, V. (2022). *Brasil tem a quarta maior base de usuários do Twitter no mundo*. https://valorinveste.globo.com/mercados/internacional-e-commodities/noticia/2022/04/25/brasil-tem-a-quarta-maior-base-de-usuarios-do-twitter-no-mundo.ghtml. Acessado em 23 de julho de 2022. 1

Khurana, D., Koli, A., Khatter, K., and Singh, S. (2017). Natural language processing: State of the art, current trends and challenges. Acessado em 18 de dezembro de 2021. 6

Kusner, Matt e Sun, Y. and Kolkin, Nicholas e Weinberger, K. (2015). From word embeddings to document distances. In Bach, F. and Blei, D., editors, *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pages 957–966, Lille, France. PMLR. 6

MacAvaney, S., Yao, H.-R., Yang, E., Russell, K., Goharian, N., and Frieder, O. (2019). Hate speech detection: Challenges and solutions. *PLOS ONE*, 14(8):1–16. https://doi.org/10.1371/journal.pone.0221152. Acessado em: 2020-09-21. 3, 16

Meyer-Pflug, S. R. (2008). *Discurso do ódio*. Tese (Doutorado em Direito) - Pontifícia Universidade Católica de São Paulo, São Paulo. Acessado em 23 de julho de 2022. 1

Monard, M. C. and Baranauskas, J. A. (2003). Conceitos sobre aprendizado de máquina. In *Sistemas Inteligentes Fundamentos e Aplicações*, pages 89–114. Manole Ltda, Barueri-SP, 1 edition. http://dcm.ffclrp.usp.br/~augusto/publications/2003-sistemas-inteligentes-cap4.pdf. Acessado em 21 de setembro de 2020. 7

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830. 8, 9, 10

Recuero, R. (2012). *A conversação em rede: comunicação mediada pelo computador e redes sociais na Internet*. Porto Alegre: Sulina. `http://www.raquelrecuero.com/livros/a_conversacao_em_rede.pdf`. Acessado em 13 de setembro de 2021. 1

Ricci, F., Rokach, L., Shapira, B., and Kantor, P. B. (2010). *Recommender Systems Handbook*. Springer-Verlag, Berlin, Heidelberg, 1st edition. 7, 12

Saha, K., Kim, S. C., Reddy, M. D., Carter, A. J., Sharma, E., Haimson, O. L., and Choudhury, M. D. (2019). The language of lgbtq+ minority stress experiences on social media. *Proceedings of the ACM on Human-Computer Interaction*, 3:1 – 22. 17

Silva, A. and Roman, N. (2020). Hate speech detection in portuguese with naïve bayes, svm, mlp and logistic regression. In *Anais do XVII Encontro Nacional de Inteligência Artificial e Computacional*, pages 1–12, Porto Alegre, RS, Brasil. SBC. 16

S.PAULO, O. E. D. (2017). Youtuber contratado pelo governo fez posts racistas e homofóbicos no Twitter. `https://emais.estadao.com.br/noticias/gente/youtuber-contratado-por-temer-fez-posts-racistas-e/homofobicos-no-twitter-confira,70001670052`. Acessado em 16 de setembro de 2020. , 2

Twitter, I. (2020). Perguntas frequentes de novos usuários. `https://help.twitter.com/pt/new-user-faq`. Acessado em 13 de setembro de 2021. 1, 3, 4, 22

UOL (2010). *Grupo gay condena perfil homofóbico que já tem 15 mil adeptos no Twitter*. `https://noticias.uol.com.br/cotidiano/ultimas-noticias/2010/11/18/grupo-gay-condena-perfil-homofobico-do-twitter-que-ja/tem-15-mil-adeptos.htm`. Acessado em 16 de setembro de 2020. 2

UOL (2020). *Entenda o que significa cada uma das letras desta bandeira de luta*. `https://www.uol.com.br/universa/amp-stories/lgbtqi-entenda-as-letras`. Acessado em 13 de setembro de 2021. 2

Vandersmissen, B. (2012). Automated detection of offensive language behavior on social networking sites. `https://lib.ugent.be/fulltxt/RUG01/001/887/239/RUG01-001887239_2012_0001_AC.pdf`. Acessado em 20 de setembro de 2021. 17

Vilela, M. (1997). O léxico do português: perspectiva geral. *Filologia e Linguística Portuguesa*, (1):31–50. http://www.revistas.usp.br/flp/article/view/59644. Acessado em 21 de setembro de 2020. 6

Apêndice A

O Programa de Pesquisa Acadêmica do Twitter concede acesso à API do Twitter para pesquisadores acadêmicos, de maneira gratuita. A submissão se deu através de acesso a `https://developer.twitter.com/en/use-cases/do-research/academic-research`, inserindo um breve relato da pesquisa que se quiser realizar, indicando o professor orientador, a instituição de ensino e uma comprovação do vínculo do pesquisador com a instuição.

A figura VI.2 ilustra o email de confirmação da submissão, em seguida, no mesmo dia, foi recebido a aprovação da submissão conforme VI.3.

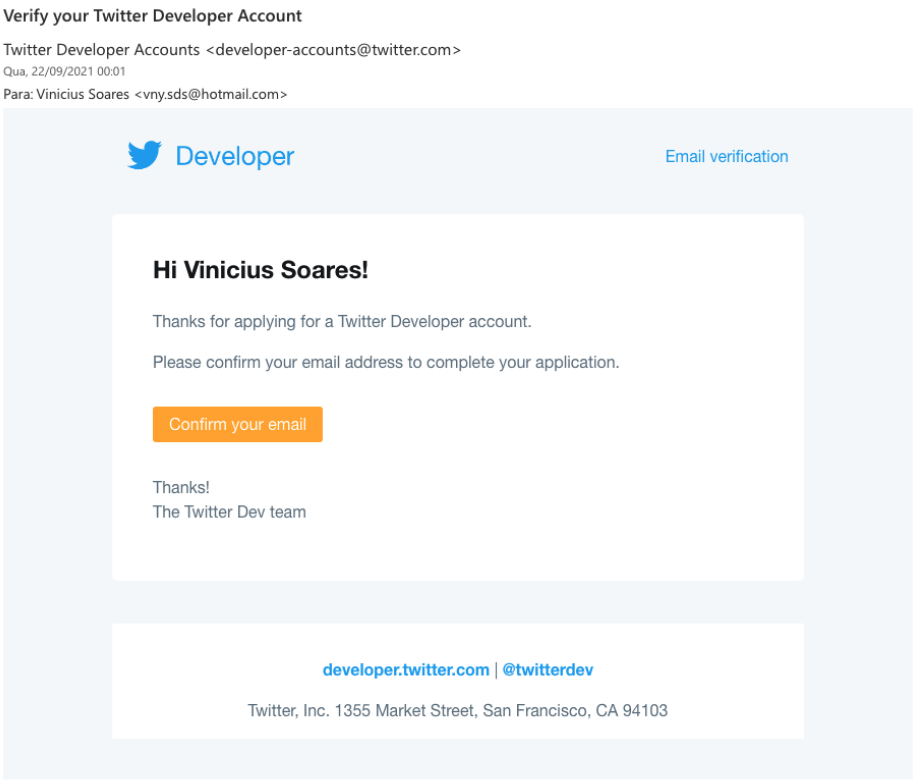

Figura VI.2: E-mail de confirmação da submissão API Twitter v2 - Pesquisador

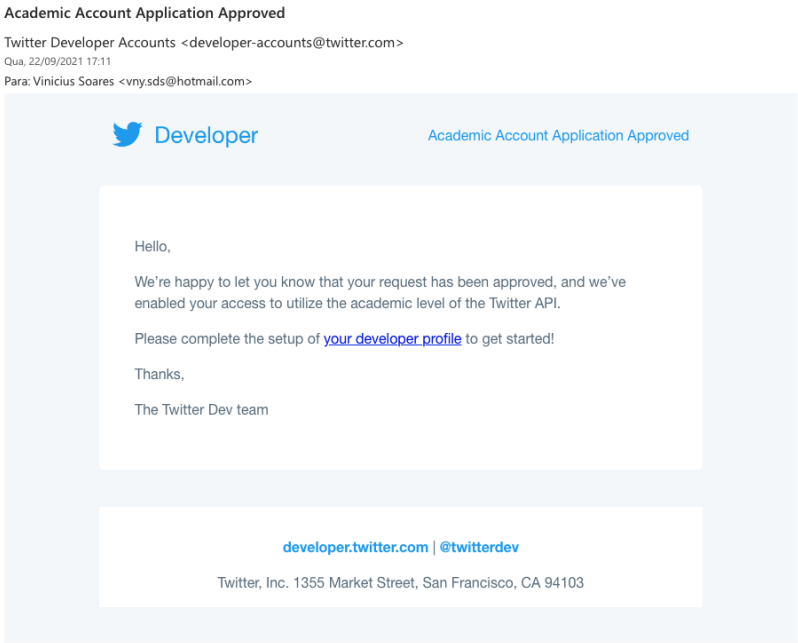

Figura VI.3: E-mail de aprovação da submissão API Twitter v2 - Pesquisador

A figura VI.4 ilustra o resumo do projeto na API, bem como as credenciais de acesso a mesma.

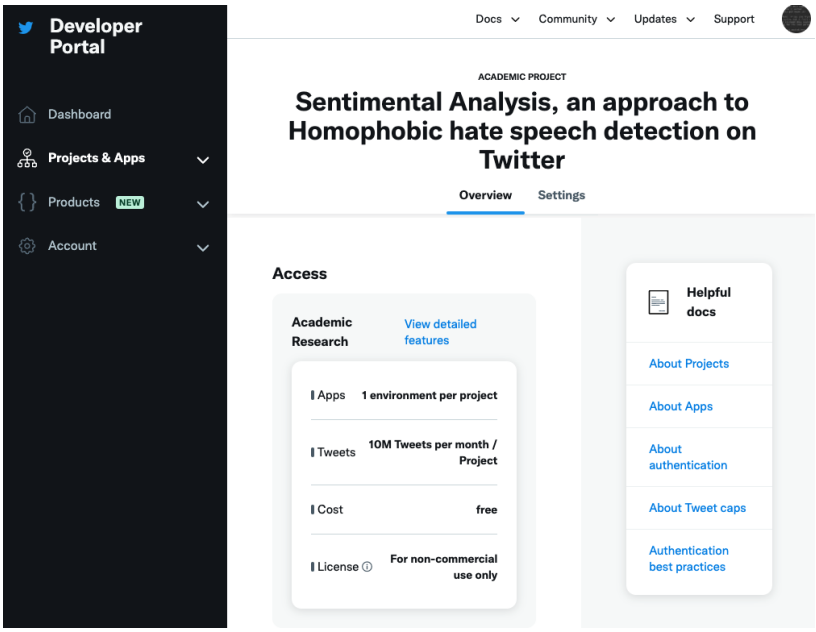

Figura VI.4: Área do desenvolvedor API Twitter v2 - Pesquisador

Apêndice B

Projeto de pesquisa, Léxico de termos homofóbicos e a identificação da homofobia em mensagens textuais

A presente pesquisa, denominada Léxico de termos homofóbicos e a identificação da homofobia em mensagens textuais, tem por objetivo a construção de uma base de dados textuais com conteúdos extraídos do Twitter. Para atingir tal objetivo, inicialmente é aplicado um questionário para construir um Léxico de Termos homofóbicos. A expectativa é que a pesquisa possa contribuir com a construção de um método de identificação automática de conteúdos de discurso de ódio homofóbico.

Os possíveis benefícios dessa pesquisa são: 1) Referencial bibliográfico para estudos sobre a homofobia; 2) Publicação e disponibilização dos conteúdos textuais rotulados para treinamento de futuros modelos de classificação de textos, como no caso de aprendizado de máquina; 3) Contribuir com a construção de método de identificação automática de conteúdos de discurso de ódio homofóbico.

A pesquisa possui os seguintes riscos: (1) os indivíduos acharem inapropriado responder ao questionário. Como mitigação a esse risco o participante está recebendo esse documento de Termo de Consentimento Livre e Esclarecido (TCLE) para que ele possa ter conhecimento da pesquisa e concordar ou não com sua participação. Somente os indivíduos que concordarem com o TCLE participarão da pesquisa. Os resultados do estudo serão divulgados exclusivamente pelos pesquisadores em formato de relatórios e/ou artigos científicos.

A pesquisa é liderada pelo Laboratório de Computação Afetiva (LaCAfe), grupo de pesquisa do CEFET-RJ. Está sendo desenvolvida no âmbito do PPCIC (Programa de Pós-graduação em Ciência da Computação), no curso de Mestrado em Ciência da Computação do CEFET/RJ.

Pesquisador: Vinícius Soares dos Santos
E-mail: vinicius.soares@aluno.cefet-rj.br

Professor Orientador: Gustavo Paiva Guedes e Silva
E-mail: gustavo.guedes@cefet-rj.br

Se você é maior de 18 anos, convidamos você a participar desse estudo. Sua participação é voluntária e você poderá desistir a qualquer momento. Sua participação no estudo não implicará em custos adicionais, não terá qualquer despesa com a realização dos procedimentos previstos nesse estudo. Também não haverá nenhuma forma de benefício acadêmico ou financeiro pela sua participação.

É garantido o direito a indenização diante de eventuais danos decorrentes da pesquisa. O Comitê de Ética em Pesquisa (CEP) da Universidade Salgado de Oliveira - ASOEC - UNIVERSO encontra-se à disposição para eventuais esclarecimentos éticos e outras providências que se façam necessárias (cepuniverso@nt.universo.edu.br - Telefone: (21) 2138-4983). Compreendo que posso me retirar do estudo a qualquer momento, sem sofrer qualquer penalidade.

Clicando no botão abaixo, dou meu consentimento de livre e espontânea vontade para participar deste estudo e garanto responder a esta pesquisa de forma honesta para contribuir ao máximo com os resultados propostos.

EU DECLARO QUE ENTENDI E ACEITO PARTICIPAR DESTA PESQUISA

Figura VI.5: Termo de consentimento livre e esclarecido

Apêndice C - Léxico homofóbico

Termos Homofóbicos
afeminada
afetada
agasalha croquete
aidetica
baitola
bambi
biba
bicha
boiola
caminhoneira
coca cola é fanta
cola velcro
dá a rosca
dá cu
dá ré no kibe
desmunheca
desviada
enrustida
entendida
escorregar no quiabo
fancha
flozô
franga
fresco
fruta
fufa
gay
guena
indeciso
kitty
mamador
manja rola
marica
maricona
mocinha
morde a fronha
mulher macho
mulherzinha
paneleira
pão com ovo
passiva
princesa
qualira
queima rosca
rabeta
sabonete
sapa
sapatão
tchola
transviado
traveco
viado
xibungo
xinxa

Apêndice D - Revisão sistemática

Motivo	Critério de Inclusão - O texto refere-se a Métodos ou Modelos de Classificação ou Detecção Textual do Discurso de Ódio (CI-MCDO)		Critério de Inclusão - O texto refere-se a Métodos ou Modelos de Classificação ou Detecção Textual do Discurso de Ódio Homofóbico (CI-MCDOH)	
	Absoluto	Percentual	Absoluto	Percentual
Abordagem ao viés da classificação	-	-	1	8,3%
Abordagem exclusivamente análise de sentimentos	1	5,6%	1	8,3%
Abordagem exclusivamente lexical	3	16,7%	1	8,3%
Abordagem geoespacial	-	-	1	8,3%
Abordagem meta algoritmo	1	5,6%	-	-
Abordagem multi banco de dados	-	-	1	8,3%
Abordagem multilingual	2	11,1%	2	16,7%
Abordagem rotulagem	-	-	3	25,0%
Abordagem série temporal	1	5,6%	-	-
Não descreve os algoritmos	2	11,1%	-	-
Não é um método de classificação textual	1	5,6%	-	-
Não possui métrica F1-measure	3	16,7%	-	-
Texto não disponível	2	11,1%	2	16,7%
Trata-se de uma revisão sistemática	2	11,1%	-	-
Total geral	18		12	

Figura VI.6: Tabela Revisão Sistemática - Decisão Significância