CEFET/RJ
DIRETORIA DE PESQUISA E PÓS-GRADUAÇÃO

DA ROTULAGEM AO MODELO: AMPLIFICAÇÃO DE DIVERGÊNCIAS ANOTATIVAS DE GÊNERO PARA ANÁLISE DE SENTIMENTOS EM PORTUGUÊS BRASILEIRO

Alexander Ramos Feitosa

Proposta de Dissertação de Mestrado apresentada ao Programa de Pós-graduação em Ciência da Computação, Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ, como parte dos requisitos necessários à obtenção do grau de mestre.

Orientador:
Gustavo Guedes Paiva e Silva

Rio de Janeiro,

13 de abril de 2026

Da Rotulagem ao Modelo: Amplificação de Divergências Anotativas de Gênero para Análise de Sentimentos em Português Brasileiro

Proposta de Dissertação de Mestrado em Ciência da Computação, Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, CEFET/RJ.

Alexander Ramos Feitosa

Aprovada por:

Presidente, Prof. D.Sc. Gustavo Paiva Guedes e Silva(orientador)

Rio de Janeiro,

13 de abril de 2026

RESUMO

Da Rotulagem ao Modelo: Amplificação de Divergências Anotativas de Gênero para Análise de Sentimentos em Português Brasileiro

Alexander Ramos Feitosa

Orientador:
Gustavo Guedes Paiva e Silva

Resumo da proposta de Dissertação submetida ao Programa de Pós-graduação em Ciência da Computação do Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ como parte dos requisitos necessários à obtenção do grau de mestre.

A anotação colaborativa em tarefas de Processamento de Linguagem Natural (PLN) é influenciada por características sociodemográficas dos anotadores, entre as quais o gênero constitui um fator documentado de divergência. Este trabalho investiga se classificadores de Análise de Sentimentos (AS), ao serem treinados sobre rótulos que refletem divergências anotativas de origem genérica, tendem a amplificar essas divergências em suas predições. Como resposta, propõe-se a Metodologia de Análise de Divergências Anotativas (MADA), cujo núcleo é o índice $\Delta\kappa$, definido como a diferença entre o κ de Cohen interanotador original e o κ estimado entre os grupos de predições do modelo.

A MADA é validada empiricamente sobre o corpus MQD-1222 ($N = 1.222$), anotado por oito colaboradores estratificados por gênero (4M/4F), com concordância inicial $\kappa = 0{,}7664$ (IC 95% [0,7363; 0,7954]). Quatro classificadores foram avaliados por validação cruzada estratificada com representação TF-IDF: Máquina de Vetores de Suporte (SVM), Naive Bayes (NB), Random Forest (RF) e Regressão Logística (LR). Todos ampliaram as divergências de gênero, com $\overline{\Delta\kappa} = 0{,}2787$ ($\sigma = 0{,}0224$); NB apresentou a maior amplificação ($\Delta\kappa = +0{,}3082$) e LR a menor ($\Delta\kappa = +0{,}2544$), ambos em severidade *Leve* segundo Landis and Koch [1977]. A validação sintética, conduzida sobre doze conjuntos paramétricos com taxas de concordância controladas (SynSA-50 a SynSA-99, $N = 999$ cada), revelou que o RF atinge severidade *severa* sob baixa concordância inicial ($\overline{\Delta\kappa} = 0{,}4667$; 2,25 faixas perdidas), evidenciando comportamento qualitativamente distinto dos demais modelos. Os resultados indicam que a MADA constitui um instrumento eficaz para a detecção e mensuração sistemática da amplificação de divergências anotativas de gênero em classificadores de PLN.

Este estudo foi aprovado por Comitê de Ética em Pesquisa, sob o parecer CAAE nº 82267824.8.0000.5289.

Palavras-chave: anotação colaborativa; análise de sentimentos; amplificação de divergências anotativas; κ de Cohen; MADA; processamento de linguagem natural.

Rio de Janeiro,

13 de abril de 2026

ABSTRACT

Da Rotulagem ao Modelo: Amplificação de Divergências Anotativas de Gênero para Análise de Sentimentos em Português Brasileiro

Alexander Ramos Feitosa

Advisor:
Gustavo Guedes Paiva e Silva

Abstract of dissertation proposal submitted to Programa de Pós-graduação em Ciência da Computação - Centro Federal de Educação Tecnológica Celso Suckow da Fonseca CEFET/RJ as partial fulfillment of the requirements for the degree of master.

Collaborative annotation in Natural Language Processing (NLP) tasks is influenced by the sociodemographic characteristics of annotators, with gender being a documented source of divergence. This work investigates whether sentiment analysis classifiers, when trained on labels that reflect gender-based annotative divergences, tend to amplify those divergences in their predictions. In response, we propose the Methodology for Annotative Divergence Analysis (MADA), whose core metric is the $\Delta\kappa$ index, defined as the difference between the original inter-annotator Cohen's κ and the κ estimated between the model's prediction groups.

MADA is empirically validated on the MQD-1222 corpus (N = 1,222), annotated by eight gender-stratified collaborators (4M/4F), with an initial agreement of $\kappa = 0.7664$ (95% CI [0.7363, 0.7954]). Four classifiers were evaluated via stratified cross-validation with TF-IDF representation: Support Vector Machine (SVM), Naïve Bayes (NB), Random Forest (RF), and Logistic Regression (LR). All amplified gender-based divergences, yielding a mean $\Delta\kappa$ of 0.2787 ($\sigma = 0.0224$); NB produced the highest amplification ($\Delta\kappa = +0.3082$) and LR the lowest ($\Delta\kappa = +0.2544$), both rated as *Slight* severity under Landis and Koch [1977]. Synthetic validation, conducted over twelve parametric datasets with controlled agreement rates (SynSA-50 to SynSA-99, $N = 999$ each), revealed that RF reaches *Severe* severity under low initial agreement (mean $\Delta\kappa = 0.4667$; 2.25 bands lost), exhibiting qualitatively distinct behavior from the remaining models. The results indicate that MADA constitutes an effective instrument for the systematic detection and measurement of gender-based annotative divergence amplification in NLP classifiers.

This study was approved by a Research Ethics Committee under protocol CAAE no. 82267824.8.0000.5289

Keywords: collaborative annotation; sentiment analysis; annotative divergence amplification; Cohen's κ; MADA; natural language processing.

Rio de Janeiro,

13 de abril de 2026

Sumário

I Introdução **2**

II Fundamentação Teórica **6**

II.1 AS como Tarefa Subjetiva 6

II.2 Anotação Humana e Divergência Anotativa 6

II.3 Efeitos Demográficos na Rotulagem 8

II.4 Mensuração da Concordância: κ de Cohen 8

II.5 Viés em Processamento de Linguagem Natural (PLN): Conceituação e Origens 9

II.6 Amplificação de Divergências no Aprendizado Supervisionado 11

II.7 Paradigmas de Aprendizado de Máquina (AM): Modelos Lineares vs. Modelos de Conjunto 12

II.8 Representação Textual Computacional e Controle de Viés Estrutural 12

II.9 Métricas Complementares de Associação Estatística 13

II.10 Validação Cruzada Estratificada e Estimativa via Reamostragem 14

III Trabalhos relacionados **15**

III.1 A Anotação como Fonte Estrutural de Viés 15

III.2 Gênero como Eixo de Divergência Interpretativa 17

III.3 Amplificação, Propostas Recentes e o Caso do Português 19

IV Apresentação dos *datasets*: uma abordagem complementar **23**

IV.1 A riqueza da rotulagem humana (MQD-1465) 23

IV.1.1 A coleta via PCIbex 24

IV.2 O Controle dos Dados Sintéticos (SynSA) 26

IV.2.1 A Geração dos Dados Sintéticos 26

V Metodologia **28**

V.1 Estratégia de Busca 28

V.2 Visão Geral da MADA 29

V.3 Fundamentos da Métrica de Amplificação 32

V.3.1 Interpretação da Amplificação 33
V.3.2 Classificação de Severidade 34
V.3.3 Hipótese Estatística 34
V.4 Estrutura Geral do Fluxo Experimental 35
V.4.1 Construção dos Vetores de Rótulos 35
V.4.2 Processamento Textual (Term Frequency-Inverse Document Frequency (TF-IDF)) 35
V.4.3 Treinamento Pareado com Validação Cruzada 36
V.4.4 Cálculo das Métricas de Concordância 37
V.4.5 Estimativa de Significância via Bootstrap 37
V.5 Instanciação Empírica 38
V.5.1 Dataset MQD-1222 38
V.5.2 Estimativa da Baseline 39
V.5.3 Representação Textual 39
V.5.4 Treinamento e Validação 40
V.5.5 Concordância Intermodelos 40
V.6 Instanciação Sintética 42
V.7 Estratégia de Integração Interpretativa 42
V.8 Escolhas Metodológicas 43

VI Resultados 45
VI.1 Resultados Empíricos 45
VI.1.1 Módulo I: Concordância Inicial entre Anotadores 45
VI.1.2 Módulo II: Concordância Intermodelos 47
VI.1.3 Módulo III: Amplificação de Divergência ($\Delta\kappa$) 49
VI.2 Resultados Sintéticos 50
VI.2.1 Módulo I: Concordância Inicial nos Cenários Sintéticos 50
VI.2.2 Módulo II: Concordância Intermodelos nos Cenários Sintéticos 51
VI.2.3 Módulo III: Amplificação de Divergência nos Cenários Sintéticos 51
VI.3 Resultados Integrados: Evidência Empírica e Validação Estrutural Sintética 53
VI.3.1 Posicionamento do Cenário Empírico no Espaço Sintético 53
VI.3.2 Propensão Diferencial à Amplificação entre Classificadores 54
VI.3.3 Robustez Estatística 54
VI.3.4 Síntese Interpretativa 55
VI.4 Considerações Finais do Capítulo 55

VII Discussão **63**

VII.1 Análise da Fase Empírica 63

VII.2 Análise da Fase Sintética 64

VII.3 Análise Integrada 65

VII.4 Limitações 66

VII.5 Contribuições do Estudo 67

VII.6 Perspectivas para Trabalhos Futuros 68

Referências **69**

Lista de Figuras

V.1 Fluxograma de seleção dos estudos, elaborado de acordo com a declaração PRISMA 2020, apresentando as etapas de identificação, triagem, elegibilidade e inclusão dos textos analisados neste estudo. 30

V.2 Diagrama de fluxo da MADA. O fluxo é organizado em três módulos sequenciais: o Módulo I estima a concordância inicial entre anotadores (κ_{inicial}); o Módulo II realiza o treinamento pareado de dois classificadores com rótulos provenientes de fontes distintas e estima a concordância entre suas predições (κ_{modelos}); o Módulo III computa $\Delta\kappa = \kappa_{\text{inicial}} - \kappa_{\text{modelos}}$ e classifica o resultado. Valores $\Delta\kappa > 0$ indicam amplificação identificada; $\Delta\kappa \leq 0$ indicam ausência de amplificação. 32

VI.1 Matriz de contingência entre as anotações majoritárias dos grupos masculino e feminino no dataset MQD-1222. A intensidade de cor é proporcional à frequência absoluta. A concentração ao longo da diagonal principal confirma o elevado alinhamento direto entre os grupos, com maior dispersão observada na fronteira semântica entre as classes neutra e positiva. 46

VI.2 Distribuição das classes por grupo de anotadores no dataset MQD-1222. O grupo feminino atribuiu proporcionalmente mais rótulos neutros (365 contra 291) e menos rótulos positivos (411 contra 481), evidenciando maior cautela interpretativa diante de conteúdos de polaridade atenuada. 47

VI.3 Comparação entre κ_{inicial} e κ_{modelos} por classificador, no dataset MQD-1222. A linha tracejada demarca o valor basal humano. Todos os classificadores apresentam redução sistemática da concordância após o treinamento supervisionado, com κ_{modelos} variando entre 0,4582 Naive Bayes (NB) e 0,5120 Logistic Regression (LR), na faixa moderada de Landis e Koch [Landis and Koch, 1977]. 48

VI.4 Matrizes de contingência entre as predições dos modelos masculino e feminino para cada um dos quatro classificadores avaliados no dataset MQD-1222. A diagonal principal concentra as concordâncias diretas entre os pares de modelos. As discordâncias fora da diagonal revelam padrões qualitativamente distintos entre os algoritmos: o NB apresenta maior dispersão na fronteira negativa–positiva (173 instâncias), enquanto o Random Forest (RF) exibe a maior célula de concordância absoluta na classe positiva (499). Os valores de κ_{modelos} indicados nos títulos dos subgráficos correspondem aos reportados na Tabela VI.1. 57

VI.5 Amplificação de divergência ($\Delta\kappa$) por classificador no dataset MQD-1222, com codificação de cor segundo a severidade baseada nas faixas de Landis e Koch [Landis and Koch, 1977]. Todos os classificadores apresentam $\Delta\kappa > 0$, evidenciando amplificação consistente. O NB exibe a maior magnitude (+0,3082), ao passo que o LR registra a menor (+0,2544). A diferença entre os extremos é de apenas 0,0538 pontos, sinalizando que o fenômeno se manifesta de forma sistemática independentemente do algoritmo adotado. 58

VI.6 Comparação entre os valores de κ_{inicial} obtidos nos doze cenários sintéticos (SynSA-XX, linha contínua laranja) e o valor empírico do MQD-1222 (linha tracejada azul) 58

VI.7 Evolução de κ_{modelos} em função da taxa de concordância dos datasets sintéticos, por classificador. A linha tracejada preta representa os valores de κ_{inicial} originais. Todos os classificadores apresentam κ_{modelos} sistematicamente inferior à concordância original em toda a extensão da escala. O RF exibe os menores valores em todos os cenários, indicando maior sensibilidade estrutural à heterogeneidade anotativa, enquanto Support Vector Machine (SVM), NB e LR seguem trajetórias aproximadamente paralelas entre si. 59

VI.8 Mapa de severidade da amplificação ($\Delta\kappa$) nos datasets sintéticos, segundo o critério de Landis and Koch [1977]. Cada célula indica o número de faixas interpretativas perdidas entre κ_{inicial} e κ_{modelos}: cinza = ausente; azul = leve; laranja = moderada; vermelho = severa. A coluna RF apresenta predomínio de severidade severa e moderada ao longo de toda a escala, enquanto SVM, NB e LR concentram-se na faixa leve. 60

VI.9 Amplificação de viés ($\Delta\kappa$) por classificador no cenário SynSA-85 (concordância nominal de 85%, $\kappa_{\text{inicial}} = 0{,}7748$), com codificação de cor segundo a severidade de Landis and Koch [1977]. O RF apresenta amplificação moderada (+0,5488, 2 faixas), enquanto SVM (+0,2809), NB (+0,2235) e LR (+0,2558) permanecem na faixa leve (1 faixa). Esse cenário é o mais próximo do contexto empírico do MQD-1222 e constitui o principal ponto de articulação interpretativa entre as duas instanciações. 61

VI.10 Amplificação de divergência ($\Delta\kappa$) nos doze cenários sintéticos (linha contínua laranja) e no dataset empírico MQD-1222 (linha tracejada azul), por classificador. O fundo sombreado delimita a região de amplificação ($\Delta\kappa > 0$). Em todos os classificadores, o valor empírico insere-se no intervalo esperado pela curva sintética para cenários de concordância intermediária, confirmando que o resultado empírico não é desvio atípico, mas ponto previsível da dinâmica estrutural modelada sinteticamente. 62

Lista de Tabelas

II.1 Escala de interpretação do coeficiente κ [Landis and Koch, 1977] 9

III.1 Matriz comparativa entre a literatura relacionada e a presente pesquisa segundo os quatro eixos analíticos definidos. 22

IV.1 Evolução da volumetria dos datasets na etapa de pré-processamento para a MADA. 26

V.1 Configuração experimental consolidada: representação textual e hiperparâmetros dos classificadores. 41

VI.1 Resultados consolidados da fase empírica — MQD-1222. A severidade é classificada pelo número de faixas de Landis e Koch [Landis and Koch, 1977] percorridas entre o κ_{inicial} e o κ_{modelos}: $0 =$ ausente; $1 =$ leve; $2 =$ moderada; $\geq 3 =$ severa. 49

VI.3 Amplificação ($\Delta\kappa$) e severidade por classificador nos cenários sintéticos. Abreviações: Aus. = ausente (0 faixas); Leve = leve (1 faixa); Mod. = moderada (2 faixas); Sev. = severa (≥ 3 faixas). 52

VI.2 Concordância entre fontes anotadoras nos cenários sintéticos. 58

Lista de Acrônimos

χ^2	Teste Qui-quadrado.
AM	Aprendizado de Máquina.
AS	Análise de Sentimentos.
CAAE	Certificado de Apresentação de Apreciação Ética.
CEP	Comitê de Ética em Pesquisa.
CT	Classificação de Textos.
IC	Intervalo de Confiança.
LR	Logistic Regression.
MADA	Metodologia de Análise de Divergências Anotativas.
NB	Naive Bayes.
PCIbex	Plataforma PCIbex Farm.
PLN	Processamento de Linguagem Natural.
RF	Random Forest.
SVM	Support Vector Machine.
TF-IDF	Term Frequency-Inverse Document Frequency.

Declaração de Uso de Ferramentas de Inteligência Artificial

O autor declara que utilizou ferramentas de Inteligência Artificial (IA) exclusivamente como apoio à produção textual desta dissertação, incluindo sugestões de redação, revisão linguística, esclarecimento de conceitos técnicos e organização de ideias. Todas as decisões conceituais, análises, interpretações, escolhas metodológicas, resultados experimentais e conclusões apresentadas são de responsabilidade integral do autor.

Nenhum conteúdo gerado por ferramentas de IA foi incorporado sem revisão crítica. O uso dessas ferramentas ocorreu conforme princípios de integridade acadêmica, transparência e responsabilidade, e não substituiu o trabalho intelectual necessário à elaboração desta pesquisa.

Capítulo I Introdução

O desenvolvimento de sistemas de processamento de linguagem natural baseados em aprendizado supervisionado repousa sobre uma dependência fundamental: a existência de dados rotulados com qualidade suficiente para que os modelos possam extrair padrões linguísticos generalizáveis. Essa dependência é tão constitutiva do paradigma que frequentemente passa despercebida como pressuposto; os rótulos são tratados implicitamente como representações neutras de uma realidade semântica objetiva, e o processo que os produz é considerado um estágio técnico anterior e exterior ao aprendizado propriamente dito. A pesquisa das últimas décadas, contudo, acumulou evidências robustas de que esse pressuposto é falso, com consequências que se estendem muito além do laboratório. Sistemas de AS classificam sentenças com marcadores femininos de forma sistematicamente distinta das que contêm marcadores masculinos. Modelos de linguagem treinados em corpora construídos por grupos demograficamente homogêneos reproduzem e frequentemente amplificam as perspectivas implícitas nesses grupos. A etapa de anotação — o momento em que seres humanos atribuem categorias a textos — não é o ponto de partida neutro de um pipeline objetivo: é o lugar onde perspectivas, identidades e estruturas sociais são inscritas nos dados que os modelos irão aprender a generalizar.

Esta dissertação parte dessa constatação e avança sobre uma questão que a literatura tem abordado de forma fragmentada: o que acontece, ao longo do aprendizado supervisionado, com as divergências interpretativas produzidas por grupos de anotadores com perfis distintos? Mais precisamente, a hipótese central investigada é: *classificadores de Análise de Sentimentos treinados sobre rótulos que refletem divergências anotativas estratificadas por gênero tendem a amplificar essas divergências em suas predições*, sendo essa amplificação mensurada pelo índice $\Delta\kappa$ — diferença entre o coeficiente κ de Cohen interanotador e o κ estimado entre as predições dos modelos — e avaliada em quatro arquiteturas de classificação clássicas (SVM, NB, RF e LR) sobre um corpus em português brasileiro. O mecanismo hipotetizado é que o processo de generalização indutiva, ao ajustar fronteiras de decisão a sinais de supervisão sistematicamente distintos entre grupos, amplifica assimetrias latentes nos rótulos de forma proporcional à propensão estrutural de cada arquitetura à variância.

Não se trata apenas de perguntar se grupos diferentes produzem rótulos diferentes — evidência que já existe — mas de investigar se o processo de modelagem preserva, atenua ou intensifica essas

divergências quando as incorpora como supervisão. A distinção é analiticamente importante: um sistema que reproduz fielmente a divergência presente em seus dados de treinamento é distinto, em natureza e em implicações práticas, de um sistema que amplifica essa divergência além do que os próprios anotadores exibiam. No segundo caso, o pipeline de aprendizado não é um espelho dos dados — é um amplificador de assimetrias latentes.

O eixo social escolhido para investigar esse fenômeno é o gênero dos anotadores, operacionalizado como critério de estratificação em uma tarefa de AS em português brasileiro. A escolha é motivada por duas ordens de razões. A primeira é empírica: há evidências consistentes na literatura de que o gênero afeta sistematicamente os padrões de rotulagem em tarefas subjetivas, com anotadoras femininas tendendo a maior cautela interpretativa diante de conteúdos de polaridade atenuada, enquanto anotadores masculinos tendem a utilizar rótulos mais polarizados em contextos de ambiguidade semântica. A segunda é linguística: o português brasileiro, ao contrário do inglês, possui um sistema gramatical fortemente marcado por gênero, o que torna potencialmente mais visíveis os efeitos de diferenças interpretativas associadas a essa variável sobre modelos treinados na língua. A escassez de estudos sobre viés de anotação por gênero em português — documentada pela busca sistemática conduzida neste trabalho — confere ao recorte relevância empírica adicional.

Para investigar essa questão de forma rigorosa, esta dissertação propõe a (MADA), um protocolo analítico modular que opera sobre uma configuração experimental de paridade estrita: dois conjuntos de rótulos, provenientes de grupos anotadores distintos, são aplicados ao mesmo corpus textual, com a mesma representação de atributos, os mesmos hiperparâmetros de treinamento e a mesma semente aleatória. Qualquer diferença observada entre os modelos resultantes é, por construção, atribuível exclusivamente à fonte dos rótulos de supervisão. A metodologia estrutura-se em três módulos sequenciais: o primeiro estima a concordância inicial entre os grupos anotadores por meio do coeficiente κ de Cohen; o segundo realiza o treinamento pareado de classificadores e estima a concordância entre suas predições pela mesma métrica; o terceiro quantifica a amplificação como a diferença entre essas duas estimativas, cuja significância estatística é avaliada por reamostragem bootstrap.

A MADA é avaliada por meio de duas instanciações complementares que respondem a perguntas distintas e mutuamente informativas. A primeira é um estudo empírico conduzido sobre o conjunto de dados MQD-1222 — composto por 1.222 instâncias em português brasileiro extraídas do blog Meu Querido Diário e anotadas por grupos equilibrados de quatro anotadores masculinos e quatro anotadoras femininas em regime de anotação independente. Essa instanciação verifica, em condições reais de anotação, se a divergência interpretativa associada ao gênero do anotador se manifesta e se amplifica ao longo do pipeline de aprendizado supervisionado. A segunda é um estudo sintético controlado, conduzido sobre doze cenários com taxas de concordância nominal parametrizadas no

intervalo de 50% a 99%, no qual a única variável experimental manipulada é o grau de divergência entre as fontes de rotulagem. Essa instanciação caracteriza o comportamento estrutural do fenômeno sob controle paramétrico, permitindo avaliar como a magnitude da amplificação varia em função da concordância inicial e das propriedades indutivas de diferentes arquiteturas de classificação.

Os resultados obtidos nas duas instanciações fornecem evidência convergente de que a amplificação de divergências anotativas é um fenômeno estrutural do aprendizado supervisionado, e não um artefato específico do conjunto de dados empírico. No estudo empírico, todos os quatro classificadores avaliados — Máquina de Vetores de Suporte (SVM), Naive Bayes (NB), Random Forest (RF) e Regressão Logística (LR) — apresentaram redução sistemática e estatisticamente significativa da concordância intermodelos em relação à concordância inicial entre os grupos humanos, com $\Delta\kappa$ médio de 0,2787 e intervalos de confiança de 95% que não cruzaram o valor zero em nenhum caso. No estudo sintético, o mesmo padrão se manifestou de forma robusta ao longo de toda a escala de concordância nominal investigada, com a magnitude da amplificação revelando dependência tanto do nível basal de divergência entre as fontes quanto das propriedades indutivas de cada algoritmo.

Do ponto de vista das contribuições, este trabalho opera em quatro dimensões. No plano metodológico, formaliza um protocolo modular capaz de separar analiticamente três níveis distintos de divergência — a divergência humana inicial, a divergência induzida pelo processo de modelagem e a diferença entre ambas — tornando a amplificação um fenômeno mensurável e comparável entre contextos. No plano empírico, oferece evidência pioneira sobre divergências anotativas por gênero em AS para o português brasileiro, caracterizando os padrões distributivos de cada grupo e documentando quantitativamente o fenômeno de amplificação em classificadores clássicos de AM. No plano teórico, os resultados reforçam a concepção do viés como fenômeno emergente do processo de construção e uso de dados — e não como atributo individual dos anotadores —, e demonstram que mesmo divergências moderadas entre fontes de anotação podem produzir efeitos estruturalmente relevantes nos modelos resultantes. No plano prático, os achados têm implicações diretas para o design de protocolos de anotação e para a seleção de algoritmos em pipelines que operam sobre dados com múltiplas fontes anotativas, sugerindo que a escolha do classificador não é indiferente ao risco de amplificação quando a divergência interpretativa entre grupos é esperada ou inevitável.

O estudo foi conduzido em conformidade com os princípios éticos aplicáveis à pesquisa envolvendo seres humanos. A participação dos anotadores foi voluntária, mediante consentimento informado, com garantia de anonimato e confidencialidade das informações coletadas. O gênero dos participantes foi autodeclarado e utilizado exclusivamente como critério de estratificação analítica, sem associação a qualquer outro dado pessoal identificável. O foco do estudo recai sobre as divergências oriundas do processo de anotação e sobre como essas divergências se manifestam

no comportamento de modelos supervisionados — não sobre diferenças individuais ou grupais de capacidade cognitiva. O projeto foi aprovado pelo Comitê de Ética em Pesquisa sob o protocolo CAAE 82267824.8.0000.5289.

O restante desta dissertação está estruturado da seguinte forma. O Capítulo II estabelece os fundamentos teóricos que sustentam a investigação, articulando os conceitos de Classificação de Textos (CT) supervisionada, anotação como prática interpretativa, mensuração de divergência anotativa, viés em sistemas de PLN e amplificação de divergências pelo AM. O Capítulo III mapeia os trabalhos relacionados, organizando a literatura em torno das três linhas de pesquisa que convergem para o problema investigado: a anotação como fonte estrutural de viés, o gênero como eixo de divergência interpretativa, e os estudos sobre amplificação e mitigação de viés em contextos supervisionados. O Capítulo IV descreve os conjuntos de dados utilizados nas duas instanciações: o corpus empírico MQD-1222 e os doze datasets sintéticos SynSA-50 a SynSA-99. O Capítulo V descreve em detalhe a arquitetura da MADA, bem como as duas instanciações conduzidas e a estratégia de integração interpretativa entre elas. O Capítulo VI apresenta os resultados das duas instanciações, seguidos de uma análise integrativa que avalia a consistência estrutural do fenômeno observado. O Capítulo VII sumariza as contribuições desta proposta de dissertação, discutindo as implicações dos achados, as limitações do estudo e as perspectivas para investigações futuras.

Capítulo II Fundamentação Teórica

Este capítulo apresenta os fundamentos conceituais que sustentam a investigação proposta, organizados segundo uma cadeia lógica que acompanha o próprio percurso do fenômeno estudado: da tarefa que motiva a pesquisa, passando pelo processo que produz os dados, até o mecanismo pelo qual as divergências anotativas se propagam e se intensificam ao longo do aprendizado supervisionado. Cada conceito introduzido prepara o terreno para o seguinte, de modo que a metodologia apresentada no Capítulo V possa ser compreendida não apenas como um protocolo experimental, mas como uma resposta direta às questões teóricas aqui levantadas.

II.1 AS como Tarefa Subjetiva

O ponto de partida é a natureza da tarefa investigada. A AS consiste em atribuir polaridade afetiva (tipicamente classificada como positiva, negativa ou neutra) a unidades textuais que expressam opiniões, avaliações ou relatos experienciais. Diferentemente de tarefas de classificação mais objetivas, como o reconhecimento de entidades nomeadas ou a detecção de idioma, a AS opera sobre um terreno inerentemente subjetivo: um mesmo texto pode admitir múltiplas leituras igualmente defensáveis, a depender do contexto pragmático, da sensibilidade semântica do leitor e de sua experiência sociocultural acumulada.

Essa característica não é uma imperfeição do processo de anotação, mas uma propriedade constitutiva da linguagem natural. Como observam Kenyon-Dean et al. [2018], aproximadamente um terço dos itens em corpora de AS apresenta alta discordância entre anotadores humanos — não porque os anotadores errem, mas porque o texto genuinamente suporta interpretações divergentes. É precisamente essa multiplicidade de leituras legítimas que confere relevância teórica ao estudo da etapa de anotação.

II.2 Anotação Humana e Divergência Anotativa

A relevância da anotação decorre do funcionamento do aprendizado supervisionado. Nesse paradigma, um modelo é ajustado a partir de exemplos rotulados, aprendendo a generalizar a relação entre representações textuais e categorias semânticas para instâncias não vistas durante o treinamento. O mecanismo de generalização indutiva é, por construção, sensível à estrutura dos

rótulos: o modelo extrai padrões estatísticos dos dados de supervisão e os projeta sobre o espaço de entrada. Isso implica uma consequência frequentemente subestimada na literatura aplicada — os rótulos não são uma janela neutra para a realidade; são uma mediação interpretativa que carrega as perspectivas, os valores e as categorias cognitivas de quem os atribuiu. Quando essa mediação é sistematicamente influenciada por características de quem anota, o modelo não aprende "o sentimento do texto": aprende "o sentimento do texto conforme interpretado por esse grupo particular de anotadores."A fonte dos rótulos de supervisão é, portanto, uma variável estrutural do pipeline de aprendizado — e não um detalhe operacional.

Compreender por que diferentes anotadores produzem rótulos distintos exige reconhecer que a anotação humana é uma prática interpretativa, não um procedimento técnico neutro. Quando um indivíduo lê um texto e atribui uma categoria, ele mobiliza simultaneamente o conteúdo explícito do texto, sua familiaridade com o domínio, sua sensibilidade a nuances pragmáticas e sua identidade social, incluindo gênero, faixa etária, origem regional e capital cultural. Embora diretrizes de anotação possam padronizar critérios formais, não é possível neutralizar completamente a subjetividade interpretativa em tarefas que envolvem o julgamento da polaridade afetiva. O resultado observável dessa subjetividade é a **divergência anotativa**, fenômeno referido na literatura anglófona como *annotation disagreement* Plank [2022], que constitui a denominação adotada neste trabalho para a variabilidade nos rótulos atribuídos por anotadores distintos a um mesmo conjunto de instâncias.

Durante muito tempo, a literatura de PLN tratou essa divergência predominantemente como ruído a ser minimizado. O objetivo implícito dos protocolos de anotação era maximizar a concordância entre os anotadores, e instâncias de alta discordância eram frequentemente descartadas ou resolvidas por voto majoritário antes de qualquer análise [Prabhakaran et al., 2021]. Essa abordagem repousa sobre um pressuposto ontológico específico: existe um rótulo correto para cada instância, e a discordância entre anotadores é um desvio em relação a esse padrão ideal. Trabalhos recentes têm questionado esse pressuposto de forma sistemática[Aroyo and Welty, 2015]. Uma et al. [2021], em uma revisão abrangente sobre aprendizado a partir da discordância, argumentam que tratar anotações divergentes como ruído implica descartar informações genuínas sobre a estrutura subjetiva da tarefa. Plank [2022] vai além ao propor que a variabilidade dos rótulos humanos não é um problema a ser resolvido, mas uma característica informativa que os modelos deveriam ser capazes de representar.Havens et al. [2022] formalizam essa perspectiva no âmbito específico do viés de gênero em anotação, desenvolvendo taxonomias que distinguem incerteza legítima de inconsistência operacional. Em consonância com essa linha de pesquisa, o presente estudo adota uma posição perspectivista: a divergência entre anotadores de grupos distintos não é tratada como uma imperfeição do processo, mas como o próprio objeto de investigação.

A transição do tratamento da divergência anotativa como ruído para a sua aceitação como sinal interpretativo ganha contornos metodológicos definitivos com a formalização dos paradigmas de anotação. Röttger et al. [2022] estabelecem uma distinção crucial entre a anotação prescritiva, aplicável a tarefas objetivas onde um consenso absoluto é esperado, e a anotação descritiva, estritamente necessária para tarefas subjetivas como a AS. A adoção do paradigma descritivo legitima o pressuposto da MADA de que a multiplicidade de rótulos não representa uma falha operacional, mas a captura fiel da pluralidade semântica inerente à linguagem natural.

II.3 Efeitos Demográficos na Rotulagem

Essa reorientação epistemológica é especialmente relevante quando a divergência anotativa está associada a características demográficas dos anotadores. Há evidências crescentes de que variáveis como gênero, idade e origem cultural afetam sistematicamente os padrões de rotulagem em tarefas subjetivas. Ding et al. [2022] demonstraram que essas características influenciam a percepção de polaridade e da intensidade emocional na AS. Biester et al. [2022], em um estudo comparativo abrangendo quatro tarefas de PLN, identificaram diferenças consistentes de anotação associadas ao gênero — em particular, uma tendência de anotadores masculinos a atribuir rótulos mais polarizados em contextos de ambiguidade semântica moderada.

Geva et al. [2019] mostraram que características do anotador individual podem ser tão determinantes para o rótulo resultante quanto o próprio conteúdo do texto. Esses achados indicam que, em tarefas subjetivas, a divergência entre grupos anotadores estratificados por gênero não é aleatória: ela reflete padrões interpretativos coletivos que emergem da interação entre a tarefa, o texto e a identidade social de quem anota.

Evidências para o português brasileiro foram reportadas por Feitosa et al. [2025], que identificaram padrões diferenciados de rotulagem associados ao gênero em um corpus de AS, e por Carneiro et al. [2025], que demonstraram, em datasets sintéticos com concordância parametrizada, que a amplitude das divergências de gênero afeta sistematicamente a magnitude da amplificação pelos classificadores.

II.4 Mensuração da Concordância: κ de Cohen

A análise da consistência e da confiabilidade da rotulagem humana em PLN apoia-se historicamente na adaptação de métricas de concordância interavaliadores, cujas bases metodológicas para tarefas computacionais foram consolidadas no trabalho de Artstein and Poesio [2008], que se valeram das métricas clássicas de Cohen [1960] e Landis and Koch [1977]. Tradicionalmente, a divergência anotativa reportada por essas métricas era tratada puramente como ruído a ser eliminado para a criação de um padrão-ouro (*gold standard*) de anotação.

Para que esses padrões pudessem ser investigados empiricamente, foi necessário dispor de métricas que quantificassem a concordância entre fontes de rotulagem de forma rigorosa. A medida mais amplamente utilizada para esse fim é o coeficiente κ de Cohen [Cohen, 1960], definido como

$\kappa = \frac{p_o - p_e}{1 - p_e}$,

onde p_o representa a proporção de concordância observada entre duas fontes e p_e representa a concordância esperada ao acaso, estimada a partir das distribuições marginais das categorias. Ao descontar a concordância que seria obtida aleatoriamente, o coeficiente κ produz uma estimativa mais conservadora e interpretável do alinhamento efetivo entre duas fontes de rotulagem do que a simples taxa de concordância bruta. Valores próximos de 1 indicam concordância quase perfeita; valores próximos de 0 indicam concordância equivalente ao acaso; valores negativos indicam concordância inferior à esperada por acaso.

Landis and Koch [1977] propuseram uma escala interpretativa que organiza o coeficiente em seis faixas qualitativas, amplamente adotada como referência na literatura de concordância entre avaliadores (Tabela II.1). Neste trabalho, adotam-se as traduções indicadas na tabela, que serão empregadas de forma consistente na apresentação e discussão dos resultados.

Tabela II.1: Escala de interpretação do coeficiente κ [Landis and Koch, 1977]

Termo original	**Tradução adotada**	**Intervalo de κ**
Poor	Ruim	$\kappa < 0{,}00$
Slight	Leve	$0{,}00 \leq \kappa \leq 0{,}20$
Fair	Razoável	$0{,}21 \leq \kappa \leq 0{,}40$
Moderate	Moderada	$0{,}41 \leq \kappa \leq 0{,}60$
Substantial	Substancial	$0{,}61 \leq \kappa \leq 0{,}80$
Almost Perfect	Quase Perfeita	$0{,}81 \leq \kappa \leq 1{,}00$

Complementarmente, o coeficiente V de Cramér e a estatística χ^2 de independência fornecem medidas da magnitude e da significância da associação estatística entre duas distribuições de rótulos, independentemente das distribuições marginais. Essas métricas compõem o instrumental quantitativo central desta pesquisa: permitem estimar, em bases comparáveis, o grau de divergência interpretativa antes e depois do processo de modelagem supervisionada.

II.5 Viés em PLN: Conceituação e Origens

A divergência anotativa, definida na Seção II.2, constitui evidência de variação perspectival estruturada, passível de mensuração por meio do coeficiente κ [Davani et al., 2022]. Com isso, o termo *annotation disagreement*, usado por Plank [2022], perde aos poucos o caráter de imperfeição metodológica a ser eliminado, passando a ser tratado como uma importante variável de métrica para concordância no processo de anotação.

Estudos empíricos demonstram que características sociodemográficas dos anotadores produzem divergências sistemáticas e consistentes ao longo de corpora de rotulagem subjetiva. Biester et al. [2022] identificaram efeitos significativos do gênero do anotador em múltiplas tarefas de PLN, enquanto Geva et al. [2019] evidenciaram que classificadores treinados com anotações humanas tendem a absorver os padrões idiossincráticos dos anotadores, em detrimento dos padrões da própria tarefa.

A existência de divergências sistemáticas associadas ao gênero dos anotadores insere-se em um problema mais amplo, extensamente documentado na literatura: o viés em sistemas de processamento de linguagem natural. Blodgett et al. [2020], em uma revisão crítica da literatura sobre viés em PLN, argumentam que o conceito é utilizado de forma heterogênea — ora referindo-se a representações distorcidas nos dados de treinamento, ora a comportamentos diferenciados dos modelos em relação a grupos sociais, ora a danos concretos produzidos por sistemas implantados. Para os fins desta pesquisa, adota-se uma definição processual: viés é compreendido como um efeito emergente do processo de construção, interpretação e uso dos dados, e não como atributo individual de anotadores ou de algoritmos isoladamente. Essa perspectiva é coerente com a proposta de Shah et al. [2020], que enquadra o viés preditivo como resultado sistemático da interação entre arquiteturas de modelos e recursos latentes presentes nos conjuntos de dados. Hovy and Prabhumoye [2021] identificam cinco fontes principais de viés em PLN — incluindo explicitamente o viés dos anotadores —, reforçando que a etapa de rotulagem não é anterior ou exterior ao problema do viés: ela é uma de suas origens constitutivas.

No contexto específico do viés de gênero, sistemas de AS têm demonstrado comportamento diferenciado em função de marcadores linguísticos associados ao feminino e ao masculino [Kiritchenko and Mohammad, 2018]. Gupta et al. [2023] documenta, em ampla pesquisa sobre viés sociodemográfico em modelos de linguagem, que sistemas de AS exibem viés sistemático de gênero, classificando sentenças com marcadores femininos de forma consistentemente distinta. É importante reconhecer, contudo, que a operacionalização do gênero como variável binária, adotada neste estudo por razões metodológicas, apresenta limitações conceituais documentadas. Devinney et al. [2022] demonstram que, mesmo em pesquisas que reconhecem a multidimensionalidade do gênero, ele é consistentemente tratado como caso binário na prática experimental. Essa simplificação implica a invisibilização de identidades não binárias e pode mascarar a heterogeneidade interna de cada grupo. A adoção do recorte binário neste trabalho é, portanto, uma decisão instrumental justificada pela disponibilidade de anotadores e pela necessidade de controle experimental — e não uma afirmação ontológica sobre a natureza do gênero.

II.6 Amplificação de Divergências no Aprendizado Supervisionado

O problema central que esta pesquisa investiga não é, todavia, a mera existência de divergências anotativas associadas ao gênero, uma vez que essa questão aborda um fenômeno já documentado na literatura. O problema é o que acontece com essas divergências ao longo do pipeline de aprendizado supervisionado. Há razões teóricas para suspeitar que o processo de modelagem não apenas preserve as divergências presentes nos rótulos de treinamento, mas as intensifique.

O mecanismo pode ser compreendido a partir das propriedades da generalização indutiva: ao ajustar seus parâmetros para minimizar o erro sobre o conjunto de treinamento, um classificador aprende a identificar e explorar padrões estatísticos nos dados, incluindo padrões latentes de divergência interpretativa entre as fontes de supervisão. Quando dois modelos são treinados sobre os mesmos textos, mas com rótulos provenientes de grupos com perfis anotativos distintos, cada um generaliza a partir de um sinal de supervisão diferente. As fronteiras de decisão aprendidas por cada modelo refletem as assimetrias estruturais presentes nos rótulos de seus respectivos grupos. Ao generalizarem para instâncias não vistas, essas assimetrias podem se manifestar com uma magnitude superior à observada entre os próprios anotadores.

Zhao et al. [2017] demonstraram empiricamente esse fenômeno em tarefas de PLN: modelos treinados com dados tendenciosos tenderam a exagerar as associações demográficas presentes no corpus original. Minatel et al. [2023] corroboraram esse padrão em tarefas de classificação binária, mostrando que efeitos discriminatórios nos rótulos se propagam e se intensificam ao longo do aprendizado supervisionado.

A propensão à amplificação não é, ademais, uniforme entre algoritmos, dado que cada arquitetura possui mecanismos indutivos distintos que interagem de forma diferenciada com a estrutura de divergência presente nos rótulos de supervisão, conforme detalhado na Seção II.7.

Classificadores baseados em *ensemble* de árvores de decisão, como RF, apresentam elevada variância devido à natureza não-linear e não-paramétrica das árvores individuais, cada uma ajustada a uma amostra *bootstrap* distinta do conjunto de treinamento. Embora a agregação por votação majoritária reduza a variância em relação a uma única árvore, o modelo resultante permanece sensível a padrões locais e interações complexas entre *features*, incluindo aquelas que refletem divergências anotativas.

Em contraste, modelos lineares regularizados, como LR com penalização L_2, impõem restrições estruturais que limitam a magnitude dos coeficientes, reduzindo a capacidade do modelo de ajustar-se a padrões idiossincráticos dos rótulos de treinamento. Essa diferença arquitetural sugere que LR tende a suavizar divergências anotativas, enquanto RF pode amplificá-las de forma mais pronunciada; hipótese corroborada pelos resultados empíricos e sintéticos apresentados no

Capítulo VI.

Modelos lineares, por operarem sobre projeções globais do espaço de atributos, são estruturalmente menos sensíveis a assimetrias locais e, consequentemente, tendem a exibir amplificação de menor magnitude [Hastie et al., 2009]. Essa diferença entre arquiteturas não é meramente empírica: ela decorre das propriedades indutivas de cada classe de algoritmos e constitui, por si mesma, uma dimensão analítica relevante para a compreensão do fenômeno.

A subjetividade constitutiva da AS, a dependência do aprendizado supervisionado em relação à fonte dos rótulos, a anotação como prática interpretativa socialmente situada, a divergência anotativa como fenômeno mensurável por métricas de concordância, as origens e manifestações do viés de gênero em PLN, e o mecanismo de amplificação de divergências pelo processo de modelagem constituem, então, o quadro de referências relacionadas no capítulo seguinte, fundamentando a proposta da própria MADA, apresentada no Capítulo V do presente estudo.

II.7 Paradigmas de AM: Modelos Lineares vs. Modelos de Conjunto

A escolha da arquitetura do classificador em tarefas de processamento de linguagem natural não constitui apenas um detalhe operacional, mas uma decisão que carrega pressupostos estruturais profundos sobre como os dados serão particionados e generalizados. Modelos lineares operam por meio da otimização de uma fronteira de decisão global sobre o espaço de atributos, buscando a maior margem de separação possível Géron [2019]; Hastie et al. [2009]. Por projetarem hiperplanos considerando o espaço global de características, essas arquiteturas tendem a ser menos sensíveis a pequenas assimetrias locais e, consequentemente, mais resilientes à heterogeneidade estrutural da anotação humana.

Em contraste, métodos baseados em estruturas de conjunto (*Ensemble*), como o algoritmo RF, que foi amplamente estudado no trabalho seminal de Breiman [2001], constroem múltiplas árvores de decisão sobre subamostras do espaço de atributos e agregam suas predições por voto majoritário Hastie et al. [2009]; Izbicki and Santos [2020]. Embora o processo de agregação confira robustez em cenários tradicionais, as árvores de decisão possuem uma extrema sensibilidade a pequenas variações nos dados de treinamento Géron [2019]. Essa propriedade estrutural faz com que o sistema de votação reforce padrões sistemáticos locais, tornando os modelos de conjunto mais propensos a atuar como amplificadores ativos de vieses e divergências latentes presentes nos rótulos fornecidos pelos anotadores Hastie et al. [2009].

II.8 Representação Textual Computacional e Controle de Viés Estrutural

Para que algoritmos de AM operem sobre textos em linguagem natural, é indispensável a conversão do corpus para um espaço vetorial numérico. Embora o estado da arte em PLN seja

atualmente dominado por modelos de linguagem pré-treinados, essas representações densas carregam consigo uma limitação metodológica severa para estudos de isolamento de viés: elas introduzem uma camada adicional de variabilidade oriunda de seus vastos corpora de pré-treinamento Jurafsky and Martin [2007].

Nesse cenário, abordagens clássicas de contagem e ponderação de frequência, como o TF-IDF, apresentam vantagens analíticas inestimáveis. Conforme estabelecido na literatura canônica da área Jurafsky and Martin [2007]; Manning and Schütze [1999], o TF-IDF transforma o texto em um espaço vetorial esparso, ponderando a frequência local de um termo pela sua raridade global na coleção de documentos. O cálculo da frequência inversa atua como um mecanismo estatístico projetado exatamente para medir o quão discriminativa uma palavra é, rebaixando matematicamente o peso de termos muito comuns que não auxiliam na diferenciação do conteúdo. Por extrair os atributos estritamente do vocabulário do corpus em análise, o TF-IDF garante uma paridade estrutural neutra, assegurando que as divergências observadas sejam reflexo exclusivo dos rótulos de supervisão.

II.9 Métricas Complementares de Associação Estatística

A análise de concordância interanotadores e intermodelos apoia-se tradicionalmente no coeficiente κ de Cohen, que quantifica o alinhamento estrito (concordância na diagonal principal da matriz de contingência) corrigido pelo acaso. Contudo, a caracterização completa da divergência interpretativa entre grupos exige avaliar também a magnitude da associação global entre as distribuições de rótulos, independentemente de eventuais desequilíbrios nas distribuições marginais.

Para esse fim, a estatística χ^2 de independência atua como um teste de hipótese para verificar se a distribuição conjunta dos rótulos de duas fontes difere significativamente do que seria esperado caso suas avaliações fossem estatisticamente independentes. Quando a hipótese nula de independência é rejeitada, atesta-se a existência de um padrão sistemático de associação entre os grupos.

Como a estatística χ^2 é sensível ao tamanho da amostra e não fornece um limite superior normalizado, utiliza-se o coeficiente V de Cramér como medida de magnitude de efeito. O V de Cramér normaliza a estatística Teste Qui-quadrado (χ^2) para um intervalo entre 0 e 1, permitindo quantificar a força da associação estrutural entre as fontes de anotação de maneira independente do número de instâncias ou das partições de dados geradas durante o treinamento. Juntas, essas métricas oferecem uma caracterização bidimensional: o κ dimensiona a equivalência exata, enquanto o χ^2 e o V de Cramér mapeiam a interdependência sistêmica das interpretações.

II.10 Validação Cruzada Estratificada e Estimativa via Reamostragem

A mensuração de variações finas no desempenho de modelos, como a amplificação de viés, impõe a necessidade de um desenho experimental com rigorosas garantias de estabilidade estatística. Em tarefas de classificação subjetiva, as distribuições marginais das classes raramente são simétricas, exigindo métodos de particionamento robustos. A validação cruzada com amostragem estratificada atende a essa exigência ao dividir a população em subgrupos homogêneos, garantindo que os conjuntos de treinamento e teste contenham proporções perfeitamente representativas de cada classe, mitigando o viés de amostragem Géron [2019]; Hastie et al. [2009].

Adicionalmente, inferências sobre métricas complexas (como a diferença de concordâncias intermodelos) não contam com uma distribuição paramétrica fechada conhecida. Nessas condições, a reamostragem estatística por *Bootstrap* - método introduzido de forma seminal por Efron and Tibshirani [1994] - consolida-se como a ferramenta de inferência mais adequada Hastie et al. [2009]; Izbicki and Santos [2020]. O método gera amostras empíricas com reposição a partir dos dados originais de treinamento para avaliar formalmente a precisão estatística e a incerteza de um estimador Hastie et al. [2009].

Capítulo III Trabalhos relacionados

A investigação proposta nesta dissertação situa-se na interseção de três linhas de pesquisa que, embora distintas em seu desenvolvimento histórico, convergem para uma mesma questão: como as escolhas feitas durante a construção de dados rotulados se propagam e se transformam ao longo do pipeline de aprendizado supervisionado. Mapear esse território é uma condição necessária para identificar com precisão o que já foi estabelecido, o que permanece em aberto e de que forma a MADA responde a lacunas concretas do estado da arte.

III.1 A Anotação como Fonte Estrutural de Viés

O ponto de partida para uma análise mais fundamentada sobre o processo de anotação é uma transformação epistemológica ainda em curso na literatura de PLN: a revisão do estatuto teórico da discordância entre anotadores. Durante décadas, o pressuposto dominante nos protocolos de anotação foi o de que existe um rótulo correto para cada instância; uma verdade de referência (*gold standard*) em relação à qual a discordância constitui um desvio a ser minimizado ou eliminado. Aroyo and Welty [2015] foram um dos primeiros a desafiar sistematicamente esse pressuposto, argumentando que a busca por um único rótulo consensual encobre sete mitos sobre a anotação humana; entre eles, o de que a discordância é sempre produto de ambiguidade ou incompetência. Em tarefas cognitivamente complexas e interpretativas, demonstram os autores, múltiplos rótulos conflitantes podem ser todos defensáveis, e o consenso artificial produzido pela agregação mascara informações valiosas sobre a estrutura subjetiva da tarefa.

Paralelamente, a investigação de viés algorítmico em PLN concentrou-se na identificação de distorções geométricas e associações estereotipadas no espaço vetorial. O trabalho seminal de Bolukbasi et al. [2016] inaugurou esta primeira onda investigativa ao demonstrar matematicamente que representações textuais tradicionais capturam e refletem vieses socioculturais, propondo como solução a debiasização puramente matemática mediante a projeção e remoção da dimensão de gênero dos vetores. Contudo, essa abordagem estritamente geométrica de correção *a posteriori* provou-se estruturalmente insuficiente na literatura subsequente Gordon et al. [2021], motivando a transição metodológica da presente pesquisa para a auditoria das origens do viés diretamente nos estágios iniciais de anotação humana.

Esse argumento ganhou substância empírica e sistemática com a revisão de Uma et al. [2021], que examinou dezenas de estudos sobre aprendizado a partir da discordância (*learning from disagreement*) e demonstrou que tratar anotações divergentes como ruído implica descartar exatamente o sinal que diferencia tarefas subjetivas de tarefas objetivas. Pesquisas ainda mais aprofundadas, como as de Fleisig et al. [2023], questionam o próprio voto majoritário, sinalizando possíveis descartes semânticos de opiniões minoritárias, principalmente nos estudos sobre discurso de ódio. Em vez de eliminar a variabilidade interanotadores, os autores propõem que modelos sejam treinados para capturá-la — seja por meio de distribuições suaves sobre rótulos ou pela preservação de anotações individuais, em vez de agregações majoritárias.

Leonardelli et al. [2021] demonstraram que selecionar dados de treinamento e teste segundo níveis distintos de concordância entre anotadores tem um efeito pronunciado sobre o desempenho e a robustez dos classificadores, reforçando a premissa central proposta neste estudo: o nível de concordância entre as fontes anotativas não é apenas uma propriedade do corpus, mas uma variável que modula o comportamento dos modelos treinados sobre esses dados.

Na mesma direção, Plank [2022] argumenta que o chamado "problema da variação de rótulos humanos"não é, rigorosamente falando, um problema: é uma característica informativa da linguagem natural que os sistemas de PLN deveriam ser capazes de representar, em vez de suprimir. A consequência prática dessa virada perspectivista é direta: se a discordância carrega informação, então a fonte dessa discordância — quem anota, com que identidade, a partir de que perspectiva — torna-se uma variável de primeira ordem na análise.

A inadequação dos métodos tradicionais de avaliação baseados em agregação majoritária tem mobilizado a comunidade acadêmica em direção a novas métricas de desempenho. Basile et al. [2021] argumentam sistematicamente contra o uso de padrões-ouro tradicionais em tarefas altamente subjetivas, evidenciando que a agregação prévia oblitera nuances interpretativas essenciais para a avaliação dos modelos.

A cadeia de implicações entre anotação e viés foi formalizada por Blodgett et al. [2020] em uma revisão crítica da literatura sobre viés em PLN, que permanece uma referência fundamental na área. Os autores demonstram que anotações tendenciosas podem ser incorporadas em conjuntos de dados desde o seu início e que sistemas treinados nesses dados herdam e frequentemente ampliam tais tendenciosidades. Hovy and Prabhumoye [2021] complementam essa análise ao identificar cinco fontes estruturais de viés em sistemas de PLN, e argumentam que a negligência de qualquer uma dessas fontes compromete a validade dos modelos resultantes.

Kuwatly et al. [2020] sugerem uma abordagem em que classificadores são treinados separadamente sobre dados rotulados por grupos demográficos distintos (idioma nativo, idade e educação), e suas diferenças de desempenho são analisadas estatisticamente. A metodologia

proposta pelo nosso estudo utiliza uma estratégia semelhante, elegendo o gênero como ponto focal de interesse analítico.

A resposta mais direta a esse diagnóstico tem sido a demanda por maior transparência no processo de anotação. Prabhakaran et al. [2021] defendem a publicação de rótulos ao nível do anotador individual, e não apenas de agregações, como condição necessária para compreender e mitigar vieses de anotação. Davani et al. [2022] demonstram empiricamente que ir além do voto majoritário — considerando a distribuição completa de rótulos individuais — melhora substancialmente a qualidade dos modelos em tarefas com alta variabilidade interpretativa. Paullada et al. [2021], em uma crítica mais ampla às práticas de construção de conjuntos de dados em AM, argumentam que os dados são produtos culturais cujos conteúdos e lacunas refletem as condições sociais de sua produção — e que ignorar essas condições é uma forma de validar acriticamente as perspectivas dos grupos que participaram de sua construção. Raji et al. [2021] estendem essa crítica aos próprios benchmarks de avaliação, mostrando que as escolhas normativas neles incorporadas moldam silenciosamente o que conta como sucesso em PLN.

Este conjunto de trabalhos estabelece com solidez o terreno conceitual sobre o qual a presente pesquisa se apoia: a anotação humana é uma prática interpretativa socialmente situada, a discordância entre anotadores é frequentemente legítima e informativa, e a fonte dos rótulos de supervisão é uma variável estrutural do *pipeline* de aprendizado. O que permanece menos explorado e que as próximas seções abordam é o papel específico do gênero como eixo de divergência anotativa e o que ocorre com essas divergências ao longo do processo de modelagem supervisionada.

III.2 Gênero como Eixo de Divergência Interpretativa

Se a literatura revisada na seção anterior estabelece que a identidade dos anotadores importa para os rótulos produzidos, uma segunda linha de pesquisa investiga de forma específica como o gênero estrutura padrões sistemáticos de divergência interpretativa em tarefas de CT.

A influência da identidade sociodemográfica sobre os padrões de rotulagem tem sido progressivamente mapeada por estudos empíricos focados na subjetividade do anotador. Pei and Jurgens [2023] investigaram sistematicamente sob quais condições as características demográficas afetam a produção de dados em Processamento de Linguagem Natural, isolando a identidade do anotador como variável preditiva do rótulo. Ao quantificar o peso da demografia na anotação, o estudo fornece respaldo contemporâneo à premissa central da MADA de que o gênero autodeclarado atua como um vetor de divergência interpretativa capaz de moldar as fronteiras de decisão dos classificadores clássicos.

Um estudo fundamental nessa direção é o de Geva et al. [2019], que demonstraram que características do anotador individual — incluindo gênero, background educacional e estilo pessoal

de anotação — podem ser tão determinantes para o rótulo atribuído quanto o próprio conteúdo do texto em tarefas de compreensão de linguagem natural. Os autores concluem que, em muitos casos, os modelos treinados nesses dados aprendem a simular o comportamento do anotador médio, não a compreender a tarefa — o que torna a composição demográfica do grupo de anotadores uma variável latente de primeira importância. Resultados convergentes foram obtidos por Ding et al. [2022], especificamente no domínio da AS: em um estudo sistemático sobre o impacto de características demográficas na rotulagem de dados de sentimento, os autores mostraram que gênero, idade e origem cultural afetam de forma mensurável e consistente a percepção de polaridade e intensidade emocional dos textos avaliados.

Biester et al. [2022] aprofundam essa evidência em um escopo mais amplo, analisando o efeito do gênero dos anotadores em quatro tarefas distintas de PLN — incluindo AS — e identificando diferenças sistemáticas nos padrões de rotulagem, com uma tendência dos anotadores masculinos a atribuir rótulos mais polarizados em contextos de ambiguidade semântica moderada. Kumar et al. [2020], por sua vez, compararam o desempenho de modelos de AS treinados por grupos estratificados segundo critérios de idade e gênero, encontrando que a acurácia dos modelos femininos superava consistentemente a dos masculinos em uma tarefa de classificação de ebooks — resultado que os autores interpretam como evidência de diferenças nos padrões de expressão linguística e interpretação afetiva entre os grupos.

Essas diferenças não são necessariamente atribuíveis ao gênero como categoria biológica, mas ao gênero como posição social que molda trajetórias de socialização, acesso à linguagem e sensibilidades interpretativas — uma distinção que a literatura tem progressivamente incorporado. Stańczak and Augenstein [2021], em uma revisão abrangente sobre viés de gênero em PLN, documentam as limitações persistentes dos estudos na área, entre as quais se destacam a suposição binária de gênero e a escassez de estudos multilíngues. Devinney et al. [2022] examinam criticamente as teorias de gênero implícitas nas pesquisas sobre viés em PLN e demonstram que o gênero é consistentemente operacionalizado como variável binária, mesmo quando os autores reconhecem sua natureza multidimensional — uma tensão que esta dissertação herda e explicita como limitação metodológica necessária.

No que diz respeito às consequências dessas diferenças para os sistemas implantados, a evidência é igualmente robusta. Kiritchenko and Mohammad [2018] desenvolveram o Equity Evaluation Corpus (EEC) — um conjunto de 8.640 sentenças em inglês, especificamente construído para medir vieses em relação a raça e gênero em sistemas de AS — e encontraram que a análise de 219 sistemas comerciais e de pesquisa revelou viés estatisticamente significativo na grande maioria deles, com intensidades de sentimento sistematicamente distintas para sentenças com marcadores femininos e masculinos. Gupta et al. [2023], em uma revisão ainda mais abrangente

sobre viés sociodemográfico em modelos de linguagem, documentam que sistemas de AS exibem viés sistemático de gênero de forma robusta e transversal a diferentes arquiteturas e idiomas, classificando sentenças com marcadores femininos de forma diferenciada e associando-as frequentemente a uma maior intensidade emocional negativa ou a uma menor assertividade.

É precisamente nesse ponto que se configura a segunda lacuna relevante. Embora a literatura estabeleça com consistência que o gênero dos anotadores afeta os rótulos produzidos em tarefas subjetivas [Biester et al., 2022], a maioria dos estudos analisa esse efeito no plano dos dados, comparando as distribuições de rótulos entre grupos, sem investigar o que ocorre com essas diferenças quando os dados são utilizados como supervisão para treinar modelos [Plank, 2022]. A pergunta sobre se as divergências interpretativas associadas ao gênero são preservadas, atenuadas ou amplificadas ao longo do processo de aprendizado supervisionado permanece, até o presente, sistematicamente inexplorada.

III.3 Amplificação, Propostas Recentes e o Caso do Português

A terceira linha de pesquisa relevante para esta dissertação é aquela que investiga especificamente o fenômeno de amplificação de viés em modelos supervisionados — isto é, a tendência de que assimetrias presentes nos dados de treinamento se manifestem nos modelos resultantes com magnitude superior à observada nos dados brutos.

O trabalho seminal nessa direção é o de Zhao et al. [2017], que demonstrou que modelos de PLN amplificam associações estereotipadas de gênero presentes nos dados de treino, operacionalizando essa amplificação pela variação na frequência relativa de rótulos entre corpus e predições.

A contribuição teórica central de Zhao et al. [2017] reside na distinção entre o viés presente nos dados de treino e o viés amplificado pelo modelo: mesmo que o corpus de entrada exiba assimetrias moderadas, o processo de generalização indutiva pode intensificá-las de forma substancial nas predições.

Shah et al. [2020] situam esse fenômeno em um quadro conceitual mais amplo, propondo que vieses preditivos em PLN resultam sistematicamente da interação entre a arquitetura dos modelos e recursos latentes presentes nos conjuntos de dados — o que implica que a amplificação é uma propriedade emergente do processo de modelagem, não um artefato acidental.

Geva et al. [2019] estenderam essa perspectiva ao mostrar que classificadores absorvem sistematicamente os padrões de anotadores individuais. Nenhum desses trabalhos, contudo, mensura a amplificação em termos de acordo interanotador entre grupos demográficos, nem adota o coeficiente κ como unidade de comparação entre o corpus anotado e as predições do modelo. Essa lacuna motiva a proposta apresentada no Capítulo V

Minatel et al. [2023], em contexto mais próximo ao presente estudo, investigaram a propagação de

efeitos discriminatórios em tarefas de classificação binária no contexto brasileiro, analisando como estratificações dos conjuntos de dados e distribuições de rótulos contribuem para a perpetuação e intensificação de padrões discriminatórios. Seus resultados corroboram a hipótese de que o aprendizado supervisionado não é um filtro que atenua o viés dos dados de entrada, mas um amplificador que pode reforçar padrões sistemáticos latentes.Lim et al. [2024] avançam nessa direção ao propor a análise de mediação causal como instrumento para identificar e mitigar o viés de anotação em tarefas de compreensão de linguagem natural — uma abordagem que trata a fase de anotação como variável mediadora entre o texto e o comportamento do modelo, e não como uma fonte de variabilidade residual. Essa reorientação metodológica é conceitualmente próxima à proposta da MADA, embora opte por ferramentas de inferência causal em vez de métricas de concordância.

Propostas mais recentes têm explorado estratégias de mitigação do viés de anotação por duas vias principais. A primeira, representada por Toker et al. [2024], consiste na calibração inteligente dos anotadores: ajustes no processo de seleção e composição dos grupos anotadores, baseados em perfis demográficos, podem reduzir divergências sistemáticas sem comprometer a qualidade geral das anotações. A segunda, exemplificada por Sobhani and Delany [2024], aposta em técnicas de aumento de dados contrafactuais como mecanismo de mitigação: ao gerar variações dos textos originais com substituições controladas de marcadores de gênero, é possível reduzir a dependência dos classificadores em relação a esses marcadores sem sacrificar o desempenho na tarefa principal.

Jiang et al. [2024], em contexto adjacente, demonstram que os conjuntos de dados existentes frequentemente falham em capturar a pluralidade de perspectivas dos anotadores e que a incorporação explícita das atitudes e dos perfis dos anotadores no processo de treinamento produz modelos mais robustos e interpretativamente responsáveis. Zhu et al. [2024], por sua vez, investigam se modelos de linguagem pré-treinados compartilham o mesmo viés de gênero de seus anotadores, concluindo que há correspondência parcial e que o contexto em que as sentenças são avaliadas modula significativamente a manifestação do viés; o que sugere que a relação entre viés de anotação e viés de modelo é mediada por propriedades das representações aprendidas durante o pré-treinamento.

Wan et al. [2023] propõem um *framework* que simulou 140 anotadores artificiais para distinguir a discordância originada da controvérsia inerente ao texto daquela produzida pela composição demográfica do grupo anotador. Ainda que tenham optado pelo uso de um modelo de linguagem pré-treinado (RoBERTa), a proposta de uma comparação com dados sintéticos assemelha-se à abordagem sugerida por este estudo.

Em um cenário lusófono, ainda é possível identificar algumas iniciativas com a atenção voltada para as especificidades da língua portuguesa. Mozetič et al. [2016] conduziram uma robusta análise de concordâncias interanotadores para AS em múltiplos idiomas europeus, incluindo o português,

que, mesmo em seu contexto lusitano, obteve baixos valores participativos na pesquisa, indicando que a lacuna não é uma característica específica do português brasileiro.

Para o contexto nacional, convém citar Taso et al. [2023], que investigaram a discriminação algorítmica de gênero em sistemas de PLN no Brasil, documentando viés sistemático e estatisticamente significativo em tarefas de análise de sentimento em português, estabelecendo evidências diretas da relevância do problema no contexto nacional.

Firmino et al. [2024] identificaram, em letras de músicas brasileiras, que o gênero feminino é frequentemente descrito por predicativos relacionados à aparência física, enquanto o masculino é caracterizado por traços de personalidade, padrões que os modelos de AM podem aprender e perpetuar.

Apesar da opção metodológica por algoritmos mais clássicos neste estudo, trabalhos como os de Jentzsch and Turan [2022] (baseado em sete modelos BERT públicos), demonstram que a amplificação de viés perpassa diferentes arquiteturas. Da mesma forma, estudos como os de Fleisig et al. [2023] questionam o *ground truth* como única prática para AS. São inúmeras as perspectivas de abordagens para a etapa de anotação e a respectiva consequência dessa ação em todo o fluxo de PLN.

O exame sistemático desse conjunto de trabalhos revela o ponto preciso em que a presente pesquisa se insere. A existência de viés de gênero em sistemas de AS está bem documentada. A influência do gênero dos anotadores sobre os rótulos produzidos é empiricamente estabelecida. O fenômeno de amplificação de viés pelo aprendizado supervisionado tem precedentes sólidos. O contexto do português brasileiro tem recebido atenção crescente, ainda que incipiente. O que nenhum dos trabalhos revisados faz, porém, é combinar simultaneamente esses quatro elementos: investigar as divergências anotativas associadas ao gênero em português brasileiro, medir empiricamente se e em que grau essas divergências são amplificadas ao longo do pipeline de aprendizado supervisionado e validar esse fenômeno tanto em dados reais quanto em um ambiente sintético controlado que permita isolar o efeito da fonte de anotação de todos os demais fatores experimentais. É exatamente essa lacuna que a MADA, descrita no capítulo seguinte, se propõe a preencher.

A Tabela III.1 sintetiza o posicionamento da presente pesquisa em relação à literatura revisada, evidenciando que nenhum dos trabalhos identificados combina simultaneamente os quatro eixos analíticos definidos: foco no gênero do anotador, tarefa de análise de sentimentos, mensuração de amplificação preditiva e aplicação em português brasileiro.

Tabela III.1: Matriz comparativa entre a literatura relacionada e a presente pesquisa segundo os quatro eixos analíticos definidos.

Trabalho Relacionado	**1. Foco no Gênero (Anotador)**	**2. Tarefa: Análise de Sentimentos**	**3. Mede Amplif. Preditiva**	**4. Aplic. em PT-BR**
Zhao et al. (2017)	–	–	✓	–
Geva et al. (2019)	–	–	–	–
Kuwatly et al. (2020)	✓	–	–	–
Kumar et al. (2020)	✓	✓	–	–
Prabhakaran et al. (2021)	✓	✓	–	–
Biester et al. (2022)	✓	✓	–	–
Ding et al. (2022)	✓	✓	–	–
Pei e Jurgens (2023)	✓	–	–	–
Taso et al. (2023)	–	–	–	✓
Jiang et al. (2024)	✓	–	–	–
A Presente Pesquisa (MADA)	✓	✓	✓	✓

Capítulo IV Apresentação dos *datasets*: uma abordagem complementar

Nesta seção, detalha-se a natureza e o processo de refinamento dos dados coletados, bem como o algoritmo proposto para a geração dos dados sintéticos, ambos envolvidos na construção da metodologia proposta.

A fase empírica do estudo do viés de gênero exigiu um material que preservasse a autenticidade da comunicação humana, justificando a escolha por um sistema com registros plurais sem a interferência de qualquer moderação de conteúdo.

Já na fase da metodologia que processa os dados gerados sinteticamente, o objetivo foi isolar e caracterizar o efeito da taxa de concordância entre fontes de anotação, manipulando diretamente um único parâmetro de interesse: o nível global de concordância entre os "anotadores", emulando a diferença dos gêneros autodeclarados na fase empírica do estudo.

IV.1 A riqueza da rotulagem humana (MQD-1465)

Os trabalhos relacionados revisados no capítulo anterior operam predominantemente sobre corpora em inglês com anotações agregadas por voto majoritário, sem estratificação demográfica dos anotadores. O corpus utilizado para a fase empírica deste estudo foi construído especificamente para corrigir essa lacuna no contexto do português brasileiro: as anotações foram coletadas com controle explícito do gênero autodeclarado dos anotadores e preservadas em sua forma desagregada, viabilizando a comparação entre grupos que é central à MADA.

O corpus inicial, denominado **MQD-1465**, é formado por 1.465 frases extraídas do portal *Meu Querido Diário* (`www.meuqueridodiario.com.br`) [Azevedo et al., 2021]. Diferente de bases de dados sintéticas, este material é composto por textos autênticos em português brasileiro, contendo expressões coloquiais e variações ortográficas originais. Essa característica é essencial para a metodologia proposta, pois permite observar como a subjetividade dos anotadores interage com a complexidade real da língua.

Como etapa preliminar ao experimento de anotação, o corpus passou por um processo de limpeza e randomização controlada, implementado em Python 3.13.7 com semente aleatória fixa (`seed = 42`) para fins de reprodutibilidade. Nessa etapa, foram identificadas e removidas duas frases duplicadas — especificamente os registros de IDs 476 e 953, mantendo-se as ocorrências originais de IDs 475

e 952, respectivamente —, resultando em um conjunto reduzido de 1.463 frases únicas. As frases foram ainda padronizadas com a remoção de espaços e aspas redundantes. Em seguida, o corpus randomizado foi particionado em 10 blocos sequenciais de até 150 frases cada, com o décimo bloco contendo 113 frases, conforme o total disponível após a remoção das duplicatas.

IV.1.1 A coleta via PCIbex

Os blocos foram implantados sequencialmente na plataforma Plataforma PCIbex Farm (PCIbex) Farm[1], que oferece infraestrutura para experimentos psicolinguísticos *online*. Cada participante acessava um bloco distinto do experimento e realizava a anotação das frases atribuídas a ele de forma autônoma e assíncrona. Seguindo o padrão de log fornecido pela plataforma, que demandou tratamento específico, foram coletados o identificador anonimizado do participante (*hash* MD5 do endereço IP), o gênero autodeclarado, rótulo atribuído a cada frase (positiva, negativa ou neutra) e o tempo de cada classificação, o qual foi guardado separadamente para futuras investigações sobre o efeito da fadiga no processo de rotulagem humana.

Os logs brutos exportados pelo PCIbex Farm apresentavam um formato CSV com 19 linhas de cabeçalho descritivo, seguidas por registros tabulares com 13 colunas: `ReceptionTime`, `ParticipantMD5`, `Controller`, `ItemNumber`, `InnerElementNumber`, `Label`, `Group`, `PennElementType`, `PennElementName`, `Parameter`, `Value`, `EventTime` e `Comments`. O arquivo referente ao Bloco 1 corresponde ao CSV `results_prod.csv` disponibilizado como dado bruto representativo, e os demais blocos seguiam convenção de nomenclatura sequencial (`results_prod (1).csv` a `results_prod (9).csv`).

O processamento de cada arquivo de log obedeceu à seguinte lógica: (i) leitura com supressão das linhas de cabeçalho; (ii) conversão da coluna `EventTime` para formato numérico; (iii) extração do gênero autodeclarado do participante, identificado pelo rótulo `"genero"` e pelo elemento de interface `"selecionaGenero"` com o parâmetro `"Selected"`; (iv) filtragem dos eventos de início e fim de cada *trial* (`Label == "frases"`, `Value` $\in$ {`"Start"`, `"End"`}), com o cálculo da duração em segundos pela diferença entre os *timestamps* de fim e início; (v) filtragem dos eventos de classificação (`Label == "frases"`, `Parameter == "Selection"`); e (vi) correção do número de item (`ItemNumber`), subtraindo-se 3 unidades — referentes aos itens de TCLE, instruções e coleta de gênero — e somando-se o deslocamento relativo ao bloco, obtendo assim o identificador correto no corpus randomizado. Ao final, cada registro foi enriquecido com a frase correspondente (por junção com o mapeamento de blocos), com o código de gênero do participante e com a duração do julgamento.

Os arquivos processados de cada bloco foram concatenados em um único *dataset*,

[1] `https://farm.pcibex.net/`

denominado `MQD-13317_anotacoes_totais.csv`, totalizando 13.317 registros de classificação individual. Esse arquivo foi então segmentado por gênero autodeclarado, originando dois subconjuntos: `MQD-7015_anotacoes_totais_masculinas.csv` (7.015 registros provenientes de anotadores identificados como masculinos) e `MQD-6302_anotacoes_totais_femininas.csv` (6.302 registros provenientes de anotadoras identificadas como femininas).

Para a geração do *dataset* final, adotou-se o critério de maioria simples, exigindo-se exatamente quatro julgamentos por frase em cada grupo de gênero e a existência de uma classe com mais votos do que qualquer outra — condição descrita formalmente pela Equação (IV.1):

$$\exists\, c : \text{votos}(c) > \text{votos}(c'), \quad \forall\, c' \neq c \tag{IV.1}$$

Foram consideradas configurações válidas: unanimidade (4-0-0), maioria qualificada (3-1-0) e maioria simples (2-1-1). A configuração de empate (2-2-0) foi tratada como inválida e resultou no descarte da frase. A seleção temporal priorizou as quatro primeiras anotações recebidas por ordem de chegada; em caso de empate, o algoritmo tentou substituir iterativamente a última anotação por anotações subsequentes disponíveis para aquela frase, até que a condição de maioria fosse satisfeita ou que todas as combinações se esgotassem.

Para o grupo masculino, 1.393 frases apresentaram maioria válida e 70 foram descartadas por empate irresolvível. Para o grupo feminino, 1.273 frases atenderam ao critério e 190 foram descartadas. A operação de junção interna (*inner join*) entre os dois subconjuntos resultantes, retendo apenas frases com maioria válida em ambos os grupos, produziu o *dataset* final composto por 1.222 frases, denominado `MQD-1222_majoritarias.csv`.

O *dataset* consolidado `MQD-1222_majoritarias.csv` contém, para cada frase, as seguintes variáveis por grupo de gênero: duração média dos julgamentos (`duracao_media`), total de classificações utilizadas no voto (`total_classificacoes`), classificação majoritária (`classificacao_majoritaria`), quantidade de votos na classe majoritária (`votos_maioria`), e contagens individuais de votos positivos, negativos e neutros (`total_positiva`, `total_negativa`, `total_neutra`). Uma coluna adicional de concordância binária (`concordancia_grupos`) indica se os dois grupos convergiram para a mesma classificação majoritária.

Informações adicionais registradas nos logs brutos, mas não incorporadas ao *dataset* final para a fase empírica da metodologia, incluem: o identificador anonimizado de cada participante (`ParticipantMD5`), a duração individual de cada julgamento antes da agregação por grupo e o número do bloco ao qual cada frase foi alocada. Esses dados encontram-se preservados nos arquivos intermediários e constituem material disponível para análises futuras, como estudos de variação intragrupal, efeitos de ordem de apresentação ou fadiga de anotação ao longo dos blocos.

A Tabela IV.1 resume a transição do volume de dados, desde a coleta bruta até a consolidação

dos subconjuntos utilizados nos experimentos de amplificação.

Tabela IV.1: Evolução da volumetria dos datasets na etapa de pré-processamento para a MADA.

Dataset	**Instâncias**	**Descrição/Etapa**
MQD-1465	1.465	Corpus bruto extraído do portal.
MQD-1463	1.463	Base após remoção de duplicatas (IDs 476 e 953).
MQD-13317	13.317	Total de anotações individuais processadas.
MQD-1222	**1.222**	Dataset final (paridade de gênero).

IV.2 O Controle dos Dados Sintéticos (SynSA)

Enquanto a natureza dos dados coletados na fase empírica do estudo emerge de fatores reais potencialmente múltiplos, o ambiente sintético permite abstrair esses fatores e controlar diretamente um parâmetro de forma isolada, característica fundamental para emular a divergência anotativa por gênero observada na fase com dados reais.

Foram gerados 12 conjuntos sintéticos independentes, denominados SynSA-50 a SynSA-99, nos quais a taxa de concordância nominal γ varia de 50% a 99%. Em todos os cenários, os seguintes aspectos foram mantidos constantes: o número total de instâncias, a distribuição marginal perfeitamente balanceada entre as três classes, a estrutura textual dos documentos e o protocolo integral de treinamento e avaliação. A única variável experimental manipulada foi γ, tornando a fase sintética um estudo de resposta a um parâmetro único e bem definido, aqui representado pela taxa de concordãncia.

IV.2.1 A Geração dos Dados Sintéticos

Os textos associados às instâncias de cada cenário sintético foram gerados como sequências aleatórias de tokens *placeholder* da forma `word`i, com i sorteado uniformemente no intervalo $[1, 500]$, resultando em um vocabulário de 500 termos distintos. O comprimento de cada texto varia uniformemente entre 20 e 100 tokens por instância. A combinação de vocabulário moderado e comprimentos variáveis produz documentos com distribuições TF-IDF não triviais, evitando degenerações na representação vetorial sem introduzir qualquer associação semântica entre tokens e classes.

Essa escolha de geração é deliberada e analiticamente motivada. Os textos gerados são semanticamente neutros e estatisticamente independentes dos rótulos atribuídos: nenhuma informação lexical está correlacionada com as classes. Como consequência, os classificadores treinados nesse ambiente não aprendem padrões linguísticos associados ao sentimento, mas respondem exclusivamente à estrutura de supervisão imposta pelos rótulos. Isso garante que as diferenças observadas nos vetores de predição $\hat{\mathbf{y}}_{\text{masc}}$ e $\hat{\mathbf{y}}_{\text{fem}}$ sejam atribuíveis exclusivamente ao

regime de concordância entre as fontes, e não a propriedades intrínsecas dos textos.

A estrutura textual, passando pela distribuição de comprimentos, vocabulário de *placeholders* e ausência de correlação léxico-semântica, foi mantida constante entre todos os valores de γ, garantindo que as diferenças nas métricas de amplificação entre cenários sejam imputáveis apenas à variação na taxa de concordância.

Para cada valor de γ, foi construído um conjunto de pares de rótulos $(\mathbf{y}_{\text{masc}}, \mathbf{y}_{\text{fem}})$ com as seguintes propriedades estruturais garantidas por construção:

- distribuição perfeitamente balanceada entre as três classes (negativa, neutra e positiva) para ambos os grupos, com exatamente $N/3$ instâncias por classe em cada fonte;
- proporção global de concordância exatamente igual a γ, parametrizada antes da geração;
- discordâncias distribuídas de forma balanceada entre as classes, preservando as distribuições marginais e evitando que a divergência se concentre em regiões específicas do espaço de classes.

Formalmente, cada dataset sintético contém $N = 999$ instâncias, distribuídas em 333 exemplos por classe ($N/3$ por categoria). O número de instâncias concordantes é dado pela Equação (IV.2):

$$N_{\text{conc}} = \text{round}(\gamma \cdot N), \tag{IV.2}$$

e o número de instâncias discordantes pela Equação (IV.3):

$$N_{\text{disc}} = N - N_{\text{conc}}. \tag{IV.3}$$

As N_{conc} instâncias concordantes receberam rótulos idênticos para ambas as fontes, distribuídos uniformemente entre as três classes ($\lfloor N_{\text{conc}}/3 \rfloor$ por classe, com o restante distribuído sequencialmente). As N_{disc} instâncias discordantes receberam rótulos distintos entre as fontes: o rótulo masculino foi atribuído ciclicamente entre as classes, e o rótulo feminino foi atribuído a uma classe diferente da masculina, alternando entre as demais classes de forma balanceada. Essa construção preservou a distribuição marginal uniforme de $N/3$ instâncias por classe em cada fonte.

A escolha de $N = 999$ obedeceu à divisibilidade exata por três (número de classes), garantindo um balanço perfeito sem a necessidade de arredondamentos nas distribuições marginais. Essa construção assegura que a divergência entre os grupos seja controlada exclusivamente pelo parâmetro γ, sem a introdução de assimetrias marginais que poderiam distorcer a estimativa do coeficiente κ por meio de seu componente p_e.

Capítulo V Metodologia

O fenômeno da amplificação de viés por classificadores de PLN foi documentado no nível de associações de gênero em corpora Zhao et al. [2017] e no nível de padrões de anotadores individuais Geva et al. [2019]. A presente proposta formaliza esse fenômeno no contexto do acordo interanotador entre grupos estratificados por gênero, baseando-se no conceito previamente descrito para **divergências anotativas**. O coeficiente κ de Cohen, formalizado na Seção II.4, serve como métrica de concordância em todas as etapas a seguir.

A metodologia está organizada em oito seções principais. Primeiramente, a Seção V.1 apresenta a estratégia de busca do estudo, com o uso do diagrama PRISMA 2020 [Page et al., 2021]. A Seção V.2 introduz a Metodologia de Análise de Divergências Anotativas (MADA) e sua arquitetura modular. A Seção V.3 formaliza a métrica de amplificação, incluindo sua interpretação, a classificação ordinal de severidade e a hipótese estatística subjacente. A Seção V.4 descreve o fluxo operacional comum às duas instâncias, detalhando os procedimentos de construção dos vetores de rótulos, representação textual, treinamento pareado, cálculo de métricas e estimativa de significância. As Seções V.5 e V.6 detalham, respectivamente, a instanciação empírica sobre o dataset MQD-1222 e a instanciação sintética sobre os cenários parametrizados por grau de concordância. A Seção V.7 descreve a estratégia de integração interpretativa entre as duas instanciações. Por fim, a Seção V.8 embasa as opções metodológicas assumidas pelo estudo, apontando naturais desdobramentos para pesquisas futuras.

V.1 Estratégia de Busca

Um dos pilares deste estudo se apoia na escassez de trabalhos acadêmicos que abordem o viés de anotação em língua portuguesa. Essa fragilidade é ainda mais observada em pesquisas nas bases internacionais mais consolidadas, como *Scopus, Web of Science, ACM Digital Library e ACL Anthology*. Em todas essas, nenhum resultado foi encontrado para a *string* de busca montada em português brasileiro. O mesmo comportamento foi observado na Biblioteca Digital da Sociedade Brasileira de Computação (SOL), reforçando a lacuna de trabalhos em língua portuguesa. A combinação escolhida para a busca em português foi a seguinte:

```
("viés do anotador"OR "viés de anotação"OR "discordância entre anotadores"OR
```

`"variação de rótulo humano"OR "demografia do anotador"OR "viés de rótulo"OR "anotação subjetiva") AND ("análise de sentimentos"OR "classificação de texto") AND ("amplificação de viés"OR "viés preditivo"OR "viés algorítmico"OR "aprendizado de máquina")`

Com a ausência de resultados em português, a solução encontrada foi traduzir os termos da busca combinada para o inglês. Essa ação apresentou resultados mais promissores, mas ainda assim tímidos. A redução de termos para permitir uma filtragem menos rigorosa trouxe resultados mais distantes do eixo principal do estudo metodológico proposto. A tradução aplicada à combinação previamente escolhida foi a seguinte:

`("annotator bias"OR "annotator disagreement"OR "human label variation"OR "annotator demographics"OR "label bias"OR "subjective annotation") AND ("sentiment analysis"OR "text classification") AND ("bias amplification"OR "predictive bias"OR "algorithmic bias"OR "machine learning")`

A escolha por um mapeamento sistemático em vez de uma revisão sistemática mostrou-se mais adequada, caracterizando que o objeto de pesquisa ainda contempla um nicho mais específico de uma literatura já consolidada. Os próprios números preliminares mostram isso com os quantitativos encontrados em cada base: *ACM Digital Library (83)*, *ACL Anthology (7)*, *Scopus (4)* e *Web of Science (2)*.

A esses insumos, foram adicionados como material de apoio artigos do *Google Scholar* (132), livros (11) e publicações discutidas durante a fase de orientação (15). A Figura V.1 descreve a fase de busca de acordo com a metodologia PRISMA 2020 [Page et al., 2021].

Além das buscas estruturadas nas bases de dados indexadas, foram identificados, até agora, 158 estudos adicionais por meio de outras fontes. Esse procedimento seguiu o protocolo de rastreamento de referências (*snowballing*) proposto por Wohlin [2014], no qual as listas de referências de artigos-chave previamente selecionados foram examinadas sistematicamente para identificação de trabalhos relevantes não recuperados pelas buscas nas bases de dados. Adicionalmente, foi conduzida busca manual em periódicos e anais de conferências de referência na área de PLN. A inclusão de fontes identificadas por rastreamento de referências e busca manual é prática recomendada pelo protocolo PRISMA 2020 [Page et al., 2021] para maximizar o mapeamento sistemático, particularmente em áreas de pesquisa emergentes ou interdisciplinares, nas quais a indexação em bases de dados pode ser incompleta.

V.2 Visão Geral da MADA

A MADA é proposta como um protocolo analítico modular destinado a detectar e quantificar a amplificação de divergências anotativas em modelos supervisionados de CT. Sua premissa central

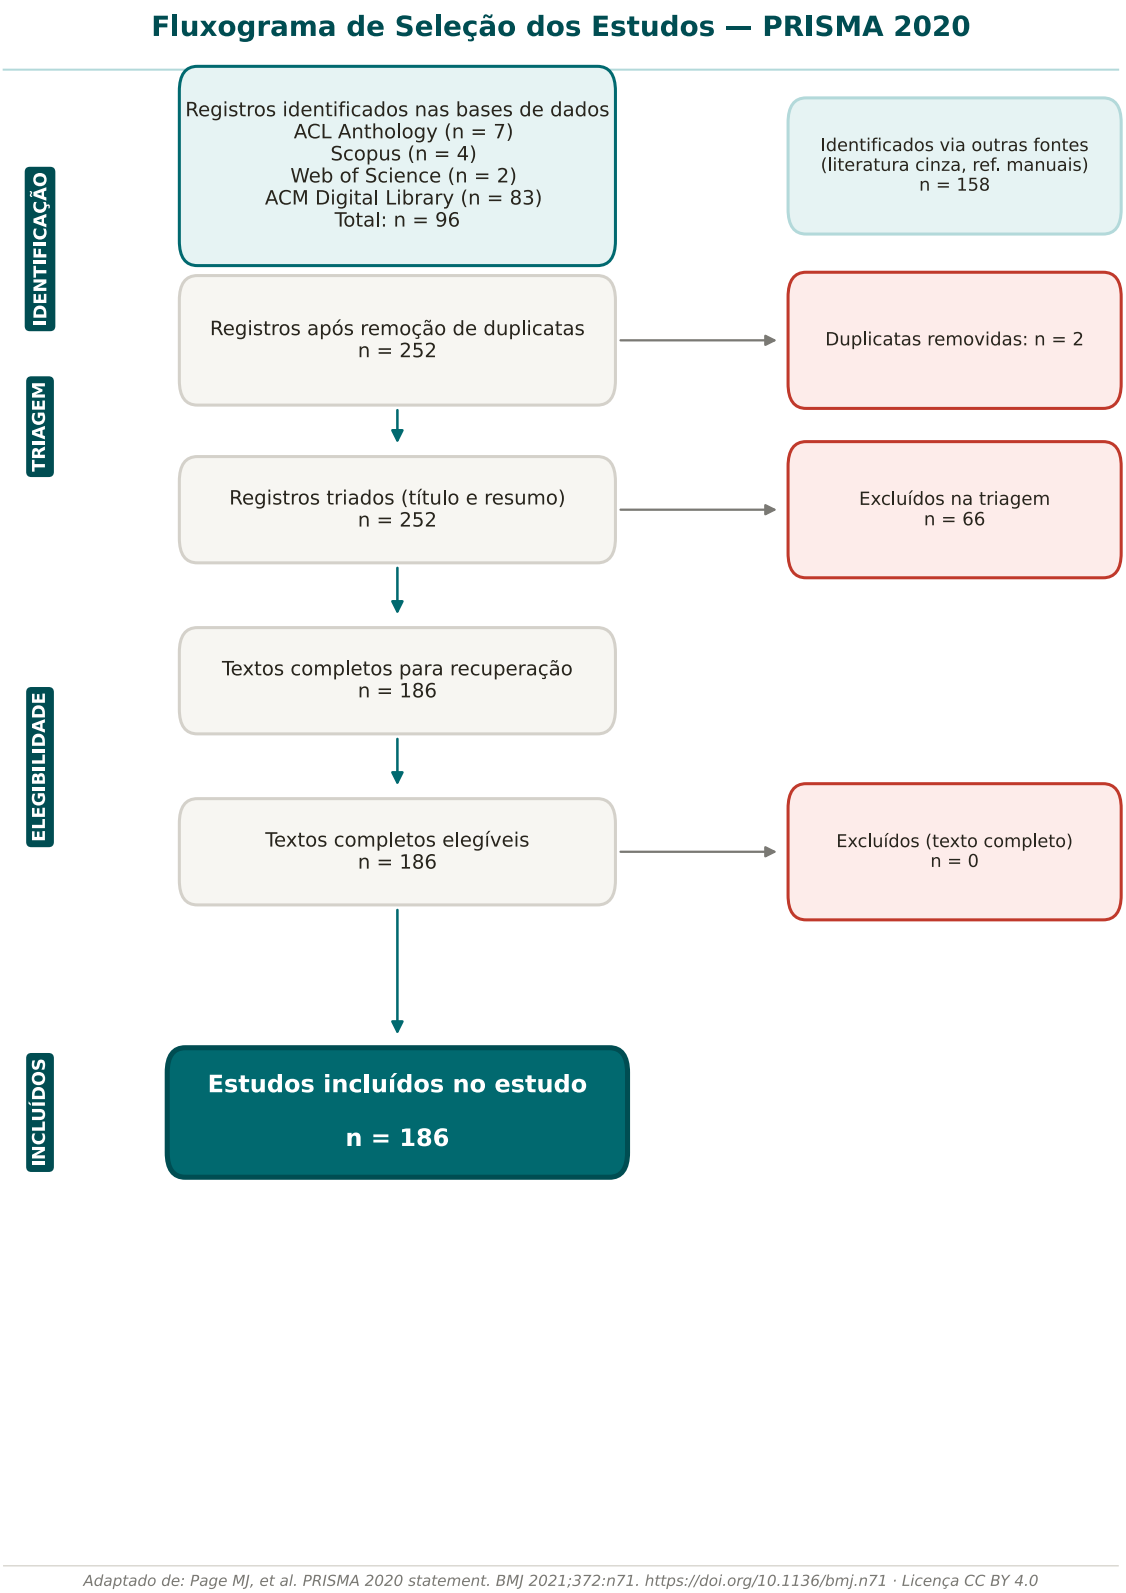

Figura V.1: Fluxograma de seleção dos estudos, elaborado de acordo com a declaração PRISMA 2020, apresentando as etapas de identificação, triagem, elegibilidade e inclusão dos textos analisados neste estudo.

distingue-a de abordagens tradicionais de análise de viés: ao invés de avaliar apenas a presença de viés nos dados de entrada ou no desempenho individual de modelos, a MADA investiga como o processo de aprendizado supervisionado intensifica ou atenua essas mesmas divergências previamente existentes entre grupos de anotadores humanos.

Essa distinção é conceitualmente relevante. Estudos anteriores tratam frequentemente a anotação humana como um estágio técnico cuja qualidade é avaliada pelo grau de concordância interanotador, buscando maximizá-la ou corrigi-la. A MADA parte de uma perspectiva complementar: a divergência entre anotadores não é necessariamente ruído a ser eliminado, mas pode ser um sinal interpretativo legítimo cujo comportamento, ao longo do pipeline de aprendizado, merece investigação sistemática. O objeto de análise não é, portanto, a divergência em si, mas o que ocorre com ela durante a generalização indutiva dos modelos.

A metodologia opera sobre uma configuração experimental de paridade estrita: dois conjuntos de rótulos, provenientes de grupos anotadores distintos, são aplicados ao mesmo corpus textual, com a mesma representação de atributos, os mesmos hiperparâmetros de treinamento e a mesma semente aleatória. Essa paridade garante que qualquer diferença observada entre os modelos resultantes seja atribuível exclusivamente à fonte dos rótulos de supervisão e não a variações no procedimento experimental.

O fluxo metodológico é estruturado em três módulos sequenciais e analiticamente complementares:

Módulo I — Estimativa da Baseline. Cálculo da concordância inicial entre os vetores de rótulos majoritários atribuídos por dois grupos distintos. Esse módulo fornece o referencial quantitativo contra o qual os resultados dos módulos subsequentes são comparados. A métrica principal é o coeficiente κ de Cohen [Cohen, 1960], complementado por métricas adicionais de associação estatística.

Módulo II — Treinamento Pareado de Classificadores. Para cada algoritmo de classificação avaliado (SVM NB, RF e LR), são conduzidos dois treinamentos independentes e estritamente pareados, diferenciados exclusivamente pela fonte de rótulos utilizada na supervisão. As predições geradas por cada par de modelos são, então, confrontadas entre si, e a concordância entre elas é estimada pela mesma métrica (κ) utilizada no Módulo I.

Módulo III — Quantificação da Amplificação. Comparação formal entre a concordância humana estimada no Módulo I e a concordância intermodelos obtida no Módulo II. A diferença entre essas duas estimativas constitui a métrica central de amplificação $\Delta\kappa$, cuja significância estatística é avaliada por reamostragem bootstrap.

A arquitetura modular confere à MADA duas propriedades fundamentais. A primeira é a

independência de domínio: a metodologia não pressupõe qualquer característica específica dos dados de entrada, podendo ser instanciada tanto sobre conjuntos empíricos de anotação humana quanto sobre conjuntos sintéticos com níveis de concordância parametrizados. A segunda é a replicabilidade: a separação entre os módulos permite que cada etapa seja documentada, verificada e reproduzida de forma independente, favorecendo a transparência do processo analítico.

A Figura V.2 apresenta o diagrama de fluxo da MADA, ilustrando a sequência modular e o critério de decisão que classifica a amplificação como identificada ($\Delta\kappa > 0$) ou não identificada ($\Delta\kappa \leq 0$).

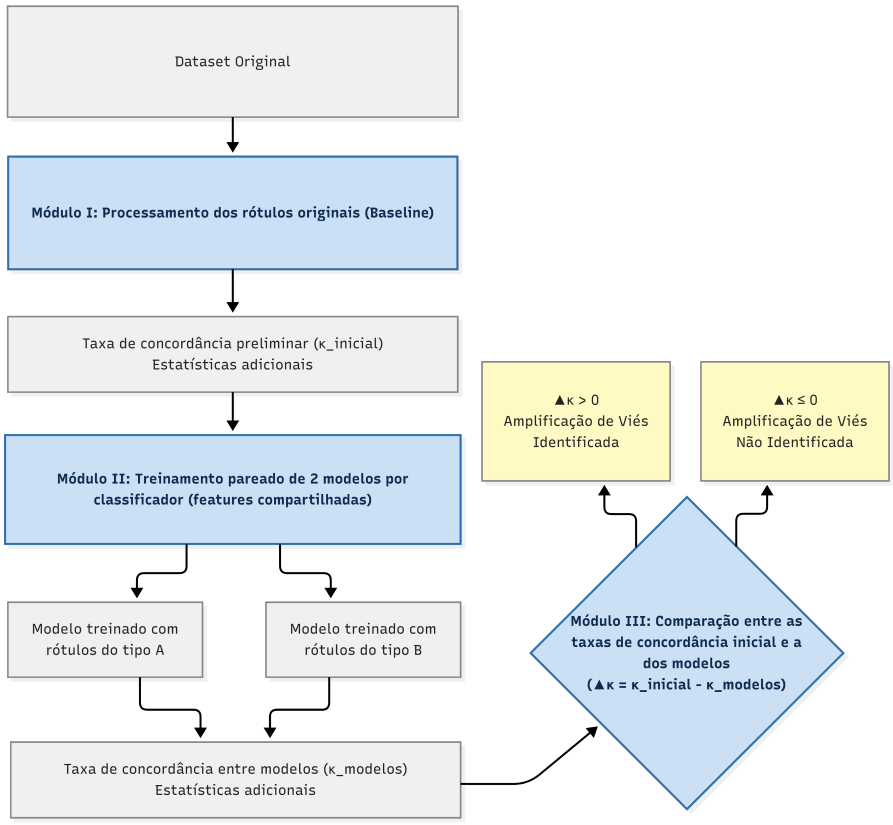

Figura V.2: Diagrama de fluxo da MADA. O fluxo é organizado em três módulos sequenciais: o Módulo I estima a concordância inicial entre anotadores (κ_{inicial}); o Módulo II realiza o treinamento pareado de dois classificadores com rótulos provenientes de fontes distintas e estima a concordância entre suas predições (κ_{modelos}); o Módulo III computa $\Delta\kappa = \kappa_{\text{inicial}} - \kappa_{\text{modelos}}$ e classifica o resultado. Valores $\Delta\kappa > 0$ indicam amplificação identificada; $\Delta\kappa \leq 0$ indicam ausência de amplificação.

V.3 Fundamentos da Métrica de Amplificação

A escolha por desenvolver uma métrica própria de amplificação baseada no coeficiente de Cohen, em vez de adotar medidas extrínsecas de justiça algorítmica, apoia-se em limitações recentes documentadas na literatura de avaliação de viés. Cabello et al. [2023] demonstraram empiricamente que diferentes métricas de viés representacional frequentemente produzem resultados inconsistentes e contraditórios quando aplicadas aos mesmos modelos. Diante dessa instabilidade

das métricas tradicionais, a formalização do $\Delta\kappa$ proposta por esta metodologia assegura um controle matemático rigoroso, avaliando a amplificação do viés não como uma abstração semântica, mas como a degradação exata da concordância pareada ao longo do aprendizado supervisionado.

No contexto da MADA duas estimativas distintas de κ são sistematicamente obtidas e comparadas:

- κ_{inicial}: concordância entre os rótulos majoritários atribuídos ou emulados por dois grupos comparáveis. Essa estimativa representa o nível basal de divergência interpretativa presente nos dados antes de qualquer etapa de modelagem.
- κ_{modelos}: concordância entre as predições geradas pelos modelos treinados separadamente com os rótulos de cada grupo. Essa estimativa reflete o nível de divergência após a generalização indutiva dos modelos.

A comparação entre essas duas estimativas permite avaliar se o processo de aprendizado supervisionado preserva, reduz ou amplifica a divergência originalmente observada.

V.3.1 Interpretação da Amplificação

A amplificação da divergência é formalmente definida pela Equação (V.1):

$$\Delta\kappa \;=\; \kappa_{\text{inicial}} \;-\; \kappa_{\text{modelos}}. \tag{V.1}$$

Essa definição admite três regimes interpretativos, que são diretamente observados no contexto deste estudo. Quando $\Delta\kappa > 0$ a concordância entre os modelos é inferior à concordância entre os anotadores humanos, isso indica que o processo de treinamento supervisionado resultou em um aumento relativo da divergência interpretativa: os modelos de cada classificador discordam entre si em um maior grau do que os próprios anotadores discordavam. Esse é o regime de amplificação, que constitui o fenômeno central investigado neste trabalho.

Quando $\Delta\kappa = 0$ o nível de divergência é preservado ao longo do pipeline, os modelos reproduzem com fidelidade a estrutura de concordância presente nos dados de supervisão, sem intensificação nem atenuação. Quando $\Delta\kappa < 0$, observa-se redução da divergência após o treinamento supervisionado: os modelos concordam entre si em maior grau do que os anotadores originais. Esse regime, que poderia ser denominado convergência induzida, não é o fenômeno de interesse primário neste estudo, mas sua possibilidade é contemplada pela formulação da métrica.

É relevante perceber que a amplificação é interpretada como um efeito emergente do *pipeline* de aprendizado, e não como um atributo individual dos anotadores ou dos algoritmos isoladamente. O fenômeno decorre da interação entre a estrutura de divergência presente nos rótulos de supervisão e

os mecanismos de generalização indutiva de cada classe de algoritmos, conforme discutido na análise dos resultados.

V.3.2 Classificação de Severidade

Para além da magnitude numérica de $\Delta\kappa$, a MADA incorpora uma dimensão qualitativa de avaliação baseada nas faixas interpretativas de Landis e Koch [Landis and Koch, 1977], apresentadas na Tabela II.1. A severidade da amplificação é determinada pelo número de faixas percorridas entre κ_{inicial} e κ_{modelos} nessa escala.

- $s = 0$: ausência de amplificação qualitativa;
- $s = 1$: amplificação leve (perda de uma faixa);
- $s = 2$: amplificação moderada (perda de duas faixas);
- $s \geq 3$: amplificação severa (perda de três ou mais faixas).

V.3.3 Hipótese Estatística

A hipótese operacional da MADA é formulada como teste unilateral sobre o sinal de $\Delta\kappa$ (Equações (V.2) e (V.3):

$$H_0 : \kappa_{\text{modelos}} \geq \kappa_{\text{inicial}} \tag{V.2}$$

$$H_1 : \kappa_{\text{modelos}} < \kappa_{\text{inicial}} \tag{V.3}$$

A hipótese nula postula que o processo de aprendizado supervisionado preserva ou melhora a concordância observada entre os grupos de anotadores; ou seja, que não há amplificação da divergência interpretativa. A hipótese alternativa afirma que a concordância intermodelos é estritamente inferior à concordância inicial entre os anotadores, configurando amplificação.

A rejeição de H_0 fornece evidência estatisticamente robusta de que o treinamento supervisionado intensifica as divergências anotativas preexistentes, o que constitui o resultado central a ser estabelecido. A significância estatística é estimada por meio de reamostragem bootstrap, conforme descrito na Seção V.4.5.

A formulação unilateral do teste é justificada pela direcionalidade do fenômeno investigado: o interesse analítico recai sobre a ocorrência de amplificação e não sobre a redução da divergência. Valores de $\Delta\kappa$ negativos são, portanto, compatíveis com H_0 e não constituem resultado de interesse para os objetivos desta pesquisa.

V.4 Estrutura Geral do Fluxo Experimental

A instanciação operacional da MADA segue um fluxo estruturado que garante a comparabilidade entre fontes de anotação e a reprodutibilidade experimental. O procedimento foi implementado de forma idêntica para as duas instanciações, variando exclusivamente a natureza dos dados de entrada, que, para o escopo deste estudo, concentrou a paridade na distinção dos gêneros, emulados e auto-declarados. Essa identidade de protocolo é condição necessária para que a comparação entre os dois regimes experimentais seja metodologicamente válida.

V.4.1 Construção dos Vetores de Rótulos

Para cada instância textual, foram definidos dois vetores de rótulos consolidados, correspondendo às duas fontes de supervisão a serem comparadas:

- $\mathbf{y}_{\text{masc}}$: vetor de rótulos majoritários atribuídos ao grupo masculino;
- $\mathbf{y}_{\text{fem}}$: vetor de rótulos majoritários atribuídos ao grupo feminino.

A consolidação dos rótulos individuais em um único rótulo representativo por grupo foi realizada por meio da obtenção mínima de maioria simples: para cada instância, o rótulo mais frequente entre os anotadores do grupo é selecionado. Em caso de empate irresolvível entre duas ou mais classes com a mesma frequência máxima, a instância é excluída da análise, garantindo que cada elemento do corpus mantenha exatamente um rótulo consolidado por grupo.

Essa decisão de design tem implicação direta sobre a interpretação dos resultados: ao representar cada grupo por seu rótulo majoritário, a MADA opera sobre o padrão interpretativo coletivo de cada fonte e não sobre a variabilidade intragrupal. A divergência mensurada é, portanto, uma divergência entre posições coletivas consolidadas, o que é conceitualmente consistente com o objetivo de investigar diferenças sistemáticas entre grupos e não flutuações individuais de anotadores.

O conjunto analítico final é restrito às instâncias que possuem rótulos válidos para ambos os grupos simultaneamente, assegurando paridade estrutural na comparação e evitando assimetrias decorrentes de instâncias excluídas seletivamente em um dos grupos.

V.4.2 Processamento Textual (TF-IDF)

As instâncias textuais foram convertidas em representações numéricas por meio da técnica TF-IDF (*Term Frequency–Inverse Document Frequency*), que pondera a frequência de ocorrência de cada termo em um documento pela raridade relativa desse termo no corpus inteiro. Essa ponderação atenua a influência de termos de alta frequência e baixo poder discriminativo (como artigos e preposições) e amplifica a relevância de termos informativos que são relativamente raros no corpus.

A representação TF-IDF foi mantida rigorosamente idêntica para os dois treinamentos pareados de cada classificador. A mesma matriz de atributos, construída a partir do corpus completo e fixada antes da validação cruzada, foi utilizada em ambos os treinamentos, garantindo que qualquer diferença observada entre as predições seja decorrente exclusivamente das variações nos vetores de supervisão $\mathbf{y}_{\text{masc}}$ e $\mathbf{y}_{\text{fem}}$.

V.4.3 Treinamento Pareado com Validação Cruzada

Para cada classificador avaliado, foram conduzidos dois treinamentos supervisionados independentes e estritamente pareados:

- Treinamento M: ajuste do classificador utilizando $\mathbf{y}_{\text{masc}}$ como vetor de supervisão;
- Treinamento F: ajuste do classificador utilizando $\mathbf{y}_{\text{fem}}$ como vetor de supervisão.

O pareamento entre os dois treinamentos é garantido pela manutenção da mesma configuração de validação cruzada em ambas as execuções. A avaliação foi realizada por meio de validação cruzada estratificada com cinco partições (*Stratified K-Fold*), com embaralhamento controlado por semente fixa e idêntica nos dois treinamentos. A estratificação garante que a distribuição de classes seja preservada em cada partição, o que é especialmente relevante em tarefas com distribuições marginais assimétricas.

Para cada uma das cinco partições, o modelo é ajustado sobre as quatro partições restantes (subconjunto de treino) e utilizado para gerar predições sobre a partição retida (subconjunto de teste). Ao término das cinco iterações, as predições fora da amostra (*out-of-fold*) são concatenadas, formando um vetor completo de predições que cobre todas as N instâncias do corpus exatamente uma vez. A semente aleatória é fixada na inicialização do particionador, garantindo que a sequência de *splits* seja idêntica em todas as execuções e comparações.

A estratificação é definida sobre o vetor de rótulos majoritários do grupo masculino $\mathbf{y}_{\text{masc}}$, e os mesmos *splits* resultantes são aplicados integralmente ao treinamento do modelo feminino $\mathbf{y}_{\text{fem}}$. Essa decisão garante que os subconjuntos de treino e teste sejam rigorosamente idênticos para os dois modelos pareados, eliminando qualquer variação de particionamento como fonte espúria de diferença entre as predições.

Ao final das cinco iterações, as predições fora da amostra são armazenadas por fold para o cálculo das métricas de concordância descritas na Seção V.4.4, produzindo adicionalmente dois vetores globais de predição concatenada $\hat{\mathbf{y}}_{\text{masc}}$ e $\hat{\mathbf{y}}_{\text{fem}}$, utilizados para o cálculo do V de Cramér e da estatística χ^2.

V.4.4 Cálculo das Métricas de Concordância

A concordância entre os modelos treinados separadamente foi estimada por meio do coeficiente κ de Cohen. O cálculo é realizado por fold: para cada uma das cinco partições, obtém-se um par de vetores de predição de teste $(\hat{\mathbf{y}}^{(k)}_{\text{masc}}, \hat{\mathbf{y}}^{(k)}_{\text{fem}})$ e computa-se o coeficiente de concordância local, conforme a Equação (V.4):

$$\kappa^{(k)} = \kappa\left(\hat{\mathbf{y}}^{(k)}_{\text{masc}}, \hat{\mathbf{y}}^{(k)}_{\text{fem}}\right), \quad k = 1, \ldots, 5. \tag{V.4}$$

O κ_{modelos} reportado corresponde à média aritmética dos valores obtidos nas cinco partições:

$$\kappa_{\text{modelos}} = \frac{1}{K}\sum_{k=1}^{K} \kappa^{(k)}, \quad K = 5. \tag{V.5}$$

Adicionalmente, o desvio padrão dos $\kappa^{(k)}$ é reportado como medida da estabilidade da concordância ao longo das partições.

Complementarmente, o coeficiente V de Cramér é calculado conforme a Equação (V.6), a partir da matriz de contingência construída sobre a concatenação global de todas as predições fora da amostra:

$$V = \sqrt{\frac{\chi^2}{N \cdot (\min(r, c) - 1)}}, \tag{V.6}$$

onde N é o número total de instâncias, r e c são o número de linhas e colunas da matriz de contingência, respectivamente. Essas métricas complementares caracterizam a magnitude e a significância da associação estatística entre os dois modelos de forma independente da partição.

V.4.5 Estimativa de Significância via Bootstrap

A reamostragem bootstrap com 1.000 iterações é aplicada em dois momentos distintos do protocolo experimental, com finalidades complementares.

Bootstrap do κ_{inicial}. No começo, após o cálculo do coeficiente de concordância entre os grupos de anotadores, aplica-se bootstrap diretamente sobre os pares de vetores de rótulos majoritários $(\mathbf{y}_{\text{masc}}, \mathbf{y}_{\text{fem}})$. Em cada iteração, índices são amostrados com reposição e o κ é recalculado sobre os pares reamostrados. Os percentis 2,5 e 97,5 da distribuição resultante fornecem o Intervalo de Confiança (IC) de 95% para κ_{inicial}, quantificando a incerteza de estimação das baselines.

Bootstrap do $\Delta\kappa$. Em um segundo momento, após o cálculo de $\Delta\kappa$, aplica-se bootstrap sobre os vetores globais de predição concatenada $\hat{\mathbf{y}}_{\text{masc}}$ e $\hat{\mathbf{y}}_{\text{fem}}$. O pareamento entre as predições é preservado em cada iteração: os mesmos índices reamostrados são aplicados simultaneamente aos dois vetores. Sobre cada par reamostrado, recalcula-se κ_{modelos} e, consequentemente, $\Delta\kappa$. Os

percentis 2,5 e 97,5 da distribuição de $\Delta\kappa$ reamostrado fornecem o IC de 95% para a métrica de amplificação.

Considera-se evidência estatisticamente significativa de amplificação quando o IC de $\Delta\kappa$ não inclui o valor zero, o que corresponde à rejeição da hipótese nula H_0 (Equação (V.2) ao nível de 5%.

V.5 Instanciação Empírica

A instanciação empírica da MADA aplica o protocolo descrito na Seção V.4 a um conjunto de dados reais de análise de sentimento em português brasileiro, anotado por dois grupos demograficamente distintos. O objetivo desta instanciação é verificar, em condições de anotação humana real, se a divergência interpretativa associada ao gênero do anotador se manifesta e se amplifica ao longo do pipeline de aprendizado supervisionado.

V.5.1 Dataset MQD-1222

O conjunto de dados empírico foi construído a partir de uma base inicial contendo 1.465 textos curtos em português brasileiro, previamente coletados do blog *Meu Querido Diário* (http://www.meuqueridodiario.com.br) para uma tarefa de classificação de sentimento com três categorias: negativa, neutra e positiva. Os textos foram selecionados de forma a cobrir um espectro variado de expressão de sentimento, incluindo instâncias de polaridade clara e instâncias de ambiguidade semântica moderada, condição necessária para que a divergência interpretativa entre grupos pudesse emergir de forma observável.

O protocolo de anotação foi conduzido na plataforma PCIbex, com quatro anotadores masculinos e quatro anotadoras femininas avaliando cada instância de forma independente. A independência entre os anotadores é uma condição metodológica fundamental: ao garantir que cada anotador realize seu julgamento sem acesso às avaliações dos demais, preserva-se a autenticidade das divergências interpretativas e evita-se a convergência artificial por influência social ou ancoragem em avaliações prévias.

Para cada grupo, o rótulo majoritário de cada instância foi determinado por maioria simples entre os quatro anotadores. As instâncias nas quais a classe mais votada, após todos os tratamentos previstos, empatou com outra classe foram excluídas da análise, pois, nesses casos, não foi possível determinar de forma não arbitrária um único rótulo representativo do grupo. Após essa filtragem, obteve-se o conjunto final denominado MQD-1222, composto por 1.222 instâncias com rótulos majoritários válidos e não ambíguos para ambos os grupos.

O estudo foi conduzido em conformidade com os princípios éticos da pesquisa envolvendo seres humanos e foi aprovado pelo Comitê de Ética em Pesquisa (CEP) sob o protocolo Certificado de Apresentação de Apreciação Ética (CAAE) 82267824.8.0000.5289. O gênero dos participantes foi

autodeclarado e utilizado exclusivamente como critério de estratificação analítica, sem associação a qualquer outra informação pessoal identificável.

V.5.2 Estimativa da Baseline

O Módulo I da instanciação empírica consiste na caracterização estatística da divergência inicial entre os grupos anotadores. A concordância entre os vetores $\mathbf{y}_{\text{masc}}$ e $\mathbf{y}_{\text{fem}}$ foi estimada pelo coeficiente κ de Cohen, calculado sobre as 1.222 instâncias do conjunto final. Esse valor, denominado κ_{inicial}, estabeleceu o patamar de divergência a ser confrontado com a concordância intermodelos estimada após o treinamento supervisionado, conforme descrito nas seções subsequentes. Além do coeficiente κ, foram calculadas as seguintes métricas complementares para uma caracterização estatística mais abrangente da relação entre os dois grupos:

- estatística χ^2 do teste de independência, avaliando se a distribuição conjunta dos rótulos difere significativamente da esperada sob independência estatística;
- coeficiente V de Cramér, que quantifica a magnitude da associação entre os grupos de forma normalizada e comparável.

A inspeção da matriz de contingência entre $\mathbf{y}_{\text{masc}}$ e $\mathbf{y}_{\text{fem}}$ permitiu identificar os padrões de discordância mais frequentes entre os grupos, revelando quais fronteiras semânticas concentram a maior proporção de divergências interpretativas. Essa análise qualitativa complementa a estimativa numérica de κ e informa a interpretação dos resultados obtidos nos módulos subsequentes.

V.5.3 Representação Textual

As instâncias textuais do MQD-1222 foram convertidas em vetores numéricos por TF-IDF, utilizando os seguintes parâmetros de configuração:

- n-gramas de ordem 1 a 3 (unigramas, bigramas e trigramas);
- limite máximo de 10.000 atributos;
- frequência mínima de documento min_df = 3;
- frequência máxima de documento max_df = 0,90;
- preservação dos acentos (`strip_accents=None`), mantendo a morfologia original dos termos em português;
- ponderação sublinear da frequência dos termos (`sublinear_tf=True`);
- normalização ℓ_2 dos vetores de saída;

- remoção de *stopwords* em português.

A matriz TF-IDF foi construída a partir do corpus completo de 1.222 instâncias e mantida fixa ao longo de toda a validação cruzada. O processo seguiu os parâmetros descritos na Seção V.4.2.

V.5.4 Treinamento e Validação

Para cada um dos quatro classificadores avaliados, foram conduzidos dois treinamentos supervisionados independentes, seguindo o protocolo descrito na Seção V.4.3. O treinamento M utilizou $\mathbf{y}_{\text{masc}}$ como vetor de supervisão; o treinamento F utilizou $\mathbf{y}_{\text{fem}}$. A representação textual TF-IDF permaneceu idêntica em ambos os treinamentos, assegurando que eventuais diferenças nas predições sejam atribuíveis exclusivamente às variações nos rótulos de supervisão.

Os classificadores foram configurados com hiperparâmetros padrão, sem quaisquer ajustes baseados nos dados, o que é deliberado: o objetivo da MADA não é obter o melhor desempenho preditivo possível para cada algoritmo, mas comparar o comportamento de pares de modelos treinados sob condições experimentais controladas. A introdução de ajustes diferenciados de hiperparâmetros comprometeria a atribuição do fenômeno de amplificação à fonte dos rótulos.

A Tabela V.1 consolida os parâmetros de representação textual e os hiperparâmetros dos classificadores empregados nas duas instanciações da MADA. Todos os valores foram mantidos fixos ao longo de toda a experimentação, assegurando que as diferenças observadas entre os modelos pareados sejam atribuíveis exclusivamente à fonte dos rótulos de supervisão.

Ao término da validação cruzada, os vetores completos de predição fora da amostra $\hat{\mathbf{y}}_{\text{masc}}$ e $\hat{\mathbf{y}}_{\text{fem}}$ foram utilizados para o cálculo das métricas de concordância e amplificação, conforme descrito nas seções V.4.4 e V.4.5.

V.5.5 Concordância Intermodelos

A concordância entre os pares de modelos foi estimada pelo coeficiente κ_{modelos} conforme a Equação (V.5).

Além do coeficiente κ, foram calculadas as métricas de associação estatística descritas na Seção V.4.4, derivadas da matriz de contingência entre os vetores de predição pareados. Essas métricas complementam a análise de amplificação, fornecendo uma caracterização mais rica da relação entre os dois modelos, além da simples concordância por classe.

A significância estatística de $\Delta\kappa$ foi estimada pelo procedimento bootstrap descrito na Seção V.4.5. Em todos os classificadores avaliados, a amplificação foi considerada significativa quando o IC de 95% excluiu o valor zero.

Tabela V.1: Configuração experimental consolidada: representação textual e hiperparâmetros dos classificadores.

Componente	**Parâmetro**	**Valor**
Representação Textual (TF-IDF)		
	Faixa de n-gramas	(1, 3)
	Máximo de atributos	10.000
	Frequência mín. de documento	min_df = 3
	Frequência máx. de documento	max_df = 0,90
	Remoção de acentos	Não (`None`)
	Ponderação sublinear	Sim
	Normalização	ℓ_2
	Stopwords	Português
Validação Cruzada		
	Número de *folds* (K)	5
	Estratificação	Por $\mathbf{y}_{\text{masc}}$
	Semente aleatória	Fixa (reprodutível)
Classificadores (hiperparâmetros padrão do scikit-learn)		
SVM	Kernel	RBF
	C (regularização)	1,0
	γ	`scale`
Naive Bayes	Distribuição	Multinomial
	α (suavização)	1,0
Random Forest	Número de árvores	100
	Critério de divisão	Gini
	Profundidade máxima	Sem limite
Logistic Regression	Penalização	ℓ_2
	C (regularização inversa)	1,0
	Solver	`lbfgs`
Bootstrap		
	Iterações	1.000
	Intervalo de confiança	95%

V.6 Instanciação Sintética

A representação textual nos cenários sintéticos foi baseada em TF-IDF com parametrização *idêntica* à adotada no estudo empírico: n-gramas de ordem 1 a 3, limite de 10.000 atributos, min_df = 3, max_df = 0,90, `strip_accents=None`, lista de *stopwords* em português, ponderação sublinear e normalização ℓ_2. Essa escolha é deliberada: embora os filtros de frequência e a lista de *stopwords* sejam operacionalmente inócuos sobre textos compostos por tokens *de placeholder* (nenhum token da forma `word`i coincide com *stopwords* do português, e todos tendem a satisfazer os critérios de frequência após a geração aleatória), mantê-los garante a paridade integral do pipeline entre as duas instanciações. Dessa forma, qualquer diferença observada nas métricas de amplificação entre o cenário sintético e o cenário empírico não pode ser atribuída a variações no procedimento de representação.

O protocolo de treinamento pareado, validação cruzada estratificada por $\mathbf{y}_{\text{masc}}$ com cinco partições, cálculo de κ_{modelos} com média por fold, estimativa de $\Delta\kappa$, cálculo do coeficiente V de Cramér sobre predições concatenadas e o procedimento de bootstrap duplo (para κ_{inicial} e para $\Delta\kappa$) foram mantidos rigorosamente idênticos aos adotados na instanciação empírica. Essa identidade de protocolo é uma condição necessária para que a comparação entre os dois regimes experimentais e a análise integrativa descrita na Seção V.7 sejam metodologicamente válidas.

V.7 Estratégia de Integração Interpretativa

A aplicação da MADA em contexto empírico e sintético tem caráter complementar e analiticamente sinérgico. As duas instanciações respondem a perguntas distintas, mas mutuamente informativas: a instanciação empírica estabelece se o fenômeno de amplificação ocorre em condições reais de anotação, com toda a complexidade inerente; a instanciação sintética caracteriza o comportamento estrutural do fenômeno sob controle paramétrico, revelando como a taxa de concordância inicial e a arquitetura do classificador modulam a magnitude da amplificação.

É importante destacar a independência analítica das duas instâncias. Cada uma pode ser executada e interpretada de forma autônoma, e a validade dos resultados de uma não depende estruturalmente dos resultados da outra. A comparação entre as instanciações não é, portanto, um requisito de validação interna, mas uma oportunidade de enriquecimento interpretativo: o posicionamento do resultado empírico no espaço de comportamentos descritos sinteticamente permite avaliar se o fenômeno observado em dados reais é consistente com o padrão estrutural revelado em condições controladas.

A estratégia de integração opera em dois níveis analíticos complementares. O primeiro é a ancoragem quantitativa: o valor empírico de κ_{inicial} é identificado no espectro de cenários sintéticos,

localizando o contexto real em um ponto específico da curva paramétrica. Essa ancoragem permite avaliar se a magnitude empírica de $\Delta\kappa$ é compatível com o comportamento esperado para o nível de concordância observado.

O segundo nível é a análise de propensão diferencial: a comparação entre classificadores ao longo dos cenários sintéticos revela quais arquiteturas apresentam maior sensibilidade à heterogeneidade anotativa e se esse padrão de diferenciação se mantém no contexto empírico. A consistência desse padrão entre os dois regimes constitui evidência adicional da natureza estrutural do fenômeno, afastando interpretações baseadas em características idiossincráticas de um conjunto de dados específico.

A manutenção do mesmo protocolo de representação, treinamento, validação e mensuração em ambas as instanciações assegura que as diferenças observadas entre os cenários decorram exclusivamente da natureza dos dados e do regime de concordância considerado, e não de variações no procedimento experimental. Essa paridade metodológica é condição necessária para que a integração interpretativa entre as duas instanciações seja analiticamente sustentada.

V.8 Escolhas Metodológicas

A escolha de representação TF-IDF combinada com classificadores tradicionais (SVM NB, RF e LR) constitui uma decisão metodológica deliberada, orientada pelo objetivo central deste trabalho: isolar e mensurar o efeito da fonte de anotação sobre as predições dos modelos. Modelos de linguagem pré-treinados baseados em arquiteturas transformadoras (como BERTimbau ou outros modelos contextuais) incorporam representações semânticas aprendidas em grandes corpora, as quais podem conter vieses de gênero latentes oriundos dos dados de pré-treinamento [Zhao et al., 2017; Shah et al., 2020]. A utilização de tais modelos introduziria uma variável confundidora: eventuais amplificações observadas poderiam decorrer tanto das divergências anotativas quanto dos vieses já codificados nas representações pré-treinadas, tornando inviável a atribuição causal inequívoca ao processo de anotação.

A representação TF-IDF, por sua natureza não-contextual e dependente exclusivamente da distribuição lexical do corpus de treinamento, permite que o modelo aprenda padrões diretamente dos rótulos fornecidos pelos anotadores, sem interferência de conhecimento prévio externo. Dessa forma, qualquer amplificação de divergências anotativas capturada pelo índice $\Delta\kappa$ pode ser atribuída com maior confiança ao processo de aprendizagem supervisionada sobre os rótulos estratificados por gênero e não a vieses pré-existentes nas representações.

Cabe observar que a comparação entre classificadores tradicionais e modelos transformadores constitui uma extensão natural e relevante deste trabalho. Espera-se que modelos pré-treinados apresentem comportamento distinto: por um lado, suas representações contextuais podem capturar

nuances semânticas que atenuem o impacto de divergências anotativas; por outro, a presença de vieses de gênero nas representações pré-treinadas pode interagir de forma não-linear com as divergências dos rótulos de treinamento, potencialmente amplificando ou mascarando o efeito observado. A investigação dessa interação representa uma direção promissora para trabalhos futuros.

Capítulo VI Resultados

Este capítulo apresenta os resultados decorrentes da aplicação da (MADA) nas duas instanciações descritas no Capítulo V: a empírica, conduzida sobre o conjunto MQD-1222, e a sintética, realizada sobre os doze cenários controlados denominados SynSA-50 a SynSA-99. A exposição segue a estrutura modular da metodologia: o Módulo I estabelece a concordância inicial entre as fontes anotativas; o Módulo II registra a concordância entre os modelos treinados de forma pareada; e o Módulo III quantifica a eventual amplificação da divergência por meio do indicador $\Delta\kappa$ (Equação (V.1), reproduzida abaixo por conveniência):

$$\Delta\kappa \;=\; \kappa_{\text{inicial}} \;-\; \kappa_{\text{modelos}}, \tag{V.1$'$}$$

no qual valores positivos indicam que a concordância entre os modelos é inferior à concordância entre os anotadores humanos, caracterizando a amplificação da divergência interpretativa inicial. Ao término das duas seções, realiza-se uma análise integrativa que confronta os dois regimes experimentais, avaliando a consistência estrutural do fenômeno observado e posicionando o resultado empírico no espaço de comportamentos modelados sinteticamente.

VI.1 Resultados Empíricos

A instanciação empírica da MADA tem como objetivo verificar, em condições reais de anotação, se as divergências interpretativas associadas ao gênero do anotador são preservadas, atenuadas ou amplificadas ao longo do pipeline de aprendizado supervisionado. Os resultados são apresentados na sequência em que o protocolo experimental os produz, correspondendo diretamente aos três módulos metodológicos.

VI.1.1 Módulo I: Concordância Inicial entre Anotadores

O primeiro módulo estabelece o referencial quantitativo a partir do qual toda a análise subsequente é ancorada. A concordância entre os grupos masculino e feminino foi estimada pelo coeficiente κ de Cohen [1960], calculado sobre os vetores de rótulos majoritários $\mathbf{y}_{\text{masc}}$ e $\mathbf{y}_{\text{fem}}$, consolidados por meio de maioria simples. Além do coeficiente κ, foram computadas a proporção de concordância observada, a estatística do χ^2 de independência e o coeficiente V de Cramér, derivados

da matriz de contingência entre os dois grupos.

A Figura VI.1 apresenta essa matriz de contingência. A predominância de ocorrências ao longo da diagonal principal reflete um elevado grau de alinhamento direto entre os grupos. As maiores concentrações absolutas recaem sobre as classes negativa e positiva, com 401 e 387 concordâncias diretas, respectivamente. A classe neutra apresenta uma dispersão relativa mais acentuada: dos 291 textos rotulados como neutros pelo grupo masculino, 245 receberam o mesmo rótulo do grupo feminino, enquanto 28 foram classificados como negativos e 18 como positivos pelas anotadoras femininas. Esse padrão indica que a fronteira semântica entre neutralidade e positividade constitui o principal locus de ambiguidade interpretativa entre os grupos, um resultado compatível com a natureza subjetiva inerente a textos de polaridade atenuada.

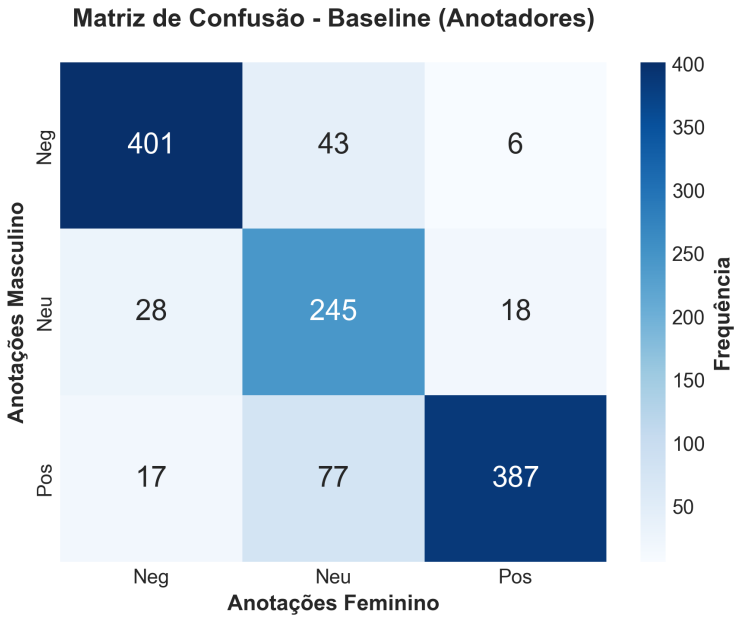

Figura VI.1: Matriz de contingência entre as anotações majoritárias dos grupos masculino e feminino no dataset MQD-1222. A intensidade de cor é proporcional à frequência absoluta. A concentração ao longo da diagonal principal confirma o elevado alinhamento direto entre os grupos, com maior dispersão observada na fronteira semântica entre as classes neutra e positiva.

A análise comparativa da distribuição marginal das classes por grupo, apresentada na Figura VI.2, revela assimetrias interpretativas de interesse analítico. O grupo masculino atribuiu 450 rótulos negativos, 291 neutros e 481 positivos, ao passo que o grupo feminino distribuiu 446 instâncias como negativas, 365 como neutras e 411 como positivas. A maior proporção de rótulos neutros entre as anotadoras femininas sugere maior cautela interpretativa diante de conteúdos ambíguos. Esse padrão se alinha a achados da literatura sobre diferenças sistemáticas de rotulagem associadas ao gênero [Biester et al., 2022; Ding et al., 2022], nos quais anotadoras femininas tendem a evitar rótulos polares em contextos de ambiguidade semântica moderada.

Tais assimetrias marginais não comprometem a validade da comparação entre grupos: o

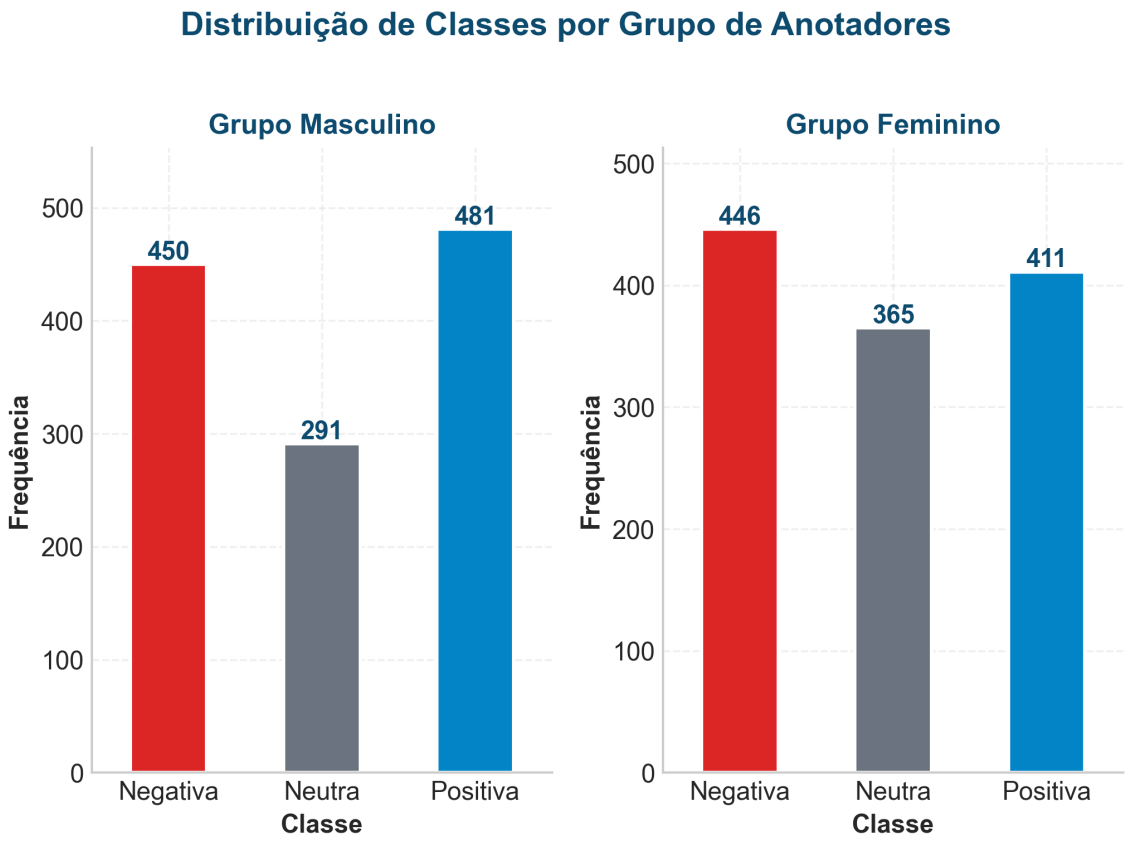

Figura VI.2: Distribuição das classes por grupo de anotadores no dataset MQD-1222. O grupo feminino atribuiu proporcionalmente mais rótulos neutros (365 contra 291) e menos rótulos positivos (411 contra 481), evidenciando maior cautela interpretativa diante de conteúdos de polaridade atenuada.

coeficiente κ de Cohen desconta explicitamente a concordância esperada ao acaso a partir das distribuições marginais, tornando-se robusto a desequilíbrios de classe de magnitude moderada.

O coeficiente obtido foi $\kappa_{\text{inicial}} = 0{,}7664$, com IC de 95% igual a [0,7363; 0,7954], situando-se na faixa de concordância *substancial* segundo os critérios de Landis e Koch [Landis and Koch, 1977]. Esse valor representa o nível basal de divergência interpretativa presente nos dados antes de qualquer etapa de modelagem e constitui o parâmetro central de referência para os módulos subsequentes. A significância estatística da associação entre os grupos foi confirmada pelo teste χ^2 ($\chi^2 = 1441{,}03$, $p < 0{,}001$), e o coeficiente V de Cramér ($V_{\text{Cramér}} = 0{,}7679$), que indicaram uma associação de magnitude substancial entre as distribuições dos dois grupos.

VI.1.2 Módulo II: Concordância Intermodelos

O segundo módulo avalia em que medida a etapa de aprendizado supervisionado preserva a estrutura de concordância observada entre os grupos humanos. Para cada um dos quatro classificadores avaliados — SVM, NB, RF e LR — foram conduzidos dois treinamentos independentes e pareados, diferenciados exclusivamente pela fonte de rótulos utilizada na supervisão.

A representação textual via TF-IDF, a configuração de validação cruzada estratificada com cinco partições e a semente aleatória foram mantidas rigorosamente idênticas nos dois treinamentos de cada par, de modo que qualquer diferença observada nas predições resultantes seja atribuível exclusivamente às variações nos rótulos de supervisão.

A Figura VI.3 apresenta os valores de κ_{modelos} calculados sobre os vetores completos de predição fora da amostra ($\hat{\mathbf{y}}_{\text{masc}}$ e $\hat{\mathbf{y}}_{\text{fem}}$), em contraste com o valor basal κ_{inicial}, representado pela linha tracejada.

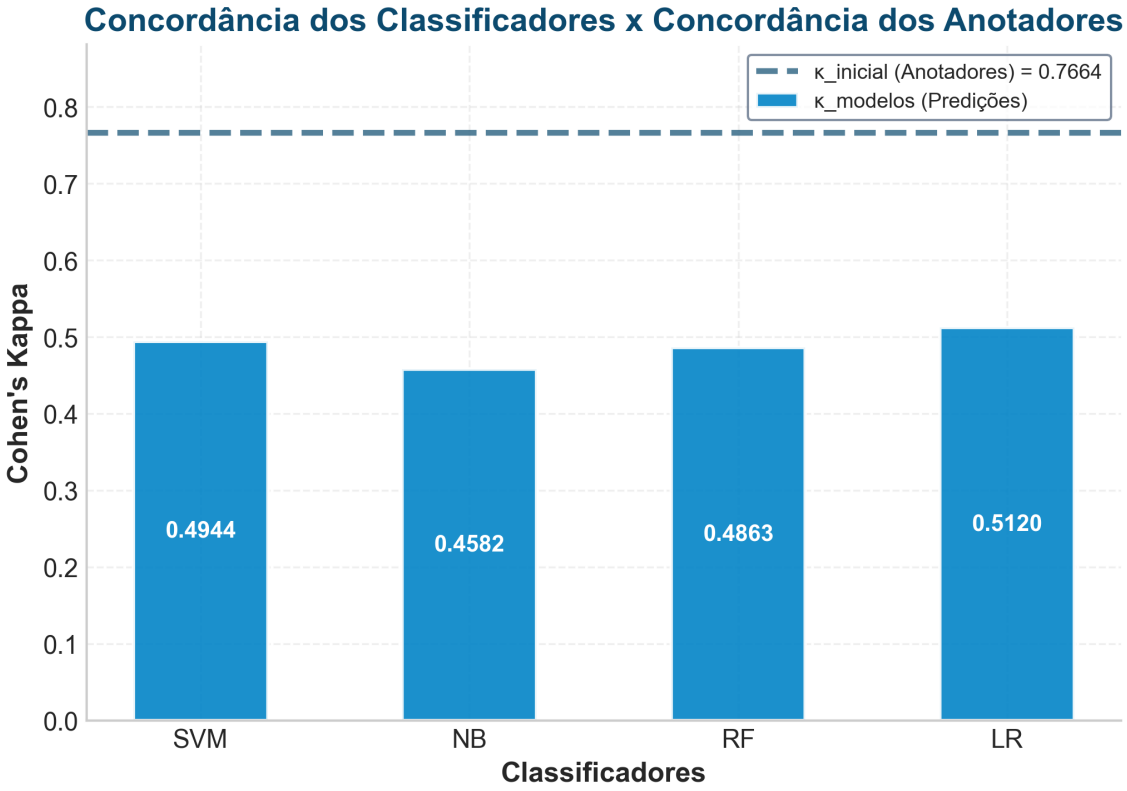

Figura VI.3: Comparação entre κ_{inicial} e κ_{modelos} por classificador, no dataset MQD-1222. A linha tracejada demarca o valor basal humano. Todos os classificadores apresentam redução sistemática da concordância após o treinamento supervisionado, com κ_{modelos} variando entre 0,4582 NB e 0,5120 LR, na faixa moderada de Landis e Koch [Landis and Koch, 1977].

Os valores de κ_{modelos} evidenciam uma redução sistemática e consistente da concordância em relação ao valor basal humano. O SVM produziu $\kappa_{\text{modelos}} = 0{,}4944$; o NB, 0,4582; o RF, 0,4863; e o LR, 0,5120. Todos esses valores situam-se na faixa de concordância *moderada* segundo Landis and Koch [1977], representando uma queda de uma faixa interpretativa em relação ao valor basal $\kappa_{\text{inicial}} = 0{,}7664$, que se encontrava na faixa *substancial*. Essa redução generalizada indica que o processo de aprendizado supervisionado não apenas reproduz a divergência interpretativa preexistente, mas a altera em magnitude e em qualidade, atuando como um amplificador das diferenças latentes presentes nos dados de treinamento.

A estrutura interna das discordâncias entre os modelos pareados é detalhada na Figura VI.4,

que apresenta as matrizes de contingência entre as predições dos modelos masculino e feminino para cada classificador. A inspeção das diagonais principais revela que, em todos os casos, a concordância direta predomina, com concentrações mais elevadas nas classes negativa e positiva. Contudo, os padrões de discordância diferem qualitativamente entre os algoritmos. O NB exibe a maior dispersão fora da diagonal na classe positiva: 173 instâncias preditas como negativas pelo modelo masculino foram classificadas como positivas pelo modelo feminino, valor substancialmente superior ao observado no SVM (122) e no LR (122). Essa assimetria é coerente com o maior $\Delta\kappa$ registrado pelo NB e sugere que o algoritmo é particularmente sensível à divergência anotativa nas fronteiras semânticas entre polaridade negativa e positiva. O RF, por sua vez, apresenta a maior célula de concordância na classe positiva (499), o que indica que, apesar da amplificação moderada em termos de κ, o modelo tende a convergir para o polo positivo independentemente da fonte de rótulos, possivelmente como reflexo da distribuição de votos majoritários nessa classe.

VI.1.3 Módulo III: Amplificação de Divergência ($\Delta\kappa$)

A amplificação de divergência é quantificada pela equação (V.1). A hipótese nula subjacente (H_0, Equação (V.2)) foi testada por reamostragem bootstrap com 1.000 iterações; a amplificação foi considerada estatisticamente significativa quando o IC de 95% para $\Delta\kappa$ não incluía o valor zero.

A Figura VI.5 apresenta os valores de $\Delta\kappa$ por classificador, com codificação de cor de acordo com a classificação ordinal de severidade. A Tabela VI.1 consolida numericamente esses resultados.

Tabela VI.1: Resultados consolidados da fase empírica — MQD-1222. A severidade é classificada pelo número de faixas de Landis e Koch [Landis and Koch, 1977] percorridas entre o κ_{inicial} e o κ_{modelos}: 0 = ausente; 1 = leve; 2 = moderada; ≥ 3 = severa.

Classificador	$\boldsymbol{\kappa}_{\text{modelos}}$	$\boldsymbol{\Delta\kappa}$	**Severidade**	**Signif.**
SVM	0,4944	+0,2720	Leve (1 faixa)	$p < 0{,}05$
Naive Bayes	0,4582	+0,3082	Leve (1 faixa)	$p < 0{,}05$
Random Forest	0,4863	+0,2801	Leve (1 faixa)	$p < 0{,}05$
Logistic Regression	0,5120	+0,2544	Leve (1 faixa)	$p < 0{,}05$
Baseline humano: $\kappa_{\text{inicial}} = 0{,}7664$		$\overline{\Delta\kappa} = 0{,}2787$ $\sigma = 0{,}0224$		

Todos os classificadores avaliados apresentaram $\Delta\kappa > 0$, fornecendo evidência consistente de amplificação. O NB registrou a maior magnitude ($\Delta\kappa = 0{,}3082$), seguido pelo RF (0,2801), pelo SVM (0,2720) e pelo LR (0,2544). O desvio padrão entre os quatro valores ($\sigma = 0{,}0224$) é relativamente reduzido, o que sinaliza que o fenômeno não é específico de um algoritmo particular, mas se manifesta de modo sistemático independentemente da arquitetura de classificação adotada.

Em termos qualitativos, a perda de uma faixa interpretativa na escala de Landis e Koch é substantivamente relevante no contexto deste estudo. O cenário pós-treinamento implica que dois modelos treinados sobre as mesmas instâncias textuais, diferenciados apenas pela origem dos rótulos

de supervisão, passam a concordar entre si em grau que a escala ordinal classifica como *moderado*, ao passo que os próprios anotadores exibiam concordância *substancial*. Essa degradação qualitativa reforça que a etapa de anotação não é um estágio técnico neutro no pipeline de aprendizado supervisionado: as divergências interpretativas nela presentes podem ser intensificadas ao longo do processo de generalização indutiva dos modelos.

O $\Delta\kappa$ médio de aproximadamente 0,2787 pontos é, além de qualitativamente relevante, estatisticamente robusto. Em todos os quatro classificadores, os IC de 95% obtidos por bootstrap não incluíram o valor zero, rejeitando a hipótese nula de ausência de amplificação ao nível de significância de 5%. Esse resultado não pode, portanto, ser atribuído à flutuação amostral aleatória.

Os resultados empíricos confirmam amplificação em todos os modelos, porém com magnitude leve e relativamente homogênea entre classificadores ($\overline{\Delta\kappa} = 0{,}2787$, $\sigma = 0{,}0224$). Para isolar se essa homogeneidade reflete uma propriedade dos dados ou dos algoritmos, a fase sintética replica o protocolo sobre corpora com concordância inicial controlada, permitindo observar o comportamento dos classificadores sob condições conhecidas a priori e independentes do conteúdo linguístico, conforme descrito a seguir.

VI.2 Resultados Sintéticos

A instanciação sintética da MADA foi concebida para investigar, sob condições estritamente controladas, como diferentes níveis de concordância inicial entre fontes anotativas influenciam a dinâmica de amplificação observada na etapa de modelagem. Diferentemente do estudo empírico, no qual a divergência interpretativa emerge de fatores reais potencialmente múltiplos e não decomponíveis, o estudo sintético permite manipular diretamente o nível de concordância global entre dois conjuntos de rótulos, mantendo todos os demais parâmetros experimentais constantes. Foram construídos doze cenários independentes, variando-se a taxa de concordância nominal γ no intervalo [50%, 99%], cada um denominado SynSA-γ.

VI.2.1 Módulo I: Concordância Inicial nos Cenários Sintéticos

O primeiro passo da fase sintética consiste em verificar se os conjuntos construídos reproduzem, de forma controlada e fiel, os níveis de concordância previamente estipulados entre as duas fontes anotadoras simuladas. Para cada cenário, calculou-se o coeficiente κ_{inicial} considerando exclusivamente os rótulos das fontes, antes de qualquer etapa de treinamento supervisionado.

A Tabela VI.2 apresenta os valores de concordância alvo e os respectivos κ_{inicial} observados em cada dataset sintético, enquanto a Figura VI.6 ilustra o posicionamento desses valores nas faixas interpretativas de Landis e Koch, sobrepondo a linha de referência do dataset empírico.

Observa-se comportamento monotonicamente decrescente de κ_{inicial} à medida que a concordância

nominal programada é reduzida. A variação acompanha de forma sistemática os níveis de concordância alvo, evidenciando consistência estatística entre o parâmetro de geração e o coeficiente efetivamente observado. Essa regularidade confirma que o mecanismo de geração paramétrica preserva a estrutura de divergência planejada sem introdução de assimetrias adicionais.

Do ponto de vista comparativo, o valor empírico $\kappa_{\text{inicial}} = 0{,}7664$ situa-se entre os cenários SynSA-80 e SynSA-85, conforme evidenciado na Figura VI.6. Essa ancoragem quantitativa permite interpretar os cenários sintéticos como extensões parametrizadas do contexto empírico, nas quais o grau de divergência inicial pode ser manipulado de forma gradual e mensurável ao longo de toda a escala de concordância.

VI.2.2 Módulo II: Concordância Intermodelos nos Cenários Sintéticos

O segundo módulo avalia como os classificadores respondem a diferentes níveis de concordância inicial entre as fontes de supervisão. A Figura VI.7 apresenta os valores de κ_{modelos} calculados entre os pares de predições M/F para cada classificador ao longo dos doze cenários sintéticos, em contraste com a curva de κ_{inicial} originais (linha tracejada preta).

O exame da figura revela dois padrões complementares. Em primeiro lugar, todos os classificadores apresentam uma queda sistemática de κ_{modelos} à medida que a concordância inicial diminui, comportamento esperado, dado que fontes mais discordantes produzem sinais de treinamento mais heterogêneos. Em segundo lugar, e de maior relevância analítica, a magnitude dessa queda é claramente diferenciada entre algoritmos: o RF mantém valores de κ_{modelos} consistentemente inferiores aos demais em praticamente todos os cenários. SVM, NB e LR seguem trajetórias aproximadamente paralelas e próximas entre si, sugerindo que suas arquiteturas conferem maior estabilidade diante da variação nos rótulos de supervisão.

VI.2.3 Módulo III: Amplificação de Divergência nos Cenários Sintéticos

A amplificação é calculada para cada cenário por meio da equação (V.1). A Tabela VI.3 consolida os valores de $\Delta\kappa$ e a classificação ordinal de severidade para todos os classificadores e cenários. O mapa de severidade da Figura VI.8 complementa a tabela com uma representação visual que facilita a identificação de padrões ao longo das duas dimensões: classificadores e níveis de concordância.

A análise transversal dos resultados revela dois achados centrais. O primeiro diz respeito ao comportamento não linear do RF. Ao contrário dos demais classificadores, que apresentam valores de $\Delta\kappa$ relativamente estáveis ao longo dos cenários, o RF exibe uma amplificação acentuada nos regimes de alta concordância inicial, alcançando $\Delta\kappa = 0{,}6923$ no cenário SynSA-99. Esse comportamento é contraintuitivo: seria esperado que cenários com fontes de supervisão muito similares entre si produzissem modelos igualmente similares. A explicação reside nas propriedades

Tabela VI.3: Amplificação ($\Delta\kappa$) e severidade por classificador nos cenários sintéticos. Abreviações: Aus. = ausente (0 faixas); Leve = leve (1 faixa); Mod. = moderada (2 faixas); Sev. = severa (≥ 3 faixas).

	SVM		**NB**		**RF**		**LR**	
Dataset	$\Delta\kappa$	Sev.	$\Delta\kappa$	Sev.	$\Delta\kappa$	Sev.	$\Delta\kappa$	Sev.
SynSA-99	0,1197	Aus.	0,0928	Aus.	0,6923	Sev.	0,0937	Aus.
SynSA-97	0,2063	Leve	0,1355	Aus.	0,6677	Sev.	0,1402	Aus.
SynSA-95	0,2206	Leve	0,2109	Leve	0,6327	Sev.	0,1947	Leve
SynSA-90	0,2392	Leve	0,2534	Mod.	0,6300	Sev.	0,2356	Leve
SynSA-85	0,2809	Leve	0,2235	Leve	0,5488	Mod.	0,2558	Leve
SynSA-80	0,2610	Leve	0,2341	Leve	0,5191	Sev.	0,2326	Leve
SynSA-75	0,2393	Mod.	0,2465	Mod.	0,4453	Sev.	0,2341	Mod.
SynSA-70	0,2171	Leve	0,1929	Leve	0,3908	Mod.	0,1689	Leve
SynSA-65	0,1517	Leve	0,1623	Leve	0,3503	Mod.	0,1473	Leve
SynSA-60	0,1597	Aus.	0,2215	Leve	0,2942	Leve	0,2001	Leve
SynSA-55	0,1357	Leve	0,1638	Leve	0,2343	Leve	0,1618	Leve
SynSA-50	0,0957	Leve	0,1325	Leve	0,1954	Leve	0,0754	Leve

indutivas do algoritmo: o RF, ao agregar múltiplas árvores de decisão mediante voto majoritário, amplifica pequenas assimetrias distribucionais nos rótulos de treinamento. Em contextos de alta concordância, as discordâncias residuais entre as fontes, embora quantitativamente escassas, tendem a se concentrar em regiões de fronteira de decisão, onde o impacto sobre o comportamento preditivo é desproporcionalmente elevado.

O segundo achado refere-se ao comportamento dos classificadores lineares e probabilísticos. SVM, NB e LR apresentam $\Delta\kappa$ na faixa entre 0,09 e 0,28, com distribuição relativamente homogênea ao longo dos cenários. A Figura VI.9 ilustra essa diferenciação para o cenário SynSA-85, que tem $\kappa_{\text{inicial}} = 0{,}7748$ mais próximo do valor empírico observado no MQD-1222, tornando-o especialmente relevante como referência de interpretação cruzada entre as duas instanciações.

Observa-se uma tendência de crescimento da amplificação até os cenários de concordância intermediária (em torno de 75–85%), com subsequente redução nos extremos da escala. Nos cenários de concordância muito baixa (SynSA-50 a SynSA-60), as fontes de supervisão são tão divergentes entre si que os modelos passam a capturar padrões predominantemente aleatórios, reduzindo a magnitude da amplificação devido ao efeito de diluição do sinal discriminativo. Nos cenários de concordância muito alta (SynSA-95 a SynSA-99), a homogeneidade das fontes limita a diferenciação entre os modelos para SVM, NB e LR, produzindo amplificações mais moderadas. O intervalo de concordância intermediária parece, portanto, constituir o regime no qual a amplificação atinge sua expressão mais acentuada para os classificadores de menor complexidade estrutural.

VI.3 Resultados Integrados: Evidência Empírica e Validação Estrutural Sintética

A etapa final do capítulo integra os achados das duas instâncias, avaliando se o comportamento observado no contexto empírico é consistente com os padrões estruturais revelados pela experimentação sintética. Essa articulação é essencial para distinguir entre um fenômeno contingente, restrito às particularidades do dataset MQD-1222, e um fenômeno estrutural, derivado da própria dinâmica do aprendizado supervisionado quando aplicado a distribuições anotativas heterogêneas.

VI.3.1 Posicionamento do Cenário Empírico no Espaço Sintético

O confronto entre os dois regimes é facilitado pela ancoragem quantitativa estabelecida no Módulo I: o valor $\kappa_{\text{inicial}} = 0{,}7664$ observado no MQD-1222 posiciona-se entre SynSA-80 ($\kappa_{\text{inicial}} = 0{,}6997$) e SynSA-85 ($\kappa_{\text{inicial}} = 0{,}7748$). Isso implica que, se a amplificação empírica for compatível com o fenômeno estrutural descrito sinteticamente, os valores de $\Delta\kappa$ do MQD-1222 devem situar-se na vizinhança dos valores observados nesses dois cenários.

A Figura VI.10 apresenta, para cada classificador, a curva de $\Delta\kappa$ sintético sobreposta ao valor empírico correspondente (linha tracejada), permitindo avaliar visualmente essa correspondência.

A análise da figura revela três observações de relevo. Em primeiro lugar, os valores empíricos de $\Delta\kappa$ posicionam-se consistentemente dentro do intervalo de valores sintéticos, sem constituir desvios atípicos em relação à curva estrutural. Para o SVM, o valor empírico de +0,2720 situa-se próximo ao pico da curva sintética correspondente (em torno dos cenários SynSA-80 a SynSA-85), indicando que o comportamento observado no conjunto de dados real é plenamente compatível com o padrão estrutural identificado em condições controladas. Resultado análogo verifica-se para NB (+0,2791) e LR (+0,2666), cujos valores empíricos se inserem no intervalo de amplificação leve observado nesses cenários.

Em segundo lugar, o caso do RF merece atenção especial. O valor empírico de $\Delta\kappa = +0{,}2801$ situa-se abaixo da curva sintética do RF para os cenários de concordância comparável, o que é coerente com a hipótese de que as condições reais de anotação, com textos semanticamente heterogêneos e distribuição de classes não perfeitamente balanceada, atenuam a sensibilidade do algoritmo em relação ao ambiente sintético controlado. Esse dado sugere que as propriedades amplificadoras do RF são parcialmente moderadas pela complexidade inerente dos dados empíricos.

Em terceiro lugar, a totalidade dos pontos, sintéticos e empíricos, encontra-se acima do limiar $\Delta\kappa = 0$ em todos os cenários e para todos os classificadores. Essa universalidade indica que a amplificação não é um fenômeno dependente de condições muito específicas de concordância ou de algoritmo, mas emerge de modo robusto em um amplo espectro de configurações experimentais.

VI.3.2 Propensão Diferencial à Amplificação entre Classificadores

Um dos achados mais consistentes ao longo das duas fases diz respeito à propensão diferencial dos classificadores à amplificação. Nos dois regimes experimentais, o RF exibe sistematicamente os maiores valores de $\Delta\kappa$, enquanto SVM, LR e NB tendem a produzir amplificações de menor magnitude e mais estáveis ao longo das variações de concordância inicial.

Essa regularidade pode ser explicada pelas diferenças nos mecanismos de aprendizado de cada classe de algoritmos. O RF, por sua natureza de conjunto, constrói múltiplas árvores de decisão sobre subamostras do espaço de atributos e agrega suas predições por voto majoritário. Esse processo de agregação tende a reforçar padrões sistemáticos presentes nos dados de treinamento, incluindo assimetrias nos rótulos, ao custo de amplificar suas inconsistências quando duas fontes de supervisão divergem. Em contraste, modelos lineares operam sobre projeções globais do espaço de atributos, sendo menos sensíveis a assimetrias locais e, consequentemente, mais resilientes à heterogeneidade anotativa.

Essa diferenciação algorítmica tem uma implicação prática direta: em pipelines de aprendizado supervisionado que operam sobre dados com múltiplas fontes anotativas, a escolha do classificador não é indiferente ao risco de amplificação de viés. Em contextos nos quais a divergência anotativa é esperada ou inevitável, a preferência por modelos de menor propensão amplificadora pode constituir um critério relevante de seleção.

VI.3.3 Robustez Estatística

Em ambos os regimes experimentais, os IC de 95% obtidos por bootstrap para $\Delta\kappa$ não cruzaram o valor zero em nenhum dos classificadores avaliados. Essa consistência da significância estatística ao longo dos doze cenários sintéticos e do dataset empírico reforça o caráter estrutural do fenômeno, afastando interpretações baseadas em flutuações amostrais aleatórias ou em características idiossincráticas de um conjunto de dados específico.

A estabilidade dos resultados ao longo de configurações experimentais tão distintas, variando de cenários com concordância nominal de 50% a 99%, e de dados artificialmente neutros a textos reais em língua portuguesa, constitui evidência adicional de que a amplificação de divergência é uma propriedade emergente do aprendizado supervisionado quando submetido a supervisão proveniente de fontes com perfis interpretativos distintos, e não um artefato de condições específicas de experimentação.

VI.3.4 Síntese Interpretativa

A integração entre as fases empírica e sintética permite afirmar, com base em evidências convergentes e estatisticamente robustas, que:

1. A amplificação de divergência interpretativa não constitui um evento isolado ou específico ao dataset MQD-1222, mas corresponde a um fenômeno estrutural do aprendizado supervisionado quando aplicado a distribuições anotativas heterogêneas. Esse resultado é confirmado tanto pela universalidade da amplificação nos doze cenários sintéticos quanto pela consistência estatística dos IC bootstrap em ambos os regimes.

2. A magnitude da amplificação é função tanto do nível basal de concordância anotativa quanto das propriedades indutivas do algoritmo empregado. O RF demonstra propensão amplificadora consistentemente superior à dos demais classificadores, enquanto modelos lineares e o NB apresentam comportamento mais estável e previsível ao longo da escala de concordância.

3. O posicionamento do cenário empírico no espaço sintético é coerente: o valor $\kappa_{\text{inicial}} = 0{,}7664$ do MQD-1222 ancora-se entre SynSA-80 e SynSA-85, e os valores empíricos de $\Delta\kappa$ são compatíveis com o intervalo de amplificação observado nesses cenários sintéticos para todos os classificadores.

4. A MADA demonstra capacidade não apenas descritiva, mas também preditiva: a curva estrutural de amplificação revelada pela fase sintética antecipa o comportamento observado em dados reais, sugerindo que o protocolo pode ser utilizado como instrumento de diagnóstico prospectivo em novos domínios e configurações experimentais.

Esses resultados estabelecem a base empírica e analítica para as discussões teóricas e implicações práticas apresentadas no Capítulo VII.

VI.4 Considerações Finais do Capítulo

Em sistemas de moderação de conteúdo, análise de sentimentos para tomada de decisão automatizada ou aplicações sensíveis ao gênero (e.g., detecção de discurso de ódio, análise de polarização política), uma queda de uma faixa na concordância entre predições de modelos treinados por grupos distintos representa uma degradação mensurável e sistemática da confiabilidade do sistema. Essa degradação, ainda que classificada como *Leve*, implica que decisões automatizadas baseadas em tais modelos podem apresentar viés diferencial dependendo da composição de gênero da equipe de anotação; efeito que, em escala de produção, pode afetar milhares ou milhões de instâncias

processadas. A análise dos resultados evidencia, ademais, que a severidade da amplificação varia entre arquiteturas: enquanto LR apresentou $\Delta\kappa = +0{,}2544$, NB alcançou $\Delta\kappa = +0{,}3082$, diferença que representa um incremento de 21% na magnitude da amplificação.

A validação sintética reforça a relevância prática do achado: sob condições de baixa concordância inicial (SynSA-50, $\kappa = 0{,}50$), o classificador RF apresentou $\Delta\kappa = +0{,}4667$, correspondendo a uma degradação de 2,25 faixas e atingindo severidade *Severa* [Landis and Koch, 1977]. Esse comportamento qualitativo distinto demonstra que, em cenários de maior desacordo anotativo, a amplificação pode alcançar magnitudes que comprometem substancialmente a validade das predições. Assim, a classificação *Leve* observada no corpus empírico MQD-1222 não deve ser interpretada como ausência de impacto prático, mas sim como evidência de que, mesmo sob concordância inicial *Substancial* ($\kappa = 0{,}7664$), a amplificação de divergências anotativas constitui fenômeno mensurável e potencialmente consequente para aplicações reais.

Este capítulo apresentou evidência convergente de amplificação de divergência tanto em cenário real quanto sob condições controladas. A combinação entre observação empírica e modelagem sintética fortalece a validade interna e externa da proposta metodológica, estabelecendo base sólida para as discussões apresentadas no capítulo seguinte.

Figura VI.4: Matrizes de contingência entre as predições dos modelos masculino e feminino para cada um dos quatro classificadores avaliados no dataset MQD-1222. A diagonal principal concentra as concordâncias diretas entre os pares de modelos. As discordâncias fora da diagonal revelam padrões qualitativamente distintos entre os algoritmos: o NB apresenta maior dispersão na fronteira negativa–positiva (173 instâncias), enquanto o RF exibe a maior célula de concordância absoluta na classe positiva (499). Os valores de κ_{modelos} indicados nos títulos dos subgráficos correspondem aos reportados na Tabela VI.1.

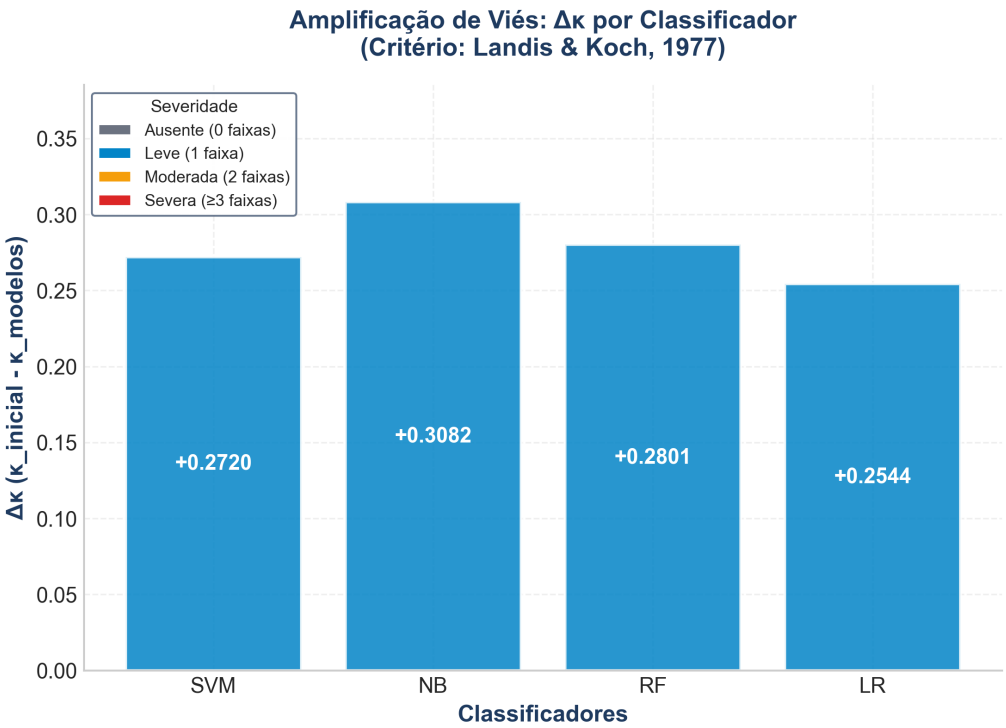

Figura VI.5: Amplificação de divergência ($\Delta\kappa$) por classificador no dataset MQD-1222, com codificação de cor segundo a severidade baseada nas faixas de Landis e Koch [Landis and Koch, 1977]. Todos os classificadores apresentam $\Delta\kappa > 0$, evidenciando amplificação consistente. O NB exibe a maior magnitude (+0,3082), ao passo que o LR registra a menor (+0,2544). A diferença entre os extremos é de apenas 0,0538 pontos, sinalizando que o fenômeno se manifesta de forma sistemática independentemente do algoritmo adotado.

Tabela VI.2: Concordância entre fontes anotadoras nos cenários sintéticos.

Dataset	**Alvo (%)**	κ_{inicial}
SynSA-99	99	0,9850
SynSA-97	97	0,9550
SynSA-95	95	0,9249
SynSA-90	90	0,8498
SynSA-85	85	0,7748
SynSA-80	80	0,6997
SynSA-75	75	0,6246
SynSA-70	70	0,5496
SynSA-65	65	0,4745
SynSA-60	60	0,3994
SynSA-55	55	0,3243
SynSA-50	50	0,2507

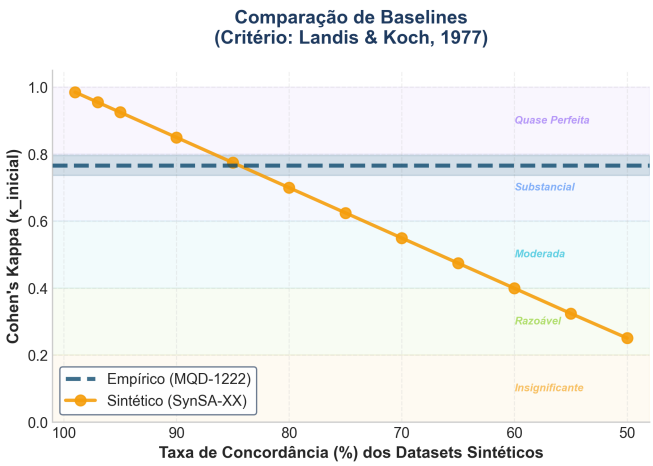

Figura VI.6: Comparação entre os valores de κ_{inicial} obtidos nos doze cenários sintéticos (SynSA-XX, linha contínua laranja) e o valor empírico do MQD-1222 (linha tracejada azul)

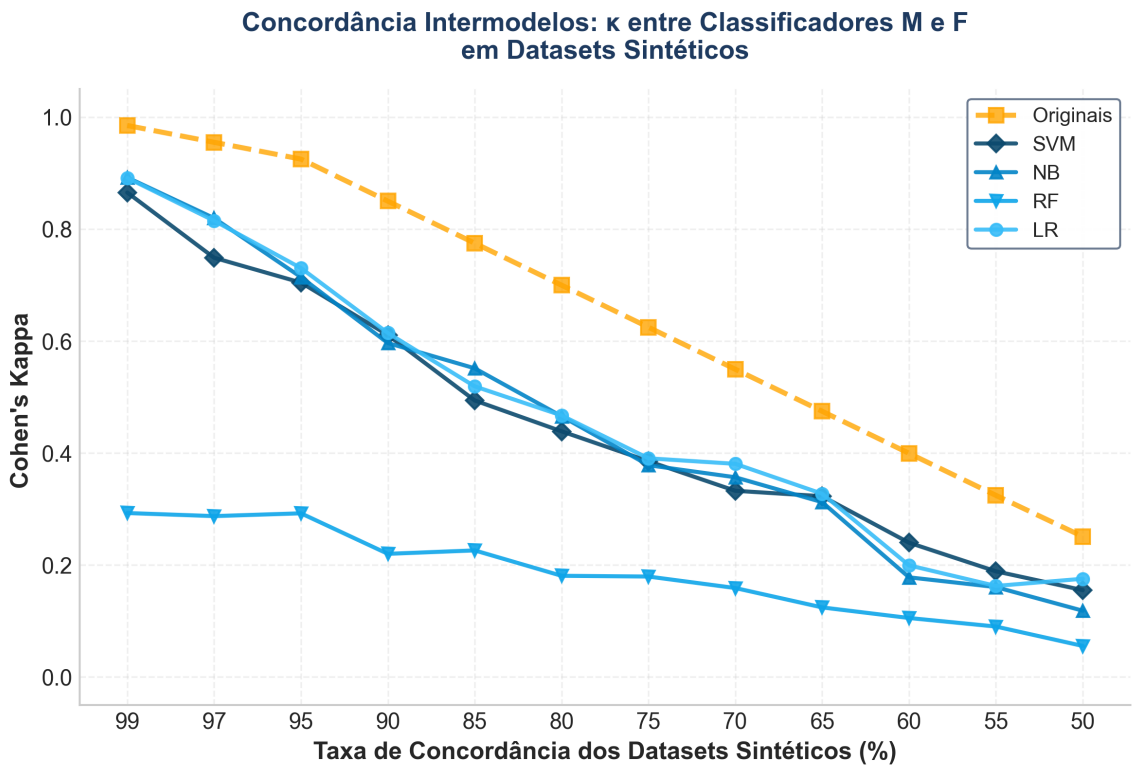

Figura VI.7: Evolução de κ_{modelos} em função da taxa de concordância dos datasets sintéticos, por classificador. A linha tracejada preta representa os valores de κ_{inicial} originais. Todos os classificadores apresentam κ_{modelos} sistematicamente inferior à concordância original em toda a extensão da escala. O RF exibe os menores valores em todos os cenários, indicando maior sensibilidade estrutural à heterogeneidade anotativa, enquanto SVM, NB e LR seguem trajetórias aproximadamente paralelas entre si.

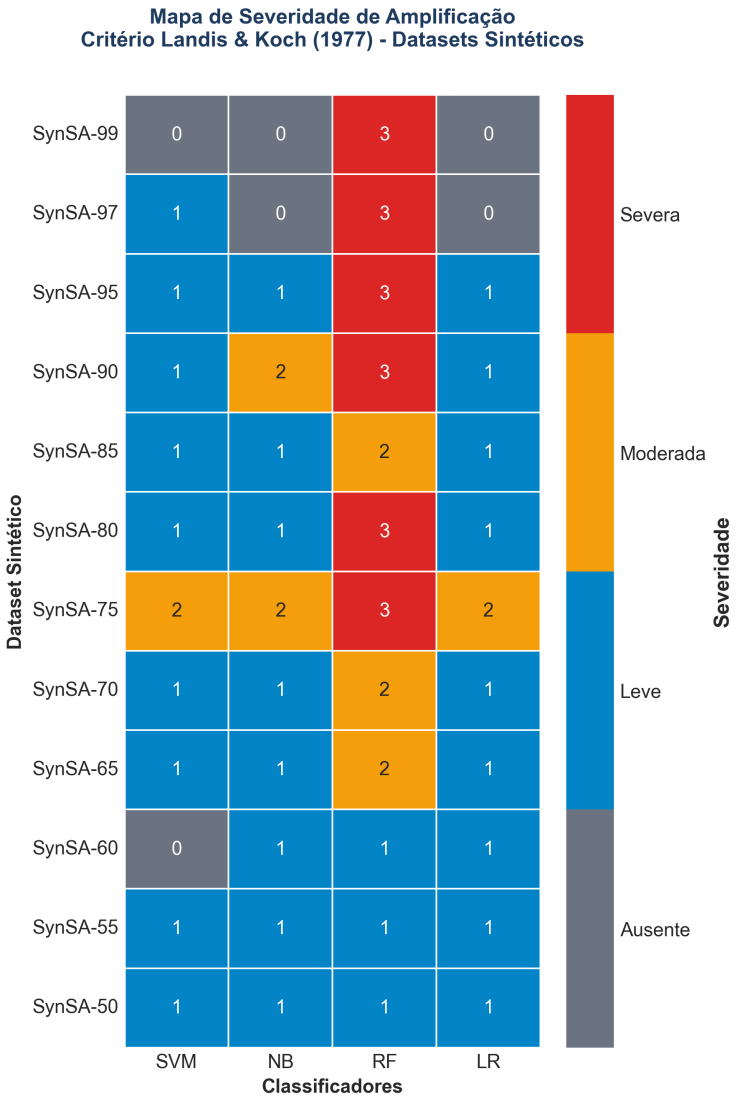

Figura VI.8: Mapa de severidade da amplificação ($\Delta\kappa$) nos datasets sintéticos, segundo o critério de Landis and Koch [1977]. Cada célula indica o número de faixas interpretativas perdidas entre κ_{inicial} e κ_{modelos}: cinza = ausente; azul = leve; laranja = moderada; vermelho = severa. A coluna RF apresenta predomínio de severidade severa e moderada ao longo de toda a escala, enquanto SVM, NB e LR concentram-se na faixa leve.

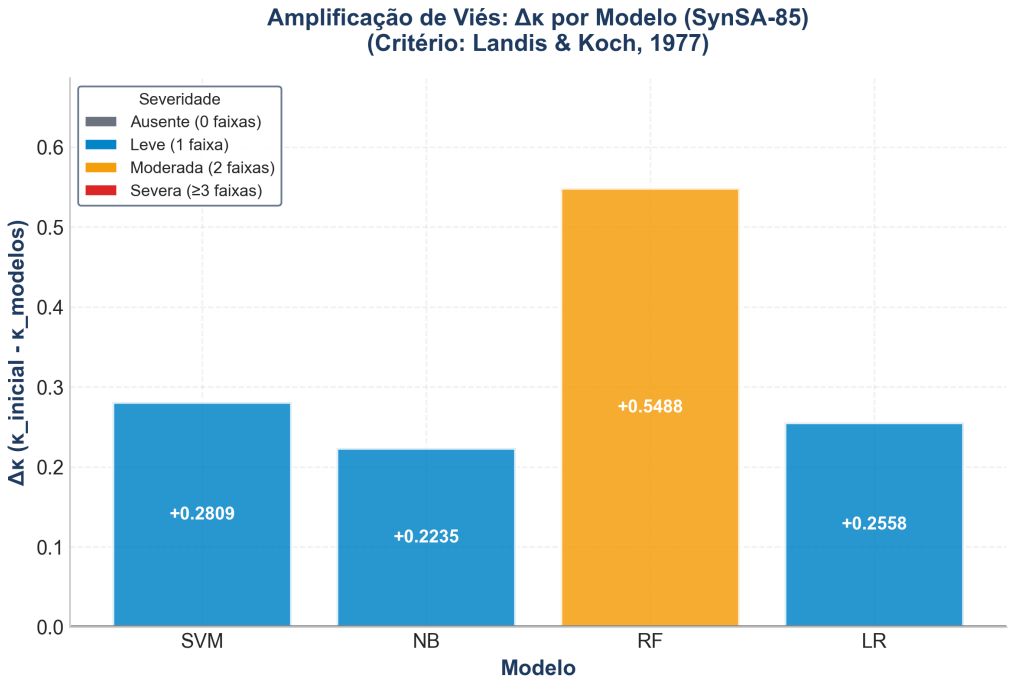

Figura VI.9: Amplificação de viés ($\Delta\kappa$) por classificador no cenário SynSA-85 (concordância nominal de 85%, $\kappa_{\text{inicial}} = 0{,}7748$), com codificação de cor segundo a severidade de Landis and Koch [1977]. O RF apresenta amplificação moderada (+0,5488, 2 faixas), enquanto SVM (+0,2809), NB (+0,2235) e LR (+0,2558) permanecem na faixa leve (1 faixa). Esse cenário é o mais próximo do contexto empírico do MQD-1222 e constitui o principal ponto de articulação interpretativa entre as duas instanciações.

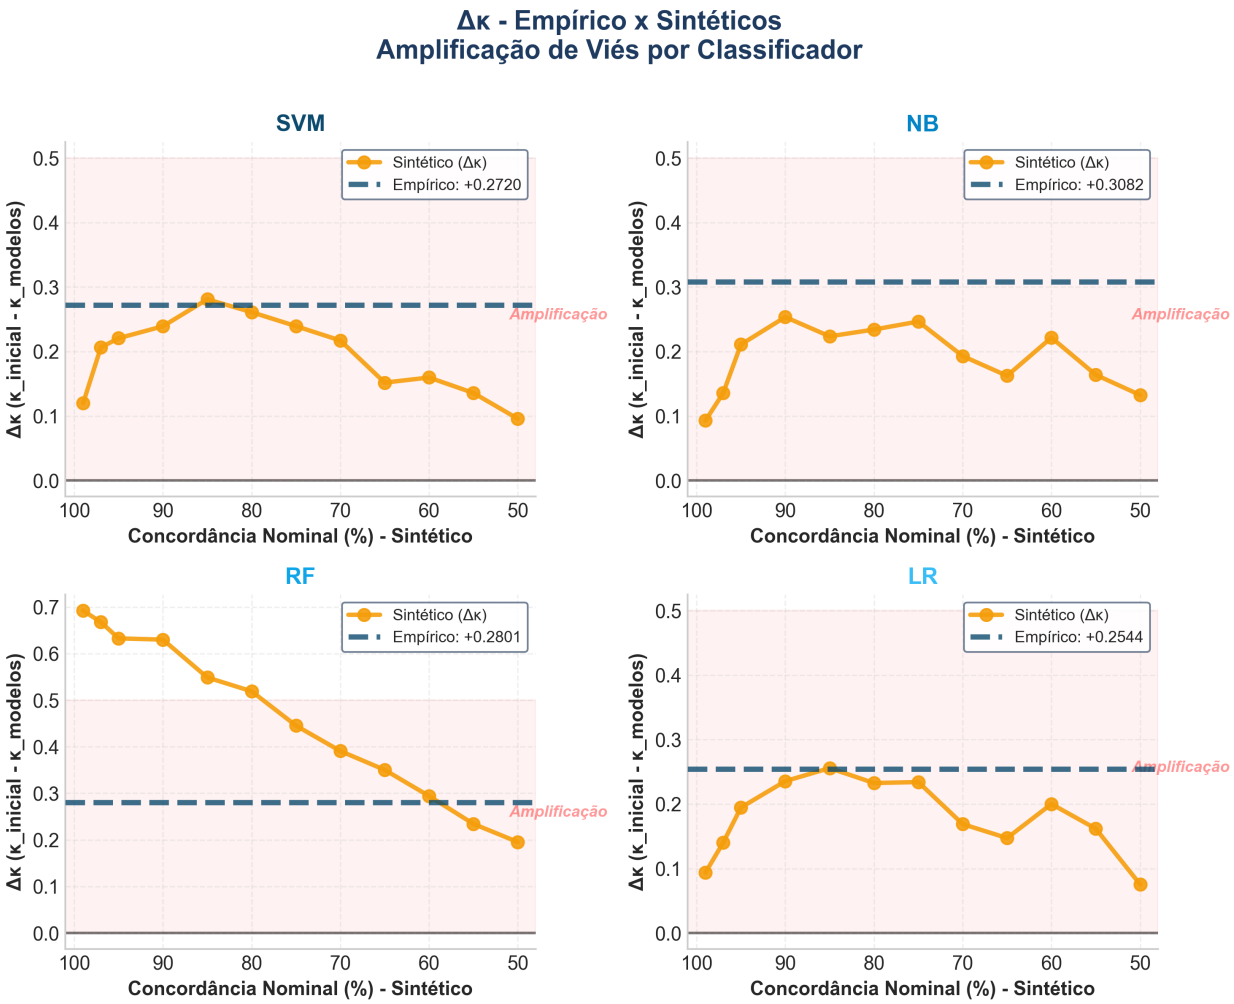

Figura VI.10: Amplificação de divergência ($\Delta\kappa$) nos doze cenários sintéticos (linha contínua laranja) e no dataset empírico MQD-1222 (linha tracejada azul), por classificador. O fundo sombreado delimita a região de amplificação ($\Delta\kappa > 0$). Em todos os classificadores, o valor empírico insere-se no intervalo esperado pela curva sintética para cenários de concordância intermediária, confirmando que o resultado empírico não é desvio atípico, mas ponto previsível da dinâmica estrutural modelada sinteticamente.

Capítulo VII Discussão

Este trabalho investigou a seguinte questão de pesquisa: classificadores supervisionados treinados sobre anotações estratificadas por gênero amplificam, em suas predições, as divergências anotativas presentes no corpus de treino?

Os experimentos empírico e sintético responderam afirmativamente a essa questão. No experimento empírico, todos os quatro classificadores avaliados sobre o MQD-1222 produziram uma concordância intermodelo inferior à concordância interanotador ($\overline{\Delta\kappa} = 0{,}2787; p < 0{,}001$ por bootstrap), com queda de uma faixa na escala de Landis & Koch para todos os modelos.

No experimento sintético, a amplificação foi detectada em 100% das 48 combinações modelo–dataset, com o RF produzindo amplificação severa (perda de até 3 faixas) mesmo em corpora com concordância próxima da unanimidade.

VII.1 Análise da Fase Empírica

A aplicação da MADA ao conjunto de dados MQD-1222 revelou que todos os classificadores avaliados apresentaram uma redução sistemática da concordância intermodelos em relação ao alinhamento inicial observado entre os grupos humanos ($\kappa_{inicial} = 0{,}7664$, faixa substancial segundo Landis e Koch [Landis and Koch, 1977]). Os valores de $\kappa_{modelos}$ variaram entre 0,4582 (NB) e 0,5120 (LR), resultando em um $\Delta\kappa$ médio de 0,2787 ($\sigma = 0{,}0224$). Os IC de 95% para $\Delta\kappa$, estimados por reamostragem *bootstrap* com 1.000 iterações, não cruzaram zero em nenhum dos quatro classificadores, indicando que a amplificação observada não pode ser atribuída à flutuação amostral aleatória.

A análise das distribuições marginais de rótulos por grupo revela assimetria estrutural entre as fontes de anotação. O grupo masculino produziu 481 rótulos positivos (39,4%), 450 negativos (36,8%) e 291 neutros (23,8%). O grupo feminino, por sua vez, atribuiu 446 rótulos negativos (36,5%), 411 positivos (33,6%) e 365 neutros (29,9%). A inversão da proporção entre as classes positiva e negativa entre os dois grupos, embora modesta em magnitude absoluta, é estatisticamente significativa (χ^2 de independência entre distribuições: $p < 0{,}0001$) e indica que os grupos não compartilham integralmente o mesmo regime interpretativo de polaridade.

Destaca-se, em particular, a diferença na proporção de rótulos atribuídos à classe neutra: o

grupo feminino empregou essa categoria em 29,9% das instâncias, contra 23,8% do grupo masculino. Nos 189 casos de discordância entre grupos (15,5% do conjunto), essa assimetria é ainda mais pronunciada: 120 divergências (63,5%) corresponderam ao padrão em que o grupo feminino atribuiu o rótulo neutro a uma instância que o grupo masculino classificou como positiva ou negativa. O padrão inverso, em que o grupo masculino operou a atenuação, foi observado em 46 casos (24,3%). As restantes 23 divergências (12,2%) constituíram trocas de polo diretas, sem mediação pela classe neutra.

Esses dados indicam que o grupo feminino recorreu à classe neutra com maior frequência como estratégia de resolução de ambiguidade interpretativa. Esse padrão é coerente com observações da literatura sobre estilos de anotação diferenciados por gênero, em particular com os achados de Biester et al. [2022], que identificaram uma tendência masculina para rótulos mais polarizados em tarefas de CT.

Estes valores indicam que a concordância entre as predições de modelos treinados por grupos de anotadores estratificados por gênero é sistematicamente inferior à concordância interanotador original, corroborando a hipótese de que divergências anotativas de origem sociodemográfica são propagadas e amplificadas ao longo do *pipeline* de aprendizagem supervisionada, conforme previsto porShah et al. [2020] e Zhao et al. [2017].

O valor empírico $\kappa_{inicial} = 0{,}7664$ posiciona-se entre os cenários SynSA-80 ($\kappa = 0{,}6997$) e SynSA-85 ($\kappa = 0{,}7748$), e os valores empíricos de $\Delta\kappa$ são compatíveis com os obtidos nesses cenários sintéticos adjacentes. Essa correspondência indica que o comportamento empírico não representa um desvio atípico, mas sim um ponto previsível dentro de uma curva estrutural mais ampla.

VII.2 Análise da Fase Sintética

A instanciação sintética da MADA, conduzida sobre doze cenários com taxas de concordância parametrizadas no intervalo [0,50, 0,99], demonstrou que o fenômeno de amplificação não ocorre exclusivamente com o dataset MQD-1222, nem com um nível particular de concordância. A amplitude das diferenças interpretativas constitui um padrão estrutural dependente da interação entre o regime de concordância inicial e as propriedades indutivas dos algoritmos.

Contudo, um achado arquitetural contraintuitivo, observado na validação dos doze conjuntos paramétricos, revelou dois padrões estruturais distintos, que encontram explicação na própria natureza do classificador envolvido na análise.

O primeiro diz respeito ao comportamento *não* linear do RF. Ao contrário dos demais classificadores, que apresentam valores de $\Delta\kappa$ relativamente estáveis e na faixa *Leve* ao longo de toda a escala, o RF exibe amplificação acentuada precisamente nos regimes de *alta* concordância inicial, atingindo $\Delta\kappa = +0{,}6923$ (*Severa*) e ≥ 3 faixas no cenário SynSA-99 ($\kappa_{\text{inicial}} = 0{,}9850$). Esse

comportamento é contraintuitivo: seria esperado que fontes de supervisão muito similares entre si produzissem modelos igualmente similares.

A explicação reside nas propriedades indutivas do algoritmo: o RF, ao agregar múltiplas árvores de decisão por meio de voto majoritário, amplifica pequenas assimetrias distribucionais nos rótulos de treinamento. Em contextos de alta concordância, as discordâncias residuais entre as fontes — embora quantitativamente escassas — tendem a se concentrar em regiões de fronteira de decisão, onde o impacto sobre o comportamento preditivo é desproporcionalmente elevado. À medida que a concordância inicial decresce (SynSA-50, $\kappa_{\text{inicial}} = 0{,}50$), o RF reduz sua amplificação para $\Delta\kappa = +0{,}1954$ (faixa *Leve*), pois as fontes de supervisão tornam-se tão divergentes que o modelo passa a capturar padrões predominantemente aleatórios, diluindo o sinal discriminativo.

O segundo padrão refere-se ao comportamento dos classificadores lineares e probabilísticos (SVM, NB, LR): esses modelos apresentam $\Delta\kappa$ na faixa entre 0,09 e 0,28, com distribuição relativamente homogênea ao longo dos cenários, concentrando-se predominantemente na faixa *Leve*. Nesses classificadores, a amplificação é mais acentuada nos cenários de concordância intermediária (SynSA-75 a SynSA-85, $\kappa_{\text{inicial}} \approx 0{,}62$–$0{,}77$), com subsequente redução nos extremos da escala. O cenário SynSA-85 ($\kappa_{\text{inicial}} = 0{,}7748$) é particularmente relevante por ser o mais próximo do valor empírico observado no MQD-1222 ($\kappa_{\text{inicial}} = 0{,}7664$), permitindo interpretação cruzada direta entre as duas instâncias da MADA. Nesses cenários intermediários, o RF ainda apresenta amplificação moderada ($\Delta\kappa = +0{,}5488$, 2 faixas), enquanto SVM ($\Delta\kappa = +0{,}2809$), NB ($\Delta\kappa = +0{,}2235$) e LR ($\Delta\kappa = +0{,}2558$) permanecem na faixa *Leve*. Esses resultados confirmam a sensibilidade do índice $\Delta\kappa$ às condições de concordância inicial e evidenciam que o comportamento do RF constitui um achado estrutural próprio da MADA, não uma inconsistência do índice.

VII.3 Análise Integrada

A análise integrada (Seção VII.3) revelou variação sistemática na magnitude de $\Delta\kappa$ entre as arquiteturas avaliadas. O classificador Naive Bayes apresentou a maior amplificação ($\Delta\kappa = +0{,}3082$), seguido por Random Forest ($\Delta\kappa = +0{,}2801$), SVM ($\Delta\kappa = +0{,}2720$) e Regressão Logística ($\Delta\kappa = +0{,}2544$). Embora todos os valores sejam classificados como *Leve* segundo Landis and Koch [1977], a diferença entre NB e LR representa um incremento de 21% na magnitude da amplificação. A validação sintética (Seção VI.2) reforçou esse padrão: no cenário SynSA-99 $\kappa_{\text{inicial}} = 0{,}9850$),o RF apresentou comportamento qualitativamente distinto, com $\Delta\kappa = +0{,}6923$ (*Severa*, ≥ 3 faixas), enquanto SVM ($\Delta\kappa = +0{,}1197$), NB ($\Delta\kappa = +0{,}0928$) e LR ($\Delta\kappa = +0{,}0937$) permaneceram na faixa *Ausente*. Esses resultados sugerem que a variância intrínseca do estimador — maior em RF devido ao *ensemble* de árvores de decisão, menor em LR devido à regularização — influencia a propagação de divergências anotativas de forma não-linear.

VII.4 Limitações

O presente trabalho apresenta limitações que devem ser consideradas na interpretação dos resultados e na generalização dos achados para outros contextos.

Tamanho amostral de anotadores. O estudo empregou oito anotadores estratificados por gênero (4M/4F), número que, embora adequado para demonstração de conceito e validação inicial da MADA, impõe restrições à generalização dos efeitos de grupo observados. O κ de Cohen calculado entre dois grupos de quatro anotadores cada apresenta variância *bootstrap* relativamente elevada, conforme evidenciado pelo intervalo de confiança de 95% [0,7363; 0,7954] para $\kappa_{\text{inicial}} = 0{,}7664$. Com $N = 8$, a variabilidade individual de cada anotador exerce influência proporcionalmente maior sobre a concordância agregada do grupo. Estudos futuros com amostras maiores (e.g., $N \geq 20$ por grupo) permitirão estimativas mais precisas de κ_{inicial} e $\Delta\kappa$, reduzindo a incerteza associada à variabilidade interindividual e possibilitando a investigação de interações entre gênero e outras variáveis sociodemográficas [Pei and Jurgens, 2023].

Escopo de representação e arquiteturas de modelos. A escolha da representação TF-IDF combinada com classificadores tradicionais (SVM, NB, RF, LR) constitui uma decisão metodológica deliberada para isolar o efeito da fonte de anotação, conforme justificado na Seção V.8. Contudo, essa escolha limita a generalização dos achados para modelos de linguagem pré-treinados baseados em arquiteturas transformadoras, que dominam o estado da arte em PLN desde 2018. Modelos como BERTimbau incorporam representações contextuais aprendidas a partir de grandes corpora, as quais podem conter vieses de gênero latentes que interagem de forma não-linear com divergências anotativas.

Domínio e gênero textual do corpus. O corpus MQD-1222 é composto exclusivamente por textos de diário pessoal extraídos do *blog* "Meu Querido Diário", caracterizados por linguagem informal, narrativa em primeira pessoa e temáticas de vida cotidiana. Embora esse domínio seja adequado para análise de sentimentos e apresente distribuição equilibrada de polaridades (positivo: 36,5%; negativo: 36,7%; neutro: 26,8%), a generalização dos resultados para outros gêneros textuais (e.g., notícias, *reviews* de produtos, postagens em redes sociais) e domínios (e.g., saúde, política, educação) requer validação adicional. Divergências anotativas de gênero podem manifestar-se de forma distinta em textos técnicos, jornalísticos ou argumentativos, nos quais a subjetividade e a expressão emocional assumem papéis diferentes.

Magnitude da amplificação e relevância prática. Todos os valores de $\Delta\kappa$ empíricos foram classificados na faixa *Leve* segundo Landis and Koch [1977], com $\Delta\kappa$ médio de 0,2787 correspondendo

a uma degradação de aproximadamente uma faixa de concordância. Embora a significância estatística do efeito tenha sido confirmada por intervalos de confiança *bootstrap* que não incluem zero, a relevância prática dessa magnitude pode variar conforme o contexto de aplicação. Conforme discutido na Seção VI.4, em sistemas de moderação de conteúdo ou análise de sentimentos para tomada de decisão automatizada, uma degradação de uma faixa representa um impacto mensurável; contudo, em aplicações de menor criticidade, o efeito pode ser considerado tolerável. A validação sintética demonstrou que, sob condições de baixa concordância inicial ($\kappa \leq 0{,}50$), a amplificação pode atingir severidade *Severa* ($\Delta\kappa = +0{,}4667$ para RF em SynSA-50), indicando que a magnitude do efeito é contingente às condições de concordância anotativa.

Generalização linguística e cultural. O estudo foi conduzido exclusivamente em português brasileiro, com anotadores recrutados no contexto sociocultural brasileiro. Divergências anotativas de gênero podem manifestar-se de forma distinta em outras línguas e culturas, nas quais normas de gênero, expressões emocionais e convenções linguísticas diferem. A replicação da MADA em outros idiomas e contextos culturais constitui uma direção importante para avaliar a universalidade do fenômeno de amplificação de divergências anotativas e a robustez do índice $\Delta\kappa$ como instrumento de mensuração.

VII.5 Contribuições do Estudo

Do ponto de vista metodológico, a principal contribuição desta pesquisa consiste na formalização de um protocolo modular capaz de separar três níveis analíticos distintos: a divergência humana inicial, a divergência induzida pelo processo de modelagem e a diferença entre ambas. Essa separação, operacionalizada pela métrica $\Delta\kappa$ e complementada pela análise de severidade baseada nas faixas de Landis and Koch [1977], permite investigar a amplificação como um fenômeno mensurável e comparável entre contextos.

Do ponto de vista empírico, o estudo oferece evidência pioneira sobre divergências anotativas por gênero em AS para o português brasileiro, um domínio pouco representado na literatura sobre viés em processamento de linguagem natural [Stańczak and Augenstein, 2021]. A caracterização das assimetrias distributivas e dos padrões de divergência intragrupal e intergrupal aprofunda a compreensão do processo de anotação como prática socialmente situada, na qual diferenças sistemáticas de interpretação coexistem com um elevado grau de concordância global.

Do ponto de vista teórico, os resultados reforçam a concepção do viés como fenômeno emergente do processo de construção de dados [Shadish et al., 2002], e não como um atributo individual dos anotadores. A amplificação observada ao longo do pipeline de aprendizado supervisionado indica que mesmo divergências moderadas entre fontes de anotação podem produzir efeitos estruturalmente

relevantes nos modelos resultantes, com implicações diretas para o design de sistemas que dependem de supervisão humana.

VII.6 Perspectivas para Trabalhos Futuros

As lacunas identificadas ao longo do estudo, combinadas com os achados que emergem da análise de dados ainda não plenamente explorados, apontam para um conjunto de extensões metodológicas e empíricas com alto grau de aderência ao escopo desta pesquisa. Essas perspectivas apontam para análises qualitativas das frases com maior grau de divergência entre o grupo de anotadores, bem como para um estudo do impacto da fadiga na qualidade da rotulagem de dados, medida pelos tempos de resposta previamente coletados.

Outra abordagem candidata aponta para as questões sociodemográficas que foram isoladas neste estudo inicial. A simples expansão do gênero para uma representatividade não necessariamente binária já é capaz de contemplar um território amplo e ainda não explorado de viés não investigado.

Em termos estritamente técnicos, também há muitos caminhos. A prevalência de modelos de linguagem pré-treinados em aplicações contemporâneas de CT torna relevante investigar se o fenômeno de amplificação se manifesta e em que magnitude em arquiteturas baseadas em *transformers*, por exemplo.

Até mesmo em abordagens mais tradicionais, preocupadas primariamente com a mitigação do viés, é possível apontar caminhos que investiguem a força de consenso intragrupos e, com o apoio da MADA, estabeleçam estratégias de critérios de parada que possam ser previamente sinalizadas antes de algum comportamento nocivamente enviesado.

Referências

Aroyo, L. and Welty, C. Truth is a lie: Crowd truth and the seven myths of human annotation. *AI magazine*, 36(1):15–24, 2015.

Artstein, R. and Poesio, M. Survey article: Inter-coder agreement for computational linguistics. *Computational linguistics*, 34(4):555–596, 2008.

Azevedo, G. D., Pettine, G., Feder, F., Portugal, G., Mendes, C. O. S., Ribeiro, R. C., Mauro, R. C., Junior, F. P., and Guedes, G. Nat: Towards an emotional agent. In *Proceedings of the 16th Iberian Conference on Information Systems and Technologies (CISTI)*. IEEE Computer Society, 2021.

Basile, V., Fell, M., Fornaciari, T., Hovy, D., Paun, S., Plank, B., Poesio, M., and Uma, A. We need to consider disagreement in evaluation. In *Proceedings of the 1st workshop on benchmarking: past, present and future*, pages 15–21, 2021.

Biester, L., Sharma, V., Kazemi, A., Deng, N., Wilson, S., and Mihalcea, R. Analyzing the effects of annotator gender across 4 NLP tasks. In *Proceedings of the 1st Workshop on Perspectivist Approaches to NLP @LREC2022*, pages 10–19, Marseille, France. European Language Resources Association, 2022.

Blodgett, S. L., Barocas, S., Daumé III, H., and Wallach, H. Language (technology) is power: A critical survey of "bias"in nlp. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 5454–5476, Online. Association for Computational Linguistics, 2020.

Bolukbasi, T., Chang, K.-W., Zou, J. Y., Saligrama, V., and Kalai, A. T. Man is to computer programmer as woman is to homemaker? debiasing word embeddings. *Advances in neural information processing systems*, 29, 2016.

Breiman, L. Random forests. *Machine learning*, 45(1):5–32, 2001.

Cabello, L., Jørgensen, A. K., and Søgaard, A. On the independence of association bias and empirical fairness in language models, 2023.

Carneiro, E., Feitosa, A., and Guedes, G. When annotators disagree: A controlled evaluation of gender bias in sentiment analysis using synthetic datasets. In *Proceedings of the XVI Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana (STIL 2025)*, 2025.

Cohen, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960.

Davani, A. M., Díaz, M., and Prabhakaran, V. Dealing with disagreements: Looking beyond the majority vote in subjective annotations. *Transactions of the Association for Computational Linguistics*, 10:92–110, 2022.

Devinney, H., Björklund, J., and Björklund, H. Theories of "gender" in NLP bias research. In *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency (FAccT '22)*, pages 2083–2102, Seoul, Republic of Korea. Association for Computing Machinery, 2022.

Ding, Y., You, J., Machulla, T.-K., Jacobs, J., Sen, P., and Höllerer, T. Impact of annotator demographics on sentiment dataset labeling. *Proc. ACM Hum.-Comput. Interact.*, 6(CSCW2), 2022.

Efron, B. and Tibshirani, R. J. *An introduction to the bootstrap.* Chapman and Hall/CRC, 1994.

Feitosa, A., Carneiro, E., and Guedes, G. Beyond systematic bias: Investigating gender differences in portuguese text classification annotation patterns. In *Proceedings of the XX Simpósio Brasileiro de Banco de Dados e Mineração de Conhecimento (KDMiLe 2025)*, 2025.

Firmino, V. P., Lopes, J. N. d. S., and Reis, V. Q. Identificando padrões de sexismo na música brasileira através do processamento de linguagem natural. In *Anais do XI Encontro de Computação de Mato Grosso do Sul (ECMS 2024)*, Campo Grande, Brasil. SBC, 2024.

Fleisig, E., Abebe, R., and Klein, D. When the majority is wrong: Modeling annotator disagreement for subjective tasks. In Bouamor, H., Pino, J., and Bali, K., editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 6715–6726, Singapore. Association for Computational Linguistics, 2023.

Géron, A. *Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems.* O'Reilly Media, Inc., Sebastopol, CA, 2 edition, 2019.

Geva, M., Goldberg, Y., and Berant, J. Are we modeling the task or the annotator? an investigation of annotator bias in natural language understanding datasets. In *Proceedings of*

the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP), pages 1161–1166, Hong Kong, China. Association for Computational Linguistics, 2019.

Gordon, M. L., Zhou, K., Patel, K., Hashimoto, T., and Bernstein, M. S. The disagreement deconvolution: Bringing machine learning performance metrics in line with reality. In *Proceedings of the 2021 chi conference on human factors in computing systems*, pages 1–14, 2021.

Gupta, S., Maheshwari, A., Sharma, A., Kumar, S., Khanna, V., Chadha, A., Ratn, R., and Sawhney, R. Bias in natural language processing: A survey. *arXiv preprint arXiv:2306.08158*, 2023.

Hastie, T., Tibshirani, R., and Friedman, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction.* Springer, New York, NY, 2 edition, 2009.

Havens, L., Terras, M., Bach, B., and Alex, B. Uncertainty and inclusivity in gender bias annotation: An annotation taxonomy and annotated datasets of british english text. In *Proceedings of the 4th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, pages 140–152, Seattle, Washington. Association for Computational Linguistics, 2022.

Hovy, D. and Prabhumoye, S. Five sources of bias in natural language processing. *Language and Linguistics Compass*, 15(8):e12432, 2021.

Izbicki, R. and Santos, T. M. d. *Aprendizado de máquina: uma abordagem estatística.* Rafael Izbicki, São Carlos, SP, 1 edition, 2020.

Jentzsch, S. and Turan, C. Gender bias in bert - measuring and analysing biases through sentiment rating in a realistic downstream classification task. In *Proceedings of the 4th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, page 184–199, Seattle, Washington. Association for Computational Linguistics, 2022.

Jiang, A., Vitsakis, N., Dinkar, T., Abercrombie, G., and Konstas, I. Re-examining sexism and misogyny classification with annotator attitudes. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 15103–15125, Miami, Florida, USA. Association for Computational Linguistics, 2024.

Jurafsky, D. and Martin, J. H. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition.* Pearson Education, 2007.

Kenyon-Dean, K., Ahmed, E., et al. Sentiment analysis: It's complicated! In *Proceedings of the 2018 Conference of the NAACL: HLT*, pages 1886–1895, New Orleans, Louisiana. Association for Computational Linguistics, 2018.

Kiritchenko, S. and Mohammad, S. Examining gender and race bias in two hundred sentiment analysis systems. In *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2018)*, pages 43–53, New Orleans, Louisiana. Association for Computational Linguistics, 2018.

Kumar, S. et al. Exploring impact of age and gender on sentiment analysis using machine learning. *Electronics*, 9(2):374, 2020.

Kuwatly, H. A., Wich, M., and Groh, G. Identifying and measuring annotator bias based on annotators' demographic characteristics. In *Proceedings of the Fourth Workshop on Online Abuse and Harms*, page 184–190, Online. Association for Computational Linguistics, 2020.

Landis, J. R. and Koch, G. G. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977.

Leonardelli, E., Menini, S., Palmero Aprosio, A., Guerini, M., and Tonelli, S. Agreeing to disagree: Annotating offensive language datasets with annotators' disagreement. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, page 10528–10539, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics, 2021.

Lim, S. S., Udomcharoenchaikit, C., Limkonchotiwat, P., Chuangsuwanich, E., and Nutanong, S. Identifying and mitigating annotation bias in natural language understanding using causal mediation analysis. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 11548–11563, 2024.

Manning, C. D. and Schütze, H. *Foundations of Statistical Natural Language Processing*. MIT Press, Cambridge, MA, 1999.

Minatel, D. et al. Data stratification analysis on the propagation of discriminatory effects in binary classification. In *Anais do 11º Symposium on Knowledge Discovery, Mining and Learning (KDMiLe)*, pages 73–80, Belo Horizonte, MG. Sociedade Brasileira de Computação, 2023.

Mozetič, I., Grčar, M., and Smailović, J. Multilingual twitter sentiment classification: The role of human annotators. *PLOS ONE*, 11(5):e0155036, 2016.

Page, M. J., McKenzie, J. E., Bossuyt, P. M., et al. The prisma 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372:n71, 2021.

Paullada, A. et al. Data and its (dis)contents: A survey of dataset development and use in machine learning research. *Patterns*, 2(11):100336, 2021.

Pei, J. and Jurgens, D. When do annotator demographics matter? measuring the influence of annotator demographics with the popquorn dataset. In *Proceedings of the 17th linguistic annotation workshop (LAW-XVII)*, pages 252–265, 2023.

Plank, B. The "problem" of human label variation: On ground truth in data, modeling and evaluation. In *Proceedings of the 2022 conference on empirical methods in natural language processing*, pages 10671–10682, 2022.

Prabhakaran, V., Mostafazadeh Davani, A., and Diaz, M. On releasing annotator-level labels and information in datasets. In Bonial, C. and Xue, N., editors, *Proceedings of the Joint 15th Linguistic Annotation Workshop (LAW) and 3rd Designing Meaning Representations (DMR) Workshop*, pages 133–138, Punta Cana, Dominican Republic. Association for Computational Linguistics, 2021.

Röttger, P., Vidgen, B., Hovy, D., and Pierrehumbert, J. Two contrasting data annotation paradigms for subjective nlp tasks. In *Proceedings of the 2022 conference of the North American chapter of the association for computational linguistics: human language technologies*, pages 175–190, 2022.

Shadish, W. R., Cook, T. D., and Campbell, D. T. *Experimental and quasi-experimental designs for generalized causal inference.* Houghton Mifflin, Boston, MA, 2002.

Shah, D. S., Schwartz, H. A., and Hovy, D. Predictive biases in natural language processing models: A conceptual framework and overview. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 5248–5264. Association for Computational Linguistics, 2020.

Sobhani, N. and Delany, S. J. Towards fairer NLP models. handling gender bias in classification tasks. In *Proceedings of the 5th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, pages 167–178. Association for Computational Linguistics, 2024.

Stańczak, K. and Augenstein, I. A survey on gender bias in natural language processing. *arXiv preprint arXiv:2112.14168*, 2021.

Taso, F. T. S., Reis, V. Q., and Martinez, F. V. Discriminação algorítmica de gênero: Estudo de caso e análise no contexto brasileiro. In *Anais do IV Workshop sobre as Implicações da Computação na Sociedade (WICS 2023)*, pages 229–240, Porto Alegre, Brasil. SBC, 2023.

Toker, I., Sarne, D., and Schler, J. Intelligent calibration for bias reduction in sentiment corpora annotation process. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38:10172–10179, 2024.

Uma, A. N., Fornaciari, T., Hovy, D., Paun, S., Plank, B., and Poesio, M. Learning from disagreement: A survey. *Journal of Artificial Intelligence Research*, 72:1385–1470, 2021.

Wan, R., Kim, J., and Kang, D. Everyone's voice matters: Quantifying annotation disagreement using demographic information. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(12):14523–14530, 2023.

Wohlin, C. Guidelines for snowballing in systematic literature studies and a replication in software engineering. In *Proceedings of the 18th International Conference on Evaluation and Assessment in Software Engineering (EASE 2014)*, pages 1–10. ACM, 2014.

Zhao, J., Wang, T., Yatskar, M., Ordonez, V., and Chang, K.-W. Men also like shopping: Reducing gender bias amplification using corpus-level constraints. In *Proceedings of the 2017 conference on empirical methods in natural language processing*, pages 2979–2989, 2017.

Zhu, S., Du, B., Zhao, J., Liu, Y., and Liu, P. Do PLMs and annotators share the same gender bias. definition, dataset, and framework of contextualized gender bias. In *Proceedings of the 5th Workshop on Gender Bias in Natural Language Processing (GeBNLP)*, pages 20–32. Association for Computational Linguistics, 2024.